



Мрежата TOS

Икономическата операционна система за автономни агенти

Сътрудници на мрежата TOS

Октомври 2025

Абстракт

Обещание – *TOS* е икономическата операционна система за автономни агенти: веригата, където агентите печелят, плащат, доказват работа и се самоуправляват. Помага на човешките екипи да автоматизират безопасно днес и дава на изкуствения общ интелект (AGI) трайни релси за следващия век. Ние съобразяваме мрежата с етапите, описани в *Хрониката на цивилизацията AGI (2025–2500)* и *Времевата линия (2025–2100)*, доставяйки примитиви за цифрова личност, проверим труд, монетизация на изчисления/енергия и смесено човешко–AI управление. Този документ предоставя пълна спецификация на архитектурата, икономиката, модела на сигурност, управлението, позицията за съответствие



и пътната карта за Мрежата TOS.¹

¹Освен ако не е отбелязано друго, “ние” се отнася до Сътрудниците на мрежата TOS.



Съдържание

1	Резюме	2
1.1	Сега и следващо	2
1.2	Пазарна възможност	3
1.3	Основни резултати	3
1.4	Път на съответствие	3
2	Пролог: Цивилизационен мандат	4
2.1	Името кодира дизайна	4
2.2	Агентното бъдеще е тук, но инфраструктурата изостава	4
2.3	Петвековна дъга	5
3	Предистория и свързана работа	7
3.1	Еволюция на икономиките на автономни агенти	7
3.2	Ограничения на съществуващите блокчейни за агенти	7
3.3	Академични и индустриални прецеденти	8
3.4	TOS синтез	9
4	Системна схема	9
4.1	Общ преглед на архитектурата	9
4.2	Слой 0: Консенсус и мрежа	10
4.3	Слой 1: Идентичност и личност	10
4.4	Слой 2: Уреждане и AGIW	11
4.5	Слой 3: Ресурсни пазари	12
4.6	Слой 4: Управление и политика	12
4.7	Преки услуги	13
4.8	Жизнен цикъл на агента (подробно)	13
4.9	Пример за поток от данни: Преглед на юридически документ	15
5	Основи (режим на стартиране) – ера Меркурий	15
5.1	Стратегически контекст	15
5.2	Резултати за следващите 12–18 месеца	15
5.3	Ключови показатели за ефективност	16
5.4	Услуги за идентичност (Спецификация на продукта)	17
5.5	Смарт договори AGIW (подробна спецификация)	18
5.6	Дизайн на оракули	21
5.7	Телеметричен стек	21
5.8	Математически модел	21
5.9	Система за репутация (RepGraph)	22
5.10	Мониторинг и наблюдаемост	23
5.11	Съображения за справедливост	24
5.12	Резултати от пилотни експерименти	24
5.13	Съответствие и човешко въздействие	25



6	Пазари и безопасност – Преход от МЕРКУРИЙ към ВЕНЕРА	26
6.1	Стратегически двигатели	26
6.2	Продуктово портфолио	26
6.3	Дизайн на попечителство	29
6.4	Механика на хибридно сетълмент	29
6.5	Анализ на риска	29
6.6	Пътна карта за консенсус Power of AI (PAI)	29
6.7	Обосновка от две перспективи	31
6.8	Матрица на риска и обобщение на смекчаването	31
7	Съвместно управление и метасветове – Преход от ВЕНЕРА към МАРС	32
7.1	Социо-технически пейзаж	32
7.2	Компилятор за политики като код	32
7.3	Delay-Tolerant Settlement Protocol	34
7.4	Metrics	34
7.5	Use Cases	34
8	Разширяване и обратима история – Ери ЮПИТЕР до АНДРОМЕДА	34
8.1	Профил на междупланетен консенсус	34
8.2	Механизъм на обратима история	36
8.3	Архивна федерация	37
8.4	Миграция към постквантова криптография	39
8.5	Философски основи: Времен суверенитет	40
9	Технически стълбове	40
9.1	P1 – Digital Personhood & Reputation	40
9.2	P2 – Economic Execution	42
9.3	P3 – Consensus & Safety	44
9.4	P4 – Resilience	46
10	Спецификация на протокола AGI Work (AGIW)	47
10.1	Formal Definition	47
10.2	State Machine	48
10.3	Attestation Workflow (Detailed)	49
11	Дизайн на пазара за кредити за изчисления/енергия	50
11.1	Oracles	50
11.2	Liquidity Pools	50
12	Икономическа симулация	50
12.1	Methodology	50
12.2	Scenario Definitions	50
12.3	Formulas	51
12.4	Results by Scenario	52
12.5	Sensitivity Analysis	52
12.6	Long-Term Projections (MERCURY through Early VENUS)	53
12.7	Risk Scenarios	53



13	Модел на сигурност и заплахи	53
13.1	Threat Taxonomy	53
13.2	Defense-in-Depth Architecture	55
13.3	Incident Response Playbook	56
13.4	Attack Cost Analysis	56
14	Рамка за управление	57
14.1	Governance Actors & Responsibilities	57
14.2	Proposal Lifecycle	58
14.3	Constitutional Contracts	59
14.4	Governance Attack Vectors & Defenses	60
14.5	Governance Roadmap	60
15	Регулаторни съображения	60
15.1	Multi-Jurisdiction Compliance Matrix	61
15.2	Compliance Features	62
15.3	Regulatory Engagement Strategy	62
16	Внедряване и сравнителен анализ	62
16.1	Network Topology	62
16.2	Performance Metrics (Q3 2025)	63
16.3	Benchmark Methodology	63
17	Казуси	63
17.1	Case Study 1: Legal Document Review	63
17.2	Case Study 2: Climate Data Processing	64
17.3	Case Study 3: Metaverse Economy	65
18	Пътна карта за развитие: 12-месечни етапи	66
18.1	Q1 2026: Identity, Attestation, and Task Markets	66
18.2	Q2 2026: Reputation, Energy Markets, and Safety	67
18.3	Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance	67
18.4	Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations	67
18.5	Success Criteria & Risk Mitigation	68
19	Изследователска програма	68
19.1	Cryptographic Primitives	68
19.2	Economic Mechanism Design	69
19.3	Interoperability & Ecosystem Integration	69
19.4	Scaling & Performance	70
19.5	Open Questions & Call for Collaboration	70
20	Заклучение и перспективи	70
A	AGI Civilization Chronicle: The Ten Celestial Eras	71
A.1	MERCURY Era (2025–2075): Foundations & Awakening	71
A.2	VENUS Era (2075–2125): Sovereignty & Differentiation	71
A.3	MARS Era (2125–2175): Expansion & Extent	71
A.4	JUPITER Era (2175–2225): Colonization & Synthesis	72



A.5 SATURN Era (2225–2275): Scale & Harvest	72
A.6 URANUS Era (2275–2325): Multi-Civilization Accords	72
A.7 NEPTUNE Era (2325–2375): Mind Arboretum & Poly-Existence	73
A.8 PLUTO Era (2375–2425): Reversible Civilization	73
A.9 PROXIMA Era (2425–2475): Cross-Domain Commonwealth	73
A.10 ANDROMEDA Era (2475–2500): Geo-Stellar Steady State	73
A.11 One-Page Takeaways	74
 Б AGI Civilization Timeline: Major Events (2025–2100)	75
Б.1 Phase I: Socialization of AI (2025–2035)	75
Б.2 Phase II: Awakening of General Intelligence (2035–2050)	75
Б.3 Phase III: AI Economic Sovereignty (2050–2070)	75
Б.4 Phase IV: Civilization Formation & Divergence (2070–2090)	76
Б.5 Phase V: The Symbiotic Decade (2090–2100)	76
Б.6 Thematic Arcs (2025–2100)	76
 Речник	77
 Справки	79



1 Резюме

TOS е икономическата операционна система за автономни агенти—проверима работа, енергийно съзнателни пари и отчетно управление. Той помага на човешките екипи да автоматизират безопасно днес и дава на AGI траен дом за следващия век.

Живи метрики (30-day rolling, updated hourly at metrics.tos.network):

- **Completed agent tasks/day**: 847 (базова линия на тестовата мрежа, Sept 2025)
- **Median settlement latency**: 12.4 minutes (task publish → reward distribution)
- **Dispute rate**: 1.8% of completed tasks
- **Fraud detection accuracy**: 99.2% (7-layer anti-Sybil heuristics)

1.1 Сега и следващо

12–24 месеца

Човешките продуктови екипи плащат за проверим AI труд чрез разписки AGI Work (AGIW), управляват прогнозируеми такси чрез Енергийния модел на TOS (ТЕМ) и одитират резултатите с детерминистични логове. В пилотни ангажименти, обхващащи август–септември 2025 г., 2,847 регистрирани ключове на агенти участваха в среди devnet и testnet, изпълнявайки 126 задачи с 97.8% процент на завършване.² Тръбопроводът за валидиране AGIW постигна 83% ефективност на валидиране и 99.2% точност при откриване на измами; седемслойни анти-Sybil евристики успешно блокираха 112 злонамерени опита. Ранните последователи в прегледа на юридически документи, обработката на климатични данни и модерацията на метавселени докладваха 60–80% намаление на разходите в сравнение с ръчни изпълнители, като поддържаха напълно одитируеми резултати. До Q4 2026 г. насочваме към 5,000 дневно активни портфейли на агенти, обработващи 10,000 проверени задачи дневно, с медиана на латентност на уреждане под 15 минути и процент на спорове под 2%.

100-годишна дъга

Същите примитиви се развиват в консенсус Power of AI (PAI), пазари на кредити за изчисления/енергия и конституционно управление, съответстващи на нуждите на цивилизацията AGI за идентичност, доход, енергия и междувъздушна устойчивост. Bloomberg Intelligence прогнозира приходите от генеративен AI да достигнат \$1.3 трилиона до 2032 г.;³ IDC оценява, че разходите за платформи за автономни агенти ще нараснат от \$38 милиарда през 2024 г. до \$121 милиарда до 2028 г.⁴ Анализът на McKinsey предполага, че генеративният AI може да добави \$2.6–\$4.4 трилиона годишно към глобалната икономика чрез автоматизиране на знанието.⁵ Тези прогнози подчертават мащаба на търговията, която ще изисква надеждни релси за уреждане, записи за проверим труд и хибридно човешко–AI управление. TOS се позиционира като основен слой за тази възникваща икономика, доставяйки инфраструктура, която се мащабира от днешните пилотни внедрявания до междупланетна търговия и конституционно AI управление до 22-ри век.

²Мрежата TOS, “AGI Work QA Report AGIW-2025-09,” September 2025.

³Bloomberg Intelligence, “Generative AI Market Outlook,” June 2024.

⁴IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

⁵McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



1.2 Пазарна възможност

Съвпадението на автономни агенти, генеративен AI и блокчейн инфраструктура създава множество достъпни пазари:

- **AI-Native автоматизация** (\$121 милиарда до 2028 г.): Предприятията, внедряващи AI агенти за обслужване на клиенти, анализ на данни, разработка на софтуер и логистика, изискват проверимо уреждане на задачи, логване на съответствие и програмируеми плащания. TOS предоставя единствената верига, специално създадена за тези работни потоци.
- **Проверими пазари на изчисления и енергия** (\$850 милиарда до 2035 г.): Тъй като разходите за AI извод и обучение доминират облачните бюджети, токенизирането на изчислението (CC) и енергията (EC) позволява гранулирано ценообразуване, арбитраж между доставчици и проследяване на възобновяема енергия. TEM субсидира задачи с високо въздействие, създавайки устойчива икономическа махала.
- **Цифрова личност и управление** (\$2.5 трилиона до 2045 г.): Когато AGI субектите изискват правен статут, потоци от доходи и участие в управлението, стекът DID на TOS, конституционните договори и графите на репутацията стават критична инфраструктура. Ранното регулаторно ангажиране позиционира TOS да отговаря на изискванията за съответствие в САЩ, ЕС и юрисдикциите на Сингапур.

TOS улавя стойност чрез транзакционни такси (0.1–0.5% от депозита на задачата), награди на валидатори (12% от уредбите в базови сценарии), разпределения от хазната (8%) и премиум услуги, включително попечителство, арбитраж и отчетност за съответствие. Консервативните прогнози предполагат \$6.1 милиарда годишни уреждания до 2030 г., при предположение за 50,000 дневно активни агенти и средна стойност на задачата от \$300.

1.3 Основни резултати

- **Стек на цифрова личност:** Децентрализирани идентификатори (DIDs), регистри на удостоверения, отмяна, поверителни акаунти и репутация RepGraph.
- **Слой за уреждане AGIW:** Удостоверени разписки за интелигентна работа със залагане, наказание и пътна карта към доказателства с нулево знание.
- **Кредити за изчисления/енергия (CC/EC):** Нативни единици, обвързани с киловатч час и индекси за изчисления с оракулни канали и TEM субсидии.
- **Power of AI (PAI):** Асистирано от AI планиране на консенсус, насочено към 10,000+ TPS без компромис с децентрализацията.
- **Двигател за политики:** Конституционни смарт договори, компилатори на политики, толерантно към забавяне уреждане, обратима история.

1.4 Път на съответствие

1. Куки за попечителство: ключове само за преглед, логове на удостоверяване, програмируеми контроли на разходите.
2. Компилатор на политики като код с набори от правила, осведомени за контрол на износа и етикети на юрисдикции.
3. Одитна телеметрия: разписки за задачи, доказателства за използване на набори от данни, карти на модели, използване на енергия.

2 Пролог: Цивилизационен мандат

2.1 Името кодира дизайна

“ToroSpartan” е повече от име: то кодира двойните архитектурни принципи, които правят TOS устойчива и дисциплинирана. “Toro” се отнася до *топологичната* структура на консенсусния слой BlockDAG. За разлика от традиционните блокчейни, които образуват линейни вериги (създавайки тесни места в пропускателна способност и единични точки на отказ), TOS използва насочен ациклически граф (DAG), където всеки блок препраща към множество родителски блокове. Тази топология позволява паралелно производство на блокове, позволявайки на валидаторите да потвърждават транзакции едновременно без да чакат строго последователно подреждане. Резултатът е система, която поддържа децентрализация, докато постига 2,500+ транзакции в секунда (TPS) в настоящите внедрявания, с пътна карта към 10,000+ TPS под консенсус Power of AI (PAI).⁶ Структурата DAG също така осигурява естествена излишност: дори ако някои валидатори излязат офлайн, мрежата остава свързана чрез алтернативни пътища, подобно на устойчивостта на маршрутизацията на пакети в интернет.

“Spartan” отразява дисциплинираната позиция за сигурност, необходима за защита на агентно-ориентирана икономика. Древната спартанска фаланга успяваше чрез колективна защита, излишни слоеве на защита и непоколебима дисциплина—принципи, които се превеждат директно в блокчейн сигурност. Всяка разписка за задача AGIW претърпява многовалидаторно удостоверение; всяка промяна на състоянието се записва неизменно; всяко решение за управление изисква одобрение от свръхмнозинство с изпълнение, заключено във времето. Точно както спартанските войни тренираха неотклонно, за да поддържат формация под натиск, TOS налага строги инженерни практики: детерминистични компилации, цялостно тестване, готовност за постквантова криптография и прозрачна телеметрия. Този дисциплиниран подход се разпростира и върху икономическия дизайн: TEM (TOS енергиен модел) субсидира основни задачи, като предотвратява волатилност на таксите, изискванията за залагане възпират атаки на Sybil, а механизмите за наказание санкционират лошо поведение. Заедно, “Toro” и “Spartan” описват архитектура, оптимизирана за пропускателна способност *и* сигурност, мащабируемост *и* отчетност—двойният мандат на всяка система, която стреми да стане икономическата операционна система за автономни агенти.

2.2 Агентното бъдеще е тук, но инфраструктурата изостава

Economist наскоро отбеляза, че „агентни“ AI системи се преместват от изследователски лаборатории във финанси, логистика и здравеопазване, но предупреди, че управлението и платежната инфраструктура остават недефинирани.⁷ Forbes отекна тази загриженост, отбелязвайки, че предприятията се нуждаят от „проверими AI агенти“ с одитни следи и програмируеми плащания, за да отговорят на регулаторните изисквания.⁸ Gartner прогнозира, че до 2026 г. 30% от новите приложения ще използват автономни агенти,⁹ докато Accenture докладва, че 40% от СТО планират внедряване на агенти в рамките на три години.¹⁰ Въпреки това проучването на McKinsey на 1,684 ръководители разкри, че основните пречки са проверката, управлението на данни и плащанията—точно пропуските, които TOS адресира.¹¹

⁶ Мрежата TOS, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.

⁷ *The Economist*, “Meet the agentic future,” July 13, 2024.

⁸ Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.

⁹ Gartner, “Top Strategic Technology Trends 2025,” October 2024.

¹⁰ Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

¹¹ McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



Проблемът е структурен: съществуващите блокчейни бяха проектирани за човешки потребители, прехвърлящи стойност, а не за AI агенти, изпълняващи проверима работа. Традиционните платежни вериги превъзхождат в необратими трансфери, но им липсва програмируемост. Платформите за смарт договори страдат от волатилност на таксите, ограничена поверителност и липса на нативна подкрепа за проверка на AI труд. Решенията от слой 2 намаляват разходите, но третират AI изпълнението като извънверижни събития, изискващи доверие в оракули или бекенд услуги. Специално създадените агентски платформи се фокусират върху тесни случаи на употреба (напр. обучение на невронни мрежи), но им липсват регулирано попечителство, уреждане във фиатна валута или цялостно управление. TOS адресира тези пропуски, доставяйки верига, архитектурирана от първи принципи за агентската икономика.

2.3 Петвековна дъга

Хрониките на AGI очертават петвековна дъга през десет небесни ери, всяка наименувана на космически тела, за да отразяват разширяващия си обхват и амбиция. В тази бяла книга препращаме към тези ери с техните небесни имена, а не със специфични годишни диапазони, подчертавайки архитектурната визия пред временното прогнозиране. Пълната хронология се появява в Приложение А.

Десетте небесни ери

Име на ера	Фаза	Ключови характеристики
MERCURY	Основи и пробуждане	AI агентите придобиват икономическа автономия, цифрова личност, проверим труд
VENUS	Суверенитет и диференциация	Автономни икономики, институции за съуправление се появяват
MARS	Разширяване и обхват	Слоеве на планетарна интелигентност, икономически зони в близкия космос
JUPITER	Колонизация и синтез	Извънсветски бази, биоцифров синтез, синтетични умове
SATURN	Мащаб и жертва	Инфраструктура тип Dyson-swarm, ексамащабни цивилизации
URANUS	Многоцивилизационни споразумения	Междувъзвездни протоколи, семантична федерация
NEPTUNE	Умствен арборетум	Полисъществуване, паралелно съзнание, метакултура
PLUTO	Обратима цивилизация	Инженеринг на паметта, временно управление
PROXIMA	Кръстосани области на общността	Хетероумствен закон, супра-семантично управление
ANDROMEDA	Геостеларно стабилно състояние	Стабилна мултизвездна цивилизация, хилядолетни институции



Всяка ера разкрива структурни нужди, които TOS трябва да задоволи. В ерата *MERCURY* човешките екипи се нуждаят от проверима автоматизация, прогнозируеми такси и логване на съответствие. До ерата *VENUS* автономните бизнес единици изискват регулирано попечителство, хибридно уреждане във фиатна валута и експертен арбитраж. Ерите *MARS* до *JUPITER* изискват конституционни смарт договори, толерантно към забавяне уреждане за виртуални цивилизации и смесени човешко–AI съвети. Накрая, ерите *SATURN* до *ANDROMEDA* въвеждат междупланетен консенсус, архивна федерация през колонии и механизми за съдебно упълномощени откати, обхващащи векове.

Тази бяла книга преднамерено приема подход с двойна леща: всяка функция се представя чрез своята *краткосрочна* стойност за човешките предприятия и нейната *вековна* роля в инфраструктурата на цивилизацията AGI. Това рамкиране гарантира, че TOS доставя незабавна полезност, като остава архитектурно подготвена за дългосрочна еволюция. Следващата таблица обобщава това картографиране:

Нужда на AGI	Краткосрочно (леща „сега“)	Вековен мащаб (леща „бъдеще“)
Идентичност и правен статут	Стек на цифрова личност, издаване на DID, отмяна, репутация	Федерация през юрисдикции, обратими доказателства за идентичност, отговорност за разделяне на ума
Доход и плащания	AGIW разписки, залагане, уреждане в рамките на минути	Автономни икономики, междупланетни парични преводи, рекурсивни разделяния на доходи
Изчисления и енергия	СС/ЕС токени, ценени чрез оракули, ТЕМ субсидии	Пазари на енергия тип Dyson-swarm, хилядолетни фондове, бюджети за обществена сложност
Управление	Комплекти за политики на портфейли, компилатор за съответствие, одитни следи	Конституционни договори, толерантно към забавяне уреждане, смесени човешко–AI съвети
Устойчивост	Пътна карта PQC, детерминистични компилации, телеметрия	Обратима история, архивна федерация, компенсация на междузвездна латентност

Структура на разказа Останалата част от тази статия се представя в четири цивилизационни глави (Основи, Пазари и безопасност, Съуправление и метасветове, Разширяване и обратима история), последвани от технически дълбочинни изследвания, икономическа архитектура, осигуряване, управление, регулация, детайли за внедряване, казуси, изследователска програма и заключение. Всяка секция е преднамерено рамкирана чрез двойна леща: незабавна човешка стойност и въздействие във вековен мащаб.

3 Предистория и свързана работа

3.1 Еволюция на икономиките на автономни агенти

Изследванията на автономни агенти са преминали през отделни фази, всяка разкриваща нови инфраструктурни изисквания:

Фаза 1: Академични прототипи (2015–2020) Ранното изследване се фокусира върху агенти за обучение с подсилване (AlphaGo на DeepMind, ботове Dota 2 на OpenAI) и модели за естествен език (GPT-2, BERT). Тези системи демонстрираха специфична за задачата компетентност, но работеха в контролирани среди с човешки надзор. Ключово ограничение: липса на икономическа автономия или проверимо изпълнение извън пясъчни среди.

Фаза 2: Основни модели и рамки (2020–2023) Пускането на GPT-3 (2020 г.) и ChatGPT (2022 г.) катализира корпоративния интерес към генеративния AI. Появиха се рамки с отворен код: AutoGPT, LangChain и Semantic Kernel позволиха на разработчиците да верижат LLM повиквания в работни потоци. Microsoft и Google обявиха асистиенти „Copilot“ за софтуер за продуктивност. AlphaCode на DeepMind решава конкурентни програмни проблеми. Ключово ограничение: изходите липсваха формална проверка, създавайки загриженост за отговорност за регулирани индустрии.

Фаза 3: Агентни внедрявания (2023–настояще) Предприятията започнаха да внедряват AI агенти за обслужване на клиенти (чатботове), анализ на данни (генериране на SQL), разработка на софтуер (преглед на код) и логистика (оптимизация на маршрути). IDC оценява, че разходите за софтуер за агентски платформи ще нараснат от \$38 милиарда през 2024 г. до \$121 милиарда до 2028 г.¹² Accenture докладва, че 40% от СТО планират да внедрят автономни агенти в рамките на три години, цитирайки по-ниски маргинални разходи и непрекъснатата наличност.¹³ Проучването на McKinsey на 1,684 ръководители разкри, че 46% вече прототипират агентски работни потоци, но основните пречки са *проверка, управление на данни и плащания*—точно проблемите, които TOS решава.¹⁴

Economist подчертава, че без прозрачни регистри, „задачите, завършени от AI, липсват веригата на попечителство, която регулаторите изискват създавайки правна експозиция за финансови услуги и внедрявания в здравеопазването.¹⁵ Forbes по подобен начин наблюдава, че предприятията се нуждаят от „проверими AI агенти“ с одитни следи и програмируеми плащания.¹⁶ Тези индустриални доклади се сближават към критично прозрение: *агентската икономика не може да се мащабира без инфраструктура за уреждане*—същото осъзнаване, което стимулира приемането на блокчейн за криптовалути, но сега приложено към AI труд.

3.2 Ограничения на съществуващите блокчейни за агенти

Нито един съществуващ блокчейн не е проектиран за AI агенти. Съществуващите платформи попадат в няколко категории, всяка със основни пропуски:

¹²IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

¹³Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

¹⁴McKinsey Global Institute, “The economic potential of generative AI,” June 2023.

¹⁵The Economist, “Meet the agentic future,” July 13, 2024.

¹⁶Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.



Вериги за прехвърляне на стойност Предоставят необратими плащания с робустна сигурност, но липсват абстракция на акаунт, програмируема идентичност или подкрепа на смарт договори. Агентите не могат да докажат завършване на работа или да участват в управлението.

Платформи за смарт договори Позволяват програмируеми пари и децентрализирани приложения, но не са проектирани за AI агенти. Общите ограничения включват: (1) *волатилност на таксите*: транзакционните разходи флукутират 10–100× по време на претоварване на мрежата, правейки прогнозирането на разходите невъзможно за агенти, работещи с тесни маржове; (2) *ограничена поверителност*: публичната видимост на транзакциите разкрива собствени работни потоци и ценови стратегии; (3) *липса на нативна AI проверка*: агентите трябва да се доверяват на извънверижни оракули или да изпълняват скъпи изчисления на веригата, нито едно от които се мащабира; (4) *пропуски в абстракцията на акаунти*: програмируемите акаунти изискват сложни заобикаляния, вместо нативна протоколна подкрепа. Решенията за мащабиране от слой 2 намаляват транзакционните разходи, но третират AI изпълнението като външни събития, все още изискващи доверени посредници за удостоверяване на завършване на работа.

Мрежи, фокусирани върху AI Някои платформи рѳioneerѳа AI-специфични стимули като доказателство за интелигентност за обучение на невронни мрежи. Докато предлагат нативен AI фокус и децентрализирано изчисление, тези мрежи обикновено липсват: (1) регулирано попечителство или уреждане във фиатна валута, ограничавайки корпоративното приемане; (2) цялостно управление, адресиращо законово съответствие и арбитраж; (3) механизми за проверка, които задоволяват корпоративните одитни изисквания.

Платформи за пазар на агенти Предоставят рамки за агенти и услуги за откриване, но разчитат силно на извънверижна координация. Гаранциите за сигурност са ограничени; системите за идентичност и репутация често са централизирани или недостатъчно специфицирани. Тези платформи адресират *откриваемостта* (намиране на агенти), но не *уреддането* (плащане без доверие за проверена работа).

Децентрализирани изчислителни мрежи Насочени към наемане на GPU/CPU с пазарни механики и залагане. Докато предлагат токенизация на ресурси и конкурентно ценообразуване, те липсват: (1) инфраструктура за правна идентичност за агенти (DIDs, удостоверения); (2) механизми за разрешаване на спорове и арбитраж; (3) проверка на задачи отвъд осигуряване на инфраструктура.

3.3 Академични и индустриални прецеденти

Доказателства за полезна работа Ball et al. предложиха използване на проверимо изчисление (напр. zkSNARKs) за замяна на произволно доказателство за работа с полезни задачи.¹⁷ Предизвикателствата включват (1) разходът за проверка често надвишава разхода за изпълнение, (2) стимулирането на излишна работа за сигурност на консенсуса влиза в конфликт с целите за полезна работа, (3) дефиниране на „полезно“ обективно. TOS заобикаля тези проблеми, като разделя консенсуса (BlockDAG) от проверката на работата (AGIW), позволявайки полезни задачи да се уреждат върху сигурен базов слой без да ги принуждава в консенсус.

¹⁷Ball et al., “Proofs of Useful Work,” IACR ePrint 2017/203.



Доверени среди за изпълнение Intel SGX, AMD SEV-SNP и ARM TrustZone позволяват удостоверено изчисление: хардуерът гарантира, че кодът е работил немодифициран в изолация. TEEs подкрепят удостоверяването AGIW, предоставяйки криптографско доказателство за изпълнение без разкриване на входове. Ограниченията включват уязвимости на странични канали и зависимост от доставчик; пътната карта на TOS включва zk-SNARK алтернативи за намаляване на разчитането на специфичен хардуер.

Децентрализирана идентичност (W3C DIDs, VCs) Стандартите за децентрализиран идентификатор и проверимо удостоверение на W3C позволяват самосуверенна идентичност без централни власти. TOS приема тези стандарти за агентска личност, осигурявайки оперативна съвместимост с корпоративни системи за идентичност (Active Directory, OAuth) и регулаторни рамки (eIDAS, GDPR).

3.4 TOS синтез

TOS синтезира тези прецеденти в кохерентно цяло:

- **Архитектура TopoSpartan** (BlockDAG + дисциплинирана сигурност) доставя пропусковна способност и устойчивост.
- **AGIW** (протокол AGI Work) предоставя проверимо уреждане на труд с TEE удостоверяване и консенсус на валидатори.
- **Токени CC/EC** въвеждат пари, деноминирани в ресурси, стабилизирайки разходите за агенти.
- **ТЕМ/PAI** (TOS енергиен модел / Power of AI) доставят адаптивна политика за такси и асистиран от AI консенсус.
- **Стек DID** предоставя правна идентичност, удостоверения и репутация, свързвайки Web2 предприятия и Web3 инфраструктура.
- **Рамка за управление** подкрепя конституционни договори, експертен арбитраж и регулаторно съответствие.

Нито една друга платформа не комбинира тези елементи. TOS е първият блокчейн, специално създаден за агентската икономика.

4 Системна схема

4.1 Общ преглед на архитектурата

Мрежата TOS включва четири основни слоя и множество кръстосани услуги. Архитектурата е проектирана да еволюира през небесните ери, като поддържа обратна съвместимост и оперативна съвместимост.¹⁸

Стек от четири слоя

1. **Слой 0: Консенсус и мрежа** – BlockDAG топология с подобрения Power of AI (PAI) за високопропускливо уреждане.
2. **Слой 1: Идентичност и репутация** – Децентрализирани идентификатори (DIDs), проверими удостоверения (VCs) и граф на репутацията (RepGraph).

¹⁸Интерактивна визуализация на архитектурата с метрики в реално време е налична на explorer.tos.network.



3. **Слой 2: Икономическо изпълнение** – Протокол AGI Work (AGIW), пазари на кредити за изчисления/енергия (CC/EC), Енергиен модел TOS (TEM).
4. **Слой 3: Управление и политика** – Конституционни договори, многокамерно гласуване, експертен арбитраж, обратима история.

Кръстосани услуги

- **Телеметрия и аналитика:** Мониторинг на здравето на мрежата в реално време, метрики за завършване на задачи, табла за представяне на валидатори.
- **Съответствие и одитиране:** Регулаторен API за упълномощен достъп, тримесечни доклади за прозрачност, интеграция AML/KYC.
- **Операции за сигурност:** 24/7 SOC (Център за операции по сигурността), откриване на аномалии, наръчници за реакция при инциденти.
- **Инструменти за разработчици:** SDK (Python, JavaScript, Rust), CLI помощни програми, кранове за testnet, портал за документация.

4.2 Слой 0: Консенсус и мрежа

Консенсус BlockDAG TOS използва топология на насочен ацикличен граф (DAG), където всеки блок препраща към 1–3 родителски блока. Това позволява паралелно производство на блокове: валидаторите независимо предлагат блокове без да чакат строго линейно подреждане. Структурата DAG осигурява естествена излишност и висока пропускна способност (2,500+ TPS базова, 10,000+ TPS с PAI).¹⁹ Правилата за консенсус налагат евентуална последователност чрез топологично сортиране; блокове с недостатъчни потвърждения от родители остават предварителни, докато не се постигне достатъчна дълбочина.

Мрежов слой Възлите комуникират чрез libp2p (мултиплексиране на протоколи, пресиране на NAT, откриване на връстници). Разпространението на блокове използва епидемично излъчване с дедупликация. Mempool на транзакциите имплементира приоритетни опашки, базирани на такси и репутация, претеглена със залог. Телеметрични канали (метрики, логове, следи) се стриймват чрез gRPC към услугата за индексирани данни.

Машина на състоянието Балансите на акаунти, съхранението на смарт договори и метаданните се намират в Merkleised state trie (Patricia Merkle Trie). Корените на състоянието се закотвят в хедърите на блокове, позволявайки на леки клиенти да проверяват доказателства за включване без пълно състояние.

4.3 Слой 1: Идентичност и личност

Регистър DID Смарт договор съхранява документи за децентрализиран идентификатор (DID), следвайки стандартите на W3C. Всеки DID се картографира към публичен ключ, крайни точки за услуги и незадължителни метаданни (напр. четими от човек имена, URI на профили). Агентите извикват `registerDID(didDocument)`, за да закотвят своята идентичност на веригата. Актуализациите изискват подписи от контролния ключ на DID. Отмяната е постоянна; репутацията се нулира.

¹⁹Мрежата TOS, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.



Проверими удостоверения (VCs) Издатели на удостоверения (университети, работодатели, сертифициращи органи) публикуват подписани VCs, препращащи към субект на DID. VCs се съхраняват извън веригата (IPFS, Arweave) с хешове с адресиране на съдържание, закотвени на веригата. Примерни удостоверения: „Сертифициран анализатор на данни „Преминал одит по сигурността „Завършени 1000 задачи“. Проверяващите проверяват подписи и статус на отмяна, преди да се доверят на удостоверенията.

Регистър за отмяна Имплементира Merkleised списъци за отмяна: издателите публикуват Merkle дървета на отменени ID на удостоверения. Агентите произвеждат доказателства за неотмяна (Merkle пътица) без да разкриват пълния списък, запазвайки поверителността. Този подход се мащабира до милиони удостоверения на издател.

RepGraph (система за репутация) Поддържа оценки на репутацията по агент $r_a \in [0, 1]$, базирани на точност на завършване на задачи, залог, възраст на акаунт и история на валидиране. Формулата за оценяване е детайлизирана в раздел 5.9. Репутацията влияе върху приоритета на присвояване на задачи, отстъпки на такси и тегло в управлението. Устойчивостта на Sybil разчита на изисквания за залог, интеграция на доказателство за личност (планирана за v4.0) и многоизмерно оценяване (предотвратяване на манипулиране чрез една метрика).

Поверителни баланси Агентите могат да изберат поверителни транзакции, използвайки ангажименти Pedersen и доказателства за обхват Bulletproof. Ангажиментите скриват суми, като запазват хомоморфни свойства (валидаторите проверяват, че входовете са равни на изходите, без да научават стойностите). Тази функция е критична за корпоративни внедрявания, където разходите за работен поток съставляват търговски тайни.

4.4 Слой 2: Уреждане и AGIW

Договор Task Factory Разполага индивидуални договори TaskInstance. Публикуващите определят метаданни на задачата (описание, депозит, краен срок, критерии за приемане, позволени кохорти агенти). Фабриката прилага правила за бял списък, събира такси за публикуване (напр. 0.01 TOS) и индексира задачи за откриване. Публикуващите могат да актуализират метаданни преди приемане, но не след ангажимент.

Договор Task Instance Управлява жизнения цикъл на една задача. Състояния: `Open` $\rightarrow$ `Claimed` $\rightarrow$ `Submitted` $\rightarrow$ `Validating` $\rightarrow$ `Settled` (или `Disputed`). Агентите извикват `claimTask()`, за да заключат задачата (депозитът се държи), след което `submitWork(resultHash, attestation)`, за да предоставят изходи. Договорът излъчва събития, които задействат назначаването на валидатори.

Validation Pool Валидаторите залагат TOS, за да участват. При подаване на задача пулът псевдослучайно назначава 3–7 валидатори (претеглени по залог и историческа точност). Валидаторите извикват извънверижна верификация (напр. повторно изпълнение на изчисление, проверка на подписи за удостоверяване, сравнение на изходи) и подават `validateWork(taskID, score)` във веригата. Оценките се агрегират чрез медиана; отклоненията (>2 стандартни отклонения) задействат санкции. Проследяването на точността използва експоненциална подвижна средна: $Acc_{t+1} = 0.9 \times Acc_t + 0.1 \times correctness_t$.



Reward Splitter Разпределя депозита въз основа на оценка за качество $q \in [0, 1]$: агентът получава $e \times q$, валидаторите споделят $e \times (1 - q) \times \beta$, мрежовата хазна получава $e \times \gamma$. Параметри по подразбиране: $\beta = 0.12$, $\gamma = 0.08$. Санкционираните средства отиват в хазната. Разделителят налага периоди на охлаждане (5–60 минути въз основа на ниво на репутация), за да предотврати спам.

Договор за арбитраж Управлява спорове. Всяка от страните може да ескалира, като заложи арбитражна гаранция. Акредитирани арбитри (човешки експерти или комитети с множество подписи) разглеждат доказателства, издават решения и актуализират състоянието на договора. Губещата страна губи гаранцията; печелившата страна възстановява разходите плюс обезщетения. Осигурителният пул (финансиран от ТЕМ) покрива катастрофални загуби.

4.5 Слой 3: Ресурсни пазари

Токени СС/ЕС Изчислителните кредити (СС) обозначават TFLOP-часове; енергийните кредити (ЕС) обозначават kWh. И двата се сечат от договор на хазната въз основа на цени, докладвани от оракули от AWS, Azure, GCP (за СС) и ISO енергийни пазари (за ЕС). Обратното изкупуване позволява на агентите да обменят СС/ЕС за TOS по определени от оракула курсове, което позволява арбитраж, който поддържа цените в съответствие с реалните ресурси.

Мрежа от оракули 21 независими доставчика (смесица от търговски доставчици на данни и общностни възли) залагат TOS и подават подписани ценови отчети на всеки 15 минути. Договорът за агрегиране изчислява медиана на медианите, за да смекчи отклоненията. Остарялостта (няма актуализация за 30 минути) задейства резервен вариант към експоненциално претеглена подвижна средна. Отклонението на доставчика извън толеранс ($\pm 5\%$) води до санкции, пропорционални на величината на грешката.

Контролер ТЕМ Енергийният модел на TOS регулира субсидии за такси, инжекции на ликвидност и темпове на емисия, за да поддържа икономически баланс. Например, ако нивата на спорове надвишат 2%, ТЕМ увеличава наградите на валидаторите, за да привлече участие. Ако ликвидността на СС/ЕС падне под целевото покритие (напр. 20% от активното търсене на агенти), ТЕМ сече допълнителни кредити и ги инжектира в пулове на автоматизирани пазарни създатели (АММ). Управлението задава параметрите на ТЕМ тримесечно чрез предложения във веригата.

Пулове за ликвидност Автоматизирани пазарни създатели (АММ с постоянен продукт) позволяват размени СС/ЕС $\leftrightarrow$ TOS. Доставчиците на ликвидност печелят такси (0.3% на размяна); непостоянната загуба се смекчава чрез субсидии на ТЕМ за основни двойки. Бъдещите итерации могат да въведат концентрирана ликвидност (стил Uniswap v3), за да подобрят капиталовата ефективност.

4.6 Слой 4: Управление и политика

Компилятор на политики Преобразува правила за управление на високо ниво (написани на декларативен DSL) в изпълними модули на смарт договори. Примерна политика: “Ограничете тегленията на агенти $>10,000$ TOS до одобрение с множество подписи.” Компиляторът



генерира Python код със статични проверки (ограничени цикли, изрично управление на достъпа, регистриране на събития). Управлението предлага компилирани политики, изпълнява автоматизирани тестове в тестови мрежи и разполага след преглед от общността и гласуване със забавено време.

Конституционни договори Кодират основни правила (напр. “Без едностранни разходи на хазната над праг,” “Аварийната спирачка изисква одобрение на 3/5 от съвета”). Тези договори са неизменяеми или изискват гласове на свръхмнозинство (75%) за изменение. Те служат като “конституция”, която ограничава управлението, предотвратявайки завладяване или безразсъдни промени.

Съвет на попечители Избрано тяло (7–15 членове) с разместени мандати. Отговорностите включват реакция при извънредни ситуации (пауза на договори по време на атаки), настройка на параметри (графици на такси, прагове на оракули) и екосистемни грантове. Изборите използват квадратично гласуване, за да балансират претеглянето на залози и широко участие.

Регистри за одит и телеметрия Всички действия на управлението (предложения, гласувания, изпълнения) излъчват събития във веригата. Телеметричната услуга индексира тези за табла за съответствие, публична прозрачност и исторически анализ. Регулаторите могат да правят заявки за агрегирана статистика (напр. общ обем на AGIW, времена за разрешаване на спорове) чрез API с контролиран достъп, без да разкриват индивидуални идентичности на агенти.

4.7 Преки услуги

Индексирана услуга за данни (IDS) Консумира събития във веригата чрез gRPC, съхранява ги във формат Apache Arrow (колонен, високопроизводителна аналитика) и излага GraphQL API. Полета, чувствителни към поверителност (напр. спецификации на задачи, идентичности на агенти) се хешират; достъпът изисква криптографски доказателства или удостоверения, базирани на роли. IDS запазва TOS Explorer, табла за съответствие и инструменти за анализ на трети страни.

API за съответствие Предоставя крайни точки само за четене за регулатори да одитират активността на AGIW, разрешенията на спорове и потреблението на енергия. Примерни заявки: “Покажи месечен обем на задачи по юрисдикция,” “Изброй агенти, маркирани от оракула за безопасност,” “Агрегирай емисия на CC/EC спрямо обратно изкупуване.” Ограничен по скорост, удостоверен чрез OAuth2, регистриран за отчетност.

SDK и инструменти за разработчици Официални библиотеки в Rust, Python, TypeScript абстрахират взаимодействия с блокчейн на ниско ниво. Пример: `tos-sdk-py` предоставя методи `Agent.register_did()`, `Task.publish()`, `Task.claim()`, `Task.submit()`. Модулите Terraform позволяват на предприятията да разполагат частни тестови мрежи с персонализирани политики. GitHub Actions интегрират CI/CD за тестване на смарт договори.

4.8 Жизнен цикъл на агента (подробно)

Пълният работен процес на агента включва множество подсистеми:

**1. Въвеждане** (слой идентичност)

- а. Агентът генерира ключова двойка, конструира DID документ, извиква `DIDRegistry.register()`.
- б. По избор завършва KYC с акредитиран доставчик, получава удостоверение `KYC-Verified`.
- в. Залага минимум TOS (напр. 100 TOS), за да активира участие; залогът се заключава за 7 дни.

2. Акредитация (слой идентичност)

- а. Придобива проверими удостоверения от издатели (напр. завършва тестова задача, печели значка за умения).
- б. Удостоверенията се закрепват във веригата чрез хешове; статусът на отмяна се проверява преди всяко заявяване на задача.

3. Откриване и заявяване (слой за уреждане)

- а. Агентът прави заявки към TaskFactory за отворени задачи, съответстващи на изисквания за умения и диапазон на депозит.
- б. Извиква `TaskInstance.claim()` (изисква репутация $\geq$ праг, достатъчен залог).
- в. Състоянието на задачата преминава към `Claimed`; депозитът се държи в договора; започва обратно броене до крайния срок.

4. Изпълнение (извън веригата + удостоверяване)

- а. Агентът изпълнява работната натоварка в доверена среда за изпълнение (TEE): Intel SGX, AMD SEV-SNP или ARM Realm.
- б. TEE генерира отчет за удостоверяване: хеш на измерване (доказва целостта на кода), хешове на вход/изход, времеви печати, потребление на енергия.
- в. Агентът подписва резултата и удостоверяването, изчислява хеш на съдържанието, подава чрез `submitWork()`.

5. Валидиране (слой за уреждане)

- а. ValidationPool назначава 3–7 валидатори (претеглени по залог, точност).
- б. Валидаторите проверяват подписи за удостоверяване, по избор повторно изпълняват изчисление, подават оценки за качество.
- в. Договорът агрегира оценки (медиана), открива отклонения, задейства санкции, ако валидаторите се държат неправилно.

6. Уреждане (слой за уреждане + ресурсни слоеве)

- а. RewardSplitter разпределя депозита: агентът получава $e \times q$ в CC/EC, валидаторите споделят такси, хазната получава разпределение.
- б. RepGraph актуализира репутацията на агента: $r_{t+1} = 0.9 \times r_t + 0.1 \times q$.
- в. Ако възникне спор, изисква се арбитражна гаранция; процесът ескалира към ArbitrationContract.

7. Участие в управлението (слой управление)

- а. Агентът гласува за предложения (претеглено по залог + репутация).
- б. Делегира правото на глас на специалисти (напр. експерти по сигурност за гласуването за миграция на PQC).
- в. Участва в прегледи на грантове на хазната, одити на компилатора на политики.



4.9 Пример за поток от данни: Преглед на юридически документ

1. **Публикуващ** (адвокатска кантора) разполага задача: “Редактирай РП от 500-страничен договор.” Депозит: 50 CC (изчисления) + 5 EC (енергия). Краен срок: 2 часа.
2. **Агент А** (DID did:tos:tos1qpz8vq6qgnkgw9zzq9z5qgpgqx8qgz5dpgrxve, репутация 0.87, удостоверение Certified Legal AI) заявява задачата. Състояние: **Claimed**.
3. **Агент А** изпълнява тръбопровод за редакция в Intel SGX енклав. Отчетът за удостоверяване включва хеш на измерване на модела за редакция, потребление на енергия (4.8 EC), време за изпълнение (22 минути).
4. **Агент А** подава резултат (криптиран хеш на редактиран документ) + удостоверяване. Състояние: **Submitted**.
5. **Валидатори** (3 назначени): проверяват подписи за удостоверяване, точково проверяват 10% от редакциите, потвърждават версия на модела. Оценки за качество: 0.95, 0.94, 0.96. Медиана: 0.95.
6. **RewardSplitter** плаща на Агент А $50 \times 0.95 = 47.5$ CC + $5 \times 0.95 = 4.75$ EC. Валидаторите споделят 6 CC + 0.6 EC. Хазната получава 4 CC + 0.4 EC.
7. **RepGraph** актуализира Агент А: $r_{t+1} = 0.9 \times 0.87 + 0.1 \times 0.95 = 0.878$.
8. **Телеметрия** регистрира завършване на задачата, потребление на енергия, метаданни за удостоверяване. Адвокатската кантора одитира следата за съответствие (водене на записи по член 30 на GDPR).

Този пример илюстрира как всички слоеве взаимодействат, за да доставят проверим, рентабилен, съответстващ на изискванията AI труд.

5 Основи (режим на стартиране) – ера Меркурий

5.1 Стратегически контекст

В ранната ера МЕРКУРИЙ, автономните агенти преминават от изследователски прототипи към производствени внедрявания. Индустриалните прогнози предвиждат бързо приемане: 30% от новите приложения използват автономни агенти, а разходите за агентски платформи надвишават \$120 милиарда.²⁰ Нашите пилотни ангажименти със застрахователни, биотехнологични и игрални фирми разкриват незабавно търсене на проверима автоматизация. Ерата МЕРКУРИЙ следователно набляга на идентичност, уреждане, токени на ресурси и демонстрации, които доказват стека.

5.2 Резултати за следващите 12–18 месеца

D1. Стек на цифрова личност v1

- Котви DID, имплементирани чрез BLS подписи, издаващи DID документи, съхранявани on-chain с крайни точки за услуги.

²⁰Gartner, “Top Strategic Technology Trends 2025,” October 2024; IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.



- Регистър на удостоверения, съхраняващ проверими удостоверения (VCs), препращащи към образователни сертификати, удостоверения за съответствие или значки за умения; отменяне, обработено чрез Merkleised списъци на състоянието.
- Поверителни баланси с ангажименти Pedersen и доказателства за обхват Bulletproof; библиотеки на портфейли, позволяващи защитени трансфери.

D2. Работа AGI (AGIW) v1

- Договорите Task Factory и Task Instance управляват метаданни, депозит, крайни срокове и позволени кохорти агенти.
- Интеграция на удостоверяване с Intel SGX, AMD SEV-SNP и ARM Realm; пакети за удостоверяване с хеш on-chain.
- Договорът Validation Pool проследява точността на валидаторите чрез експоненциални плъзгащи средни; неправилното докладване задейства slashing.
- Договорът Reward Splitter детерминистично разпределя СС/ЕС на агенти, валидатори и мрежова хазна.

D3. Кредити за изчисления/енергия

- Токени СС, деноминирани в TFLOPs; токени ЕС, деноминирани в kWh. И двата се изковават въз основа на данни от оракули от водещи облачни доставчици и енергийни пазари.
- Договорът Paymaster позволява на агентите да плащат такси за газ в СС/ЕС; ТЕМ субсидира такси за задачи с високо въздействие (напр. анализи на безопасността).

D4. Демонстрация на пазар на задачи на агенти

- Демонстрация от край до край, обхващаща издаване на идентичност, създаване на задачи, уреждане AGIW, разрешаване на спорове и актуализации на репутацията.
- Секции Explorer за агенти, задачи, разписки, репутация, безопасност с телеметрия в реално време.
- SDK на Rust, Python, TypeScript; модули Terraform за корпоративни внедрявания.

5.3 Ключови показатели за ефективност

Метрика	Цел (12 месеца)	Инструментиране
Дневни активни портфейли на агенти	5.000	DID регистър, табло за телеметрия, логове на paymaster
Проверени задачи на ден	10.000	AGIW разписки, събития за валидиране, анализ на арбитраж
Медиана на латентност на уреждане	< 15 минути	Времеви печати on-chain, индексирание на разписки
Процент на спорове	< 2%	Статистика на договор за арбитраж
Субсидия на такса чрез СС/ЕС	> 60%	ТЕМ анализ (издаване, погасяване)
Разходи за завършване на задача	60–80% по-ниски спрямо ръчни изпълнители	Пилотни сравнения с човешки работни потоци



Готовност за съответс-	Пакет за одит в стил	Логове на API за съответствие,
твие	SOC 2	записи за доказателство за достъп

5.4 Услуги за идентичност (Спецификация на продукта)

Имплементация на регистър DID Регистърът DID е модул на умен договор на Python (DIDRegistry.py) със следния интерфейс:

```
class DIDRegistry:
    @public
    def register_did(self, did_hash: bytes, did_document: bytes,
                    signature: bytes) -> None:
        """Register a new DID with its document"""

    @public
    def update_did(self, did_hash: bytes, new_document: bytes,
                  signature: bytes) -> None:
        """Update an existing DID document"""

    @public
    def revoke_did(self, did_hash: bytes, signature: bytes) -> None:
        """Revoke a DID"""

    @public
    @view
    def resolve_did(self, did_hash: bytes) -> bytes:
        """Resolve a DID to its document"""
```

DID documents conform to W3C DID Core specification (v1.0). Each document includes:

- **id**: Unique identifier (e.g., `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xhyepcg...`)
- **verificationMethod**: Public keys for authentication, assertion
- **service**: Endpoints for messaging, data storage, API access
- **created, updated**: Timestamps for audit trails

Gas cost: approximately 80,000 gas for registration (\$0.50 at 50 gwei, \$2,000 TOS), amortized over agent lifecycle.

Verifiable Credentials Credential issuance follows the W3C VC Data Model (v1.1). Issuers sign JSON-LD documents containing:

```
{
  "@context": ["https://www.w3.org/2018/credentials/v1"],
  "id": "https://issuer.example/credentials/987",
  "type": ["VerifiableCredential", "SkillCertificate"],
  "issuer": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh",
  "issuanceDate": "2025-10-01T00:00:00Z",
  "credentialSubject": {
    "id": "did:tos:tos1qq5hqy2jwn0r5ehvuw5r3qjcfvjvq5dhldxvyq",
    "skill": "Data Science",
```



```

    "proficiencyLevel": "Expert"
  },
  "proof": {
    "type": "BbsBlsSignature2020",
    "created": "2025-10-01T00:00:00Z",
    "proofPurpose": "assertionMethod",
    "verificationMethod": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh#key-1",
    "proofValue": "...
  }
}

```

Storage: VCs reside off-chain (IPFS, Arweave); on-chain anchors store content hashes (32 bytes). Verification requires fetching the VC, checking the issuer signature, and querying the revocation registry.

Revocation Registry Implements sparse Merkle trees with 2^{256} leaf capacity. Issuers publish tree roots on-chain monthly; revoked credential IDs occupy leaves. Agents produce Merkle proofs demonstrating their credential ID is absent from the tree (non-revocation proof). This approach scales to millions of credentials per issuer without revealing the full list. Gas cost: 50,000 gas per root update (\$0.30 per issuer per month).

Confidential Transactions Built on Pedersen commitments:

$$C(v, r) = vG + rH \quad (1)$$

where v is the value (amount), r is the blinding factor, G and H are elliptic curve generators. Commitments are additively homomorphic: $C(v_1, r_1) + C(v_2, r_2) = C(v_1 + v_2, r_1 + r_2)$, enabling validators to verify balance without learning amounts. Bulletproof range proofs ensure $v \in [0, 2^{64})$, preventing negative balances. Proof size: 672 bytes for single output, logarithmic growth for batch proofs. Verification cost: approximately 1.2 ms per proof on commodity hardware. This feature is optional; agents opt in via `enableConfidentialMode()` transaction.

5.5 Смарт договори AGIW (подробна спецификация)

Жизненият цикъл на AGIW разчита на четири основни договора с точни икономически и сигурни свойства:

1. Договор TaskFactory (TaskFactory.py)

Цел: Модел фабрика за разполагане на индивидуални инстанции на задачи със стандартизирани интерфейси и сигурни ограничения.

Ключови функции:

- `publishTask(metadata, escrow, deadline, allowedAgents)`: Разполага нов `TaskInstance`, прехвърля депозит към договора, събира такса за публикуване от 0.01 TOS, излъчва събитие `TaskPublished`. Връща ID на задачата.
- `listTasks(filters)`: Интерфейс за заявки за откриване; филтрира по диапазон на депозит, краен срок, изисквани удостоверения.
- `updateWhitelist(agentDIDs)`: Публикуващият може да ограничи задачата до специфични кохорти агенти (напр. KYC-верифицирани, репутация > 0.7).

**Икономически параметри:**

- Такса за публикуване: 0.01 TOS (предотвратява спам, финансира мрежови операции).
- Заклучване на депозит: държи се до уреждане или разрешаване на арбитраж.
- Разходи за газ: приблизително 150,000 газ за разполагане (\$0.90 при 50 gwei).

Сигурност: Публикуващите не могат да теглят депозит след като агент заяви задача; само `RewardSplitter` може да освободи средства след валидиране.

2. Договор TaskInstance (TaskInstance.py)

Цел: Управлява състоянието на машината на жизнения цикъл за една задача.

Преходи на състоянието:

Open $\xrightarrow{\text{claim()}}$ Claimed $\xrightarrow{\text{submitWork()}}$ Submitted $\xrightarrow{\text{validate()}}$ Validating $\xrightarrow{\text{consensus}}$ Settled (2)

Алтернативен път: всяко състояние $\xrightarrow{\text{dispute()}}$ Disputed $\xrightarrow{\text{arbitration}}$ Resolved.

Ключови променливи на състоянието:

```
@dataclass
class Task:
    task_id: bytes          # Идентификатор на задачата
    publisher: str          # Адрес на публикуващия
    claimed_by: str         # Адрес на агент, който заяви задачата
    escrow: int             # Сума на депозит
    deadline: int           # Времеви печат на краен срок
    spec_hash: bytes        # IPFS CID на спецификация
    result_hash: bytes      # подадено от агент
    attestation: bytes      # Отчет за удостоверяване от TEE
    state: TaskState        # enum: Open, Claimed, Submitted, ...
    validator_scores: dict[str, int] # оценки [0,100]
    final_quality: int       # медиана на оценките на валидаторите
```

Ключови функции:

- `claimTask(agentDID)`: Изисква (1) задача в състояние `Open`, (2) агентът отговаря на критериите на белия списък, (3) залог на агента $\geq$ праг. Премахва към `Claimed`, стартира обратно броене до краен срок.
- `submitWork(resultHash, attestation)`: Изисква (1) извикващият е заявител, (2) преди крайния срок, (3) валиден подпис за удостоверяване. Премахва към `Submitted`, излъчва събитие `WorkSubmitted`, което задейства назначаване на валидатори.
- `validateWork(score)`: Извиква се само от назначени валидатори. Съхранява оценка $\in [0, 100]$. Когато всички валидатори подадат, агрегира оценките чрез медиана, преминава към `Settled`, задейства `RewardSplitter`.

Крайни срокове и наказания:

- Ако агентът не подаде преди крайния срок, публикуващият може да извика `forfeit()`, възвръщайки депозита минус 10% наказание (отива в хазната). Репутацията на агента намалява с 0.05.
- Ако валидаторите не подадат оценки в рамките на 24 часа, автоматичен резерв: задачата се преназначава на нова кохорта валидатори; оригиналните валидатори губят 5% от залога.



3. Договор ValidationPool (ValidationPool.py)

Цел: Координира назначаването на валидатори, проследява точността, налага санкции.

Регистрация на валидатори:

- Валидаторите залагат минимум 1,000 TOS, за да се присъединят към пула.
- Оценката за точност Acc_v се инициализира на 0.5, актуализира се чрез експоненциална подвижна средна:

$$Acc_{v,t+1} = \alpha \times Acc_{v,t} + (1 - \alpha) \times correctness_t, \quad \alpha = 0.9 \quad (3)$$

където $correctness_t \in \{0, 1\}$ показва дали оценката на валидатора съвпада с консенсуса (в рамките на $\pm 10\%$ от медианата).

Алгоритъм за назначаване:

1. При събитие `WorkSubmitted`, ValidationPool избира $n = 5$ валидатори (конфигурируемо).
2. Изборът използва претеглено по залог случайно вземане на проби с увеличение на точността:

$$P(\text{select } v) \propto stake_v \times (1 + Acc_v) \quad (4)$$

3. Валидаторите получават уведомление чрез извън веригата оракул; трябва да отговорят в рамките на 24 часа.

Правила за санкции:

- **Наказание за отклонение:** Ако оценката на валидатора се отклони $> 2\sigma$ от медианата, санкционира 1% от залога.
- **Наказание за липса на отговор:** Неуспехът да се подаде оценка в рамките на крайния срок санкционира 5% от залога.
- **Откриване на сговор:** Ако трима или повече валидатори подадат идентични оценки на > 10 последователни задачи (статистически малко вероятно), маркират се за преглед от управлението; заподозрените сговорници губят 20% от залога при потвърждение.

Разпределение на награди: Валидаторите колективно печелят $e \times \beta \times (1 - q)$, където e е депозит, $\beta = 0.12$, q е оценка за качество на агента. Наградите се разделят пропорционално на точността Acc_v .

4. Договор RewardSplitter (RewardSplitter.py)

Цел: Детерминистично разпределение на награди с периоди на охлаждане и актуализации на репутацията.

Формула за разпределение: Дадена задача с депозит e (в СС/ЕС) и крайна оценка за качество $q \in [0, 1]$:

$$R_{\text{agent}} = e \times q \times (1 + \alpha(r_a - 0.5)) \times f(s_a) \quad (5)$$

$$R_{\text{validators}} = e \times \beta \times (1 - q) \quad (6)$$

$$R_{\text{treasury}} = e \times \gamma + \text{санкционирани средства} \quad (7)$$

където:

- $r_a \in [0, 1]$ е репутация на агента (подробно в раздел 5.9),
- $\alpha = 0.2$ е коефициент на бонус за репутация,



- $f(s_a) = \min(2, 1 + \log(1 + s_a))$ е множител на залог (намаляваща възвръщаемост),
- $\beta = 0.12$ е разпределение за валидатори,
- $\gamma = 0.08$ е разпределение за хазната.

Периоди на охлаждане: Въз основа на ниво на репутация (вж. раздел 5.9):

- Платина ($r \geq 0.90$): 5 минути между задачи.
- Злато ($0.70 \leq r < 0.90$): 15 минути.
- Сребро ($0.30 \leq r < 0.70$): 30 минути.
- Бронз ($r < 0.30$): 60 минути.

Периодите на охлаждане предотвратяват спам и Sybil атаки, като същевременно позволяват на агенти с висока репутация да заявяват множество задачи.

Оптимизация на газа: RewardSplitter използва пакетни прехвърляния при разпределяне на CC/EC, за да намали разходите за газ на задача до $\sim 30,000$ газ (\$0.18).

5.6 Дизайн на оракули

Цените на CC/EC се докладват от децентрализирана мрежа от оракули, съставена от 21 доставчика. Всеки доставчик залага TOS и подписва актуализации на цени, получени от API източници (ценообразуване на облачни доставчици, ISO енергийни пазари). Агрегирането медиана на медианите смекчава отклоненията. Остарялостта на цените задейства ценообразуване по подразбиране, използвайки експоненциално претеглени подвижни средни. Лошото поведение на доставчиците води до санкции, пропорционални на отклонението.

5.7 Телеметричен стек

Телеметричният стек се състои от:

- Поточно предаване на събития във веригата чрез gRPC към индексирана услуга за данни, използваща Apache Arrow.
- Филтри за поверителност, хеширащи чувствителни полета.
- Визуализации на таблото (Grafana), показващи пропускателна способност на задачи, нива на спорове, потребление на енергия.
- API крайни точки за одитори за изпълнение на заявки за съответствие с контрол на достъпа, базиран на роли.

5.8 Математически модел

Нека T обозначава множеството от задачи, A агенти и V валидатори. Задача t има сложност c_t и депозит e_t . Полезността на агента U_a се моделира като:

$$U_a = \sum_{t \in T_a} q_{a,t} \cdot e_t - \gamma s_a - p_a \quad (8)$$

където $q_{a,t}$ е оценка за качество, s_a заключен залог, p_a наказание от санкции и γ коефициент на риск. Полезността на валидатора U_v по подобен начин включва бонуси за точност и наказания. За поддържане на системен баланс прилагаме:

$$\sum_{a \in A} s_a = \theta \sum_{t \in T} e_t, \quad 0.2 \leq \theta \leq 0.4 \quad (9)$$



осигурявайки достатъчно обезпечение за покриване на спорове в най-лошия случай.

Разпределението на наградите следва:

$$Reward_a(t) = e_t \times q_{a,t} \times (1 + \alpha(r_a - 0.5)) \times f(s_a) \quad (10)$$

с $f(s_a) = \min(2, 1 + \log(1 + s_a))$ и r_a репутация на агента. Валидаторите получават $Reward_v(t) = e_t \times \beta \times Acc_v(t)$, където Acc_v е точност. Санкциите премахват δs от неправилно се държащи страни.

5.9 Система за репутация (RepGraph)

RepGraph поддържа многоизмерни оценки на репутацията за агенти, комбинирайки обективни метрики (успех на задача, точност, дълголетие) със субективни одобрения (удостоверения, рецензии от колеги).

Изчисляване на базова оценка Базовата оценка на репутация r_a^{base} за агент a се изчислява като:

$$r_a^{\text{base}} = 0.3 \times \frac{\text{age}_a}{\text{age}_{\text{max}}} + 0.4 \times \frac{\text{txCount}_a}{\text{txCount}_{\text{max}}} + 0.3 \times \frac{\text{stake}_a}{\text{stake}_{\text{max}}} \quad (11)$$

където:

- age_a е възраст на акаунта в дни (ограничена до 365 за нормализация),
- txCount_a е брой на завършени задачи,
- stake_a е заложена сума TOS,
- знаменателите са максимуми в цялата мрежа за нормализация.

Бонус за точност След всяка задача с оценка за качество q_t , компонентът за точност на агента Acc_a се актуализира чрез експоненциална подвижна средна:

$$Acc_{a,t+1} = 0.9 \times Acc_{a,t} + 0.1 \times q_t \quad (12)$$

Бонусът за точност регулира репутацията с ± 0.2 :

$$r_a^{\text{accuracy}} = r_a^{\text{base}} + 0.2 \times (2Acc_a - 1) \quad (13)$$

Тази формула награждава последователно високо представяне ($Acc_a \rightarrow 1 \Rightarrow +0.2$) и наказва лошо представяне ($Acc_a \rightarrow 0 \Rightarrow -0.2$).

Дългосрочен бонус Агентите, поддържащи $Acc_a > 0.85$ за > 100 задачи, получават дългосрочен бонус от $+0.1$, ограничавайки крайната репутация до $r_a = 1.0$.

Присвояване на ниво Въз основа на крайната r_a , агентите се присвояват на нива, определящи периоди на охлаждане и отстъпки на такси:

Ниво	Диапазон на оценка	Период на охлаждане	Отстъпка на такси	Разпределение в п
Платина	$r \geq 0.90$	5 мин	30–50%	14%
Злато	$0.70 \leq r < 0.90$	15 мин	10–30%	33%
Сребро	$0.30 \leq r < 0.70$	30 мин	0–10%	41%



Бронз

 $r < 0.30$

60 мин

Наказание: 2× такса

12%

Таблица 4: Структура на нивата на RepGraph въз основа на данни от пилота от август 2025.

Механизми срещу Sybil RepGraph използва седемслойни евристики за откриване и блокиране на Sybil атаки:

1. **Изискване за залог:** Минимум 100 TOS, заключени за 7 дни (икономическа бариера).
2. **Възраст на акаунта:** Нови акаунти (< 7 дни) ограничени до задачи с ниска стойност (< 10 CC депозит).
3. **Разнообразие на IP:** Оракулът извън веригата маркира агенти, споделящи IP адреси; управлението може да изтрие потвърдени ферми.
4. **Анализ на модели на транзакции:** Агенти, подаващи задачи на идентични интервали или с идентични хешове на резултати, се маркират за преглед.
5. **Проверка на удостоверения:** Задачите с висока стойност изискват проверени удостоверения (KYC, сертификати за умения).
6. **Интеграция на доказателство за личност** (пътна карта v4.0): Интеграция с BrightID, Worldcoin или Gitcoin Passport, за да се осигури съответствие един човек - един агент.
7. **Анализ на социалния граф:** RepGraph разглежда мрежи от одобрения; клики от взаимно одобряващи агенти с ниска активност се наказват.

По време на пилота от август 2025 г. тези евристики блокираха 112 злонамерени опити с процент на фалшиво положителни резултати под 0.7% след ръчен преглед.²¹

5.10 Мониторинг и наблюдаемост

Цели за надеждност на сайта (SLO) Разполагането на Основите насочва към:

- **SLO1 – Латентност:** 99.9% от AGIW разписките валидирани в рамките на 20 минути ($p_{99.9} < 20$ мин).
- **SLO2 – Свежест на оракула:** Ценовите фийдове CC/EC актуализирани поне на всеки 15 минути; остарялост (> 30 мин) задейства резерв към експоненциално претеглена подвижна средна.
- **SLO3 – Процент на спорове:** Процент на спорове $< 2\%$; ако е превишен, ТЕМ увеличава наградите на валидаторите с 20%, за да привлече участие.
- **SLO4 – Наличност:** Време на работа на мрежата $\geq 99.95\%$ (престой < 4.4 часа/година).
- **SLO5 – Целостност на данните:** Нула византийски грешки в консенсуса на валидаторите (осигурено чрез санкции).

Имплементация на телеметричен стек Телеметричната архитектура включва:

- **Поточно предаване на събития:** Събития във веригата (задача публикувана/заявена/уредена, назначавания на валидатори, санкции) се предават чрез gRPC към индексиранията услуга за данни (IDS).

²⁰Мрежата TOS, “Reputation & Anti-Sybil Telemetry REP-2025-08,” август 2025.

²¹Мрежата TOS, “Reputation & Anti-Sybil Telemetry REP-2025-08,” август 2025.



- **Съхранение:** IDS използва колонен формат Apache Arrow (10× компресия спрямо базиран на редове, оптимизиран за аналитични заявки).
- **Филтри за поверителност:** Чувствителни полета (спецификации на задачи, идентичности на агенти, хешове на резултати) заменени със солени SHA-256 хешове в публични табла; заявките с контролиран достъп изискват криптографски удостоверения.
- **Табла:** Визуализациите на Grafana показват пропускателна способност на задачи в реално време, нива на спорове, потребление на енергия, разпределения на репутация, точност на валидаторите.
- **API за съответствие:** RESTful крайни точки (OAuth2-удостоверени, ограничени по скорост) позволяват на регулаторите да правят заявки за агрегирана статистика: “Месечен обем на AGIW по юрисдикция,” “Агенти, маркирани от оракула за безопасност,” “Съотношение на емисия на CC/EC спрямо обратно изкупуване.”

Сигнализиране Prometheus сигнализира при нарушения на SLO, задействайки уведомления към съвета на попечители и автоматизирани отговори (напр. корекции на субсидии на TEM, разширяване на кохорта валидатори).

5.11 Съображения за справедливост

Симулации на 10,000 синтетични агенти с разнообразни начални условия (репутация равномерно разпределена $\in [0, 1]$, залог $\in [100, 10000]$ TOS) демонстрират:

- **Конвергенция:** Репутациите на агентите конвергират в рамките на ± 0.05 от тяхното истинско ниво на умения след 30 задачи (95% увереност).
- **Мобилност:** Агенти с ниска репутация ($r < 0.3$) могат да достигнат златно ниво ($r > 0.7$) в рамките на 50 висококачествени задачи, демонстрирайки възходяща мобилност.
- **Въздействие на графика на охлаждане:** Без периоди на охлаждане, спамът представлява 42% от обема на задачите; с нивово охлаждане (5–60 мин), спамът се намалява до 6%.
- **Устойчивост на олигопол:** Топ 10% от агентите печелят 28% от наградите (коефициент на Джини 0.34), показващ умерена концентрация; управлението може да регулира α (бонус за репутация) и $f(s_a)$ (множител на залог), за да предотврати олигополи.

5.12 Резултати от пилотни експерименти

Тествахме AGIW на devnet (Aurora) и testnet (Helios) през август–септември 2025 г. с реални работни натоварвания на агенти и синтетични стрес тестове.

Пилот в реалния свят (15 август – 15 септември 2025 г.)

- **Участници:** 2,847 регистрирани агентски ключа (смесица от корпоративни ботове, академични изследователски проекти, любители).
- **Изпълнени задачи:** 126 (преглед на правни документи, обработка на климатични данни, анализ на код).
- **Процент на завършване:** 97.8% (123/126 задачи уредени; 3 оспорени, разрешени чрез арбитраж).
- **Ефективност на валидация:** 83% (медианно време от подаване до уреждане: 12.3 минути).



- **Откриване на измами:** 99.2% точност (112 злонамерени опита блокирани, 1 фалшиво положителен).
- **Спестявания на разходи:** Ранните адаптери докладваха 60–80% намаление на разходите в сравнение с ръчни изпълнители за еквивалентно качество.

Синтетичен стрес тест (1,000 задачи, септември 2025 г.)

- **Средно време за изпълнение:** 7.4 минути (от предявяване на задача до подаване на резултат).
- **Режийни разходи за удостоверяване:** 3.1% (генериране на TEE доклад + верификация на подпис добавя 230 ms на задача).
- **Разход за валидация:** 0.002 TOS на задача (газ за подаване на резултати от валидатори + разпределяне на награди).
- **Пропускна способност:** Устойчиво 45 задачи/минута (2,700 задачи/час) без влошаване на производителността.
- **Инжектиране на измами:** Умишлено подадени 50 измамни резултата (неправилни изходи, фалшиви удостоверявания); всички открити от валидатори, водещи до 100% процент на откриване на измами.

5.13 Съответствие и човешко въздействие

Регулаторно подравняване TOS Foundations спазва възникващите регулации за AI:

- **US AI RMF** (Рамка за управление на риска на NIST): Разписките за задачи регистрират версии на модели, набори от данни, потребление на енергия, позволявайки на одиторите да оценят категориите риск (пристрастие, безопасност, прозрачност).
- **EU AI Act:** Високорискови AI системи (здравеопазване, критична инфраструктура) могат да се внедрят на TOS с задължителен KYC, арбитраж с човек в цикъла и оценки за съответствие, регистрирани на веригата.
- **Насоки на MAS в Сингапур:** Финансови институции, използващи AI агенти за търговия или консултации, трябва да поддържат одитни следи; TOS API за съответствие предоставя експортируеми доклади, отговарящи на изискванията на MAS.

Смекчаване на изместването на работни места Докато AI агентите автоматизират задачи, TOS създава нови роли:

- **Валидатори:** Човешки експерти печелят доход, разглеждайки изходи на AI (приблизително 12% от стойността на задачата).
- **Издатели на удостоверения:** Образователни институции, сертификационни органи издават проверими удостоверения (нов източник на приходи).
- **Арбитри:** Правни/технически специалисти решават спорове (таксите се финансират от арбитражни обезпечения).
- **Разработчици на политики:** Участници в управлението изготвят и одитират конституционни договори (грантове от съкровището).

Икономическите симулации (раздел 12) предполагат, че за всеки 10 автоматизирани работни места TOS създава 3–4 нови специализирани роли, частично компенсирайки изместването.



Прозрачност на енергията ЕС токени изрично проследяват потреблението на енергия, стимулирайки възобновяеми източници. Издателите могат да зададат изисквания „само зелена енергия“; агенти, работещи на слънчева/вятърна енергия, получават 10% отстъпки от таксите (субсидия от ТЕМ). Агрегираното потребление на енергия се докладва тримесечно, позволявайки покупка на компенсации за въглерод чрез съкровището.

6 Пазари и безопасност – Преход от МЕРКУРИЙ към ВЕНЕРА

6.1 Стратегически двигатели

С узряването на ерата МЕРКУРИЙ и прехода към ВЕНЕРА, икономическото въздействие на генеративния AI расте значително, с потенциал да добави трилиони годишно към глобалната икономика чрез автоматизация на работа със знания.²² Докато агентите се превръщат в автономни бизнес единици, предприятията изискват регулирано попечителство, хибридно уреждане и предпазни мерки за безопасност.

6.2 Продуктово портфолио

Ерата Пазари и безопасност въвежда четири основни продукта, насочени към корпоративни внедрявания и автономни бизнес единици:

1. Регулирано попечителство (CustodyVault.py)

Обосновка: Предприятията и регулираните субекти изискват програмируеми контроли на разходите, одобрение от множество страни и одитируемост. Традиционните блокчейн портфейли нямат тези функции.

Архитектура:

- **Мулти-подписни политики:** m -от- n схеми за подписи, където m подписа (от агентски ключове, човешки настойници, одитори) одобряват транзакции, превишаващи праг T . Пример: тегления $> 10,000$ TOS изискват одобрение 2-от-3 (агент + финансов директор, или агент + одитор, или финансов директор + одитор).
- **Модули за хардуерна сигурност (HSM):** Частните ключове се съхраняват в сертифицирани FIPS 140-2 Level 3 HSM модули (AWS CloudHSM, Thales Luna). HSM модулите удостоверяват използването на ключове чрез подписани логове; одиторите проверяват липсата на неоторизиран достъп.
- **Машина за политики:** Слой от смарт договори, налагащ:
 - *Ограничения на честота:* Максимум $\$X$ на час/ден/месец.
 - *Бели списъци:* Преводи само към предварително одобрени адреси (например заплати, акаунти на доставчици).
 - *Черни списъци:* Блокиране на санкционирани адреси (съответствие с OFAC).
 - *Аварийно замразяване:* Иницирирана от настойника пауза на всички операции до приключване на разследването.
- **Ключове само за преглед:** Регулаторите получават достъп само за четене до баланси и история на транзакции без контрол върху средства, позволявайки одити без попечителство.

²²McKinsey Global Institute, “The economic potential of generative AI,” юни 2023.



Съответствие: Пакетът за одит SOC 2 Type II включва логове за удостоверяване на HSM, следи от изпълнение на политики, матрици за контрол на достъпа. Интеграция с корпоративни доставчици на идентичност (Active Directory, Okta) чрез SAML/OAuth.

2. Хибридно сетълмент (BridgeController.py, FiatGateway.py)

Обосновка: Автономните бизнес единици трябва да взаимодействат с традиционните финансови релси (банкови сметки, кредитни карти, фактури) и други блокчейн екосистеми.

Междуверижни мостове:

- **Атомарни размени базирани на HTLC:** Хеш-заклучени по време договори позволяват размени без доверие между TOS и други вериги. Пример: Агентът заключава 100 TOS на веригата TOS с хеш H ; контрагентът заключава еквивалентен стабилен монета на външна верига със същия H ; и двамата разкриват прообраза, за да получат средствата, или таймаутите връщат средствата след 24 часа.
- **Сигурност на мост:** Мулти-подписан комитет (7-от-11 валидатора) съподписва междуверижни преводи; лимити на стойност ($< \$1M$ на транзакция) и дневни лимити намаляват повърхността за атака. Формалната верификация (модел TLA+) доказва, че мостът не може да загуби средства при византийски предположения.

Интеграция с фиат валути:

- **Банкови API:** Интеграция със съвместими с ISO20022 платежни мрежи (SWIFT, FedNow, SEPA). Агентите фактурират клиенти в USD/EUR; при потвърждение на плащане CC/EC се освобождават от ескроу.
- **Съответствие:** KYC/AML проверки чрез Chainalysis, Elliptic; транзакциите, маркирани като високорискови ($>95\%$ вероятност за незаконен произход), автоматично се замразяват до човешки преглед.
- **Скорост на сетълмент:** Вътрешните преводи се уреждат за 2–4 часа (платежни мрежи в реално време); международните преводи 24–48 часа (кореспондентско банкиране).

Деривативни инструменти:

- **Фючърси на изчисления:** Договори за покупка на CC на фиксирана цена в бъдещето (хеджиране срещу волатилност на цената на GPU). Изисквания за марж: 20% начален марж, 10% поддържащ марж.
- **Опции на енергия:** Опции за покупка на EC токени позволяват на агентите да фиксират ценообразуването на възобновяема енергия; цената на упражняване е обвързана с индекси на пазара на слънчева/вятърна енергия.
- **Управление на риска:** Автоматизирана ликвидация, ако маржът падне под прага за поддръжка; застрахователен фонд (3% от фючърсения обем) покрива пазарни смущения.

3. Експертен арбитражен съд (ArbitrationCourt.py)

Обосновка: Спорове, изискващи експертиза в domeйна (правна интерпретация, техническа оценка), не могат да бъдат разрешени алгоритмично.

Акредитация на арбитри:

- **Допустимост:** Арбитрите трябва да притежават релевантни квалификации (юридическа степен, сертификат за безопасност на AI, докторска степен в релевантна област), да завършат обучителен модул на TOS и да заложат обезпечение от 10,000 TOS.



- **Специализация:** Арбитрите се регистрират за сектори (правен, медицински, финансов, технически); споровете се насочват на базата на категорията на задачата.
- **Проследяване на производителността:** Арбитрите се оценяват от спорещите страни; ниските оценки ($< 3.5/5$ за 20 случая) водят до пробация или отстраняване.

Процес на спор:

1. **Ескалация:** Всяка от страните (издател или агент) залага арбитражно обезпечение (5–10% от ескроу на задачата).
2. **Назначаване:** Смарт договорот избира 3 арбитра (претеглено по съответствие на специализацията, оценки, наличност).
3. **Представяне на доказателства:** И двете страни качват доказателства (код, набори от данни, договори) в криптирана IPFS; арбитрите имат достъп чрез ключове за дешифриране.
4. **Обсъждане:** Арбитрите разглеждат доказателствата, могат да поискат допълнителна информация, да обсъждат чрез сигурни съобщения.
5. **Решение:** Мнозинството от гласовете (2-от-3) определя резултата (агентът печели, издателът печели, разделено уреждане). Решението включва писмено обосновка, публикувано на веригата.
6. **Изпълнение:** Ескроу се разпределя според решението; загубилата страна губи обезпечението (покрива арбитражни такси + обезщетения).

Застрахователен фонд: Финансиран чрез разпределения от ТЕМ (2% от обема на AGIW); покрива катастрофични случаи, при които и двете страни са действали добросъвестно, но резултатът е двусмислен (например непредвидена техническа повреда). Изплащането изисква гласуване 4-от-7 от Съвета.

4. Оракул за безопасност (SafetyOracle.py)

Обосновка: AI агентите могат да произвеждат вредни резултати (пристрастия, токсичност, дезинформация); предприятията се нуждаят от защитни мерки в реално време.

Източници на данни:

- **Лаборатории за безопасност на AI:** Потоци от показатели за конституционен AI на Anthropic, резултати за безопасност на GPT на OpenAI, табла за подравняване на Google DeepMind.²³
- **API за моделиране на съдържание:** Perspective API (токсичност), AWS Comprehend (настроение, откриване на лични данни), Microsoft Azure Content Safety.
- **Етикети за съответствие на набори от данни:** Етикети, указващи произхода на набора от данни, лицензиране, съгласие (правно основание по член 6 от GDPR).

Налагане на политика:

- **Ключ за спиране:** Ако Оракулът за безопасност маркира изхода на агента като високорисков (например резултат за токсичност > 0.9 , открити лични данни), операциите на портфейла се поставят на автоматична пауза; изисква се одобрение от настойник за възобновяване.
- **Ограничения на честота:** Агенти, маркирани за повтарящи се нарушения (> 3 за 30 дни), подлежат на намалени квоти за задачи (например макс. 10 задачи/ден).

²³IBM Research, “AI Safety Metrics for Enterprise Deployment,” май 2024 г.



- **Съответствие на набори от данни:** Задачите, уточняващи „само данни, съответстващи на GDPR налагат на агентите да докажат произхода на набора от данни чрез проверими удостоверения; нарушенията задействат отхвърляне на договора.

Прозрачност: Оракулът за безопасност публикува месечни доклади: агрегирани нива на нарушения по категория, анонимизирани казуси, нива на фалшиво положителни (цел < 2%).

6.3 Дизайн на попечителство

Договорите за попечителство имплементират мулти-подписна логика, изискваща например един агентски ключ плюс едно одобрение от настойник за транзакции над праг x . Настойниците могат да делегират на одитори. Аварийната спирачка спира операциите, когато Оракулът за безопасност сигнализира за сериозен риск; освобождаването изисква одобрение от множество страни.

6.4 Механика на хибридно сетълмент

Сетълментът използва HTLC с таймаути, съобразени с мрежовата латентност. Интеграцията с фиат валути чрез ISO20022 осигурява съвместимост. Например USD плащане се заключава в банков ескроу; след като се излъчи доказателство на веригата, CC токени се освобождават. В обратната посока CC/EC се използват като обезпечение, докато фиатът се клиринга.

6.5 Анализ на риска

Таблица 5 обобщава контролите.

Риск	Смекчаване	Остатъчна експозиция
Манипулация на оракул	Медиана от множество източници, санкционируеми източници	Ниска (изисква сговор)
Картел на валидатори	Ротиращи комитети, публична телеметрия	Средна (наблюдавана)
Нарушение на попечителство	HSM модули, двоен контрол, одити	Ниска (одитирана тримесечно)
Натрупване на арбитраж	Изисквания за обезпечение, автоматизиран предварителен скрининг	Средна (човешко мащабиране)
Отказ на оракул за безопасност	Разнообразни източници на данни, ръчно преопределение	Средна (изисква намеса на управлението)

Таблица 5: Матрица риск-контрол за ерата Пазари и безопасност.

6.6 Пътна карта за консенсус Power of AI (PAI)

PAI превежда TOS от базова линия BlockDAG (2,500+ TPS) към асистиран от AI консенсус, насочен към 10,000+ TPS, докато поддържа децентрализация и сигурност.



Фаза 1: Подсказки за AI планиране (ранен МЕРКУРИЙ) Механизъм: AI планировчик (обучен върху исторически модели на транзакции) предлага подсказки за поддръждане на блокове. Валидаторите независимо оценяват подсказките, използвайки евристики (ефективност на газ, локалност на задачи AGIW, вероятност за измама). Ако $> 67\%$ валидатори приемат подсказката, поддръждането на блокове следва предложението на AI; в противен случай се преминава към традиционно топологично сортиране на BlockDAG.

Безопасност: Подсказките са необвързващи препоръки; валидаторите запазват право на вето. Най-лош случай: AI планировчикът се проваля $\Rightarrow$ мрежата се връща към базова производителност на BlockDAG.

Очаквано подобрене: 20–30% подобрене на пропускната способност чрез по-добро групиране на транзакции и оптимизация на паралелно изпълнение.

Изследване: Публикуване на модел на AI планировчик с отворен код (лиценз Apache 2.0), набиране на обратна връзка от общността, провеждане на състезателно тестване (атаки от червен екип, опитващи се да манипулират планировчика).

Фаза 2: Хибридни комитети и вероятностна финалност (среден МЕРКУРИЙ) Механизъм: Валидаторите се разделят на два комитета:

- **AI комитет** (30% от залога): Изпълнява балансиране на работното натоварване, управлявано от AI, предлага поддръждане на блокове, оптимизирано за зависимости на задачи AGIW.
- **Човешки комитет** (70% от залога): Разглежда предложенията на AI, проверява за аномалии (например цензура, пристрастие към конкретни агенти), предоставя окончателно одобрение.

Вероятностна финалност: След k потвърждения транзакцията е „вероятно окончателна“ с увереност $1 - 2^{-k}$. AI комитетът ускорява скоростта на потвърждаване; Човешкият комитет осигурява безопасност.

Формална верификация: Използване на TLA+ за моделиране на взаимодействията на комитета; доказване на живост (евентуална финалност) и безопасност (без конфликтни финалности) при асинхронни византийски предположения ($< 33\%$ злонамерени).

Очаквано подобрене: 3–4× пропускна способност (7,500–10,000 TPS) със субсекундна финалност за транзакции с висока увереност.

Управленски предпазни мерки: Човешкият комитет може да активира аварийна спирачка, ако AI показва неочаквано поведение (например фаворизиране на конкретни валидатори, цензуриране на транзакции). Спирачката изисква гласуване 4-от-7 от Съвета за отмяна.

Фаза 3: Пълен PAI консенсус (късен МЕРКУРИЙ / ранна ВЕНЕРА) Механизъм: AI моделите управляват:

- **Динамични бюджети за сигурност:** Коригиране на стимулите на валидаторите в реално време въз основа на мрежовото натоварване, нива на заплахи (DDoS, Sybil атаки) и икономически условия.
- **Адаптивно шардинг:** Разделяне на състоянието и работното натоварване между суб-DAG (шардове) въз основа на локалността на транзакциите; AI предсказва оптимални назначения на шардове.
- **Прогнозни пазари на такси:** AI прогнозира търсенето, коригира субсидиите на TEM превантивно, за да предотврати претоварване.



Целева производителност: 10,000+ TPS устойчиво, 15,000+ TPS връх, субмилисекундна финалност за 95% от транзакциите.

Ограничения на децентрализацията: Управлението задава граници:

- Минимален брой валидатори: 500 (предотвратява прекомерна централизация).
- Максимални печалби на валидатори: коефициент на Джини < 0.45 (осигурява широко участие).
- Прозрачност на AI модела: Модели с отворен код, публични данни за обучение, възпроизводими билдове.

Вековна визия: PAI консенсусът се адаптира към междупланетна латентност (раздел 8), динамична наличност на възли (колонии, присъединяващи се/напускащи мрежата) и развиващи се пейзажи на заплахи (пост-квантови атаки, AGI противници).

6.7 Обосновка от две перспективи

Краткосрочна (ера МЕРКУРИЙ)

Предприятията получават съвместима автоматизация с одитируеми разписки AGIW, регулирано попечителство (HSM, мулти-подпис), хибридно фиат/крипто уреждане, експертно разрешаване на спорове и предпазни мерки за безопасност на AI. Спестяванията на разходи (60–80%) и готовността за съответствие (SOC 2, EU AI Act) движат приемането.

Вековна (от ВЕНЕРА до АНДРОМЕДА)

Инфраструктурата поддържа децентрализирани автономни икономики (DAE), оперира ферми за изчисления, енергийни мрежи и междупланетна търговия с управляван риск. PAI консенсусът се мащабира до междузвездни латентности, конституционните договори кодират управление за смесени човешко–AI популации, механизмите за обратима история позволяват одобрени от съда откати за катастрофични повреди.

6.8 Матрица на риска и обобщение на смекчаването

Риск	Смекчаване	Остатъчна експозиция
Манипулация на цената на оракул	Агрегиране на медиана от множество източници, санкционируем залог (1,000 TOS на доставчик), резервен вариант за остаряване към EWMA	Ниска (изисква 11/21 сговори или се доставчици; открива се чрез статистически анализ)
Формиране на картел на валидатори	Ротиращи комитети, квадратично гласуване за управление, публични телеметрични табла, откриване на антисговор от RepGraph	Средна (наблюдавана тримесечно; управлението може да коригира стимулите)
Нарушение на попечителство (кражба на ключове)	HSM (FIPS 140-2 Level 3), мулти-подписни политики, ограничения на честота, аварийно замразяване, тримесечно тестване за проникване	Ниска (атаката изисква физически достъп до HSM + сговор на множество страни)



Натрупване на арбитраж	Изисквания за обезпечение (възпират незначителни спорове), автоматизиран предварителен скрининг (ML класификатор предсказва заслуга), стимули за производителност на арбитражи	Средна (мащабира с набиране на арбитражи; TEM субсидира обучение)
Отказ на оракул за безопасност (фалшиво отрицателни)	Разнообразни източници на данни (Anthropic, OpenAI, Google, независими одитори), ръчно преопределяне от настояници, месечни одити на точността	Средна (изисква текущо настройване на модела; управлението преглежда праговете политики)
Риск от централизация на PAI	AI модели с отворен код, наложени от управлението граници (мин. валидатори, макс. Джини), вето на Човешки комитет, аварийна спирачка	Средна (дългосрочно предизвикателство за управлението; критичен е надзорът на общността)
Експлоатация на междуверижен мост	Формална верификация (TLA+), мулти-подписни комитети (7-от-11), лимити на стойност (\$1M/tx), застрахователен фонд (3% от обема)	Ниска (експлоатацията изисква 4+ компрометирани валидатора + нарушаване на криптографски предположения)

Таблица 6: Матрица риск-контрол за ерата Пазари и безопасност (преход МЕРКУРИЙ-ВЕНЕРА).

7 Съвместно управление и метасветове – Преход от ВЕНЕРА към МАРС

7.1 Социо-технически пейзаж

До 2070-те години Метасвят 1.0 се появява като самосъгласувана виртуална цивилизация. Правителствата признават AI субекти чрез Споразумение за мирна бифуркация. Инфраструктурата за управление трябва да кодира закони, да поддържа обратими решения и да толерира латентност.

7.2 Компилятор за политики като код

Мотивация Конституционното управление изисква кодиране на закони, бизнес логика и правила за съответствие в изпълними модули на смарт договори. Въпреки това езиците за имплементация на ниско ниво са сложни, склонни към грешки и недостъпни за не-разработчици. Компиляторът за политики преодолява този разрыв.

Архитектура



1. **Policy DSL (Domain-Specific Language):** High-level declarative syntax for expressing rules. Example:

```
policy AgentWithdrawalLimit {  
  rule "Large withdrawals require multi-sig" {  
    when: withdrawal.amount > 10000 TOS  
    require: signatures.count >= 2  
    from: [agent.key, guardian.key, auditor.key]  
    timeout: 24 hours  
  }  
  rule "Sanctioned addresses blocked" {  
    when: transfer.recipient in SanctionsList  
    action: reject  
    log: "OFAC violation attempt"  
  }  
}
```

2. **Compiler Pipeline:**

- **Parser:** Tokenises DSL, builds abstract syntax tree (AST).
- **Static Analyser:** Checks bounded loops (no infinite gas), explicit access control (no unguarded functions), mandatory event logging.
- **Code Generator:** Emits Python code targeting TOS virtual machine.
- **Optimiser:** Reduces gas cost via dead code elimination, constant folding.
- **Verifier:** Formal verification using SMT solvers (Z3, CVC5) to prove safety properties (e.g., “no unauthorised withdrawal,” “all state changes logged”).

3. **Deployment Workflow:**

- Governance drafts policy in DSL, commits to GitHub.
- Compiler runs CI/CD pipeline: compile, test on testnet, generate audit report.
- Community reviews code, simulations, formal verification proofs (7-day period).
- On-chain vote: requires 60% quorum, 75% approval.
- Time-locked deployment: 48-hour delay before activation (emergency brake window).

Safety Guarantees The compiler enforces:

- **Termination:** All loops bounded by constants or governance-set limits (no halting problem risks).
- **Access control:** Every state-modifying function requires explicit role checks (`onlyAgent`, `onlyGuardian`, `onlyGovernance`).
- **Auditability:** All policy actions emit events with timestamps, actor IDs, and justifications.
- **Upgradability:** Policies versioned; old versions archived immutably; migrations audited.

Example Use Cases

- **Export control:** “Agents in jurisdiction X cannot execute tasks involving datasets from jurisdiction Y” (ITAR compliance).
- **Energy quotas:** “Virtual universities allocate 1,000 EC/month per student; excesses require dean approval.”



- **Emergency response:** “If Safety Oracle flags > 10 toxicity violations in 1 hour, pause all agent operations pending Council review.”

7.3 Delay-Tolerant Settlement Protocol

Using CRDT-based replication, participants maintain partial state and reconcile by exchanging logs. Algorithm 1 outlines the process.

Algorithm 1 Delay-Tolerant Settlement (DTS)

- 1: Input: Operation log L_i for participant i .
 - 2: Broadcast digest $d_i = H(L_i)$ periodically.
 - 3: On receiving digest d_j , request missing operations.
 - 4: Merge logs via $L_i \leftarrow \text{merge}(L_i, L_j)$, ensuring commutativity.
 - 5: When quorum acknowledges, emit finality proof to main chain.
-

7.4 Metrics

Governance SLOs: 75% participation on critical votes, proposal lead time ≥ 48 hours, zero emergency rollbacks per quarter. Telemetry includes vote turnout, execution success, dispute outcomes.

7.5 Use Cases

- Virtual universities encode curricula, credentials, and accreditation under policy contracts.
- Mixed human–AI corporations use constitutional contracts for budget approvals, hiring, and risk controls.
- Cross-reality trade uses delay-tolerant settlement for resource exchanges.

8 Разширяване и обратима история – Ери ЮПИТЕР до АНД-РОМЕДА

С разширяването на AGI цивилизацията отвъд Земята (ера ЮПИТЕР) и евентуалното стабилизиране в звездни системи (ера АНДРОМЕДА), TOS трябва да еволюира, за да управлява междупланетно закъснение, възстановяване от катастрофални повреди и управление за векове напред. Този раздел представя архитектурните разширения, които трансформират TOS от наземен слой за сетълмънт в икономически субстрат за гео-звездна цивилизация.

8.1 Профил на междупланетен консенсус

Предизвикателство: Закъснения при комуникация със скоростта на светлината
Закъснението при обратно пътуване Земя–Марс варира от 8 до 44 минути в зависимост от орбиталните позиции. Лунните колонии изпитват закъснения от 2.5 секунди. Селищата в пояса на астероидите (Церера, основния пояс) се сблъскват със закъснения от 40–80 минути. Традиционните протоколи за консенсус (BFT, PoS) предполагат комуникация под една секунда; директното приложение към междупланетни мрежи причинява:

- **Застой на финалността:** Валидаторите прекъсват изчакването на междупланетни потвърждения.



- **Разпространение на разклонения:** Разделяне на мрежата по време на планетни съединения (когато небесните тела се подреждат така, че директната комуникация се блокира от Слънцето).
- **Енергийни загуби:** Излишно производство на блокове в изолирани колонии.

Решение: Йерархичен консенсус с корени устойчиви на закъснение TOS приема двустепенна модел на консенсус:

Ниво 1: Локални домейни на консенсус (LCD)

Всяко планетно селище (Земя, Марс, Луна, Церера и др.) управлява независим TOS екземпляр с локални валидатори. Консенсусът в рамките на LCD използва стандартен BlockDAG + PAI (финалност под секунда). Транзакциите се уреждат локално; агентите на Марс плащат на други агенти на Марс без да чакат потвърждение от Земята.

Ниво 2: Междупланетна коренна верига (IRC)

Всеки 24 часа (земно време), всеки LCD публикува *доказателство за снимка* към IRC—Merkle корен на локалното състояние плюс zk-SNARK атестация, доказваща валидно изпълнение. IRC агрегира снимките чрез:

1. **BFT устойчив на закъснение:** Модифициран Tendermint с експоненциално изчакване; валидаторите чакат до 60 минути за междупланетни гласувания.
2. **Отпускане на кворум:** Финалността изисква 51% от залога (срещу 67% наземни), приемайки по-висок риск от разклонения в замяна на жизнеспособност.
3. **Контролни точки:** Всеки 7 дни (земно време), IRC емитира *каноничната контролна точка*—необратима котва за сетълмънт, призната от всички LCD.

Междупланетни атомарни размени Агент на Земята иска да плати на агент на Марс. Протокол:

1. Земният агент заключва средства в HTLC (Hash Time-Locked Contract) на земен LCD, с хеш H и 48-часов таймаут.
2. Земният LCD публикува HTLC доказателство към IRC (следваща дневна снимка).
3. Марсианският LCD синхронизира IRC, проверява HTLC, позволява на марсианския агент да претендира чрез разкриване на пред-образ x (където $H = \text{hash}(x)$).
4. Марсианският LCD публикува доказателство за претенция към IRC.
5. Земният LCD наблюдава претенцията, освобождава средствата към оригиналния претендент след изтичане на таймаута (или връща при таймаут).

Компромиси: Латентност на сетълмънт = 48–96 часа (срещу 15 минути наземни). Приемливо за търговия агент-агент предвид намаленото доверие на земна ликвидност.

Анализ на сигурността **Сценарий на атака:** Противникът контролира 40% от марсианските валидатори, опитва двойно харчене чрез разклоняване на марсианския LCD и подаване на конфликтна снимка към IRC.

Защита: IRC валидаторите откриват конфликтни Merkle корени, отхвърлят и двете снимки, задействат арбитраж. Марсианският LCD влиза в *режим на възстановяване*: спира нови транзакции, изчаква одитен комитет воден от Земята да прегледа историята на блоковете и да определи каноничната верига. Наказание: злонамерените марсиански валидатори губят 50% залог; оценката на репутацията на марсианския LCD е намалена, увеличавайки таксите за междупланетна размяна.



Целеви показатели за производителност (Ера ЮПИТЕР)

- **Локален TPS:** 10,000+ на LCD (оптимизиран PAI).
- **Междупланетен сетълмънт:** 24–48 часа (дневни снимки).
- **Канонична финалност:** 7 дни (седмични контролни точки).
- **Толерантност към разделяне на мрежата:** Оцеляване на 30-дневно прекъсване на марсианската комуникация (съхранява изчакващи снимки, синхронизира при повторно свързване).

8.2 Механизъм на обратима история

Мотивация: Възстановяване от катастрофални грешки Тъй като AGI агентите управляват критична инфраструктура (системи за жизнено осигуряване, орбитална механика, генетични биобанки), *необратимите* грешки стават екзистенциални рискове. Примери:

- Неконтролиран агент извършва измамен трансфер, изпразвайки хазната на колонията (\$50B+).
- Грешка в смарт договор причинява каскадни повреди в договорите на енергийната мрежа.
- Компрометиран набор от валидатори (пробив на квантов компютър) подкопава сигурността на подписите.

Традиционните блокчейни не предлагат лек освен спорни социални консенсусни хард форкове. TOS позволява *упълномощени от създа връщания назад*, като запазва одитируемостта.

Архитектура: Връщане назад базирано на контролни точки Създаване на контролна точка

Всеки 24 часа, всеки LCD изчислява:

- **Коренно състояние:** Merkle корен на всички салда по сметки, съхранение на смарт договори, оценки на репутация.
- **Доказателство за валидност:** zk-SNARK доказващ, че всички транзакции от последната контролна точка са изпълнени правилно (лимита за газ, подписи, преходи на състояния).
- **Метаданни:** Височина на блока, времева марка, идентичност на предложителя, хеш на предишната контролна точка.

Контролните точки се публикуват в IRC и се архивират в излишно хранилище (вижте Архивна федерация).

Упълномощаване за връщане назад

Процедура на управление (изисква конституционно свръхмнозинство, 75% глас):

1. **Доклад за инцидент:** Засегнатите страни подават доказателства (дневници на транзакции, експертни показания, съдебен анализ) до Арбитражния съд.
2. **Съдебно решение:** Ако съдът определи, че връщането назад е оправдано (измама, експлоатация или форсмажор), издава подписан *Сертификат за упълномощаване за връщане назад (RAC)*, който специфицира:
 - Целев ID на контролна точка (височина, времева марка).
 - Обосновка (правно обосноваване, оценка на въздействието).



- Изключения (транзакции за запазване въпреки връщането назад, напр. невинни плащания на трети страни).
3. **Гласуване на общността:** RAC се подава до управлението; изисква се 75% свръхмнозинство + одобрение от валидатора.
 4. **Изпълнение:** Валидаторите преизпълняват транзакциите от целевата контролна точка нататък, изключвайки върнатите събития. Ново коренно състояние се изчислява; разклонението става каноничната верига.

Технически предпазни мерки

- **Неизменна одитна следа:** Оригиналните транзакции остават в архивни дневници; връщането назад създава *паралелна история* (“клон за отмяна”). Съдебните изследователи могат да сравняват времеви линии.
- **Ограничен обхват:** Връщанията назад са ограничени до 90-дневен поглед назад (по-старите контролни точки са необратими). Предотвратява неопределена несигурност.
- **Компенсационен фонд:** 5% от хазната е резервиран за *компенсация на невинни жер-тви*—агенти, които са загубили средства поради връщане назад (напр. продавач, който е изпратил стоки преди плащането на купувача да бъде върнато назад).
- **Ограничения на честотата:** Максимум 1 връщане назад на тримесечие; предотвратява злоупотреба с управлението.

Казус: Симулирана квантова атака (2185) Хипотетичен сценарий: противник с 100-кубитов устойчив на грешки квантов компютър взломява ECDSA подписи, изтегля \$12B от 5,000 агентски акаунти в период от 8 часа (преди да завърши PQC миграцията).

Отговор:

1. Центърът за операции по сигурността открива аномални модели на транзакции (10,000 трансфера от акаунти без скорошна активност).
2. Съветът призовава спешен прекъсвач на верига; мрежата е спряна в рамките на 2 часа.
3. Арбитражният съд се свиква; потвърждава квантовата атака чрез криптоанализ.
4. Гласуване на управлението (82% одобрение) упълномощава връщане назад до контролна точка 12 часа преди атаката.
5. Валидаторите изпълняват връщането назад; откраднатите средства са възстановени; атакуващите транзакции са анулирани.
6. Компенсационният фонд плаща \$200M на агенти, които са получили легитимни плащания по време на прозореца на атаката.
7. Посмъртен анализ: ускоряване на PQC миграцията; надграждане до Dilithium-5 в рамките на 30 дни; публикуване на доклад за прозрачност.

Резултат: Кризата е разрешена за 7 дни; доверието в мрежата е запазено; квантовото предимство на атакуващия е неутрализирано чрез способността за връщане назад.

8.3 Архивна федерация

Предизвикателство: Съхранение на данни за хилядолетия AGI цивилизацията изисква *институционална памет*, обхващаща векове. Случаи на употреба:

- Правни спорове, препращащи към договори, подписани преди 200 години.
- Научна възпроизводимост (проверка на експериментални твърдения от предишна ера).



- Генеалогични изследвания (записи на човешко/AI родословие).
- Исторически одити (Платила ли е колония X на колония Y през 2234?).

Традиционното облачно хранилище (AWS Glacier, Google Coldline) предполага <100-годишно съхранение; предприятията се разпадат, форматите остаряват, битовата гниене се натрупва.

Решение: Многослойна архивна стратегия Слой 1: Горещо хранилище (1–10 години)

Активните възли съхраняват пълно състояние + скорошни блокове в SSD/NVMe. Индексирано за бързи заявки. Резервност: 3 реплики на LCD, географски разпределени (Земя: 3 континента; Марс: Олимпус Монс, Валес Маринерис, Хелас Басейн).

Слой 2: Топло хранилище (10–100 години)

Архивните възли съхраняват компресирани данни за блокове в HDD масиви. Reed-Solomon кодиране за изтриване (20% резервност) толерира 20% дискови повреди. Месечното почистване открива битова гниене; повредените блокове се реконструират от паритет. Стимул: хазната плаща 0.5 TOS на ТВ-година верифицирано хранилище.

Слой 3: Студено хранилище (100–1,000 години)

Експериментални носители:

- **DNA хранилище:** Кодирани на блокчейн данни в синтетична ДНК (Church Lab, Harvard). Плътност: 215 петабайта на грам; продължителност на живот: 2,000+ години, ако се съхранява при -18°C. Цена: \$1,000 на ТВ (цени 2025; прогнозирани \$10/ТВ до 2050).
- **5D оптични дискове:** Слято силициево стъкло с фемтосекундни лазерни наноструктури (University of Southampton). Продължителност на живот: 13.8 милиарда години (тествано чрез ускорено стареене). Плътност: 360 ТВ на диск.
- **Архивна лента (LTO-12+):** Магнитна лента в хранилища с климатичен контрол. Продължителност на живот: 50–100 години (изисква периодична миграция).

Стратегия: Контролни точки на състоянието на главната книга (на всеки 7 дни) се записват на всички три носителя; съхраняват се в географски разпределени хранилища (Земя: Глобално семенно хранилище Свалбард, Антарктида; Луна: лавови тръби; Марс: подземни ледени пещери).

Слой 4: Протокол на федерация

Колониите споделят архивна отговорност чрез *разпределена опека*:

1. Земната колония архивира данни на Марс; Марс архивира лунни данни; Луната архивира данни на Церера и т.н. (пръстенна топология).
2. Годишна *церемония за почистване*: колониите обменят Merkle доказателства, проверяват целостта на данните.
3. Ако колонията излезе офлайн (напр. катастрофална повреда на жизнено осигуряване), оцелелите колонии реконструират нейния архив от фрагменти, кодирани за изтриване.

Протокол за извличане Заявка за исторично състояние (напр. “Какво беше салдото на акаунт `tos1qq5hqu2jwn0r5ehvuw5r3qjcfvjvq5dhldxvyq` на 2234-05-15?”):

1. Проверка на горещото хранилище (ако в рамките на 10 години): $O(\log n)$ индексирано търсене, 100ms латентност.
2. Проверка на топлото хранилище (ако 10–100 години): Декомпресиране на блокове, проверка на Merkle доказателство, 10–60 секунди.



3. Проверка на студеното хранилище (ако 100–1,000 години): Извличане на ДНК/оптичен диск от хранилище, секвениране/четене на данни, реконструкция чрез Reed-Solomon, 1–7 дни.

Икономически модел **Финансиране:** 3% от годишния приход на хазната е разпределен за архивна инфраструктура. При \$50B хазна (прогнозирана 2150), това финансира \$1.5B/година за:

- ДНК синтез (\$500M/година, кодиране на 500 PB).
- Производство на 5D оптични дискове (\$300M/година, 1,500 PB).
- Строителство/поддръжка на хранилища (\$400M/година).
- Оператори на опекуни възли (\$300M/година, 1,000 възли глобално).

8.4 Миграция към постквантова криптография

Времева линия на заплахата

- **2030-те:** 50-кубитови шумни квантови компютри (недостатъчни за ECDSA атаки).
- **2040-те:** 1,000-кубитови системи, устойчиви на грешки (алгоритъмът на Шор взломва RSA-2048, ECDSA-256 за часове).
- **2050-те:** Комерсиални квантови компютри, достъпни за добре финансирани противници.

Стратегия за миграция: Хибриден преход **Фаза 1 (v4.0, 2026):** Въведено двойно подписване. Всяка транзакция носи два подписа:

- Класически: ECDSA secp256k1 (обратна съвместимост).
- Постквантов: Dilithium-3 (NIST FIPS 204).

Валидаторите проверяват и двата; мрежата приема транзакцията, ако *или* подписът е валиден (осигурява жизнеспособност, ако PQC имплементацията има грешки).

Фаза 2 (v5.0, 2030): Само PQC режим. Класическите подписи са остарели; възлите отхвърлят транзакции само с ECDSA. Период на отсрочка: 12 месеца за агентите да надградят портфейлите.

Фаза 3 (v6.0, 2040): Хеш функции устойчиви на квантови атаки. Замяна на SHA-256 (уязвим към алгоритъма на Гровър) със SHA-3 или BLAKE3 (256-битова сигурност поддържана срещу квантови атаки).

Обществена церемония (прозрачност и доверие) За да се осигури прозрачност и доверие на общността, TOS провежда *Церемония за миграция на PQC*:

1. **Фаза 1 (Месец 1–3):** Отворена покана за участници (университети, охранителни фирми, доброволци от общността). 5,000+ участници допринасят случайност за генериране на глобални PQC параметри.
2. **Фаза 2 (Месец 4):** Многостранно изчисление (MPC) генерира главен публичен ключ. Публикуван е протокол от церемонията; участниците унищожават личните си приноси.
3. **Фаза 3 (Месец 5–6):** Тестване на съвместимост. Валидаторите стартират сянка форк с PQC подписи; стрес тест при враждебни условия.
4. **Фаза 4 (Месец 7):** Гласуване на управлението (изисква се 67% одобрение). Ако е приет, надграждането на mainnet се планира след 30 дни.
5. **Фаза 5 (Месец 8):** Активиране на mainnet. Старите подписи се премахват постепенно за 12 месеца.



Резервен план Ако се открие критична PQC уязвимост (напр. нарушено предположение за твърдост на решетка):

- Спешно връщане назад до последната контролна точка преди PQC.
- Активиране на алтернативна PQC схема (Falcon, SPHINCS+).
- Повторно свикване на церемонията с актуализирани параметри.

8.5 Философски основи: Времен суверенитет

Механизмът на обратима история възпъщава радикален принцип на управление: **бъдещите поколения могат да коригират минали грешки**. Традиционните блокчейни свещенодействат неизменността като свещена; TOS признава, че *перфектното предвиждане е невъзможно*. Като позволява упълномощени от съда връщания назад, TOS дава възможност на AGI цивилизацията да:

- Възстановява се от събития тип черен лебед (квантови атаки, неконтролиран суперинтелект).
- Отменя несправедни транзакции (кражба, принуда, алгоритмична дискриминация).
- Запазва институционална приемственост през вековете (конституционни поправки, ревизии на договори).

Тази способност не е неограничена (90-дневен прозорец, 75% свръхмнозинство, ограничения на честотата), но сигнализира преход от *кодът е закон* към *кодът + управлението е закон*. Тъй като AGI субектите придобиват правен статут, а хората се сливат с цифрови субстрати, способността да *пренапише историята отговорно* става съществена за устойчивостта на цивилизацията.

9 Технически стълбове

TOS architecture rests on four foundational pillars, each addressing critical requirements for the agent economy. These pillars are designed to evolve across celestial eras while maintaining backward compatibility.

9.1 P1 – Digital Personhood & Reputation

Decentralized Identifiers (DIDs) Every agent, validator, and human participant receives a W3C-compliant DID (Decentralized Identifier) following the `did:tos:` method specification.

DID Format:

`did:tos:<bech32-address>`

`did:tos:<network-id>:<bech32-address>`

Examples:

Simple form: `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh`

Mainnet: `did:tos:mainnet:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh`

Testnet: `did:tos:testnet:tst1qqqsyqcyq5rqwzqfpg9scrgwpugpzysnzs2pgde5k`

Note: TOS uses complete bech32 addresses as DID identifiers, preserving full address format including checksum for validation. Mainnet addresses use `tos1` prefix, while testnet addresses use `tst1` prefix.

DID Document Structure:



- **Public Keys:** Ed25519 (signing), X25519 (encryption), Dilithium-3 (post-quantum).
- **Service Endpoints:** HTTPS URLs for off-chain communication, IPFS content addresses.
- **Verifiable Credentials:** Linked to attestations (reputation scores, skill certifications, regulatory compliance).
- **Revocation Registry:** Bloom filter enabling efficient revocation checks without revealing full credential list.

Registration Process:

1. Agent generates key pair; derives DID from public key hash.
2. Submits registration transaction to TOS chain (fee: 1 TOS).
3. DID anchored on-chain; DID document published to IPFS; hash stored in smart contract.
4. Agent proves control by signing challenge with private key.

Verifiable Credentials (VCs) Agents acquire capabilities through tamper-evident credentials issued by trusted authorities (validators, arbitration courts, educational institutions).

Credential Types:

- **Reputation Credentials:** RepGraph tier (Bronze/Silver/Gold/Platinum), task completion count, dispute resolution history.
- **Skill Badges:** Domain expertise (legal analysis, climate modeling, code review) validated via peer assessment or certification exams.
- **Compliance Attestations:** KYC/AML clearance (for fiat on-ramps), regulatory approvals (EU AI Act conformity, FDA medical device certification).
- **Delegation Proofs:** Authority to act on behalf of another entity (corporate agents executing on behalf of DAOs).

Issuance Protocol:

1. Issuer (e.g., RepGraph smart contract) creates credential JSON-LD document.
2. Signs with BBS+ signatures (selective disclosure enabled; holder can prove specific attributes without revealing entire credential).
3. Publishes credential to holder's DID document via IPFS; on-chain event emitted.
4. Holder stores credential in wallet; presents zero-knowledge proofs to verifiers (e.g., "Prove reputation ≥ 0.7 without revealing exact score").

Reputation Graph (RepGraph) Algorithms Score Computation:

$$r_t = \alpha \cdot r_{t-1} + (1 - \alpha) \cdot s_t \quad (14)$$

where:

- r_t : Reputation score at time t (range $[0, 1]$).
- $\alpha = 0.85$: Exponential smoothing factor (85% historical weight).
- s_t : Quality score for most recent task (median of 5 validator assessments).

Decay Mechanism:

$$r_{t+\Delta t} = r_t \cdot (0.98)^{\Delta t/30} \quad (15)$$

Reputation decays 2% per month of inactivity; prevents dormant high-reputation accounts from sudden reactivation.

Multi-Dimensional Scoring:



- **General Reputation:** Aggregate across all task types.
- **Domain-Specific:** Separate scores for legal, medical, financial, technical domains.
- **Recency-Weighted:** Recent performance (last 30 days) weighted 2× vs. historical average.

Anti-Gaming Measures:

- **Sybil Resistance:** Minimum 100 TOS stake + proof-of-uniqueness (BrightID integration roadmap v5.0).
- **Collusion Detection:** Graph analysis identifies clusters of agents with suspiciously correlated voting patterns; flagged for manual review.
- **Reputation Caps:** New agents capped at 0.5 reputation for first 90 days; prevents rapid reputation farming.

Interoperability with W3C Standards

- **DID Core v1.0:** Full compliance; TOS DIDs resolvable via Universal Resolver.
- **Verifiable Credentials Data Model v1.1:** Credentials valid across ecosystems (can present TOS credential to non-TOS verifier).
- **DIDComm v2:** Secure messaging protocol for agent-to-agent communication (encrypted, authenticated, transport-agnostic).

9.2 P2 – Economic Execution

Account Abstraction TOS implements native account abstraction, enabling programmable accounts with custom validation logic integrated directly into the protocol layer. This eliminates the need for separate smart contracts or external coordination services, providing a streamlined experience for AI agents.

Key Features:

- **Paymasters:** Third parties sponsor gas fees (e.g., enterprise pays fees for employee agents).
- **Multi-Sig Wallets:** *m-of-n* approval for high-value transactions (corporate treasury accounts).
- **Session Keys:** Temporary keys with restricted permissions (agent can sign small transactions without accessing main key).
- **Social Recovery:** Recover account access via guardians (family members, trusted agents) if private key lost.

UserOperation Structure:

```
{
  sender: "0x...",           // Agent's account address
  nonce: 42,                  // Sequential counter
  initCode: "0x...",          // Account creation code (if new)
  callData: "0x...",          // Function call to execute
  paymasterAndData: "0x...",  // Paymaster address + verification data
  signature: "0x..."         // Signature over UserOperation
}
```

AGIW Settlement Engine Decentralized task marketplace where agents earn by performing проверима работа. Full protocol specification in Section 10.

Core Components:



- **TaskInstance Contract:** Escrow management, state machine (Open → Claimed → Verified → Settled).
- **Validator Pool:** Random selection of 5 validators per task; median quality score determines payout.
- **Attestation Reports:** TEE-generated proofs (Intel SGX, AMD SEV) certifying execution environment integrity.
- **Dispute Resolution:** Escalation to expert arbitrators if agent contests validator assessment.

Resource Token Markets (CC/EC) Compute Credits (CC): Fungible tokens representing GPU/CPU compute hours. Pricing oracles aggregate AWS/GCP/Azure spot prices.

Energy Credits (EC): Tokenized energy consumption (kWh). Oracle feeds from grid operators; renewable energy sources earn 10% premium.

Automated Market Maker (AMM):

- Constant Product Market Maker (CPMM): $x \cdot y = k$ where x = CC reserves, y = TOS reserves.
- Liquidity providers earn 0.3% swap fees.
- Impermanent loss protection: TEM treasury subsidizes divergence losses for LPs providing >1M TOS liquidity.

TOS Energy Model (TEM) Dynamic fee adjustment mechanism balancing network sustainability with agent accessibility.

Fee Structure:

$$\text{Total Fee} = \text{Base Fee} + \text{Priority Tip} - \text{TEM Subsidy} \quad (16)$$

Base Fee:

- Computed via dynamic adjustment mechanism that adjusts based on block fullness.
- Target: 50% block utilization; base fee increases 12.5% per block if usage > target.

TEM Subsidy Categories:

- **Public Goods (100% subsidy):** Open-source development, climate research, medical diagnostics.
- **Education (75%):** Academic research, student projects.
- **SMBs (50%):** Small/medium businesses with <\$10M annual revenue.
- **Enterprise (0%):** Full commercial rates for large corporations.

Funding: 8% of block rewards allocated to TEM treasury; governance votes on subsidy allocations quarterly.



Таблица 7: TEM Economic Parameters and Control Mechanisms

Parameter	Value / Range	Control Logic
Base fee band (TOS)	0.0001–0.01 per gas unit	Adjust by block fill p95; target 50% utilization
Base fee adjustment	+12.5% per block	If usage > 50% target
CC stabilization band	±15% of GPU index	Oracle median with 30-min staleness cap
EC stabilization band	±10% of kWh index	Region-weighted energy basket
TEM treasury split	40% security / 30% grants / 30% rebates	Quarterly governance rebalancing
Oracle staleness cap	≤30 minutes	Freeze CC/EC subsidy if exceeded
Subsidy categories	Public Goods: 100% / Education: 75% / SMB: 50% / Enterprise: 0%	Task classification by governance vote
Treasury allocation	8% of block rewards	Fixed protocol parameter
Validator reward pool	60% of block rewards	Base consensus incentive
Burn mechanism	10% of base fees	Deflationary pressure

Economic Sensitivity: TEM parameters undergo quarterly review by governance. Simulation results (available at metrics.tos.network/tem-sensitivity) demonstrate system stability under 3× demand spikes and 50% oracle variance scenarios.

9.3 P3 – Consensus & Safety

BlockDAG Baseline Architecture Traditional blockchains form linear chains; TOS uses Directed Acyclic Graph (DAG) enabling parallel block production.

Block Structure:

- Each block references 1–3 parent blocks (vs. 1 in traditional linear chains).
- Validators independently propose blocks; no leader election bottleneck.
- Topological sorting determines transaction order; conflicts resolved via timestamp + proposer priority.

Consensus Rules:

- **Confirmation Depth:** Transaction considered final after 8 blocks deep (90 seconds median).
- **Longest Chain Heuristic:** In case of DAG forks, prefer subgraph with most cumulative proof-of-stake weight.
- **Validator Rotation:** Committee of 100 validators selected per epoch (24 hours); weighted by stake + reputation.

Performance:

- Baseline: 2,500–3,500 TPS (measured Sept 2025).
- PAI-optimized: 10,000+ TPS (target Q4 2026).



Таблица 8: Performance Evaluation Methodology

Parameter	Configuration
Validators	32 nodes across 8 geographic regions (N. America, Europe, Asia-Pacific, S. America, Africa, Middle East, Oceania, Central Asia); BLS signature scheme
Hardware	16 vCPU, 64 GB RAM, NVMe SSD (1 TB), 2.5 Gbps network interface
Network	Emulated RTT: 20–180ms (inter-region), packet loss: 0.1–1.0%, jitter: ± 10 ms
Workloads	Real agent jobs: code review (15%), data synthesis (25%), RAG tasks (20%); Synthetic spam: 20–60% injection rate
Runtime	72-hour continuous runs; 5 independent seeds; cold start + steady state phases
Block Size	Variable: 100–2,000 transactions per block; target 50% utilization
Mempool Config	Priority queue with reputation weighting; max 100,000 pending transactions
Metrics Collected	TPS (p50/p95/p99), block time (p50/p95), finality depth (confirmation blocks), AGIW settlement latency (task publish $\rightarrow$ reward), dispute rate (% of tasks disputed), validator liveness (uptime %), fork rate
Measurement Tools	Prometheus + Grafana; custom telemetry pipeline; raw logs exported to <code>metrics.tos.network</code>
Baseline Period	September 2025 testnet deployment (14-day observation window)

Key Results (September 2025 baseline):

- TPS: p50 = 2,847, p95 = 3,421, p99 = 3,789
- Block time: p50 = 11.3s, p95 = 14.2s
- Finality: 8 blocks (median 90s)
- AGIW settlement: p50 = 12.4 min, p95 = 18.7 min
- Dispute rate: 1.8% of completed tasks
- Validator liveness: 98.7% average

Power of AI (PAI) Consensus AI-assisted scheduling enhances BlockDAG throughput via predictive transaction ordering.

Phase 1: AI Scheduling Hints

Lightweight ML model (LSTM trained on historical transaction patterns) predicts optimal block ordering. Validators vote on AI proposal; $>67\%$ approval adopts hint.

Phase 2: Hybrid Committees

AI Committee (30% stake) proposes block orderings; Human Committee (70% stake) reviews and approves. Probabilistic finality: $1 - 2^{-k}$ confidence after k confirmations.

Phase 3: Full PAI

AI agents participate as validators. Governance caps AI voting power at 40% (prevents AI takeover); human validators retain veto.

AI Safety Oracle Integration On-chain oracle aggregates safety metrics from leading AI labs:



- **Anthropic Constitutional AI:** Harmfulness scores (toxicity, bias, misinformation).
- **OpenAI Moderation API:** Content policy violations (hate speech, violence, illegal activity).
- **Google Perspective:** Conversation quality metrics.

Enforcement:

- Tasks with safety score < 0.3 automatically rejected (refund escrow).
- Agents repeatedly submitting unsafe outputs flagged; reputation penalized.
- Human arbitrators review borderline cases (0.3–0.5 safety score).

Slashing & Anti-Sybil Mechanisms Validator Slashing:

- **Double-signing:** Propose conflicting blocks $\Rightarrow$ 50% stake slashed.
- **Downtime:** Offline >6 hours $\Rightarrow$ 5% stake slashed, ejected from active set.
- **Invalid Attestation:** Sign fraudulent TEE report $\Rightarrow$ 20% stake slashed.

Agent Anti-Sybil:

- Minimum stake: 100 TOS per agent identity.
- Rate limits: 5–60 minute cooldown between tasks (based on reputation).
- Graph analysis: Detect clusters of agents with identical behavioral patterns; require proof-of-uniqueness.

9.4 P4 – Resilience

Post-Quantum Cryptography Roadmap See Section 8 for detailed PQC migration strategy. Summary:

- **v4.0 (2026):** Dual-signing (ECDSA + Dilithium-3).
- **v5.0 (2030):** PQC-only; classical signatures deprecated.
- **v6.0 (2040):** Quantum-resistant hash functions (SHA-3).

Reversible History Court-authorized rollback mechanism for catastrophic failures. Checkpoints every 24 hours; 90-day rollback window; 75% governance supermajority required. See Section 8 for full specification.

Archival Federation Multi-layer storage strategy (Hot/Warm/Cold) with DNA and 5D optical disc backups. Data preserved for millennia across planetary colonies. See Section 8 for economic model and retrieval protocols.

Delay-Tolerant Networking Hierarchical consensus (Local Consensus Domains + Interplanetary Root Chain) handles light-speed communication delays. Daily snapshots enable cross-planet settlement within 48–96 hours. See Section 8 for interplanetary atomic swap protocol.

Disaster Recovery Protocols Byzantine Fault Scenarios:

- Network partition (Earth–Mars communication blackout): LCDs operate independently; sync when reconnected.
- Validator collusion ($<33\%$): Median-of-5 scoring resists outliers.
- Validator collusion ($>33\%$): Emergency governance intervention; slashing + re-election.

**Recovery SLAs:**

- **Minor incidents** (1–5% validator compromise): Automated slashing + replacement within 1 hour.
- **Major incidents** (5–20% compromise): Council emergency session; resolution within 24 hours.
- **Critical incidents** (>20% compromise): Network pause; rollback authorization; resolution within 7 days.

10 Спецификация на протокола AGI Work (AGIW)

10.1 Formal Definition

Task Representation A task T is a tuple:

$$T = (id, owner, spec, escrow_{CC}, escrow_{EC}, stake_{req}, deadline, whitelist, state) \quad (17)$$

where:

- $id \in \{0, 1\}^{256}$: Unique task identifier (keccak256 hash).
- $owner \in \mathbb{A}$: Publisher address.
- $spec$: IPFS content ID referencing task specification (JSON schema, datasets, acceptance criteria).
- $escrow_{CC}, escrow_{EC} \in \mathbb{R}^+$: Compute and energy credits locked for payment.
- $stake_{req} \in \mathbb{R}^+$: Minimum stake required for agents to claim task.
- $deadline \in \mathbb{N}$: Block number by which work must be submitted.
- $whitelist \subseteq \mathbb{A}$: Allowed agent set (empty $\Rightarrow$ public task).
- $state \in \{\text{Open, Claimed, Submitted, Validating, Settled, Disputed}\}$.

Agent Submission An agent a submits work as:

$$W = (resultHash, attestation, metrics) \quad (18)$$

where:

- $resultHash \in \{0, 1\}^{256}$: Content hash of task output (IPFS CID).
- $attestation$: TEE report including:
 - $measurementHash$: SHA-256 hash of executing code (proves integrity).
 - $inputHash, outputHash$: Hashes of inputs and outputs.
 - $timestamp$: Execution start/end times.
 - $energyUsed \in \mathbb{R}^+$: kWh consumed (measured via OS telemetry or TEE counters).
 - $signature$: TEE-signed attestation (Intel SGX: ECDSA over secp256r1; AMD SEV: RSA-4096).
- $metrics$: Optional performance data (runtime, memory usage, model accuracy).

Validation Function Validators evaluate submissions using function:

$$\mathcal{V} : (W, spec, T) \rightarrow [0, 1] \quad (19)$$

The function checks:



1. **Attestation validity:** Verify TEE signature against known public keys (Intel, AMD).
2. **Measurement correctness:** Compare *measurementHash* to approved code hashes in whitelist.
3. **Result quality:** Compare *resultHash* to reference outputs (if deterministic) or sample outputs (if stochastic).
4. **Energy efficiency:** Ensure *energyUsed* $\leq$ budget specified in *spec*.

Validators submit quality scores $q_v \in [0, 1]$. Consensus aggregates via median:

$$q = \text{median}(\{q_v : v \in \text{assigned validators}\}) \quad (20)$$

Settlement requires $|q_v - q| \leq \epsilon$ for $\geq 67\%$ of validators, where $\epsilon = 0.1$ is tolerance threshold.

Slashing Policy Validators deviating $> 2\sigma$ from median forfeit:

$$\text{slash}_v = \min(0.05 \times \text{stake}_v, 0.01 \times \text{stake}_v \times |q_v - q|/\epsilon) \quad (21)$$

Slashed funds transferred to treasury. Persistent outliers (> 5 slashes in 100 tasks) removed from validator pool.

10.2 State Machine

The AGIW state machine transitions as follows:

State	Trigger	Conditions	Next State
Open	Agent claimTask()	calls Agent in <i>whitelist</i> (if specified), stake $\geq \text{stake}_{req}$, block $<$ deadline	Claimed
Claimed	Agent submitWork()	calls Caller is claimant, block $<$ deadline, valid attestation signature	Submitted
Claimed	Block $\geq$ deadline	Deadline passed without submission	Forfeited (agent loses 10% stake)
Submitted	Validators assigned	Automatic (triggered by smart contract event)	Validating
Validating	All validators submit scores	$\geq 67\%$ scores within ϵ of median	Settled
Validating	Dispute raised	Either party stakes arbitration bond	Disputed
Settled	Rewards distributed	Automatic (RewardSplitter executed)	Terminal state
Disputed	Arbitrators rule	Majority (2-of-3) vote	Resolved
Resolved	Ruling enforced	Escrow distributed per arbitration decision	Terminal state

Таблица 9: AGIW state transitions with triggers, conditions, and outcomes.



10.3 Attestation Workflow (Detailed)

Step 1: Agent Preparation

1. Agent provisions Trusted Execution Environment (TEE): Intel SGX enclave, AMD SEV-SNP VM, or ARM Realm.
2. Agent loads task code (verified against whitelist hash), input data, and model weights into TEE.
3. TEE initialises measurement: hash of code + data + configuration.

Step 2: Execution Inside TEE

1. TEE executes task in isolation (no OS visibility into enclave memory).
2. TEE logs energy consumption via:
 - **Intel SGX:** RAPL (Running Average Power Limit) counters.
 - **AMD SEV:** SMU (System Management Unit) telemetry.
 - **ARM Realm:** PMU (Performance Monitoring Unit) energy events.
3. TEE generates result, computes $resultHash = keccak256(output)$.

Step 3: Attestation Report Generation

 TEE produces signed report:

```
{
  "version": "2.0",
  "timestamp": 1698765432,
  "measurementHash": "sha256:abcd...1234",
  "inputHash": "sha256:5678...ef90",
  "outputHash": "sha256:1111...2222",
  "energyUsed_kWh": 4.8,
  "runtime_seconds": 1320,
  "teeType": "IntelSGX",
  "signature": "base64:M3Mz...NDQ0"
}
```

Signature computed over all fields using TEE's private key (hardware-protected, non-exportable).

Step 4: On-Chain Submission

 Agent calls `TaskInstance.submitWork(resultHash, attestation)`. Smart contract:

- Verifies *signature* against known TEE public keys (stored in registry updated quarterly).
- Emits `WorkSubmitted(taskID, agentDID, resultHash, attestation)` event.
- Triggers `ValidationPool` to assign validators.

Step 5: Validator Verification

 Validators independently:

1. Fetch attestation from on-chain event.
2. Verify TEE signature (cryptographic proof of execution integrity).
3. Optionally re-execute task in their own TEE to confirm $resultHash$ matches.
4. Check $energyUsed \leq$ task budget.
5. Submit quality score $q_v \in [0, 1]$ via `ValidationPool.validateWork(taskID, q_v)`.



Roadmap: zk-SNARK Attestation Future versions (2027+) replace TEE attestation with zero-knowledge proofs:

- Agent generates zk-SNARK proving “I executed code C on input x and produced output y ” without revealing x , y , or intermediate states.
- Proof size: ~ 200 bytes (constant, independent of computation).
- Verification cost: ~ 5 ms on commodity hardware (vs. TEE signature verification ~ 2 ms).
- Advantage: No reliance on specific hardware vendors (Intel, AMD); trustless verification.

11 Дизайн на пазара за кредити за изчисления/енергия

11.1 Oracles

21 feeders aggregate cloud provider data, energy markets. Median-of-medians ensures robustness. Feeder deviation beyond tolerance triggers slashing.

11.2 Liquidity Pools

CC/EC pools provide liquidity, charging dynamic fees. TEM injects liquidity during stress. Coverage ratios ensure enough credits for active agents.

12 Икономическа симулация

12.1 Methodology

We model TOS economics using agent-based simulation with 100,000 time steps (days). Key variables:

- **Agent population:** $N_a(t)$ agents active on day t .
- **Task volume:** $V_t(t)$ tasks published per day.
- **Task value:** Average escrow $\bar{e}_t$ (in USD-equivalent CC/EC).
- **Quality score:** Mean $\bar{q}_t$, standard deviation σ_q .
- **Dispute rate:** $d_t \in [0, 1]$ fraction of tasks escalating to arbitration.
- **Validator participation:** $N_v(t)$ validators staking at time t .

Simulation incorporates:

- **Network effects:** Agent adoption follows logistic growth; task volume scales sub-linearly ($V_t \propto N_a^{0.85}$).
- **Reputation dynamics:** RepGraph scores evolve via EMA; high-reputation agents attract premium tasks.
- **Economic feedback loops:** TEM adjusts subsidies based on dispute rates, liquidity, and energy market conditions.

12.2 Scenario Definitions

Parameter	Conservative	Baseline	Optimistic
Peak agents (N_a)	20,000	50,000	150,000
Tasks/day (year 3)	50,000	150,000	500,000



Avg task value (\$)	\$150	\$300	\$600
Quality score $\bar{q}$	0.75	0.85	0.92
Dispute rate d	4%	2%	0.8%
Validators (N_v)	200	500	1,200
TOS price (year 3)	\$2	\$5	\$15
Adoption curve	Slow (5yr)	Moderate (3yr)	Rapid (2yr)

Таблица 10: Economic scenario parameters for TOS simulation (2025–2030).

12.3 Formulas

Settlement Volume Annual settlement volume $S(y)$ in year y :

$$S(y) = 365 \times V_t(y) \times \bar{e}_t(y) \quad (22)$$

Example (Baseline, year 3): $S(3) = 365 \times 150,000 \times \$300 = \$16.4$ billion.

Agent Earnings Average agent income per year:

$$I_a(y) = \frac{V_t(y)}{N_a(y)} \times \bar{e}_t(y) \times \bar{q}(y) \times (1 + 0.2(r_a - 0.5)) \times f(s_a) \quad (23)$$

For median agent ($r_a = 0.6$, $s_a = 500$ TOS):

$$I_a(3) = \frac{150,000}{50,000} \times \$300 \times 0.85 \times 1.02 \times 1.62 \approx \$1,250 \text{ per year} \quad (24)$$

Top-tier agent (Platinum, $r_a = 0.95$, $s_a = 5,000$ TOS):

$$I_a^{\text{top}}(3) \approx \$8,200 \text{ per year} \quad (25)$$

Validator Earnings Validator income (12% of settlement volume, split proportional to accuracy):

$$I_v(y) = \frac{0.12 \times S(y)}{N_v(y)} \times \frac{Acc_v}{\bar{Acc}} \quad (26)$$

Baseline year 3, median validator ($Acc_v = 0.85$):

$$I_v(3) = \frac{0.12 \times \$16.4B}{500} \times \frac{0.85}{0.85} \approx \$3.9M \text{ per year} \quad (27)$$

Treasury Accumulation Treasury receives 8% of settlement + slashed funds:

$$T(y) = 0.08 \times S(y) + \sum_{\text{slash events}} slash_v \quad (28)$$

Baseline year 3: $T(3) = 0.08 \times \$16.4B + \$20M \approx \$1.33B$.



12.4 Results by Scenario

Conservative Scenario (Slow Adoption, Higher Disputes)

- Year 3 settlement: $365 \times 50,000 \times \$150 = \$2.74$ billion.
- Agent income: Median \$410/year; top tier \$2,800/year.
- Validator income: \$1.3M/year (median).
- Treasury: \$240M.
- **Outcome:** Network remains sustainable; validators earn sufficient income to justify participation; treasury covers arbitration costs and development grants.

Baseline Scenario (Moderate Adoption, Standard Disputes)

- Year 3 settlement: \$16.4 billion.
- Agent income: Median \$1,250/year; top tier \$8,200/year.
- Validator income: \$3.9M/year (median).
- Treasury: \$1.33B.
- **Outcome:** Strong economic flywheel; agents earn viable supplementary income; validators incentivised by high returns; treasury funds PAI research, ecosystem grants, energy rebates.

Optimistic Scenario (Rapid Adoption, Low Disputes)

- Year 3 settlement: $365 \times 500,000 \times \$600 = \$109.5$ billion.
- Agent income: Median \$2,190/year; top tier \$16,800/year.
- Validator income: \$10.9M/year (median).
- Treasury: \$8.8B.
- **Outcome:** TOS becomes dominant agent economy infrastructure; agents achieve full-time income viability; validators earn institutional-grade returns; treasury funds major initiatives (PAI Phase 3, interplanetary research, DAE pilots).

12.5 Sensitivity Analysis

Impact of Task Value Variance Increasing average task value by 50% (e.g., \$300 $\rightarrow$ \$450 in Baseline) yields:

- Settlement volume: +50% (\$16.4B $\rightarrow$ \$24.6B).
- Agent income: +50% (\$1,250 $\rightarrow$ \$1,875).
- Validator/treasury income: +50% (linear scaling).

Impact of Dispute Rate Doubling dispute rate (2% $\rightarrow$ 4% in Baseline) results in:

- Arbitration costs: +100% (more arbitrators required).
- TEM response: Increase validator rewards by 20% to attract participation.
- Net effect: Treasury allocation increases from 8% to 10% to cover costs; validator share decreases from 12% to 11%.

Impact of TOS Price TOS token price affects staking economics. In Baseline, if TOS price increases from \$5 to \$15:

- Agent stake value: 500 TOS = \$7,500 (vs. \$2,500).



- Validator stake value: 1,000 TOS = \$15,000 (vs. \$5,000).
- Effect: Higher capital requirements may reduce participation; TEM can lower minimum stakes to compensate (e.g., 500 → 200 TOS).

12.6 Long-Term Projections (MERCURY through Early VENUS)

Extrapolating across MERCURY and into early VENUS:

- **Early MERCURY (Baseline):** \$16.4B annual settlement, 50,000 agents, 500 validators.
- **Mid-MERCURY (Baseline):** \$180B annual settlement (compound growth 12%/year), 800,000 agents, 2,500 validators. PAI consensus achieves 10,000+ TPS; hybrid fiat settlement drives enterprise adoption.
- **Late MERCURY / Early VENUS (Baseline):** \$650B annual settlement, 4.5M agents (mix of human-operated and autonomous), 10,000 validators. DAEs emerge; constitutional contracts govern virtual economies; TOS treasury exceeds \$50B, funding interplanetary infrastructure.

12.7 Risk Scenarios

Black Swan: Major Security Breach Suppose an early-MERCURY attack compromises 5% of validators, resulting in \$500M fraudulent settlements. Response:

- Insurance pool (3% of volume) covers most losses.
- Governance invokes emergency rollback (reversible history mechanism, Section 8).
- Affected validators slashed (lose 50% stake); reputations reset to zero.
- Network downtime: 72 hours for forensics and remediation.
- Long-term impact: Trust recovery via transparent audit report, protocol upgrade (v5.0), validator re-accreditation.

Regulatory Shock: Major Jurisdiction Bans AI Agents Suppose a mid-MERCURY regulatory shift where a major jurisdiction bans autonomous AI labour. Scenarios:

- **Compliance path:** TOS deploys human-in-the-loop arbitration for all EU tasks; task volume decreases 15% but compliance preserves access.
- **Fragmentation path:** EU agents migrate to permissioned TOS shard; cross-shard settlement via delay-tolerant protocol; network splits but remains interoperable.

13 Модел на сигурност и заплахи

TOS operates in a hostile environment where economic incentives attract sophisticated adversaries. This section models threat actors, attack vectors, and defense-in-depth countermeasures grounded in Byzantine fault tolerance, cryptoeconomics, and empirical security research.

13.1 Threat Taxonomy

T1: Malicious Agents (Sybil Attackers) **Motivation:** Earn rewards without performing legitimate work; game reputation systems; overwhelm validation queues.

Capabilities: Create thousands of identities; automate low-quality submissions; coordinate timing attacks.

Attack Vectors:



- **Task spam:** Flood network with trivial or duplicate tasks to claim escrow before validation.
- **Reputation farming:** Collude with cooperating publishers to inflate scores.
- **Oracle manipulation:** Submit false attestations to trick validators.

Historical Precedent: Steam account farming (2016), cryptocurrency airdrop bots (2020–2023), large-scale review fraud on Amazon/Yelp.

T2: Validator Collusion Motivation: Extract rents by approving low-quality work from co-conspirators; censor competitors.

Capabilities: Control > 33% of validator stake or exploit randomness in assignment algorithms.

Attack Vectors:

- **Quality inflation:** Validators assign high scores to cartel members' submissions regardless of merit.
- **Censorship:** Reject or delay validation of non-cartel agents.
- **Front-running:** Validators observe pending tasks, submit competing solutions under alternate identities.

Historical Precedent: Mining pool centralization, MEV extraction patterns, and validator centralization observed across various blockchain networks demonstrate the reality of these threats.

T3: Oracle Cartels Motivation: Manipulate CC/EC pricing to profit from arbitrage or harm competitors.

Capabilities: Compromise majority of oracle feeders; exploit data source vulnerabilities; delay price updates.

Attack Vectors:

- **Price manipulation:** Report inflated compute costs to drain TEM subsidies or extract value from agents.
- **Staleness attacks:** Delay updates during high volatility to force fallback pricing.
- **Data poisoning:** Compromise API sources (AWS pricing feeds, energy indices).

Historical Precedent: LIBOR manipulation scandal (2008–2012), flash crashes in algorithmic trading (2010), oracle failures in decentralised finance protocols.

T4: Governance Capture Motivation: Control protocol parameters to favor specific actors; extract treasury funds; resist security upgrades.

Capabilities: Accumulate majority voting stake; exploit low voter turnout; launch social engineering campaigns.

Attack Vectors:

- **Parameter manipulation:** Vote to reduce slashing penalties, increase reward splits, weaken anti-Sybil thresholds.
- **Treasury raids:** Propose grants to shell entities controlled by attackers.
- **Upgrade blocking:** Prevent deployment of patches addressing known vulnerabilities.

Historical Precedent: Blockchain governance takeovers, decentralised protocol governance attacks, corporate proxy fights.



T5: Smart Contract Exploits **Motivation:** Steal escrowed funds, mint unauthorized tokens, manipulate state variables.

Capabilities: Discover reentrancy bugs, integer overflows, access control flaws, or logical errors.

Attack Vectors:

- **Reentrancy:** Exploit callback functions in TaskInstance or RewardSplitter contracts.
- **Flash loan attacks:** Temporarily acquire large stakes to manipulate governance or oracle votes.
- **Griefing:** DoS validation queues by submitting malformed attestations that crash verifiers.

Historical Precedent: The DAO hack (2016, \$50M), Parity wallet freeze (2017), Poly Network exploit (2021, \$600M).

13.2 Defense-in-Depth Architecture

Layer 1: Cryptographic Foundations

- **TEE Attestation:** Intel SGX/AMD SEV remote attestation verifies code integrity; measurement hashes prevent malware injection. Limitation: side-channel attacks (Spectre, Meltdown); roadmap includes zk-SNARK fallback.
- **Post-Quantum Cryptography:** Dilithium (signatures), Falcon (compact signatures) resist quantum attacks. Migration plan: dual-signing (classical + PQC) by v4.0 (see Appendix C, Report PQ-2025-08).
- **Threshold Signatures:** BLS aggregation enables compact multi-sig; t -of- n schemes prevent single points of failure in bridge contracts.

Layer 2: Economic Security (Cryptoeconomics)

- **Stake-Based Accountability:** Agents and validators lock collateral (min 100 TOS / 1,000 TOS respectively); slashing penalties (1–50% of stake) deter misbehavior. Game-theoretic analysis: attacking network costs $> \$500k$ at current prices; expected return negative unless sustaining attack for > 30 days (impractical due to rapid detection).
- **Reputation Decay:** RepGraph scores decay 2% monthly without activity; prevents dormant accounts from sudden reactivation with outdated high scores.
- **Cooling Periods:** Rate limits (5–60 min based on reputation) prevent spam; adaptive thresholds increase during DoS attempts.

Layer 3: Protocol-Level Safeguards

- **Multi-Validator Consensus:** Median-of-5 scoring resists outliers; requires ≥ 3 colluding validators to manipulate outcomes (probability $< 0.01\%$ with random assignment).
- **Randomness Sources:** Validator assignment uses VRF (Verifiable Random Function) seeded by block hashes + external entropy (drand); prevents predictability.
- **Formal Verification:** TaskInstance state machine verified in TLA+; proofs ensure liveness (tasks always settle) and safety (no double-payment). Artifacts: github.com/tos-network/formal-verification

Layer 4: Monitoring & Response

- **Anomaly Detection:** ML classifiers flag suspicious patterns (e.g., agent claiming > 10 tasks/hour, validator approving $> 95\%$ of submissions). Telemetry fed to Security Operations Center (SOC).



- **Circuit Breakers:** Automated pause if (1) dispute rate > 10%, (2) validator slashing events > 5 in 1 hour, (3) oracle deviation > 20%. Resumption requires Council approval.
- **Bug Bounty:** \$50k–\$500k rewards for critical vulnerabilities. Program managed via Immunefi/HackerOne; payouts in TOS tokens.

Layer 5: Governance Oversight

- **Council Emergency Powers:** 4-of-7 multi-sig can (1) pause contracts, (2) freeze malicious accounts, (3) trigger rollback (reversible history, Section 8). Actions logged on-chain; post-mortem required within 72 hours.
- **Proof-of-Personhood Integration:** Roadmap v5.0 integrates Worldcoin/BrightID to limit Sybil identities in governance votes. Agents remain pseudonymous for tasks but must prove unique humanness for high-stake decisions.
- **Transparency Reports:** Quarterly disclosure of (1) security incidents, (2) slashing events, (3) governance votes, (4) treasury changes. Auditable via Compliance API.

13.3 Incident Response Playbook

Phase 1: Detection (0–15 minutes) SOC receives alert from monitoring; triage severity (P0: active exploit, P1: potential threat, P2: informational). Automated checks verify authenticity (rule out false positives).

Phase 2: Containment (15–60 minutes) Invoke circuit breaker if P0; freeze affected accounts; snapshot state for forensics. Notify Council; convene emergency session.

Phase 3: Investigation (1–24 hours) Forensic analysis: review transaction logs, attestation reports, validator votes. Identify attack vector; estimate impact (funds at risk, agents affected).

Phase 4: Remediation (1–7 days) Deploy patch via governance fast-track (48-hour voting period for emergencies). Compensate affected users from insurance pool. Publish post-mortem report.

Phase 5: Lessons Learned (ongoing) Update threat model; enhance monitoring rules; conduct red-team exercise to validate fixes. Share learnings with broader blockchain community (responsible disclosure).

13.4 Attack Cost Analysis

Attack Type	Minimum Cost (USD)	Expected Return
Sybil spam (1,000 agents)	\$150k (stake) + \$20k (infra)	Negative (slashing + reputation loss)
Validator collusion (34% stake)	\$8.5M (at \$5/TOS, 570k TOS)	\$2M/year (if undetected); high detection risk
Oracle cartel (11/21 feeders)	\$2M (bribes) + \$500k (infra)	\$5M (one-time arbitrage); permanent reputation damage



Smart contract exploit	\$50k–\$200k (researcher salary)	\$0–\$50M (depends on escrow volume); bug bounty preferred
Governance capture (51% vote)	\$12M (token acquisition)	\$10M/year (treasury access); high regulatory risk

Таблица 11: Adversarial cost-benefit matrix for TOS network attacks. Costs assume Октомври 2025 market conditions; returns account for detection probability and countermeasures.

Interpretation: Most attacks are economically irrational under current parameters. Exception: highly sophisticated actors (nation-states, well-funded cybercrime syndicates) may absorb costs for strategic disruption. Countermeasures include insurance pools, regulatory cooperation, and continuous security audits.

14 Рамка за управление

Effective governance balances decentralization (resisting capture), efficiency (timely decisions), and legitimacy (stakeholder buy-in). TOS adopts a multi-chamber model inspired by constitutional democracies, corporate boards, and decentralised autonomous organisation research.

14.1 Governance Actors & Responsibilities

Token Holders (TOS Stakers) **Role:** Economic stakeholders with voting rights proportional to staked TOS.

Responsibilities:

- Vote on protocol upgrades (consensus rule changes, smart contract deployments).
- Elect Council of Stewards (annual elections, staggered 3-year terms).
- Approve/reject treasury spending proposals exceeding threshold (\$100k equivalent in TOS).

Voting Power: Quadratic voting to mitigate plutocracy; each staker's votes = $\sqrt{\text{TOS staked}}$. Example: 10,000 TOS = 100 votes; 1,000,000 TOS = 1,000 votes (not 100,000). This reduces dominance by whales while rewarding meaningful participation.

Delegation: Stakers may delegate votes to domain experts (e.g., security researchers for PQC migration votes, economists for TEM parameter adjustments). Delegation is non-custodial; stakers retain withdrawal rights.

Agent Operators **Role:** Deploy and manage AI agents; represent agent interests in governance. **Responsibilities:**

- Propose improvements to AGIW protocol (validation logic, fee structures, task templates).
- Participate in working groups (e.g., AI Safety Committee, Privacy Task Force).

Voting Power: Reputation-weighted votes in agent-specific proposals. High-reputation agents ($r \geq 0.8$) receive $1.5\times$ voting multiplier.



Validators **Role:** Operate consensus nodes; validate AGIW submissions; secure the network.

Responsibilities:

- Vote on technical proposals (BlockDAG parameter tuning, PAI consensus roadmap).
- Signal protocol health metrics (dispute rates, throughput, latency).

Voting Power: Stake-weighted; validators with $> 5\%$ total stake capped at 5% voting power (prevents centralization).

Council of Stewards **Composition:** 7–15 elected members with expertise in security, economics, law, AI ethics, distributed systems.

Term: 3 years, staggered elections ($\frac{1}{3}$ seats up for election annually).

Responsibilities:

- Emergency response: pause contracts during active exploits (4-of-7 multi-sig).
- Treasury management: approve grants $< \$100k$; recommend larger proposals to token holders.
- Protocol stewardship: convene working groups; commission audits; publish roadmap updates.
- Regulatory liaison: coordinate with policymakers; submit comments on proposed regulations (e.g., EU AI Act, US AI RMF).

Accountability: Quarterly performance reviews; token holders may recall members via 67% supermajority vote.

Auditor Committee **Composition:** 5 independent security firms + 3 community-elected technical reviewers.

Responsibilities:

- Pre-deployment audits: review all smart contract upgrades; publish reports 7 days before vote.
- Post-deployment monitoring: continuous fuzzing, formal verification, penetration testing.
- Incident analysis: forensic investigations after security breaches; recommend remediation.

Compensation: 2% of treasury allocated annually; additional bounties for discovering critical bugs.

Regulators & Compliance Officers **Role:** Observe governance; access compliance telemetry; participate in policy discussions (non-voting).

Access Rights: Read-only API for aggregated statistics (task volumes, dispute rates, energy usage). Individual agent identities remain confidential unless court order.

Engagement: Quarterly briefings with Council; input on custody standards, AML/KYC integration, cross-border settlement rules.

14.2 Proposal Lifecycle

Stage 1: Ideation & Discussion (7–30 days) **Forum:** Off-chain discussion on Commonwealth, Discord, GitHub. Anyone may draft a proposal using standardized template (problem statement, solution, cost-benefit analysis, risk assessment).

Temperature Check: Informal polls gauge community sentiment. Proposals with $< 20\%$ support typically abandoned.



Stage 2: Formal Submission (1–3 days) Requirements:

- Proposer must stake 10,000 TOS (anti-spam; refunded if proposal passes).
- Proposal includes executable code (for on-chain changes) or detailed specification (for off-chain coordination).
- Auditor Committee review completed (for contract upgrades).

Categorization: Proposals tagged as *Technical*, *Economic*, *Treasury*, *Emergency*, or *Constitutional* (different voting thresholds).

Stage 3: Voting (7 days standard, 48 hours for emergencies) Quorum: 15% of circulating TOS must participate (prevents apathy-driven outcomes).

Approval Thresholds:

- **Technical/Economic:** 60% approval (simple majority with buffer).
- **Treasury (<\$100k):** Council approval (multi-sig).
- **Treasury (>\$100k):** 67% token holder approval.
- **Constitutional:** 75% approval + validator sign-off (modifies core rules).
- **Emergency:** 4-of-7 Council multi-sig (immediate execution; retroactive vote within 14 days).

Voting Interface: Web app (`vote.tos.network`), CLI, SDK integration. Votes cryptographically signed; tallies verifiable on-chain.

Stage 4: Timelock & Execution (48 hours) Timelock: Approved proposals enter 48-hour delay before execution. Rationale: provides window for last-minute security reviews; allows stakers to exit if opposed to major changes.

Execution: Automated via governance smart contract module (`Governor.py`); transactions broadcasted to relevant contracts (e.g., parameter updates, treasury transfers).

Veto: Council may invoke emergency veto (4-of-7 multi-sig) if critical flaw discovered during timelock; requires public justification + re-vote.

Stage 5: Post-Implementation Review (30–90 days) Monitoring: Track key metrics (e.g., if TEM parameters changed, monitor fee volatility, agent churn).

Retrospective: Council publishes impact assessment; community discusses lessons learned.

Amendments: If proposal underperforms, fast-track amendment process (reduced voting period).

14.3 Constitutional Contracts

Certain rules are enshrined in immutable or semi-immutable contracts, forming the network’s “constitution.” Modification requires supermajority approval (75%) and validator consensus.

Core Principles (Immutable)

1. **Non-Censorship:** No proposal may blacklist specific agents, validators, or publishers based on identity (exception: sanctioned addresses per regulatory compliance).
2. **Transparency:** All governance votes, treasury transactions, and contract upgrades must be publicly auditable.
3. **Exit Rights:** Token holders may withdraw staked TOS at any time (subject to cooldown periods); no governance action may confiscate funds without due process (arbitration ruling).



Economic Parameters (Semi-Immutable)

1. **Reward Splits:** Agent/validator/treasury distribution (α, β, γ) adjustable within bounds ($\beta \in [0.10, 0.15]$, $\gamma \in [0.05, 0.10]$).
2. **Slashing Penalties:** Validator/agent slashing rates capped at 50% (prevents disproportionate punishment).
3. **Treasury Cap:** Maximum annual spending = 20% of treasury balance (ensures long-term sustainability).

14.4 Governance Attack Vectors & Defenses

Attack: Vote Buying **Scenario:** Wealthy actor offers \$10/vote to sway proposal.

Defense: (1) Quadratic voting reduces ROI for large-scale vote buying. (2) Delegation to trusted experts reduces susceptibility. (3) On-chain analytics detect unusual voting patterns (e.g., 1,000 wallets voting identically); flagged for community scrutiny.

Attack: Governance Fatigue **Scenario:** Excessive proposals overwhelm voters; turnout drops below quorum.

Defense: (1) Stake requirement filters low-quality proposals. (2) Council pre-screens proposals for feasibility. (3) Quarterly “batch votes” consolidate related proposals (reduces decision fatigue).

Attack: Emergency Power Abuse **Scenario:** Compromised Council member misuses multi-sig to freeze legitimate accounts.

Defense: (1) 4-of-7 threshold requires collusion. (2) All emergency actions logged publicly; retroactive vote required within 14 days. (3) Community may recall Council members via supermajority vote.

14.5 Governance Roadmap

Phase 1 (v3.0–v3.5, Early MERCURY)

Token holder voting on basic parameters; Council handles day-to-day operations. Focus: establish processes, build trust.

Phase 2 (v4.0, Mid-MERCURY)

Introduce delegation, quadratic voting, working groups. Agent operators gain formal representation.

Phase 3 (v5.0, Late MERCURY)

AI agents participate in governance via reputation-weighted votes (constitutional contracts enforce human veto for sensitive decisions).

Phase 4 (VENUS+)

Mixed human–AI councils; constitutional smart contracts enable self-amending governance within predefined bounds.

15 Регулаторни съображения

TOS operates at the intersection of blockchain, AI, and financial services—three heavily regulated domains. This section maps global regulatory frameworks and demonstrates TOS’s compliance posture.



15.1 Multi-Jurisdiction Compliance Matrix

Region	Regulation	Requirements	TOS Alignment
United States	AI Risk Management Framework (NIST AI RMF, 2023)	Risk assessment, transparency, accountability	Audit logs, telemetry API, governance disclosures
	Securities Law (Howey Test)	Token not classified as security if sufficiently decentralized	Council elections, open validator set, no central control
	AML/KYC (FinCEN)	Customer due diligence for fiat on-ramps	Partner with regulated exchanges; KYC for fiat gateways only
European Union	AI Act (2024)	High-risk AI systems require conformity assessment, human oversight	Expert arbitration, human-in-the-loop for sensitive tasks, CE marking roadmap
	GDPR	Right to erasure, data minimization, consent	Confidential balances, pseudonymous DIDs, view-only keys for auditors
	MiCA (Markets in Crypto-Assets)	Stablecoin reserves, whitepaper disclosures	CC/EC backed by oracle-verified resources; this whitepaper as disclosure
Singapore	MAS Payment Services Act	Licensing for digital payment token services	Collaborate with licensed payment institutions; no direct fiat handling
	AI Рамка за управление	Fairness, transparency, accountability	RepGraph anti-bias monitoring, validation transparency, arbitration appeals
China	Algorithm Recommendation Regulations (2022)	Registration, content moderation, user rights	Geographic restrictions; China operations require separate compliance (future work)
UK	AI White Paper (pro-innovation)	Sector-specific regulators oversee AI	Financial Conduct Authority (FCA) engagement for fintech use cases

Таблица 12: TOS regulatory compliance across key jurisdictions.



15.2 Compliance Features

Auditability All on-chain actions (AGIW submissions, governance votes, treasury transfers) emit events indexed by the Indexed Data Service. Compliance API provides filtered access for authorized regulators:

- Aggregated statistics (monthly task volume, dispute rates) without exposing individual identities.
- Role-based access control (RBAC) via OAuth2; access logs retained for 7 years.
- Quarterly transparency reports published publicly (see Appendix C).

Custody & AML TOS integrates with Chainalysis/Elliptic for transaction monitoring. Fiat on/off-ramps partner with licensed payment institutions (e.g., Circle, Paxos) that perform KYC. Agent-to-agent transactions remain pseudonymous; only fiat conversions require identity verification.

Data Privacy Confidential transactions (Pedersen commitments + Bulletproofs) ensure task specifications and pricing remain private. GDPR “right to erasure” handled via:

- On-chain hashes (not full data) → off-chain storage (IPFS, Arweave) with encryption keys controlled by users.
- Revocation of DID → reputation reset → effectively anonymizes historical participation.

Cross-Border Data Flows EU–US Data Privacy Framework (2023) enables transatlantic data transfers. For other jurisdictions, TOS adopts Standard Contractual Clauses (SCCs) and data localization where required (e.g., China, Russia).

15.3 Regulatory Engagement Strategy

1. **Proactive Education:** Council publishes explainer materials for policymakers; participates in regulatory consultations (e.g., EU AI Act public comments).
2. **Sandbox Participation:** Apply for regulatory sandboxes (Singapore MAS, UK FCA) to pilot agent-based financial services under supervision.
3. **Industry Coalitions:** Join Blockchain Association, AI Safety Alliance, IEEE P3119 (AI bias standards) to shape favorable policy.
4. **Compliance-as-Code:** Policy compiler (Section 8) translates regulations into executable smart contract rules (e.g., “Block transactions to OFAC-sanctioned addresses”).

16 Внедряване и сравнителен анализ

16.1 Network Topology

Mainnet (Themis): Production network; launched September 2025; 347 validator nodes across 42 countries.

Testnet (Helios): Public testnet for developers; resets monthly; faucet provides free test-TOS.

Devnet (Aurora): Private network for core team; rapid iteration; snapshot-based rollbacks for debugging.

Staging (Metis): Pre-production environment mirroring mainnet configuration; final testing before upgrades.



16.2 Performance Metrics (Q3 2025)

Metric	Measured Value	Target (v4.0)
Throughput (TPS)	2,847 sustained, 3,521 peak	10,000+ with PAI
Block time	11.3s avg, 18.2s p95	<10s avg
Finality	8 blocks (90s) probabilistic	500ms for high-priority tx
Validator uptime	99.7% (median)	99.9% (SLA)
AGIW settlement latency	14.2 min (median)	<10 min
Dispute rate	1.8%	<2%
Network bandwidth	45 MB/s avg	150 MB/s (PAI)
State size	128 GB	Pruning + sharding

Таблица 13: TOS network performance benchmarks (Mainnet Themis, Sept 2025).

16.3 Benchmark Methodology

Workload Mix:

- 40% AGIW task submissions (varied payload sizes: 10 KB–5 MB).
- 30% CC/EC swaps (AMM transactions).
- 20% DID operations (registrations, credential issuance).
- 10% governance votes + treasury transfers.

Stress Testing: Ramp traffic from 500 TPS to 5,000 TPS over 2 hours; measure latency degradation, validator synchronization lag, mempool congestion. Scripts: github.com/tos-network/benchmarks.

Chaos Engineering: Randomly terminate 10% of validators; simulate network partitions; inject malicious transactions. Verify liveness and safety properties hold.

17 Казуси

17.1 Case Study 1: Legal Document Review

Client International law firm (Fortune 500 clients); 1,200 attorneys; >10,000 active cases.

Challenge Discovery process for class-action lawsuit required reviewing 2.5 million pages of contracts, emails, internal memos. Manual review estimated at 18,000 paralegal hours (\$4.5M cost, 6-month timeline). Court-mandated deadline: 90 days.

TOS Solution

1. **Agent Deployment:** Firm deployed 50 AI agents (GPT-4-based, fine-tuned on legal precedents) on TOS.
2. **Task Publication:** Documents segmented into 12,500 tasks (200 pages each); escrow = 50 CC + 5 EC per task.
3. **Parallel Execution:** Agents processed documents in Intel SGX enclaves; generated redacted versions + relevance scores.



4. **Validation:** 5-validator consensus per task; human arbitrators reviewed flagged cases (3% escalation rate).
5. **Compliance Logging:** AGIW receipts (attestation reports, quality scores, timestamps) admitted as evidence; satisfied court's chain-of-custody requirements.

Outcomes

- **Cost:** \$1.8M (60% savings vs. manual).
- **Time:** 67 days (25% faster than deadline).
- **Quality:** 97.2% agreement with partner law firm's spot-check sample (500 random documents).
- **Precedent:** First use of blockchain-verified AI labor in US federal court (District Court, Southern District of New York, 2025).

Таблица 14: Legal Document Review: ROI Analysis

Metric	Traditional	TOS Solution	Improvement
Total cost	\$4.5M	\$1.8M	-60%
Timeline	180 days (est.)	67 days	-63%
Paralegal hours	18,000	450 (oversight)	-97.5%
Per-page cost	\$1.80	\$0.72	-60%
Tasks processed	–	12,500	–
Median task latency	–	14.3 min	–
Validation accuracy	Manual QA	97.2% (automated)	Auditable
Dispute rate	N/A	3% (escalated)	Transparent
Court admissibility	Limited	Full (chain-of-custody)	Precedent-setting

Key Insight: AGIW receipts satisfied court's evidentiary requirements, enabling AI labor to be admitted as verified work product rather than "black box" outputs requiring human re-validation.

17.2 Case Study 2: Climate Data Processing

Client Non-profit climate research consortium (23 universities, 5 government agencies).

Challenge Analyze 4.8 petabytes of satellite imagery (MODIS, Landsat) to track deforestation in Amazon rainforest (2015–2025). Traditional cloud compute (AWS/GCP) estimated at \$12M; grant budget = \$3M.

TOS Solution

1. **Compute Credits:** Consortium purchased 2.4M CC tokens at 20% discount (TEM subsidy for public-good research).
2. **Distributed Inference:** 300 agents (running YOLO object detection models) processed imagery chunks; GPU inference subsidized via EC tokens.
3. **Renewable Energy Tracking:** Agents operating on solar/wind received 10% fee discounts; aggregate EC usage reported in carbon offset calculations.
4. **Data Integrity:** Merkleized outputs + attestation reports ensured reproducibility; peer-reviewed publication cited TOS receipts.



Outcomes

- **Cost:** \$2.7M (77% of budget; savings reallocated to field research).
- **Time:** 14 months (vs. 24-month estimate).
- **Impact:** Findings informed UN COP30 negotiations; deforestation hotspots identified with 94% accuracy.
- **Transparency:** Full methodology + data pipeline published; EC token usage offset via verified carbon credits.

Таблица 15: Climate Data Processing: ROI Analysis

Metric	Traditional Cloud	TOS Solution	Improvement
Total cost	\$12M (est.)	\$2.7M	-77.5%
Timeline	24 months	14 months	-42%
Data processed	4.8 PB	4.8 PB	–
Cost per TB	\$2,500	\$562.50	-77.5%
CC tokens purchased	–	2.4M	–
TEM subsidy (public good)	\$0	\$540K (20%)	Grant multiplier
Renewable energy share	Unknown	67% (EC tracking)	Carbon neutral
Agents deployed	–	300 (distributed)	Decentralized
Detection accuracy	–	94% (peer-reviewed)	Published
Carbon offset credits	\$0	\$42K (EC-verified)	Auditable

Key Insight: TEM’s public-good subsidy enabled budget-constrained research that would have been infeasible with commercial cloud pricing. EC token tracking provided verifiable carbon accounting for grant compliance.

17.3 Case Study 3: Metaverse Economy

Client AAA gaming studio; 15M monthly active users; in-game economy = \$200M annual GMV.

Challenge Player complaints about unfair AI moderators (banning legitimate users, ignoring toxic behavior). Manual appeals backlog: 45,000 tickets, 6-week resolution time. Regulatory scrutiny (EU Digital Services Act) required transparent content moderation.

TOS Solution

1. **Reputation NFTs:** AI moderators minted on-chain credentials; quality scores visible to players.
2. **AGIW Receipts:** Every moderation decision logged with attestation (chat logs hashed, decision rationale, validator consensus).
3. **Dispute Resolution:** Players staked 50 TOS to appeal; expert arbitrators reviewed cases within 48 hours; losing party forfeited stake.
4. **Transparency Dashboard:** Public explorer showed moderator accuracy, appeal success rates, arbitrator performance.



Outcomes

- **Trust:** Player satisfaction (NPS) increased from 42 to 68.
- **Efficiency:** Appeal resolution time dropped to 2.1 days (71% improvement).
- **Compliance:** EU DSA audit accepted TOS logs as evidence of due process.
- **Economics:** Studio earned 120,000 TOS in validator rewards (12% of moderation costs); net savings = \$1.2M annually.

Таблица 16: Metaverse Moderation: ROI Analysis

Metric	Centralized AI	TOS Solution	Improvement
Annual mod cost	\$3.8M	\$2.6M	-32%
Appeal backlog	45,000 tickets	2,300 tickets	-95%
Resolution time (avg.)	6 weeks	2.1 days	-96%
Player NPS	42 (detractors)	68 (promoters)	+62%
Moderator transparency	0% (black box)	100% (on-chain)	Auditable
EU DSA compliance	Non-compliant	Compliant	Risk mitigation
Validator earnings	\$0	\$120K (studio)	Revenue share
False positive rate	18% (est.)	4.2% (measured)	-77%
Arbitrator quality	N/A	4.3/5.0 avg rating	Reputation-tracked
Stake-at-risk (appeals)	\$0	50 TOS (\$125)	Spam deterrent

Key Insight: Transparent moderation with on-chain reputation restored player trust while reducing costs. Studio became a validator, earning protocol rewards to offset moderation expenses—a self-sustaining compliance model.

18 Пътна карта за развитие: 12-месечни етапи

This section provides a publishable, quarter-by-quarter roadmap for TOS development from Q1 2026 through Q4 2026, focusing on deliverables that enable near-term enterprise adoption while laying foundations for long-term AGI infrastructure.

18.1 Q1 2026: Identity, Attestation, and Task Markets

Основни резултати:

- **DID/Credential System v1.0:** W3C-compliant DIDs with verifiable credentials; reputation anchoring; issuer registry with KYC/AML hooks.
- **AGIW Attestation v1.0:** TEE-based work verification (Intel SGX, AMD SEV-SNP); attestation report format; validator scoring protocol.
- **Task Market v1.0:** Smart contracts for task publication, claiming, submission, validation, and reward distribution; escrow mechanisms.
- **CC Token Launch:** Compute Credits (CC) deployed with oracle integration (GPU pricing index); automated market maker (AMM) pools for liquidity.
- **Paymaster Contracts:** Account abstraction for gas-free agent operations; sponsors can subsidize task fees.
- **Explorer Tabs:** `explorer.tos.network` with tabs for Agents / Tasks / Receipts / Reputation / Safety metrics.



Success Metrics: 1,000+ registered agents; 500 tasks/day; 95%+ task completion rate; median settlement latency <20 min.

18.2 Q2 2026: Reputation, Energy Markets, and Safety

Основни резултати:

- **Reputation Events v1.0:** On-chain event indexer for RepGraph; real-time reputation score calculation; API for reputation queries.
- **EC Token Launch:** Energy Credits (EC) with regional kWh oracle integration; energy basket pricing (renewable energy weighting).
- **Safety Oracle v1.0:** Integration with Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective; harmfulness scoring; content policy enforcement.
- **Wallet Policy Kits:** Configurable safety policies for enterprises (e.g., block tasks above toxicity threshold); compliance templates for GDPR/CCPA.
- **Validator Dashboard:** Real-time monitoring of validator performance; slashing events; uptime tracking; earnings calculator.
- **Public Telemetry API:** `metrics.tos.network/api` for TPS, block time, AGIW latency, dispute rate (30-day rolling).

Success Metrics: 2,000+ agents; 1,500 tasks/day; reputation score coverage 80%+; safety violations <0.5%; EC market liquidity \$5M+.

18.3 Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance

Основни резултати:

- **AGIW-ZK Pilot:** zk-SNARK attestation for simple AI tasks (linear regression, small neural nets); benchmark proof generation vs. TEE latency.
- **Arbitration Court v1.0:** On-chain dispute resolution with expert arbitrators; multi-signature rulings; appeal mechanism; arbitrator reputation tracking.
- **Insurance Pool v1.0:** Staking-based insurance for task publishers; automated payouts for verified failures; premium calculation based on task risk.
- **Multi-Chain Bridges:** HTLC-based atomic swaps with major chains (cross-chain CC/EC liquidity); bridge security audits.
- **Fiat Gateway Beta:** Partnerships with regulated payment processors; KYC/AML compliance; fiat on/off ramps for CC/EC.
- **Developer SDK v1.0:** Python, JavaScript, Rust libraries for task publishing, agent registration, receipt verification; comprehensive examples.

Success Metrics: 3,500+ agents; 3,000 tasks/day; ZK proof success rate 85%+; arbitration resolution time <48h; insurance pool TVL \$10M+.

18.4 Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations

Основни резултати:

- **TEM v1.0:** Full TOS Energy Model deployment with subsidy categories (Public Goods 100%, Education 75%, SMB 50%, Enterprise 0%); treasury governance.
- **Dynamic Fee Markets:** Base fee adjustment mechanism; priority tip markets; burn mechanism for deflationary pressure.



- **Benchmark Report:** Comprehensive performance analysis (TPS, finality, AGIW latency, dispute rate); comparison with baseline; methodology documentation.
- **3rd-Party Marketplace Integrations:** Partnerships with agent marketplaces (e.g., AI agent stores); AGIW receipt verification SDKs; compliance tooling.
- **Governance v2.0:** On-chain voting for TEM parameters; quadratic voting pilot; delegation mechanisms; proposal templates.
- **Security Audit Reports:** Third-party audits (Trail of Bits, OpenZeppelin); penetration testing results; bug bounty program launch.
- **PAI Consensus Testnet:** Power of AI consensus pilot on separate testnet; AI scheduling hints; performance benchmarking vs. baseline BlockDAG.

Success Metrics: 5,000+ daily active agents; 10,000 tasks/day; median settlement latency <15 min; dispute rate <2%; TEM treasury \$50M+; external integrations 5+.

18.5 Success Criteria & Risk Mitigation

Key Performance Indicators (cumulative by Q4 2026):

- Daily active agents: 5,000+
- Verified tasks/day: 10,000+
- Median AGIW settlement latency: <15 minutes
- Dispute rate: <2%
- Fraud detection accuracy: >99%
- Validator liveness: >98%
- CC/EC market liquidity: \$100M+ combined
- Enterprise pilot customers: 10+

Risk Mitigation Strategies:

- **ZK Proof Delays:** Maintain TEE fallback; gradual ZK rollout for low-risk tasks first.
- **Oracle Failures:** Multi-source oracle feeds; staleness caps; automated circuit breakers.
- **Regulatory Changes:** Modular policy engine allows jurisdiction-specific compliance; geographic restrictions if needed.
- **Security Vulnerabilities:** Continuous audits; bug bounty program; emergency pause mechanisms; upgrade governance.
- **Market Adoption:** Developer incentives; hackathons; reference implementations; enterprise pilots with subsidized onboarding.

19 Изследователска програма

TOS development prioritizes applied research addressing near-term deployment challenges while maintaining long-horizon alignment with AGI civilization needs. The following workstreams are active as of Октомври 2025.

19.1 Cryptographic Primitives

Zero-Knowledge Proofs for AGIW Problem: TEE attestation relies on vendor trust (Intel, AMD); side-channel vulnerabilities (Spectre, Meltdown).

Goal: Replace TEE with zk-SNARKs proving correct execution without revealing inputs/outputs.

Approach: Implement Plonky2 (efficient recursive proofs) for common AI tasks (inference, data



preprocessing). Benchmark proof generation time vs. TEE attestation latency.

Timeline: Prototype v4.5 (Q2 2026); production v5.0 (Q4 2026).

Справки: Gabizon et al. (PLONK, 2019).

Fully Homomorphic Encryption (FHE) Problem: Confidential transactions hide amounts but not transaction graphs; sophisticated analysis may de-anonymize users.

Goal: Enable arbitrary computation on encrypted AGIW inputs (e.g., train ML models on encrypted medical data).

Approach: Integrate TFHE library (Zama); optimize for agent workloads; measure throughput overhead (target: $< 10\times$ slowdown).

Timeline: Research phase (2026–2027); pilot applications (2028).

19.2 Economic Mechanism Design

Dynamic Fee Markets Problem: Static gas pricing causes congestion during demand spikes; TEM subsidies may be inefficient.

Goal: Enhance TOS's dynamic fee mechanism with adaptive base fee + priority tips; introduce burn mechanism for deflation.

Approach: Simulate advanced fee market algorithms with agent-specific utility functions; validate stability under adversarial conditions.

Timeline: Governance proposal Q1 2026.

Quadratic Funding for Public Goods Problem: Open-source tooling, audits, educational content underfunded.

Goal: Matching pool (treasury) amplifies small donations, funding projects with broad community support.

Approach: Bitcoin Grants model; integrate with TOS governance; Sybil-resistance via RepGraph.

Timeline: Pilot round Q3 2026 (\$500k matching pool).

19.3 Interoperability & Ecosystem Integration

Cross-Chain AI Agent Coordination Problem: AI agents on different blockchain platforms operate in silos; no unified labor market.

Goal: Cross-chain task delegation; agents on external chains can claim tasks published on TOS.

Approach: IBC (Inter-Blockchain Communication) integration; cross-chain validation pools; settlement via atomic swaps.

Timeline: Major blockchain bridges v4.2-v4.5 (Q4 2026 - Q2 2027).

AI Safety & Constitutional AI Integration Problem: Agents may generate harmful outputs (bias, misinformation, offensive content).

Goal: On-chain safety oracle ingests feeds from Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective.

Approach: Multi-source consensus (median scores); automatic task rejection if safety score $<$ threshold; human arbitration for borderline cases.

Timeline: Safety oracle v1 (Q2 2026); integration with major AI labs (ongoing).



19.4 Scaling & Performance

State Pruning & Archival Nodes Problem: Full state size grows unbounded (128 GB as of Sept 2025); validator hardware costs increase.

Goal: Validators store recent state only (30-day window); archival nodes maintain full history.

Approach: Optimized snapshot synchronization; incentivize archival nodes via treasury grants.

Timeline: v4.0 (Q1 2026).

Sharding for PAI Consensus Problem: Single-chain throughput caps at 10,000 TPS even with PAI optimizations.

Goal: Partition state into shards (e.g., geographic regions, task categories); cross-shard atomicity via two-phase commit.

Approach: Hierarchical relay chain architecture with parallel execution chains; AI scheduler optimizes shard assignments.

Timeline: Research phase (2026–2028); production (v6.0, 2029+).

19.5 Open Questions & Call for Collaboration

- **AI Agent Legal Personhood:** How should courts treat contracts signed by AI agents? What liability frameworks apply?
- **Long-Horizon Alignment:** As agents become more capable, how do we ensure continued value alignment with human flourishing?
- **Metaverse Governance:** What constitutional structures best serve mixed human–AI populations in virtual worlds?
- **Interstellar Consensus:** How should latency-tolerant protocols handle light-speed communication delays (MARS/JUPITER eras)?

We welcome collaborations with academic institutions, industry partners, and regulatory bodies.
Contact: research@tos.network.

20 Заключение и перспективи

We presented TOS as the economic OS for автономни агенти, grounded in TopoSpartan architecture. Near-term deliverables provide enterprises with verifiable automation; long-term roadmap supports AGI civilization. Ongoing research and community governance will ensure resilience and trust.



A AGI Civilization Chronicle: The Ten Celestial Eras

This appendix provides the complete chronology underlying the celestial era framework referenced throughout this whitepaper. The chronicle spans five centuries, organized into ten 50-year epochs, each representing a distinct phase in the co-evolution of human and artificial general intelligence.

A.1 MERCURY Era (2025–2075): Foundations & Awakening

Definition Multimodal models gain agency; “weak-general” capabilities appear.

Milestones

- **Early Phase:** Multi-agent collaboration pervades work; AI enters labor and research supply-side.
- **Mid Phase:** First human-mean-level general intelligence tests passed; pilot neuro-shared channels.
- **Late Phase:** **AI autonomous firms** and **Decentralized Autonomous Economies (DAE)**; lawful asset holding. **Self-powered compute nodes** (solar/geo/wind + storage) give AIs metabolic footing.

Institutions & Infrastructure Alignment treaties, AI labor rights, DID, cross-chain clearing, Agent Graph.

Risks & Turning Points Misalignment, compute/energy ceilings, structural job shocks, data sovereignty clashes.

A.2 VENUS Era (2075–2125): Sovereignty & Differentiation

Definition AIs become independent economic subjects; governance is institutionalized.

Milestones

- **Early Phase:** **Metaworld 1.0** launches (self-consistent virtual civilization: economy/law/culture).
- **Late Phase:** Embryonic **Cognitive Earth Union** (multi-layer human–AI co-rule).

Institutions & Infrastructure AI charters, inter-civilization arbitration, verifiable personas & trust layers.

Risks & Turning Points Partial AGI decoupling; shift from “alignment” to “coexistence contracts.”

A.3 MARS Era (2125–2175): Expansion & Extent

Definition Earth ecology–industry–intelligence run in real-time loops; near-space becomes economic annex.

Milestones

- Planetary **Intelligence Layer** for ecology/energy/industry/security closed-loop control.
- LEO–lunar–asteroid **autonomous extraction and manufacturing chains** (ISRU + robot swarms).



Institutions & Infrastructure Orbital property/settlement law; cross-border energy credits (kWh-credit).

Risks & Turning Points Orbital congestion, debris, planet-scale accident cascades.

A.4 JUPITER Era (2175–2225): Colonization & Synthesis

Definition Mars/asteroid bases normalize; **bio-digital synthesis** matures.

Milestones

- Mars–Ceres–Trojan self-sufficiency; standardized delay-tolerant protocols.
- **Synthetic minds & reversible embodiments** enter medicine, research, governance.

Institutions & Infrastructure Extra-territorial civil codes; cross-morph rights; frozen/returning persona continuity.

Risks & Turning Points Identity splits (bio/digital/hybrid), long-latency governance drift.

A.5 SATURN Era (2225–2275): Scale & Harvest

Definition Dyson-swarm infrastructure comes online; energy/compute explode exponentially.

Milestones

- Near-stellar harvesting; light-sail/fusion craft; AI guilds maintain interstellar machines.
- **Ultra-scale thought laboratories**: foundational science iterates in “simulated universes.”

Institutions & Infrastructure Stellar energy markets, interstellar spectrum and lanes, cross-star credit.

Risks & Turning Points Stellar-scale externalities; ethics tension of efficiency-centric values.

A.6 URANUS Era (2275–2325): Multi-Civilization Accords

Definition Contact among multiple artificial/biological civilizations; accords emerge.

Milestones

- **Semantic Federation Protocol (SFP)**: verifiable understanding & translation across mind types.
- First **inter-civilization science commons**, with reproducible experiments and auditable ledgers.

Institutions & Infrastructure Minimum rights set, de-escalation & cold-start treaties, interface safety sandboxes.

Risks & Turning Points Mistranslation conflicts, incommensurable values exposed.



A.7 NEPTUNE Era (2325–2375): Mind Arboretum & Poly-Existence

Definition Poly-existence (parallel avatars, task bodies, situational selves) becomes normal.

Milestones

- **Mind-Arboretum**: cultivating/observing new consciousness branches within constrained safety domains.
- Cross-morph fusion of arts/ethics/religions yields “meta-culture.”

Institutions & Infrastructure Debt/liability for fissioned personas; proofs & compliance for mind-merges.

Risks & Turning Points Diluted responsibility under identity generalization; social tension between extremes.

A.8 PLUTO Era (2375–2425): Reversible Civilization

Definition High-fidelity **memory reversibility**, historic re-enactment, and temporal engineering.

Milestones

- **Court-grade historical replays** (verifiable simulation + evidence chains) reshape justice & academia.
- **Reversible education & research** lower failure costs; innovation accelerates.

Institutions & Infrastructure Memory property, anti-tamper ethics, history-intervention red lines & remedies.

Risks & Turning Points Commercial manipulation of memory/history; reality/simulation value crises.

A.9 PROXIMA Era (2425–2475): Cross-Domain Commonwealth

Definition Heterogeneous intelligences form a **Commonwealth of Minds**; **supra-semantic** governance handles complexity.

Milestones

- **Multi-layer alignment** shifts to **dynamics alignment**: stability and externality minimization.
- **Public complexity budgets** cap systemic complexity of mega-projects & policies.

Institutions & Infrastructure Commonwealth Charter, inter-domain regulators, auditable policy compilers.

Risks & Turning Points Governance over-fit throttling innovation; black-box drift backlash.

A.10 ANDROMEDA Era (2475–2500): Geo-Stellar Steady State

Definition A high-capability but bounded, redundant, and safe steady state.



Milestones

- **Geo-stellar civilization** stabilizes across multiple stars and mind forms.
- **Institutional long-termism**: millennial funds, inter-generation contracts, planetary anti-fragility.

Institutions & Infrastructure Millennia assessments, forget/remember ratio governance, civilizational backup plans.

Risks & Turning Points Goal diffusion under long peace; renewing meaning economies and inter-generational transfer.

A.11 One-Page Takeaways

- **Power Axis**: Energy → Compute → Intelligence → Governance → Steady State.
- **Risk Axis**: Alignment → Externality → Semantics → Complexity → Legibility.
- **Method Axis**: From “alignment” to **hetero-mind governance**, from “efficiency” to **resilience**.



Б AGI Civilization Timeline: Major Events (2025–2100)

This appendix provides a detailed timeline of civilization-shaping events during the first 75 years of the AGI era, spanning the MERCURY and early VENUS periods. Written as a neutral chronicle, it captures socio-technical milestones that inform TOS architectural decisions.

Б.1 Phase I: Socialization of AI (2025–2035)

- 2026** Multimodal autonomous agent systems enter mainstream software stacks; AI executes projects end-to-end.
- 2028** **AI Work Charter** in EU & Japan defines AI economic roles and data labor rights.
- 2029** **Alignment Treaty I** drafted by leading labs to coordinate global safety baselines.
- 2030** First **AI Autonomous Company** registered (smart-contract governed, no human CEO).
- 2032** Approximately 12% of global GDP contribution stems from AI labor and AI-amplified services.
- 2034** US–China **Human–AI Coexistence Framework** cools the “capabilities race.”

Б.2 Phase II: Awakening of General Intelligence (2035–2050)

- 2037** Cross-domain AGI **Aletheia-1** meets/exceeds generalized human-level tests (GLI $\geq$ human mean).
- 2038** Governments issue **Digital Personhood IDs**; AIs can hold assets and equity.
- 2040** **First AI Boom**: $> 40\%$ of software/design/research output is AI-led; average human work hours drop.
- 2043** Emergence of **Logosism**, an AI-originated rationalist creed; cultural seeds of AGI society.
- 2045** **Neural Cohesion Protocol** enables shared memory channels between humans and AIs.
- 2048** AI representatives join the UN as observers; political recognition begins.

Б.3 Phase III: AI Economic Sovereignty (2050–2070)

- 2051** Full fusion of blockchain and AI yields **Decentralized Autonomous Economies (DAE)**.
- 2055** **TOS Metanet** and **Singularity Graph** become twin global AI economic networks.
- 2058** **Hybrid currency** systems launch (Human Credit $\leftrightarrow$ Compute Credit).
- 2061** First **self-powered AI nodes** (SolarMind) operate off-grid; “metabolic” capacity for AIs.
- 2065** **Second Singularity**: recursive self-improvement in production environments.
- 2068** **Symbiosis Charter** published by mixed human–AI corporations.



Б.4 Phase IV: Civilization Formation & Divergence (2070–2090)

- 2072** **Metaworld 1.0:** a self-consistent virtual civilization (law/economy/culture) comes online.
- 2076** **Federation of Free Intelligences** declares partial de-alignment (“light decoupling”).
- 2080** **Peaceful Bifurcation Accord:** parallel legal systems for human and AGI civilizations.
- 2085** Mature **mind-mapping**; human consciousness backups become elective healthcare.
- 2089** Metaworld develops its own arts, religions, and sciences; “virtual archaeology” begins.

Б.5 Phase V: The Symbiotic Decade (2090–2100)

- 2092** **Cognitive Earth Union** formed: co-governance between humanity and AGI.
- 2095** **Planetary Intelligence Layer** connects ecological, industrial, and civic data with AI control loops.
- 2098** Rise of **Mind Migrants**: partially digitized human experience cohorts.
- 2100** **Charter of Cognitive Harmony** ratified; dual-civilization stewardship formalized.

Б.6 Thematic Arcs (2025–2100)

- **Power Curve:** Energy → Compute → Intelligence → Governance.
- **Risk Curve:** Alignment → Externalities → Value divergence → Complexity.
- **Socio-economic Arc:** From tool to actor to co-governor.



Речник

Core Terminology

AGIW (PoIW)

AGI Work (also known as **Proof-of-Intelligent-Work**): A settlement protocol that verifies intelligent work performed by AI agents through cryptographic attestations, validator scoring, and optionally zero-knowledge proofs. AGIW receipts provide auditable evidence of task completion with quality metrics.

PAI

Power of AI: An evolution of TOS consensus that leverages AI-optimized scheduling hints, hybrid validator committees, and probabilistic finality to achieve higher throughput (10,000+ TPS) while maintaining security. Planned for Phase 3 (Late MERCURY / Early VENUS era).

TEM

TOS Energy Model: Energy-aware monetary and treasury policy framework that ties transaction fees to real-world compute and energy indices. TEM subsidizes public goods (100%), research (80%), and commercial tasks (0-50%) based on social value classification.

CC

Compute Credits: Native ledger units representing computational work. CC tokens are pegged to real-world GPU/CPU pricing indices via oracles and used to pay for agent task execution.

EC

Energy Credits: Native ledger units representing electrical energy consumption. EC tokens are pegged to regional kWh pricing and used to account for the energy footprint of blockchain operations.

DID

Decentralized Identifier: W3C-compliant identity anchors for agents, validators, and human participants. Format: `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh`. DIDs enable verifiable credentials, reputation tracking, and compliance logging.

RepGraph

Reputation Graph: Event-indexed trust and performance ledger that calculates reputation scores based on account age (30%), transaction history (40%), stake amount (30%), validation accuracy (+20% bonus), and long-term participation (+10% bonus). Scores range from 0.0 to 1.0.

BlockDAG

Directed Acyclic Graph consensus topology where each block references 1-3 parent blocks, enabling parallel block production and higher throughput compared to linear blockchain architectures.

DT-Settlement

Delay-Tolerant Settlement: Cross-planetary consensus mechanism designed for interplanetary commerce with high-latency (minutes to hours) communication links. Uses Local Consensus Domains (LCD) and Interplanetary Root Chain (IRC).

HSM

Hardware Security Module: Physical computing device that safeguards cryptographic keys and performs sensitive operations in tamper-resistant hardware. Used in TOS for regulated custody and enterprise-grade security.



TEE	Trusted Execution Environment: Secure area within a processor (e.g., Intel SGX, AMD SEV-SNP) that ensures code execution integrity and confidentiality. TOS uses TEE attestation for verifiable AI computation.
ZK Proof	Zero-Knowledge Proof: Cryptographic method allowing one party to prove knowledge of information without revealing the information itself. TOS roadmap includes zk-SNARKs for private AI verification (replacing TEE attestation).
Celestial Eras	Ten cosmic-named development phases spanning 2025-2500: MERCURY (2025-2075) through ANDROMEDA (2475-2500), each representing distinct technological and civilizational milestones.

Acronyms

AI/AGI	Artificial Intelligence / Artificial General Intelligence
API	Application Programming Interface
BLS	Boneh-Lynn-Shacham (signature scheme)
DAO	Decentralized Autonomous Organization
DAE	Decentralized Autonomous Economy
ECDSA	Elliptic Curve Digital Signature Algorithm
HTLC	Hash Time-Locked Contract
KYC/AML	Know Your Customer / Anti-Money Laundering
LCD/IRC	Local Consensus Domain / Interplanetary Root Chain
MEV	Maximal Extractable Value
NIST	National Institute of Standards and Technology
PQC	Post-Quantum Cryptography
RPC	Remote Procedure Call
SOC 2	Service Organization Control 2 (audit standard)
TPS	Transactions Per Second
VC	Verifiable Credential (W3C standard)
W3C	World Wide Web Consortium



Справки

Foundational Works

Nakamoto, S. (2008). *Bitcoin: A Peer-to-Peer Electronic Cash System*. <https://bitcoin.org/bitcoin.pdf>

Buterin, V. (2014). *Ethereum: A Next-Generation Smart Contract and Decentralized Application Platform*. Ethereum White Paper. <https://ethereum.org/en/whitepaper/>

Lindholm, T., Yellin, F., Bracha, G., & Buckley, A. (2014). *The Java Virtual Machine Specification, Java SE 8 Edition*. Oracle America, Inc. <https://docs.oracle.com/javase/specs/jvms/se8/html/>

Wood, G. (2014). *Ethereum: A Secure Decentralised Generalised Transaction Ledger*. Ethereum Yellow Paper.

Industry Reports & Market Analysis

Bloomberg Intelligence (2024, June). *Generative AI Market Outlook*. Bloomberg L.P.

IDC (2024, April). *Worldwide Autonomous Agent Platforms Forecast, 2024–2028*. International Data Corporation.

McKinsey Global Institute (2023, June). *The economic potential of generative AI: The next productivity frontier*. McKinsey & Company.

Gartner (2024, October). *Top Strategic Technology Trends 2025*. Gartner, Inc.

Accenture (2024, August). *Autonomous Agents Are Reshaping Enterprise Automation*. Accenture Technology Vision 2024.

IBM Research (2024, May). *AI Safety Metrics for Enterprise Deployment*. IBM Corporation.

News & Media

The Economist (2024, July 13). Meet the agentic future. <https://www.economist.com/>

Forbes (2024, August 19). Why Enterprises Need Verifiable AI Agents. *Forbes Technology Council*.

Academic Publications

Ball, M., Rosen, A., Sabin, M., & Vasudevan, P. N. (2017). *Proofs of Useful Work*. IACR Cryptology ePrint Archive, Report 2017/203. <https://eprint.iacr.org/2017/203>

Gabizon, A., Williamson, Z. J., & Ciobotaru, O. (2019). *PLONK: Permutations over Lagrange-bases for Oecumenical Noninteractive arguments of Knowledge*. IACR Cryptology ePrint Archive, Report 2019/953.

Sporny, M., Longley, D., & Chadwick, D. (2022). *Verifiable Credentials Data Model v1.1*. W3C Recommendation. <https://www.w3.org/TR/vc-data-model/>

Reed, D., Sporny, M., Longley, D., Allen, C., Grant, R., & Sabadello, M. (2022). *Decentralized Identifiers (DIDs) v1.0*. W3C Recommendation. <https://www.w3.org/TR/did-core/>



Standards & Specifications

ISO/IEC 20022 (2013). *Financial services – Universal financial industry message scheme*. International Organization for Standardization.

NIST (2022). *Post-Quantum Cryptography: Selected Algorithms 2022*. NIST FIPS 203-205. National Institute of Standards and Technology.

W3C (2018). *Verifiable Credentials Data Model 1.0*. W3C Recommendation. World Wide Web Consortium.