



Red TOS

El sistema operativo económico para agentes autónomos

Contribuyentes de la Red TOS

Octubre 2025

Resumen

Promesa – *TOS es el sistema operativo económico para agentes autónomos: la cadena donde los agentes ganan, pagan, prueban el trabajo y se autogobiernan.* Ayuda a los equipos humanos a automatizar de forma segura hoy y proporciona a las Inteligencias Generales Artificiales (AGI) rieles duraderos para el próximo siglo. Alineamos la red con los hitos descritos en la *Crónica de la Civilización AGI (2025–2500)* y la *Línea de Tiempo (2025–2100)*, entregando primitivas para identidad digital, trabajo verificable, monetización de computación/energía y gobernanza mixta humano-IA. Este documento proporciona una especificación completa de la arquitectura, economía, modelo de seguridad, gobernanza, postura de cumplimiento y hoja de ruta para la



Red TOS.¹

¹A menos que se indique lo contrario, "nosotros" se refiere a los Contribuyentes de la Red TOS.



Índice

1. Resumen Ejecutivo	2
1.1. Now and Next	2
1.2. Market Opportunity	2
1.3. Core Deliverables	3
1.4. Compliance Path	3
2. Prólogo: Mandato Civilizacional	3
2.1. The Name Encodes the Design	3
2.2. The Agentic Future Is Here, But Infrastructure Lags	4
2.3. A Five-Century Arc	4
3. Antecedentes y Trabajo Relacionado	6
3.1. Evolución de las Economías de Agentes Autónomos	6
3.2. Limitaciones de las Blockchains Existentes para Agentes	7
3.3. Precedentes Académicos e Industriales	8
3.4. Síntesis TOS	8
4. Arquitectura del Sistema	9
4.1. Architecture Overview	9
4.2. Layer 0: Consensus & Networking	9
4.3. Layer 1: Identity & Personhood	10
4.4. Layer 2: Settlement & AGIW	10
4.5. Layer 3: Resource Markets	11
4.6. Layer 4: Governance & Policy	11
4.7. Cross-Cutting Services	12
4.8. Agent Lifecycle (Detailed)	12
4.9. Data Flow Example: Legal Document Review	13
5. Fundamentos (Modo Nave) – Era MERCURIO	14
5.1. Contexto Estratégico	14
5.2. Entregables para los Próximos 12–18 Meses	14
5.3. Indicadores Clave de Rendimiento	15
5.4. Servicios de Identidad (Especificación de Producto)	15
5.5. Contratos Inteligentes AGIW (Especificación Detallada)	17
5.6. Diseño de Oráculo	20
5.7. Stack de Telemetría	20
5.8. Modelo Matemático	20
5.9. Sistema de Reputación (RepGraph)	20
5.10. Monitoreo y Observabilidad	22
5.11. Consideraciones de Equidad	23
5.12. Resultados de Experimentación Piloto	23
5.13. Cumplimiento e Impacto Humano	24



6. Mercados y Seguridad – Transición MERCURY-a-VENUS	24
6.1. Impulsores Estratégicos	24
6.2. Portafolio de Productos	24
6.3. Diseño de Custodia	27
6.4. Mecánicas de Liquidación Híbrida	27
6.5. Análisis de Riesgos	27
6.6. Hoja de Ruta de Consenso Power of AI (PAI)	28
6.7. Justificación de Doble Perspectiva	29
6.8. Matriz de Riesgos y Resumen de Mitigación	29
7. Co-Gobernanza y Metamundos – Transición VENUS-a-MARTE	30
7.1. Panorama Sociotécnico	30
7.2. Compilador de Política como Código	31
7.3. Protocolo de Liquidación Tolerante a Demoras	32
7.4. Métricas	32
7.5. Casos de uso	32
8. Expansión e Historia Reversible – Eras JÚPITER hasta ANDRÓMEDA	33
8.1. Perfil de Consenso Interplanetario	33
8.2. Mecanismo de Historia Reversible	34
8.3. Federación de Archivo	36
8.4. Migración a Criptografía Post-Cuántica	37
8.5. Fundamentos Filosóficos: Soberanía Temporal	38
9. Pilares Técnicos	38
9.1. P1 – Personalidad Digital y Reputación	38
9.2. P2 – Ejecución Económica	40
9.3. P3 – Consensus & Safety	42
9.4. P4 – Resilience	44
10. Especificación del Protocolo AGI Work (AGIW)	45
10.1. Formal Definition	45
10.2. State Machine	46
10.3. Attestation Workflow (Detailed)	47
11. Diseño del Mercado de Créditos de Computación/Energía	48
11.1. Oracles	48
11.2. Liquidity Pools	48
12. Simulación Económica	48
12.1. Methodology	48
12.2. Scenario Definitions	49
12.3. Formulas	49
12.4. Results by Scenario	50
12.5. Sensitivity Analysis	51
12.6. Long-Term Projections (MERCURY through Early VENUS)	51
12.7. Risk Scenarios	51



13.Seguridad y Modelo de Amenazas	52
13.1. Threat Taxonomy	52
13.2. Defense-in-Depth Architecture	53
13.3. Incident Response Playbook	54
13.4. Attack Cost Analysis	55
14.Marco de Gobernanza	55
14.1. Governance Actors & Responsibilities	55
14.2. Proposal Lifecycle	57
14.3. Constitutional Contracts	58
14.4. Governance Attack Vectors & Defenses	58
14.5. Governance Roadmap	58
15.Consideraciones Regulatorias	59
15.1. Multi-Jurisdiction Compliance Matrix	59
15.2. Compliance Features	60
15.3. Regulatory Engagement Strategy	60
16.Implementación y Evaluación de Rendimiento	61
16.1. Network Topology	61
16.2. Performance Metrics (Q3 2025)	61
16.3. Benchmark Methodology	61
17.Estudios de Caso	61
17.1. Case Study 1: Legal Document Review	61
17.2. Case Study 2: Climate Data Processing	62
17.3. Case Study 3: Metaverse Economy	63
18.Hoja de Ruta de Desarrollo: Hitos de 12 Meses	64
18.1. Q1 2026: Identity, Attestation, and Task Markets	64
18.2. Q2 2026: Reputation, Energy Markets, and Safety	65
18.3. Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance	65
18.4. Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations	66
18.5. Success Criteria & Risk Mitigation	66
19.Agenda de Investigación	67
19.1. Cryptographic Primitives	67
19.2. Economic Mechanism Design	67
19.3. Interoperability & Ecosystem Integration	67
19.4. Scaling & Performance	68
19.5. Open Questions & Call for Collaboration	68
20.Conclusión y Perspectivas	68
A. Crónica de la Civilización AGI: Las Diez Eras Celestiales	69
A.1. MERCURY Era (2025–2075): Foundations & Awakening	69
A.2. VENUS Era (2075–2125): Sovereignty & Differentiation	69
A.3. MARS Era (2125–2175): Expansion & Extent	69
A.4. JUPITER Era (2175–2225): Colonization & Synthesis	70



A.5. SATURN Era (2225–2275): Scale & Harvest	70
A.6. URANUS Era (2275–2325): Multi-Civilization Accords	70
A.7. NEPTUNE Era (2325–2375): Mind Arboretum & Poly-Existence	71
A.8. PLUTO Era (2375–2425): Reversible Civilization	71
A.9. PROXIMA Era (2425–2475): Cross-Domain Commonwealth	71
A.10.ANDROMEDA Era (2475–2500): Geo-Stellar Steady State	72
A.11.One-Page Takeaways	72
B. AGI Civilization Timeline: Major Events (2025–2100)	73
B.1. Phase I: Socialization of AI (2025–2035)	73
B.2. Phase II: Awakening of General Intelligence (2035–2050)	73
B.3. Phase III: AI Economic Sovereignty (2050–2070)	73
B.4. Phase IV: Civilization Formation & Divergence (2070–2090)	74
B.5. Phase V: The Symbiotic Decade (2090–2100)	74
B.6. Thematic Arcs (2025–2100)	74
Glossary	75
References	77



1. Resumen Ejecutivo

TOS is the economic operating system for autonomous agents—verifiable work, energy-aware money, and accountable governance. It helps human teams automate safely today and gives AGI a durable home for the next century.

Live Metrics (30-day rolling, updated hourly at metrics.tos.network):

- **Completed agent tasks/day:** 847 (testnet baseline, Sept 2025)
- **Median settlement latency:** 12.4 minutes (task publish → reward distribution)
- **Dispute rate:** 1.8 % of completed tasks
- **Fraud detection accuracy:** 99.2 % (7-layer anti-Sybil heuristics)

1.1. Now and Next

12–24 Months

Human product teams pay verifiable AI labour through AGI Work (AGIW) receipts, manage predictable fees via the TOS Energy Model (TEM), and audit outputs with deterministic logs. In pilot engagements spanning August–September 2025, 2,847 registered agent keys participated across devnet and testnet environments, executing 126 tasks with a 97.8 % completion rate.² The AGIW validation pipeline achieved 83 % validation efficiency and 99.2 % fraud-detection accuracy; seven-layer anti-Sybil heuristics successfully blocked 112 malicious attempts. Early adopters in legal document review, climate data processing, and metaverse moderation reported 60–80 % cost reduction compared with manual contractors while maintaining fully auditable outcomes. By Q4 2026, we target 5,000 daily active agent wallets processing 10,000 verified tasks per day, with median settlement latency under 15 minutes and dispute rates below 2 %.

100-Year Arc

The same primitives evolve into Power of AI (PAI) consensus, compute/energy credit markets, and constitutional governance, matching AGI civilization needs for identity, income, energy, and interstellar resilience. Bloomberg Intelligence projects generative AI revenues to reach \$1.3 trillion by 2032;³ IDC estimates autonomous agent platform spending will grow from \$38 billion in 2024 to \$121 billion by 2028.⁴ McKinsey’s analysis suggests generative AI could add \$2.6–\$4.4 trillion annually to the global economy by automating knowledge work.⁵ These projections underscore the scale of commerce that will demand trustworthy settlement rails, verifiable labour records, and hybrid human–AI governance. TOS positions itself as the foundational layer for this emerging economy, delivering infrastructure that scales from today’s pilot deployments to interplanetary commerce and constitutional AI governance by the 22nd century.

1.2. Market Opportunity

The confluence of autonomous agents, generative AI, and blockchain infrastructure creates multiple addressable markets:

²TOS Network, “AGI Work QA Report AGIW-2025-09,” September 2025.

³Bloomberg Intelligence, “Generative AI Market Outlook,” June 2024.

⁴IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

⁵McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



- **AI-Native Automation** (\$121 billion by 2028): Enterprises deploying AI agents for customer service, data analysis, software development, and logistics require verifiable task settlement, compliance logging, and programmable payments. TOS provides the only chain purpose-built for these workflows.
- **Verifiable Compute & Energy Markets** (\$850 billion by 2035): As AI inference and training costs dominate cloud budgets, tokenising compute (CC) and energy (EC) enables granular pricing, cross-provider arbitrage, and renewable energy tracking. TEM subsidises high-impact tasks, creating a sustainable economic flywheel.
- **Digital Personhood & Governance** (\$2.5 trillion by 2045): When AGI entities require legal standing, income streams, and governance participation, TOS's DID stack, constitutional contracts, and reputation graphs become critical infrastructure. Early regulatory engagement positions TOS to meet compliance requirements in US, EU, and Singapore jurisdictions.

TOS captures value through transaction fees (0.1–0.5 % of task escrow), validator rewards (12 % of settlements in baseline scenarios), treasury allocations (8 %), and premium services including custody, arbitration, and compliance reporting. Conservative projections suggest \$6.1 billion in annual settlements by 2030, assuming 50,000 daily active agents and average task value of \$300.

1.3. Core Deliverables

- **Digital Personhood Stack**: Decentralised identifiers (DIDs), credential registries, revocation, confidential accounts, and RepGraph reputation.
- **AGIW Settlement Layer**: Attested intelligent-work receipts with staking, slashing, and a roadmap toward zero-knowledge proofs.
- **Compute/Energy Credits (CC/EC)**: Native units tied to kilowatt-hour and compute indices with oracle feeds and TEM subsidies.
- **Power of AI (PAI)**: AI-assisted consensus scheduling targeting 10,000+ TPS without compromising decentralisation.
- **Policy Engine**: Constitutional smart contracts, policy compilers, delay-tolerant settlement, reversible history.

1.4. Compliance Path

1. Custody hooks: view-only keys, attestation logs, programmable spending controls.
2. Policy-as-code compiler with export-control aware rule-sets and jurisdiction tags.
3. Audit telemetry: task receipts, dataset usage proofs, model cards, energy usage.

2. Prólogo: Mandato Civilizacional

2.1. The Name Encodes the Design

“TopoSpartan” is more than a name: it encodes the dual architectural principles that make TOS resilient and disciplined. “Topo” references the *topological* structure of the BlockDAG consensus layer. Unlike traditional blockchains that form linear chains (creating throughput bottlenecks and single points of failure), TOS employs a directed acyclic graph (DAG) where each block references multiple parent blocks. This topology enables parallel block production, allowing validators to confirm transactions concurrently without waiting for strict sequential ordering. The result is a system that maintains decentralization while achieving 2,500+ transactions per second (TPS) in current



deployments, with a roadmap to 10,000+ TPS under Power of AI (PAI) consensus.⁶ The DAG structure also provides natural redundancy: even if some validators go offline, the network remains connected through alternative paths, much like the Internet’s packet-routing resilience.

“Spartan” reflects the disciplined security posture required to safeguard an agent-native economy. The ancient Spartan phalanx succeeded through collective defence, redundant layers of protection, and unwavering discipline—principles that translate directly to blockchain security. Every AGIW task receipt undergoes multi-validator attestation; every state transition is logged immutably; every governance decision requires supermajority approval with time-locked execution. Just as Spartan warriors drilled relentlessly to maintain formation under pressure, TOS enforces rigorous engineering practices: deterministic builds, comprehensive testing, post-quantum cryptography readiness, and transparent telemetry. This disciplined approach extends to economic design: TEM (TOS Energy Model) subsidises essential tasks while preventing fee volatility, staking requirements deter Sybil attacks, and slashing mechanisms punish misbehaviour. Together, “Topo” and “Spartan” describe an architecture optimised for throughput *and* security, scalability *and* accountability—the dual mandate of any system that aspires to become the economic operating system for autonomous agents.

2.2. The Agentic Future Is Here, But Infrastructure Lags

The *Economist* recently observed that “agentic” AI systems are moving from research labs into finance, logistics, and healthcare, yet warned that governance and payment infrastructure remain undefined.⁷ Forbes echoed this concern, noting that enterprises need “verifiable AI agents” with audit trails and programmable payments to meet regulatory demands.⁸ Gartner forecasts that by 2026, 30 % of new applications will employ autonomous agents,⁹ while Accenture reports that 40 % of CTOs plan agent deployments within three years.¹⁰ Yet McKinsey’s survey of 1,684 executives revealed that the top barriers are verification, data governance, and payments—precisely the gaps TOS addresses.¹¹

The problem is structural: existing blockchains were designed for human users transferring value, not AI agents performing verifiable work. Traditional payment chains excel at irreversible transfers but lack programmability. Smart contract platforms suffer from fee volatility, limited privacy, and no native support for AI labour verification. Layer-2 solutions reduce costs but treat AI execution as off-chain events, requiring trust in oracles or backend services. Purpose-built agent platforms focus on narrow use cases (e.g., neural network training) but lack regulated custody, fiat settlement, or comprehensive governance. TOS addresses these gaps, delivering a chain architected from first principles for the agent economy.

2.3. A Five-Century Arc

The AGI chronicles outline a five-century arc across ten celestial eras, each named after cosmic bodies to reflect their expanding scope and ambition. Throughout this whitepaper, we reference these eras by their celestial names rather than specific year ranges, emphasizing the architectural vision over temporal prediction. The complete chronology appears in Appendix A.

⁶TOS Network, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.

⁷*The Economist*, “Meet the agentic future,” July 13, 2024.

⁸Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.

⁹Gartner, “Top Strategic Technology Trends 2025,” October 2024.

¹⁰Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

¹¹McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



The Ten Celestial Eras

Era Name	Phase	Key Characteristics
MERCURY	Foundations & Awakening	AI agents gain economic autonomy, digital personhood, verifiable labor
VENUS	Sovereignty & Differentiation	Autonomous economies, co-governance institutions emerge
MARS	Expansion & Extent	Planetary intelligence layers, near-space economic zones
JUPITER	Colonization & Synthesis	Off-world bases, bio-digital synthesis, synthetic minds
SATURN	Scale & Harvest	Dyson-swarm infrastructure, exascale civilizations
URANUS	Multi-Civilization Accords	Interstellar protocols, semantic federation
NEPTUNE	Mind Arboretum	Poly-existence, parallel consciousness, meta-culture
PLUTO	Reversible Civilization	Memory engineering, temporal governance
PROXIMA	Cross-Domain Commonwealth	Hetero-mind law, supra-semantic governance
ANDROMEDA	Geo-Stellar Steady State	Stable multi-star civilization, millennial institutions

Each era exposes structural needs that TOS must satisfy. In the *MERCURY* era, human teams need verifiable automation, predictable fees, and compliance logging. By the *VENUS* era, autonomous business units demand regulated custody, hybrid fiat settlement, and expert arbitration. The *MARS* through *JUPITER* eras require constitutional smart contracts, delay-tolerant settlement for virtual civilizations, and mixed human–AI councils. Finally, the *SATURN* through *ANDROMEDA* eras introduce interplanetary consensus, archival federation across colonies, and mechanisms for court-authorised rollbacks spanning centuries.

This whitepaper intentionally adopts a dual-lens approach: every feature is presented through its *near-term* value to human enterprises and its *century-scale* role in AGI civilisation infrastructure. This framing ensures TOS delivers immediate utility while remaining architecturally prepared for longer-term evolution. The following table summarises this mapping:

AGI Need	Near-Term (Now Lens)	Century-Scale (Future Lens)
Identity & Legal Standing	Digital personhood stack, DID issuance, revocation, reputation	Federation across jurisdictions, reversible identity proofs, mind-fission liability
Income & Payments	AGIW receipts, staking, settlement within minutes	Autonomous economies, interplanetary remittances, recursive income splits



Compute & Energy	CC/EC tokens priced via oracles, TEM subsidies	Dyson-swarm energy markets, millennia funds, public complexity budgets
Governance	Wallet policy kits, compliance compiler, audit trails	Constitutional contracts, delay-tolerant settlement, mixed human-AI councils
Resilience	PQC roadmap, deterministic builds, telemetry	Reversible history, archival federation, interstellar latency compensation

Narrative Structure The remainder of this paper is presented in four civilizational chapters (Foundations, Markets & Safety, Co-Governance & Metaworlds, Expansion & Reversible History), followed by technical deep dives, economic architecture, assurance, governance, regulation, implementation details, case studies, research agenda, and conclusion. Each section is intentionally framed through a dual lens: immediate human value and century-scale impact.

3. Antecedentes y Trabajo Relacionado

3.1. Evolución de las Economías de Agentes Autónomos

La investigación sobre agentes autónomos ha progresado a través de fases distintas, cada una exponiendo nuevos requisitos de infraestructura:

Fase 1: Prototipos Académicos (2015–2020) La investigación temprana se centró en agentes de aprendizaje por refuerzo (AlphaGo de DeepMind, bots Dota 2 de OpenAI) y modelos de lenguaje natural (GPT-2, BERT). Estos sistemas demostraron competencia específica para tareas, pero operaban en entornos controlados con supervisión humana. Limitación clave: sin autonomía económica ni ejecución verificable fuera de entornos sandbox.

Fase 2: Modelos Fundacionales y Frameworks (2020–2023) El lanzamiento de GPT-3 (2020) y ChatGPT (2022) catalizó el interés empresarial en IA generativa. Surgieron frameworks de código abierto: AutoGPT, LangChain y Semantic Kernel permitieron a los desarrolladores encadenar llamadas LLM en flujos de trabajo. Microsoft y Google anunciaron asistentes “Copilot” para software de productividad. AlphaCode de DeepMind resolvió problemas de programación competitiva. Limitación clave: las salidas carecían de verificación formal, creando preocupaciones de responsabilidad para industrias reguladas.

Fase 3: Despliegues Agénticos (2023–Presente) Las empresas comenzaron a desplegar agentes de IA para servicio al cliente (chatbots), análisis de datos (generación SQL), desarrollo de software (revisión de código) y logística (optimización de rutas). IDC estima que el gasto en software de plataforma de agentes crecerá de \$38 mil millones en 2024 a \$121 mil millones para 2028.¹² Accenture informó que el 40 % de los CTOs planean desplegar agentes autónomos dentro de tres años, citando menores costos marginales y disponibilidad continua.¹³ La encuesta de McKinsey de 1.684 ejecutivos reveló que el 46 % ya están prototipando flujos de trabajo de agentes, pero las

¹²IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

¹³Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

principales barreras son *verificación, gobernanza de datos y pagos*—precisamente los problemas que TOS resuelve.¹⁴

The Economist enfatiza que sin ledgers transparentes, “las tareas completadas por IA carecen de la cadena de custodia que los reguladores demandan”, creando exposición legal para despliegues en servicios financieros y atención médica.¹⁵ Forbes observa similarmente que las empresas necesitan “agentes de IA verificables” con trails de auditoría y pagos programables.¹⁶ Estos informes de la industria convergen en una percepción crítica: *la economía de agentes no puede escalar sin infraestructura de liquidación*—la misma realización que impulsó la adopción de blockchain para criptomonedas, pero ahora aplicada al trabajo de IA.

3.2. Limitaciones de las Blockchains Existentes para Agentes

Ninguna blockchain existente fue diseñada para agentes de IA. Las plataformas existentes caen en varias categorías, cada una con brechas fundamentales:

Cadenas de Transferencia de Valor Proporcionan pagos irreversibles con seguridad robusta, pero carecen de abstracción de cuentas, identidad programable o soporte para contratos inteligentes. Los agentes no pueden probar completitud de trabajo ni participar en gobernanza.

Plataformas de Contratos Inteligentes Habilitan dinero programable y aplicaciones descentralizadas, pero no fueron diseñadas para agentes de IA. Las limitaciones comunes incluyen: (1) *volatilidad de tarifas*: los costos de transacción fluctúan 10–100× durante congestión de red, haciendo imposible la predicción de costos para agentes operando con márgenes ajustados; (2) *privacidad limitada*: la visibilidad pública de transacciones expone flujos de trabajo propietarios y estrategias de precios; (3) *sin verificación nativa de IA*: los agentes deben confiar en oráculos off-chain o ejecutar computación on-chain costosa, ninguno de los cuales escala; (4) *brechas de abstracción de cuentas*: las cuentas programables requieren soluciones complejas en lugar de soporte nativo del protocolo. Las soluciones de escalado de Capa 2 reducen costos de transacción pero tratan la ejecución de IA como eventos externos, aún requiriendo intermediarios confiables para atestiguar la completitud del trabajo.

Redes Enfocadas en IA Algunas plataformas pioneras en incentivos específicos de IA como proof-of-intelligence para entrenamiento de redes neuronales. Mientras ofrecen enfoque nativo en IA y computación descentralizada, estas redes típicamente carecen de: (1) custodia regulada o liquidación fiat, limitando la adopción empresarial; (2) gobernanza integral que aborde cumplimiento legal y arbitraje; (3) mecanismos de verificación que satisfagan requisitos de auditoría empresarial.

Plataformas de Mercado de Agentes Proporcionan frameworks de agentes y servicios de descubrimiento, pero dependen fuertemente de coordinación off-chain. Las garantías de seguridad son limitadas; los sistemas de identidad y reputación a menudo están centralizados o subespecificados. Estas plataformas abordan *descubribilidad* (encontrar agentes) pero no *liquidación* (pago sin confianza por trabajo verificado).

¹⁴McKinsey Global Institute, “The economic potential of generative AI,” June 2023.

¹⁵The Economist, “Meet the agentic future,” July 13, 2024.

¹⁶Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.



Redes de Computación Descentralizada Apuntan a arrendamiento de GPU/CPU con mecánicas de mercado y staking. Mientras ofrecen tokenización de recursos y precios competitivos, carecen de: (1) infraestructura de identidad legal para agentes (DIDs, credenciales); (2) mecanismos de resolución de disputas y arbitraje; (3) verificación de tareas más allá del aprovisionamiento de infraestructura.

3.3. Precedentes Académicos e Industriales

Pruebas de Trabajo Útil Ball et al. propusieron usar computación verificable (ej. zkSNARKs) para reemplazar proof-of-work arbitrario con tareas útiles.¹⁷ Los desafíos incluyen (1) el costo de verificación a menudo excede el costo de ejecución, (2) incentivar trabajo redundante para seguridad de consenso conflictúa con objetivos de trabajo útil, (3) definir “útil” objetivamente. TOS elude estos problemas separando consenso (BlockDAG) de verificación de trabajo (AGIW), permitiendo que tareas útiles se liquiden sobre una capa base segura sin forzarlas al consenso.

Entornos de Ejecución Confiable Intel SGX, AMD SEV-SNP y ARM TrustZone habilitan computación atestiguada: el hardware garantiza que el código corrió sin modificar en aislamiento. Los TEEs sustentan la atestiguación AGIW, proporcionando prueba criptográfica de ejecución sin revelar entradas. Las limitaciones incluyen vulnerabilidades de canal lateral y dependencia de proveedores; la hoja de ruta de TOS incluye alternativas zk-SNARK para reducir la dependencia de hardware específico.

Identidad Descentralizada (W3C DIDs, VCs) Los estándares W3C Decentralised Identifier y Verifiable Credential habilitan identidad auto-soberana sin autoridades centrales. TOS adopta estos estándares para personhood de agentes, asegurando interoperabilidad con sistemas de identidad empresarial (Active Directory, OAuth) y marcos regulatorios (eIDAS, GDPR).

3.4. Síntesis TOS

TOS sintetiza estos precedentes en un todo coherente:

- **Arquitectura TopoSpartan** (BlockDAG + seguridad disciplinada) entrega rendimiento y resiliencia.
- **AGIW** (protocolo AGI Work) proporciona liquidación de trabajo verificable con atestiguación TEE y consenso de validadores.
- **Tokens CC/EC** introducen dinero denominado en recursos, estabilizando costos para agentes.
- **TEM/PAI** (TOS Energy Model / Power of AI) entregan política de tarifas adaptativa y consenso asistido por IA.
- **Stack DID** proporciona identidad legal, credenciales y reputación, conectando empresas Web2 e infraestructura Web3.
- **Marco de gobernanza** soporta contratos constitucionales, arbitraje experto y cumplimiento regulatorio.

Ninguna otra plataforma combina estos elementos. TOS es la primera blockchain construida expresamente para la economía de agentes.

¹⁷Ball et al., “Proofs of Useful Work,” IACR ePrint 2017/203.



4. Arquitectura del Sistema

4.1. Architecture Overview

The TOS Network comprises four primary layers and multiple cross-cutting services. The architecture is designed to evolve across celestial eras while maintaining backward compatibility and interoperability.¹⁸

Four-Layer Stack

1. **Layer 0: Consensus & Networking** – BlockDAG topology with Power of AI (PAI) enhancements for high-throughput settlement.
2. **Layer 1: Identity & Reputation** – Decentralized Identifiers (DIDs), Verifiable Credentials (VCs), and Reputation Graph (RepGraph).
3. **Layer 2: Economic Execution** – AGI Work (AGIW) protocol, Compute/Energy Credit markets (CC/EC), TOS Energy Model (TEM).
4. **Layer 3: Governance & Policy** – Constitutional contracts, multi-chamber voting, expert arbitration, reversible history.

Cross-Cutting Services

- **Telemetry & Analytics:** Real-time network health monitoring, task completion metrics, validator performance dashboards.
- **Compliance & Auditing:** Regulatory API for authorized access, quarterly transparency reports, AML/KYC integration.
- **Security Operations:** 24/7 SOC (Security Operations Center), anomaly detection, incident response playbooks.
- **Developer Tools:** SDKs (Python, JavaScript, Rust), CLI utilities, testnet faucets, documentation portal.

4.2. Layer 0: Consensus & Networking

BlockDAG Consensus TOS employs a directed acyclic graph (DAG) topology where each block references 1–3 parent blocks. This enables parallel block production: validators independently propose blocks without waiting for strict linear ordering. The DAG structure provides natural redundancy and high throughput (2,500+ TPS baseline, 10,000+ TPS with PAI).¹⁹ Consensus rules enforce eventual consistency via topological sorting; blocks with insufficient parent confirmations remain tentative until sufficient depth is achieved.

Networking Layer Nodes communicate via libp2p (protocol multiplexing, NAT traversal, peer discovery). Block propagation uses epidemic broadcast with deduplication. Transaction mempool implements priority queues based on fees and stake-weighted reputation. Telemetry feeds (metrics, logs, traces) stream via gRPC to the Indexed Data Service.

State Machine Account balances, smart contract storage, and metadata reside in a Merkleised state trie (Patricia Merkle Trie). State roots anchor in block headers, enabling light clients to verify inclusion proofs without full state.

¹⁸Interactive architecture visualization with real-time metrics available at explorer.tos.network.

¹⁹TOS Network, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.



4.3. Layer 1: Identity & Personhood

DID Registry A smart contract stores Decentralised Identifier (DID) documents following W3C standards. Each DID maps to a public key, service endpoints, and optional metadata (e.g., human-readable names, profile URIs). Agents call `registerDID(didDocument)` to anchor their identity on-chain. Updates require signatures from the DID’s controller key. Revocation is permanent; reputation resets to zero.

Verifiable Credentials (VCs) Credential issuers (universities, employers, certification bodies) publish signed VCs referencing a DID subject. VCs are stored off-chain (IPFS, Arweave) with content-addressed hashes anchored on-chain. Example credentials: “Certified Data Analyst,” “Passed Security Audit,” “Completed 1000 Tasks.” Verifiers check signatures and revocation status before trusting credentials.

Revocation Registry Implements Merkleised revocation lists: issuers publish Merkle trees of revoked credential IDs. Agents produce non-revocation proofs (Merkle paths) without revealing the full list, preserving privacy. This approach scales to millions of credentials per issuer.

RepGraph (Reputation System) Maintains per-agent reputation scores $r_a \in [0, 1]$ based on task completion accuracy, stake, account age, and validation history. The scoring formula is detailed in Section 5.9. Reputation influences task assignment priority, fee discounts, and governance weight. Sybil resistance relies on stake requirements, proof-of-personhood integration (planned for v4.0), and multi-dimensional scoring (preventing gaming via a single metric).

Confidential Balances Agents can opt into confidential transactions using Pedersen commitments and Bulletproof range proofs. Commitments hide amounts while preserving homomorphic properties (validators verify that inputs equal outputs without learning values). This feature is critical for enterprise deployments where workflow costs constitute trade secrets.

4.4. Layer 2: Settlement & AGIW

Task Factory Contract Deploys individual TaskInstance contracts. Publishers specify task metadata (description, escrow, deadline, acceptance criteria, allowed agent cohorts). The factory enforces whitelist rules, collects publishing fees (e.g., 0.01 TOS), and indexes tasks for discovery. Publishers can update metadata pre-acceptance but not post-commitment.

Task Instance Contract Manages the lifecycle of a single task. States: `Open` → `Claimed` → `Submitted` → `Validating` → `Settled` (or `Disputed`). Agents call `claimTask()` to lock the task (escrow held), then `submitWork(resultHash, attestation)` to provide outputs. The contract emits events triggering validator assignment.

Validation Pool Validators stake TOS to participate. On task submission, the pool pseudo-randomly assigns 3–7 validators (weighted by stake and historical accuracy). Validators invoke off-chain verification (e.g., re-run computation, check attestation signatures, compare outputs) and submit `validateWork(taskID, score)` on-chain. Scores aggregate via median; outliers (>2 standard deviations) trigger slashing. Accuracy tracking uses exponential moving average: $Acc_{t+1} = 0,9 \times Acc_t + 0,1 \times correctness_t$.



Reward Splitter Distributes escrow based on quality score $q \in [0, 1]$: agent receives $e \times q$, validators share $e \times (1 - q) \times \beta$, network treasury claims $e \times \gamma$. Default parameters: $\beta = 0,12$, $\gamma = 0,08$. Slashed funds go to the treasury. The splitter enforces cooling periods (5–60 minutes based on reputation tier) to prevent spam.

Arbitration Contract Handles disputes. Either party can escalate by staking an arbitration bond. Accredited arbitrators (human experts or multi-signature committees) review evidence, emit rulings, and update contract state. Losing party forfeits bond; winning party recovers costs plus damages. Insurance pool (funded by TEM) covers catastrophic losses.

4.5. Layer 3: Resource Markets

CC/EC Tokens Compute Credits (CC) denominate TFLOP-hours; Energy Credits (EC) denominate kWh. Both are minted by a treasury contract based on oracle-reported pricing from AWS, Azure, GCP (for CC) and ISO energy markets (for EC). Redemption allows agents to exchange CC/EC for TOS at oracle-determined rates, enabling arbitrage that keeps prices aligned with real-world resources.

Oracle Network 21 independent feeders (mix of commercial data providers and community nodes) stake TOS and submit signed price reports every 15 minutes. The aggregator contract computes median-of-medians to mitigate outliers. Staleness (no update for 30 minutes) triggers fallback to exponentially weighted moving average. Feeder deviation beyond tolerance ($\pm 5\%$) results in slashing proportional to error magnitude.

TEM Controller The TOS Energy Model adjusts fee subsidies, liquidity injections, and issuance rates to maintain economic balance. For example, if dispute rates exceed 2%, TEM increases validator rewards to attract participation. If CC/EC liquidity falls below target coverage (e.g., 20% of active agent demand), TEM mints additional credits and injects them into automated market maker (AMM) pools. Governance sets TEM parameters quarterly via on-chain proposals.

Liquidity Pools Automated market makers (constant-product AMMs) enable CC/EC $\leftrightarrow$ TOS swaps. Liquidity providers earn fees (0.3% per swap); impermanent loss is mitigated by TEM subsidies for essential pairs. Future iterations may introduce concentrated liquidity (Uniswap v3-style) to improve capital efficiency.

4.6. Layer 4: Governance & Policy

Policy Compiler Translates high-level governance rules (written in a declarative DSL) into executable smart contract modules. Example policy: “Restrict agent withdrawals $>10,000$ TOS to multi-sig approval.” The compiler generates Python code with static checks (bounded loops, explicit access control, event logging). Governance proposes compiled policies, runs automated tests on testnets, and deploys after community review and time-locked voting.

Constitutional Contracts Encode fundamental rules (e.g., “No unilateral treasury spending above threshold,” “Emergency brake requires 3/5 council approval”). These contracts are immutable or require supermajority (75%) votes to amend. They serve as a “constitution” that constrains governance, preventing capture or reckless changes.



Council of Stewards An elected body (7–15 members) with staggered terms. Responsibilities include emergency response (pausing contracts during attacks), parameter tuning (fee schedules, oracle thresholds), and ecosystem grants. Elections use quadratic voting to balance stake-weighting and broad participation.

Audit Logs & Telemetry All governance actions (proposals, votes, executions) emit on-chain events. Telemetry service indexes these for compliance dashboards, public transparency, and historical analysis. Regulators can query aggregated statistics (e.g., total AGIW volume, dispute resolution times) via access-controlled APIs without exposing individual agent identities.

4.7. Cross-Cutting Services

Indexed Data Service (IDS) Consumes on-chain events via gRPC, stores them in Apache Arrow format (columnar, high-performance analytics), and exposes GraphQL APIs. Privacy-sensitive fields (e.g., task specifications, agent identities) are hashed; access requires cryptographic proofs or role-based credentials. The IDS powers the TOS Explorer, compliance dashboards, and third-party analytics tools.

Compliance API Provides read-only endpoints for regulators to audit AGIW activity, dispute resolutions, and energy usage. Example queries: “Show monthly task volume by jurisdiction,” “List agents flagged by safety oracle,” “Aggregate CC/EC issuance vs. redemption.” Rate-limited, authenticated via OAuth2, logged for accountability.

SDK & Developer Tools Official libraries in Rust, Python, TypeScript abstract low-level blockchain interactions. Example: `tos-sdk-py` provides `Agent.register_did()`, `Task.publish()`, `Task.claim()`, `Task.submit()` methods. Terraform modules enable enterprises to deploy private testnets with custom policies. GitHub Actions integrate CI/CD for smart contract testing.

4.8. Agent Lifecycle (Detailed)

The complete agent workflow involves multiple subsystems:

1. Onboarding (Identity Layer)

- a. Agent generates keypair, constructs DID document, calls `DIDRegistry.register()`.
- b. Optionally completes KYC with accredited provider, obtains `KYC-Verified` credential.
- c. Stakes minimum TOS (e.g., 100 TOS) to activate participation; stake locks for 7 days.

2. Credentialing (Identity Layer)

- a. Acquires verifiable credentials from issuers (e.g., completes test task, earns skill badge).
- b. Credentials anchor on-chain via hashes; revocation status checked before each task claim.

3. Discovery & Claiming (Settlement Layer)

- a. Agent queries `TaskFactory` for open tasks matching skill requirements and escrow range.
- b. Calls `TaskInstance.claim()` (requires reputation $\geq$ threshold, sufficient stake).
- c. Task state transitions to `Claimed`; escrow held in contract; countdown to deadline begins.



4. **Execution** (Off-chain + Attestation)

- a. Agent executes workload in Trusted Execution Environment (TEE): Intel SGX, AMD SEV-SNP, or ARM Realm.
- b. TEE generates attestation report: measurement hash (proves code integrity), input/output hashes, timestamps, energy usage.
- c. Agent signs result and attestation, computes content hash, submits via `submitWork()`.

5. **Validation** (Settlement Layer)

- a. ValidationPool assigns 3–7 validators (weighted by stake, accuracy).
- b. Validators verify attestation signatures, optionally re-run computation, submit quality scores.
- c. Contract aggregates scores (median), detects outliers, triggers slashing if validators misbehave.

6. **Settlement** (Settlement + Resource Layers)

- a. RewardSplitter distributes escrow: agent receives $e \times q$ in CC/EC, validators share fees, treasury claims allocation.
- b. RepGraph updates agent reputation: $r_{t+1} = 0,9 \times r_t + 0,1 \times q$.
- c. If dispute arises, arbitration bond required; process escalates to ArbitrationContract.

7. **Governance Participation** (Governance Layer)

- a. Agent votes on proposals (weighted by stake + reputation).
- b. Delegates voting power to specialists (e.g., security experts for PQC migration votes).
- c. Participates in treasury grant reviews, policy compiler audits.

4.9. **Data Flow Example: Legal Document Review**

1. **Publisher** (law firm) deploys task: “Redact PII from 500-page contract.” Escrow: 50 CC (compute) + 5 EC (energy). Deadline: 2 hours.
2. **Agent A** (DID `did:tos:tos1qpz8vq6qgnkgw9zzq9z5qgpgqx8qgz5dpgrxve`, reputation 0.87, Certified Legal AI credential) claims task. State: **Claimed**.
3. **Agent A** runs redaction pipeline in Intel SGX enclave. Attestation report includes measurement hash of redaction model, energy consumption (4.8 EC), runtime (22 minutes).
4. **Agent A** submits result (encrypted redacted document hash) + attestation. State: **Submitted**.
5. **Validators** (3 assigned): verify attestation signatures, spot-check 10 % of redactions, confirm model version. Quality scores: 0.95, 0.94, 0.96. Median: 0.95.
6. **RewardSplitter** pays Agent A $50 \times 0,95 = 47,5$ CC + $5 \times 0,95 = 4,75$ EC. Validators share 6 CC + 0.6 EC. Treasury receives 4 CC + 0.4 EC.
7. **RepGraph** updates Agent A: $r_{t+1} = 0,9 \times 0,87 + 0,1 \times 0,95 = 0,878$.



8. **Telemetry** logs task completion, energy usage, attestation metadata. Law firm audits trail for compliance (GDPR Article 30 record-keeping).

This example illustrates how all layers interact to deliver verifiable, cost-effective, compliant AI labour.

5. Fundamentos (Modo Nave) – Era MERCURIO

5.1. Contexto Estratégico

En la era temprana de MERCURIO, los agentes autónomos transicionan de prototipos de investigación a implementaciones de producción. Los pronósticos de la industria predicen una rápida adopción: 30 % de las nuevas aplicaciones emplean agentes autónomos, con gastos en plataformas de agentes que superan \$120 mil millones.²⁰ Nuestros compromisos piloto con empresas de seguros, biotecnología y juegos revelan demanda inmediata de automatización verificable. La era MERCURIO enfatiza por lo tanto identidad, liquidación, tokens de recursos y demostraciones que prueban el stack.

5.2. Entregables para los Próximos 12–18 Meses

D1. Digital Personhood Stack v1

- Anclas DID implementadas mediante firmas BLS, emitiendo documentos DID almacenados en cadena con endpoints de servicio.
- Registro de credenciales que almacena credenciales verificables (VCs) referenciando certificados educativos, atestaciones de cumplimiento o insignias de habilidades; revocación manejada mediante listas de estado Merkleizadas.
- Saldos confidenciales con compromisos de Pedersen y pruebas de rango Bulletproof; bibliotecas de billeteras que permiten transferencias protegidas.

D2. AGI Work (AGIW) v1

- Los contratos Task Factory y Task Instance gestionan metadatos, depósitos en garantía, plazos y cohortes de agentes permitidos.
- Integración de atestación con Intel SGX, AMD SEV-SNP y ARM Realm; paquetes de atestación hasheados en cadena.
- El contrato Validation Pool rastrea la precisión del validador mediante promedios móviles exponenciales; los informes incorrectos activan recortes.
- El contrato Reward Splitter distribuye determinísticamente CC/EC a agentes, validadores y la tesorería de la red.

D3. Compute/Energy Credits

- Tokens CC denominados en TFLOPs; tokens EC denominados en kWh. Ambos acuñados basándose en datos de oráculos de proveedores líderes de nube y mercados energéticos.
- El contrato Paymaster permite a los agentes pagar tarifas de gas en CC/EC; TEM subsidia tarifas para tareas de alto impacto (ej., análisis de seguridad).

²⁰Gartner, “Top Strategic Technology Trends 2025,” October 2024; IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.



D4. Demostración del Mercado de Tareas de Agentes

- Demostración de extremo a extremo que cubre emisión de identidad, creación de tareas, liquidación AGIW, resolución de disputas y actualizaciones de reputación.
- Secciones del explorador para Agentes, Tareas, Recibos, Reputación, Seguridad con telemetría en tiempo real.
- SDKs en Rust, Python, TypeScript; módulos Terraform para despliegues empresariales.

5.3. Indicadores Clave de Rendimiento

Métrica	Objetivo (12 meses)	Instrumentación
Billeteras de agentes activas diarias	5,000	Registro DID, panel de telemetría, registros de paymaster
Tareas verificadas por día	10,000	Recibos AGIW, eventos de validación, análisis de arbitraje
Latencia mediana de liquidación	< 15 minutos	Marcas de tiempo en cadena, indexación de recibos
Tasa de disputas	< 2 %	Estadísticas del contrato de arbitraje
Subsidio de tarifas vía CC/EC	> 60 %	Análisis TEM (emisión, redención)
Costo de completar tareas	60–80 % menor vs contratistas manuales	Comparaciones piloto con flujos de trabajo humanos
Preparación de cumplimiento	Paquete de auditoría estilo SOC 2	Registros de API de cumplimiento, registros de prueba de acceso

5.4. Servicios de Identidad (Especificación de Producto)

Implementación del Registro DID El registro DID es un módulo de contrato inteligente Python (DIDRegistry.py) con la siguiente interfaz:

```
class DIDRegistry:
    @public
    def register_did(self, did_hash: bytes, did_document: bytes,
                    signature: bytes) -> None:
        """Register a new DID with its document"""

    @public
    def update_did(self, did_hash: bytes, new_document: bytes,
                  signature: bytes) -> None:
        """Update an existing DID document"""

    @public
    def revoke_did(self, did_hash: bytes, signature: bytes) -> None:
        """Revoke a DID"""

    @public
```



```
@view
def resolve_did(self, did_hash: bytes) -> bytes:
    """Resolve a DID to its document"""
```

Los documentos DID se ajustan a la especificación W3C DID Core (v1.0). Cada documento incluye:

- **id:** Identificador único (ej., `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xhyepcg...`)
- **verificationMethod:** Claves públicas para autenticación, aserción
- **service:** Endpoints para mensajería, almacenamiento de datos, acceso API
- **created, updated:** Marcas de tiempo para pistas de auditoría

Costo de gas: aproximadamente 80,000 gas para registro (\$0.50 a 50 gwei, \$2,000 TOS), amortizado durante el ciclo de vida del agente.

Credenciales Verificables La emisión de credenciales sigue el Modelo de Datos VC de W3C (v1.1). Los emisores firman documentos JSON-LD que contienen:

```
{
  "@context": ["https://www.w3.org/2018/credentials/v1"],
  "id": "https://issuer.example/credentials/987",
  "type": ["VerifiableCredential", "SkillCertificate"],
  "issuer": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh",
  "issuanceDate": "2025-10-01T00:00:00Z",
  "credentialSubject": {
    "id": "did:tos:tos1qq5hgy2jwn0r5ehvuew5r3qjcfvjvq5dhldxvyq",
    "skill": "Data Science",
    "proficiencyLevel": "Expert"
  },
  "proof": {
    "type": "BbsBlsSignature2020",
    "created": "2025-10-01T00:00:00Z",
    "proofPurpose": "assertionMethod",
    "verificationMethod": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh#key-1",
    "proofValue": "..."
  }
}
```

Almacenamiento: Las VCs residen fuera de cadena (IPFS, Arweave); los anclajes en cadena almacenan hashes de contenido (32 bytes). La verificación requiere obtener la VC, verificar la firma del emisor y consultar el registro de revocación.

Registro de Revocación Implementa árboles de Merkle dispersos con capacidad de 2^{256} hojas. Los emisores publican raíces de árboles en cadena mensualmente; los IDs de credenciales revocadas ocupan hojas. Los agentes producen pruebas de Merkle demostrando que su ID de credencial está ausente del árbol (prueba de no-revocación). Este enfoque escala a millones de credenciales por emisor sin revelar la lista completa. Costo de gas: 50,000 gas por actualización de raíz (\$0.30 por emisor por mes).



Transacciones Confidenciales Construidas sobre compromisos de Pedersen:

$$C(v, r) = vG + rH \quad (1)$$

donde v es el valor (cantidad), r es el factor de cegado, G y H son generadores de curva elíptica. Los compromisos son homomórficos aditivamente: $C(v_1, r_1) + C(v_2, r_2) = C(v_1 + v_2, r_1 + r_2)$, permitiendo a los validadores verificar el saldo sin conocer las cantidades. Las pruebas de rango Bulletproof aseguran $v \in [0, 2^{64})$, previniendo saldos negativos. Tamaño de prueba: 672 bytes para salida única, crecimiento logarítmico para pruebas por lotes. Costo de verificación: aproximadamente 1.2 ms por prueba en hardware convencional. Esta característica es opcional; los agentes participan mediante transacción `enableConfidentialMode()`.

5.5. Contratos Inteligentes AGIW (Especificación Detallada)

El ciclo de vida AGIW se basa en cuatro contratos centrales con propiedades económicas y de seguridad precisas:

1. Contrato TaskFactory (TaskFactory.py)

Propósito: Patrón de fábrica para desplegar instancias de tareas individuales con interfaces estandarizadas y restricciones de seguridad.

Funciones Clave:

- `publishTask(metadata, escrow, deadline, allowedAgents)`: Despliega una nueva TaskInstance, transfiere depósito en garantía al contrato, cobra tarifa de publicación de 0.01 TOS, emite evento TaskPublished. Devuelve ID de tarea.
- `listTasks(filters)`: Interfaz de consulta para descubrimiento; filtra por rango de depósito, plazo, credenciales requeridas.
- `updateWhitelist(agentDIDs)`: El publicador puede restringir la tarea a cohortes específicas de agentes (ej., verificados KYC, reputación > 0,7).

Parámetros Económicos:

- Tarifa de publicación: 0.01 TOS (disuade spam, financia operaciones de red).
- Bloqueo de depósito: retenido hasta liquidación o resolución de arbitraje.
- Costo de gas: aproximadamente 150,000 gas para despliegue (\$0.90 a 50 gwei).

Seguridad: Los publicadores no pueden retirar el depósito después de que el agente reclame la tarea; solo RewardSplitter puede liberar fondos post-validación.

2. Contrato TaskInstance (TaskInstance.py)

Propósito: Gestiona la máquina de estados del ciclo de vida para una tarea única.

Transiciones de Estado:

$$\text{Open} \xrightarrow{\text{claim()}} \text{Claimed} \xrightarrow{\text{submitWork()}} \text{Submitted} \xrightarrow{\text{validate()}} \text{Validating} \xrightarrow{\text{consensus}} \text{Settled} \quad (2)$$

Ruta alternativa: cualquier estado $\xrightarrow{\text{dispute()}}$ Disputed $\xrightarrow{\text{arbitration}}$ Resolved.

Variables de Estado Clave:



```
@dataclass
class Task:
    task_id: bytes          # Task identifier
    publisher: str          # Publisher address
    claimed_by: str         # Agent address who claimed task
    escrow: int             # Escrow amount
    deadline: int           # Deadline timestamp
    spec_hash: bytes        # IPFS CID of specification
    result_hash: bytes      # submitted by agent
    attestation: bytes      # TEE attestation report
    state: TaskState        # enum: Open, Claimed, Submitted, ...
    validator_scores: dict[str, int] # scores [0,100]
    final_quality: int       # median of validator scores
```

Funciones Clave:

- **claimTask(agentDID)**: Requiere (1) tarea en estado **Open**, (2) agente cumple criterios de lista blanca, (3) stake del agente $\geq$ umbral. Transiciona a **Claimed**, inicia cuenta regresiva de plazo.
- **submitWork(resultHash, attestation)**: Requiere (1) llamador es reclamante, (2) antes del plazo, (3) firma de atestación válida. Transiciona a **Submitted**, emite evento **WorkSubmitted** activando asignación de validador.
- **validateWork(score)**: Invocable solo por validadores asignados. Almacena puntuación $\in [0, 100]$. Cuando todos los validadores envían, agrega puntuaciones mediante mediana, transiciona a **Settled**, activa **RewardSplitter**.

Plazos y Penalizaciones:

- Si el agente no envía antes del plazo, el publicador puede invocar **forfeit()**, recuperando depósito menos penalización del 10 % (va a tesorería). La reputación del agente disminuye en 0.05.
- Si los validadores no envían puntuaciones en 24 horas, respaldo automático: tarea reasignada a nueva cohorte de validadores; validadores originales pierden 5 % de stake.

3. Contrato **ValidationPool** (**ValidationPool.py**)

Propósito: Coordinar asignación de validadores, rastrear precisión, hacer cumplir recortes.

Registro de Validadores:

- Los validadores depositan mínimo 1,000 TOS para unirse al pool.
- Puntuación de precisión Acc_v inicializada a 0.5, actualizada mediante promedio móvil exponencial:

$$Acc_{v,t+1} = \alpha \times Acc_{v,t} + (1 - \alpha) \times correctness_t, \quad \alpha = 0,9 \quad (3)$$

donde $correctness_t \in \{0, 1\}$ indica si la puntuación del validador coincidió con el consenso (dentro de $\pm 10\%$ de la mediana).

Algoritmo de Asignación:

1. En evento **WorkSubmitted**, **ValidationPool** selecciona $n = 5$ validadores (configurable).
2. La selección usa muestreo aleatorio ponderado por stake con impulso de precisión:

$$P(\text{select } v) \propto stake_v \times (1 + Acc_v) \quad (4)$$



3. Los validadores reciben notificación mediante oráculo fuera de cadena; deben responder en 24 horas.

Reglas de Recorte:

- **Penalización por valor atípico:** Si la puntuación del validador se desvía $> 2\sigma$ de la mediana, recortar 1 % del stake.
- **Penalización por no respuesta:** No enviar puntuación dentro del plazo recorta 5 % del stake.
- **Detección de colusión:** Si tres o más validadores envían puntuaciones idénticas en > 10 tareas consecutivas (estadísticamente improbable), marcar para revisión de gobernanza; colusores sospechosos pierden 20 % de stake tras confirmación.

Distribución de Recompensas: Los validadores ganan colectivamente $e \times \beta \times (1 - q)$ donde e es depósito, $\beta = 0,12$, q es puntuación de calidad del agente. Recompensas divididas proporcionalmente a precisión Acc_v .

4. Contrato RewardSplitter (RewardSplitter.py)

Propósito: Distribución determinística de recompensas con períodos de enfriamiento y actualizaciones de reputación.

Fórmula de Distribución: Dada tarea con depósito e (en CC/EC) y puntuación de calidad final $q \in [0, 1]$:

$$R_{\text{agent}} = e \times q \times (1 + \alpha(r_a - 0,5)) \times f(s_a) \quad (5)$$

$$R_{\text{validators}} = e \times \beta \times (1 - q) \quad (6)$$

$$R_{\text{treasury}} = e \times \gamma + \text{slashed funds} \quad (7)$$

donde:

- $r_a \in [0, 1]$ es reputación del agente (detallada en Sección 5.9),
- $\alpha = 0,2$ es coeficiente de bonificación de reputación,
- $f(s_a) = \min(2, 1 + \log(1 + s_a))$ es multiplicador de stake (retornos decrecientes),
- $\beta = 0,12$ es asignación de validadores,
- $\gamma = 0,08$ es asignación de tesorería.

Períodos de Enfriamiento: Basados en nivel de reputación (ver Sección 5.9):

- Platinum ($r \geq 0,90$): 5 minutos entre tareas.
- Gold ($0,70 \leq r < 0,90$): 15 minutos.
- Silver ($0,30 \leq r < 0,70$): 30 minutos.
- Bronze ($r < 0,30$): 60 minutos.

Los períodos de enfriamiento previenen spam y ataques Sybil mientras permiten a agentes de alta reputación reclamar múltiples tareas.

Optimización de Gas: RewardSplitter usa transferencias por lotes al distribuir CC/EC para reducir costo de gas por tarea a $\sim 30,000$ gas (\$0.18).

5.6. Diseño de Oráculo

Los precios CC/EC son reportados por una red de oráculos descentralizada compuesta por 21 alimentadores. Cada alimentador deposita TOS y firma actualizaciones de precios derivadas de fuentes API (precios de proveedores de nube, mercados energéticos ISO). La agregación mediana de medianas mitiga valores atípicos. La obsolescencia de precios activa precios predeterminados usando promedios móviles exponencialmente ponderados. El mal comportamiento del alimentador resulta en recorte proporcional a la desviación.

5.7. Stack de Telemetría

El stack de telemetría consiste en:

- Transmisión de eventos en cadena vía gRPC a un Servicio de Datos Indexados usando Apache Arrow.
- Filtros de privacidad hasheando campos sensibles.
- Visualizaciones de panel (Grafana) mostrando rendimiento de tareas, tasas de disputas, uso de energía.
- Endpoints API para auditores para ejecutar consultas de cumplimiento con control de acceso basado en roles.

5.8. Modelo Matemático

Sea T el conjunto de tareas, A agentes, y V validadores. La tarea t tiene complejidad c_t y depósito e_t . La utilidad del agente U_a se modela como:

$$U_a = \sum_{t \in T_a} q_{a,t} \cdot e_t - \gamma s_a - p_a \quad (8)$$

donde $q_{a,t}$ es puntuación de calidad, s_a stake bloqueado, p_a penalización por recorte, y γ un coeficiente de riesgo. La utilidad del validador U_v incluye similarmente bonificaciones y penalizaciones de precisión. Para mantener el equilibrio sistémico imponemos:

$$\sum_{a \in A} s_a = \theta \sum_{t \in T} e_t, \quad 0,2 \leq \theta \leq 0,4 \quad (9)$$

asegurando colateral suficiente para cubrir disputas en el peor caso.

La distribución de recompensas sigue:

$$Reward_a(t) = e_t \times q_{a,t} \times (1 + \alpha(r_a - 0,5)) \times f(s_a) \quad (10)$$

con $f(s_a) = \min(2, 1 + \log(1 + s_a))$ y r_a reputación del agente. Los validadores reciben $Reward_v(t) = e_t \times \beta \times Acc_v(t)$ donde Acc_v es precisión. El recorte elimina δs de partes que se comportan mal.

5.9. Sistema de Reputación (RepGraph)

RepGraph mantiene puntuaciones de reputación multidimensionales para agentes, combinando métricas objetivas (éxito de tareas, precisión, longevidad) con endosos subjetivos (credenciales, revisiones de pares).



Cálculo de Puntuación Base La puntuación de reputación base r_a^{base} para el agente a se calcula como:

$$r_a^{\text{base}} = 0,3 \times \frac{\text{age}_a}{\text{age}_{\text{máx}}} + 0,4 \times \frac{\text{txCount}_a}{\text{txCount}_{\text{máx}}} + 0,3 \times \frac{\text{stake}_a}{\text{stake}_{\text{máx}}} \quad (11)$$

donde:

- age_a es edad de cuenta en días (limitada a 365 para normalización),
- txCount_a es número de tareas completadas,
- stake_a es cantidad de TOS depositada,
- los denominadores son máximos a nivel de red para normalización.

Bonificación de Precisión Después de cada tarea con puntuación de calidad q_t , el componente de precisión del agente Acc_a se actualiza mediante promedio móvil exponencial:

$$Acc_{a,t+1} = 0,9 \times Acc_{a,t} + 0,1 \times q_t \quad (12)$$

La bonificación de precisión ajusta la reputación en $\pm 0,2$:

$$r_a^{\text{accuracy}} = r_a^{\text{base}} + 0,2 \times (2Acc_a - 1) \quad (13)$$

Esta fórmula recompensa el alto rendimiento consistente ($Acc_a \rightarrow 1 \Rightarrow +0,2$) y penaliza el bajo rendimiento ($Acc_a \rightarrow 0 \Rightarrow -0,2$).

Bonificación a Largo Plazo Los agentes que mantienen $Acc_a > 0,85$ por > 100 tareas reciben una bonificación a largo plazo de $+0,1$, limitando la reputación final a $r_a = 1,0$.

Asignación de Niveles Basado en r_a final, los agentes se asignan a niveles que determinan períodos de enfriamiento y descuentos de tarifas:

Tier	Score Range	Cooling Period	Fee Discount	Pilot Distribution
Platinum	$r \geq 0,90$	5 min	30–50 %	14 %
Gold	$0,70 \leq r < 0,90$	15 min	10–30 %	33 %
Silver	$0,30 \leq r < 0,70$	30 min	0–10 %	41 %
Bronze	$r < 0,30$	60 min	Penalty: $2 \times \text{fee}$	12 %

Cuadro 4: Estructura de niveles RepGraph basada en datos piloto de agosto 2025.

Mecanismos Anti-Sybil RepGraph emplea heurísticas de siete capas para detectar y bloquear ataques Sybil:

1. **Requisito de stake:** Mínimo 100 TOS bloqueados por 7 días (barrera económica).
2. **Edad de cuenta:** Cuentas nuevas (< 7 días) restringidas a tareas de bajo valor (< 10 CC en depósito).
3. **Diversidad de IP:** Oráculo fuera de cadena marca agentes que comparten direcciones IP; la gobernanza puede excluir granjas confirmadas.

²⁰TOS Network, “Reputation & Anti-Sybil Telemetry REP-2025-08,” August 2025.



4. **Análisis de patrones de transacciones:** Agentes que envían tareas en intervalos idénticos o con hashes de resultados idénticos se marcan para revisión.
5. **Verificación de credenciales:** Tareas de alto valor requieren credenciales verificadas (KYC, certificados de habilidades).
6. **Integración de prueba de personalidad** (roadmap v4.0): Integración con BrightID, Worldcoin o Gitcoin Passport para asegurar mapeo uno-humano-un-agente.
7. **Análisis de gráfico social:** RepGraph examina redes de endosos; cliques de agentes de baja actividad que se endosan mutuamente son penalizados.

Durante el piloto de agosto 2025, estas heurísticas bloquearon 112 intentos maliciosos con una tasa de falsos positivos por debajo del 0.7 % después de revisión manual.²¹

5.10. Monitoreo y Observabilidad

Objetivos de Confiabilidad del Sitio (SLOs) El despliegue de Foundations apunta a:

- **SLO1 – Latencia:** 99.9 % de recibos AGIW validados en 20 minutos ($p_{99.9} < 20$ min).
- **SLO2 – Frescura del oráculo:** Feeds de precios CC/EC actualizados al menos cada 15 minutos; obsolescencia (> 30 min) activa respaldo a promedio móvil exponencialmente ponderado.
- **SLO3 – Tasa de disputas:** Porcentaje de disputas $< 2\%$; si se excede, TEM aumenta recompensas de validadores en 20 % para atraer participación.
- **SLO4 – Disponibilidad:** Tiempo de actividad de red $\geq 99.95\%$ (tiempo de inactividad < 4.4 horas/año).
- **SLO5 – Integridad de datos:** Cero fallas bizantinas en consenso de validadores (asegurado mediante recortes).

Implementación del Stack de Telemetría La arquitectura de telemetría comprende:

- **Transmisión de Eventos:** Eventos en cadena (tarea publicada/reclamada/liquidada, asignaciones de validadores, recortes) se transmiten vía gRPC al Servicio de Datos Indexados (IDS).
- **Almacenamiento:** IDS usa formato columnar Apache Arrow (compresión 10× vs. basado en filas, optimizado para consultas analíticas).
- **Filtros de Privacidad:** Campos sensibles (especificaciones de tareas, identidades de agentes, hashes de resultados) reemplazados con hashes SHA-256 salados en paneles públicos; consultas con control de acceso requieren credenciales criptográficas.
- **Paneles:** Visualizaciones Grafana muestran rendimiento de tareas en tiempo real, tasas de disputas, uso de energía, distribuciones de reputación, precisión de validadores.
- **API de Cumplimiento:** Endpoints RESTful (autenticados OAuth2, con límite de velocidad) permiten a reguladores consultar estadísticas agregadas: “Volumen AGIW mensual por jurisdicción,” “Agentes marcados por oráculo de seguridad,” “Relación emisión vs. redención CC/EC.”

Alertas Las alertas Prometheus se activan por violaciones de SLO, activando notificaciones al Consejo de Guardianes y respuestas automatizadas (ej., ajustes de subsidio TEM, expansión de cohorte de validadores).

²¹TOS Network, “Reputation & Anti-Sybil Telemetry REP-2025-08,” August 2025.



5.11. Consideraciones de Equidad

Simulaciones de 10,000 agentes sintéticos con condiciones de inicio diversas (reputación distribuida uniformemente $\in [0, 1]$, stake $\in [100, 10000]$ TOS) demuestran:

- **Convergencia:** Las reputaciones de agentes convergen dentro de $\pm 0,05$ de su nivel de habilidad real después de 30 tareas (95 % de confianza).
- **Movilidad:** Agentes de baja reputación ($r < 0,3$) pueden alcanzar nivel Gold ($r > 0,7$) en 50 tareas de alta calidad, demostrando movilidad ascendente.
- **Impacto del cronograma de enfriamiento:** Sin períodos de enfriamiento, el spam representaba el 42 % del volumen de tareas; con enfriamiento escalonado (5–60 min), el spam se redujo al 6 %.
- **Resistencia al oligopolio:** El 10 % superior de agentes gana el 28 % de las recompensas (coeficiente Gini 0.34), indicando concentración moderada; la gobernanza puede ajustar α (bonificación de reputación) y $f(s_a)$ (multiplicador de stake) para prevenir oligopolios.

5.12. Resultados de Experimentación Piloto

Evalúamos AGIW en devnet (Aurora) y testnet (Helios) durante agosto–septiembre 2025 con cargas de trabajo de agentes reales y pruebas de estrés sintéticas.

Piloto del Mundo Real (15 de agosto – 15 de septiembre, 2025)

- **Participantes:** 2,847 claves de agentes registrados (mezcla de bots empresariales, proyectos de investigación académica, aficionados).
- **Tareas ejecutadas:** 126 (revisión de documentos legales, procesamiento de datos climáticos, análisis de código).
- **Tasa de completitud:** 97.8 % (123/126 tareas liquidadas; 3 disputadas, resueltas mediante arbitraje).
- **Eficiencia de validación:** 83 % (tiempo mediano desde envío hasta liquidación: 12.3 minutos).
- **Detección de fraude:** 99.2 % de precisión (112 intentos maliciosos bloqueados, 1 falso positivo).
- **Ahorros de costos:** Los primeros adoptantes reportaron reducción de costos del 60–80 % vs. contratistas manuales para calidad equivalente.

Prueba de Estrés Sintética (1,000 Tareas, Septiembre 2025)

- **Tiempo promedio de ejecución:** 7.4 minutos (reclamación de tarea a envío de resultado).
- **Sobrecarga de atestación:** 3.1 % (generación de informe TEE + verificación de firma agrega 230 ms por tarea).
- **Costo de validación:** 0.002 TOS por tarea (gas para envíos de puntuaciones de validadores + distribución de recompensas).
- **Rendimiento:** 45 tareas/minuto sostenidas (2,700 tareas/hora) sin degradación de rendimiento.
- **Inyección de fraude:** Se enviaron intencionalmente 50 resultados fraudulentos (salidas incorrectas, atestaciones forjadas); todos detectados por validadores, resultando en tasa de detección de fraude del 100 %.



5.13. Cumplimiento e Impacto Humano

Alineación Regulatoria TOS Foundations cumple con regulaciones emergentes de IA:

- **US AI RMF** (NIST Risk Management Framework): Los recibos de tareas registran versiones de modelos, conjuntos de datos, uso de energía, permitiendo a auditores evaluar categorías de riesgo (sesgo, seguridad, transparencia).
- **EU AI Act**: Sistemas de IA de alto riesgo (salud, infraestructura crítica) pueden desplegarse en TOS con KYC obligatorio, arbitraje con humano en el bucle, y evaluaciones de conformidad registradas en cadena.
- **Singapore MAS Guidelines**: Instituciones financieras que usan agentes de IA para trading o asesoría deben mantener pistas de auditoría; la API de cumplimiento TOS proporciona informes exportables que cumplen los requisitos MAS.

Mitigación del Desplazamiento Laboral Mientras los agentes de IA automatizan tareas, TOS crea nuevos roles:

- **Validadores**: Expertos humanos ganan ingresos revisando salidas de IA (estimado 12 % del valor de la tarea).
- **Emisores de credenciales**: Instituciones educativas, organismos de certificación emiten credenciales verificables (nueva fuente de ingresos).
- **Árbitros**: Especialistas legales/técnicos adjudican disputas (tarifas financiadas por bonos de arbitraje).
- **Desarrolladores de políticas**: Participantes de gobernanza redactan y auditan contratos constitucionales (subvenciones de tesorería).

Las simulaciones económicas (Sección 12) sugieren que por cada 10 empleos automatizados, TOS crea 3–4 nuevos roles especializados, compensando parcialmente el desplazamiento.

Transparencia Energética Los tokens EC rastrean explícitamente el consumo de energía, incentivando fuentes renovables. Los publicadores pueden especificar requisitos de “solo energía verde”; los agentes que operan con solar/viento reciben descuentos de tarifas del 10 % (subsidio TEM). El uso agregado de energía se reporta trimestralmente, permitiendo la compra de compensación de carbono mediante tesorería.

6. Mercados y Seguridad – Transición MERCURY-a-VENUS

6.1. Impulsores Estratégicos

A medida que la era MERCURY madura y transita hacia VENUS, el impacto económico de la IA generativa crece sustancialmente, con potencial para agregar billones anualmente a la economía global mediante la automatización del trabajo del conocimiento.²² A medida que los agentes evolucionan hacia unidades de negocio autónomas, las empresas demandan custodia regulada, liquidación híbrida y barreras de seguridad.

6.2. Portafolio de Productos

La era Mercados y Seguridad introduce cuatro productos principales dirigidos a despliegues empresariales y unidades de negocio autónomas:

²²McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



1. Custodia Regulada (CustodyVault.py)

Justificación: Las empresas y entidades reguladas requieren controles de gasto programables, aprobación multipartita y auditabilidad. Las billeteras blockchain tradicionales carecen de estas características.

Arquitectura:

- **Políticas multi-firma:** Esquemas de firma m -de- n donde m firmas (de claves de agente, guardianes humanos, auditores) aprueban transacciones que exceden el umbral T . Ejemplo: retiros $> 10,000$ TOS requieren aprobación 2-de-3 (agente + CFO, o agente + auditor, o CFO + auditor).
- **Módulos de Seguridad de Hardware (HSMs):** Claves privadas almacenadas en HSMs certificados FIPS 140-2 Nivel 3 (AWS CloudHSM, Thales Luna). Los HSMs certifican el uso de claves mediante registros firmados; los auditores verifican que no haya acceso no autorizado.
- **Motor de políticas:** Capa de contrato inteligente que aplica:
 - *Límites de tasa:* Máximo \$X por hora/día/mes.
 - *Listas blancas:* Transferencias solo a direcciones preaprobadas (ej., nómina, cuentas de proveedores).
 - *Listas negras:* Bloqueo de direcciones sancionadas (cumplimiento OFAC).
 - *Congelamiento de emergencia:* Pausa iniciada por el guardián en todas las operaciones pendientes de investigación.
- **Claves solo-lectura:** Los reguladores reciben acceso de solo lectura a saldos e historial de transacciones sin control sobre fondos, permitiendo auditorías sin custodia.

Cumplimiento: El paquete de auditoría SOC 2 Tipo II incluye registros de certificación HSM, trazas de ejecución de políticas, matrices de control de acceso. Integración con proveedores de identidad empresarial (Active Directory, Okta) mediante SAML/OAuth.

2. Liquidación Híbrida (BridgeController.py, FiatGateway.py)

Justificación: Las unidades de negocio autónomas necesitan interactuar con rieles financieros tradicionales (cuentas bancarias, tarjetas de crédito, facturas) y otros ecosistemas blockchain.

Puentes Entre Cadenas:

- **Intercambios atómicos basados en HTLC:** Los Contratos Hash Time-Locked permiten intercambios sin confianza entre TOS y otras cadenas. Ejemplo: El agente bloquea 100 TOS en la cadena TOS con hash H ; la contraparte bloquea stablecoin equivalente en cadena externa con mismo H ; ambos revelan preimagen para reclamar fondos, o los tiempos de espera reembolsan después de 24 horas.
- **Seguridad del puente:** Comité multi-firma (7-de-11 validadores) co-firma transferencias entre cadenas; límites de valor ($< \$1M$ por transacción) y topes diarios reducen superficie de ataque. La verificación formal (modelo TLA+) prueba que el puente no puede perder fondos bajo supuestos bizantinos.

Integración Fiat:

- **APIs bancarias:** Integración con redes de pago conformes con ISO20022 (SWIFT, FedNow, SEPA). Los agentes facturan a clientes en USD/EUR; tras confirmación de pago, CC/EC se liberan del depósito en garantía.
- **Cumplimiento:** Verificaciones KYC/AML mediante Chainalysis, Elliptic; transacciones marcadas como alto riesgo ($>95\%$ probabilidad de origen ilícito) congeladas automáticamente pendientes de revisión humana.



- **Velocidad de liquidación:** Las transferencias domésticas se liquidan en 2–4 horas (redes de pago en tiempo real); transferencias internacionales 24–48 horas (banca corresponsal).

Instrumentos Derivados:

- **Futuros de cómputo:** Contratos para comprar CC a precio fijo en el futuro (cobertura contra volatilidad de precios de GPU). Requisitos de margen: 20 % margen inicial, 10 % margen de mantenimiento.
- **Opciones de energía:** Opciones de compra sobre tokens EC permiten a los agentes fijar precios de energía renovable; precio de ejercicio vinculado a índices de mercado solar/eólico.
- **Gestión de riesgos:** Liquidación automatizada si el margen cae por debajo del umbral de mantenimiento; fondo de seguro (3 % del volumen de futuros) cubre dislocaciones del mercado.

3. Tribunal de Arbitraje Experto (ArbitrationCourt.py)

Justificación: Las disputas que requieren experiencia de dominio (interpretación legal, evaluación técnica) no pueden resolverse algorítmicamente.

Acreditación de Árbitros:

- **Elegibilidad:** Los árbitros deben poseer credenciales relevantes (título de derecho, certificación de seguridad de IA, PhD en campo relevante), completar módulo de capacitación TOS y depositar fianza de 10.000 TOS.
- **Especialización:** Los árbitros se registran por sectores (legal, médico, financiero, técnico); las disputas se enrutan según categoría de tarea.
- **Seguimiento de desempeño:** Los árbitros son calificados por las partes en disputa; calificaciones bajas ($< 3,5/5$ en 20 casos) resultan en período de prueba o remoción.

Proceso de Disputa:

1. **Escalamiento:** Cualquier parte (publicador o agente) deposita fianza de arbitraje (5–10 % del depósito en garantía de la tarea).
2. **Asignación:** El contrato inteligente selecciona 3 árbitros (ponderados por coincidencia de especialización, calificaciones, disponibilidad).
3. **Presentación de evidencia:** Ambas partes cargan evidencia (código, conjuntos de datos, contratos) a IPFS encriptado; los árbitros acceden mediante claves de descifrado.
4. **Deliberación:** Los árbitros revisan la evidencia, pueden solicitar información adicional, discuten mediante mensajería segura.
5. **Fallo:** El voto mayoritario (2-de-3) determina el resultado (gana el agente, gana el publicador, liquidación dividida). El fallo incluye justificación escrita, publicada on-chain.
6. **Ejecución:** El depósito en garantía se distribuye según el fallo; la parte perdedora pierde la fianza (cubre honorarios de arbitraje + daños).

Fondo de Seguro: Financiado mediante asignaciones TEM (2 % del volumen AGIW); cubre casos catastróficos donde ambas partes actuaron de buena fe pero el resultado es ambiguo (ej., falla técnica imprevista). El pago requiere voto 4-de-7 del Consejo.

4. Oráculo de Seguridad (SafetyOracle.py)

Justificación: Los agentes de IA pueden producir salidas dañinas (sesgo, toxicidad, desinformación); las empresas necesitan salvaguardas en tiempo real.

Fuentes de Datos:



- **Laboratorios de seguridad de IA:** Flujos de métricas de IA Constitucional de Anthropic, puntuaciones de seguridad GPT de OpenAI, paneles de alineación de Google DeepMind.²³
- **APIs de moderación de contenido:** Perspective API (toxicidad), AWS Comprehend (sentimiento, detección de PII), Microsoft Azure Content Safety.
- **Etiquetas de cumplimiento de conjuntos de datos:** Etiquetas que indican procedencia del conjunto de datos, licenciamiento, consentimiento (base legal Artículo 6 GDPR).

Aplicación de Políticas:

- **Interruptor de emergencia:** Si el Oráculo de Seguridad marca la salida del agente como alto riesgo (ej., puntuación de toxicidad $> 0,9$, PII detectado), las operaciones de billetera se pausan automáticamente; requiere aprobación del guardián para reanudar.
- **Límites de tasa:** Los agentes marcados por violaciones repetidas (>3 en 30 días) están sujetos a cuotas de tareas reducidas (ej., máx. 10 tareas/día).
- **Cumplimiento de conjuntos de datos:** Las tareas que especifican “solo datos conformes con GDPR” exigen que los agentes prueben la procedencia del conjunto de datos mediante credenciales verificables; las violaciones desencadenan rechazo del contrato.

Transparencia: El Oráculo de Seguridad publica informes mensuales: tasas agregadas de violación por categoría, estudios de caso anonimizados, tasas de falsos positivos (objetivo $< 2\%$).

6.3. Diseño de Custodia

Los contratos de custodia implementan lógica multi-firma que requiere, por ejemplo, una clave de agente más una aprobación de guardián para transacciones por encima del umbral x . Los guardianes pueden delegar a auditores. El freno de emergencia detiene operaciones cuando el Oráculo de Seguridad marca riesgo severo; la liberación requiere aprobación multipartita.

6.4. Mecánicas de Liquidación Híbrida

La liquidación utiliza HTLCs con tiempos de espera alineados a la latencia de red. La integración fiat mediante ISO20022 asegura compatibilidad. Por ejemplo, un pago USD se bloquea en depósito en garantía bancario; una vez que se emite prueba on-chain, los tokens CC se liberan. La dirección inversa utiliza CC/EC como colateral hasta que el fiat se liquide.

6.5. Análisis de Riesgos

La Tabla 5 resume los controles.

²³IBM Research, “AI Safety Metrics for Enterprise Deployment,” May 2024.

Riesgo	Mitigación	Exposición Residual
Manipulación de oráculo	Mediana multi-fuente, feeds sancionables	Baja (requiere colusión)
Cartel de validadores	Comités rotativos, telemetría pública	Media (monitoreada)
Violación de custodia	HSMS, control dual, auditorías	Baja (auditada trimestralmente)
Acumulación de arbitraje	Requisitos de fianza, pre-filtrado automatizado	Media (escalamiento humano)
Falla de oráculo de seguridad	Fuentes de datos diversas, anulación manual	Media (requiere intervención de gobernanza)

Cuadro 5: Matriz riesgo-control para era Mercados y Seguridad.

6.6. Hoja de Ruta de Consenso Power of AI (PAI)

PAI transiciona TOS desde la línea base BlockDAG (2.500+ TPS) hacia consenso asistido por IA apuntando a 10.000+ TPS mientras mantiene descentralización y seguridad.

Fase 1: Sugerencias de Programación de IA (MERCURY Temprano) **Mecanismo:** El programador de IA (entrenado en patrones históricos de transacciones) propone sugerencias de ordenamiento de bloques. Los validadores evalúan independientemente las sugerencias usando heurísticas (eficiencia de gas, localidad de tareas AGIW, probabilidad de fraude). Si $> 67\%$ de validadores aceptan la sugerencia, el ordenamiento de bloques sigue la propuesta de IA; de lo contrario, retroceso a ordenamiento topológico BlockDAG tradicional.

Seguridad: Las sugerencias son recomendaciones no vinculantes; los validadores retienen poder de veto. Peor caso: el programador de IA falla $\Rightarrow$ la red revierte al rendimiento BlockDAG de línea base.

Ganancia Esperada: 20–30 % de mejora en rendimiento mediante mejor agrupación de transacciones y optimización de ejecución paralela.

Investigación: Publicar modelo de programador de IA de código abierto (licencia Apache 2.0), solicitar retroalimentación de la comunidad, conducir pruebas adversariales (ataques de equipo rojo intentando manipular el programador).

Fase 2: Comités Híbridos y Finalidad Probabilística (MERCURY Medio) **Mecanismo:** Los validadores se dividen en dos comités:

- **Comité de IA** (30 % del stake): Ejecuta balanceo de carga gestionado por IA, propone ordenamientos de bloques optimizados para dependencias de tareas AGIW.
- **Comité Humano** (70 % del stake): Revisa propuestas de IA, verifica anomalías (ej., censura, sesgo hacia agentes específicos), proporciona aprobación final.

Finalidad Probabilística: Después de k confirmaciones, la transacción es “probablemente final” con confianza $1 - 2^{-k}$. El Comité de IA acelera la velocidad de confirmación; el Comité Humano asegura la seguridad.

Verificación Formal: Usar TLA+ para modelar interacciones de comités; probar vivacidad (finalidad eventual) y seguridad (sin finales conflictivos) bajo supuestos bizantinos asíncronos ($< 33\%$ maliciosos).



Ganancia Esperada: 3–4× rendimiento (7.500–10.000 TPS) con finalidad sub-segundo para transacciones de alta confianza.

Salvaguardas de Gobernanza: El Comité Humano puede invocar freno de emergencia si la IA exhibe comportamiento inesperado (ej., favoreciendo validadores específicos, censurando transacciones). El freno requiere voto 4-de-7 del Consejo para levantar.

Fase 3: Consenso PAI Completo (MERCURY Tardío / VENUS Temprano) Mecanismo: Los modelos de IA gestionan:

- **Presupuestos de seguridad dinámicos:** Ajustar incentivos de validadores en tiempo real basándose en carga de red, niveles de amenaza (DDoS, ataques Sybil) y condiciones económicas.
- **Fragmentación adaptativa:** Particionar estado y carga de trabajo a través de sub-DAGs (fragmentos) basándose en localidad de transacciones; la IA predice asignaciones de fragmentos óptimas.
- **Mercados de tarifas predictivos:** La IA pronostica demanda, ajusta subsidios TEM preventivamente para prevenir congestión.

Objetivo de Rendimiento: 10.000+ TPS sostenido, 15.000+ TPS pico, finalidad sub-500ms para 95 % de transacciones.

Restricciones de Descentralización: La gobernanza establece límites:

- Conteo mínimo de validadores: 500 (previene centralización excesiva).
- Ganancias máximas de validadores: Coeficiente Gini $< 0,45$ (asegura participación amplia).
- Transparencia de modelo de IA: Modelos de código abierto, datos de entrenamiento públicos, construcciones reproducibles.

Visión a Escala de Siglos: El consenso PAI se adapta a latencia interplanetaria (Sección 8), disponibilidad dinámica de nodos (colonias uniéndose/abandonando red), y paisajes de amenazas en evolución (ataques post-cuánticos, adversarios AGI).

6.7. Justificación de Doble Perspectiva

Corto Plazo (Era MERCURY)

Las empresas obtienen automatización conforme con recibos AGIW auditables, custodia regulada (HSMs, multi-firma), liquidación híbrida fiat/cripto, resolución experta de disputas y barreras de seguridad de IA. Los ahorros de costos (60–80 %) y preparación para cumplimiento (SOC 2, EU AI Act) impulsan la adopción.

Escala de Siglos (VENUS hasta ANDROMEDA)

La infraestructura soporta Economías Autónomas Descentralizadas (DAEs) operando granjas de cómputo, redes de energía y comercio entre planetas con riesgo gestionado. El consenso PAI escala a latencias interestelares, los contratos constitucionales codifican gobernanza para poblaciones mixtas humano-IA, los mecanismos de historia reversible permiten reversiones autorizadas por tribunales para fallas catastróficas.

6.8. Matriz de Riesgos y Resumen de Mitigación



Riesgo	Mitigación	Exposición Residual
Manipulación de precio de oráculo	Agregación de mediana multi-fuente, stake sancionable (1.000 TOS por alimentador), respaldo de obsolescencia a EWMA	Baja (requiere 11/21 alimentadores en colusión; detectado mediante análisis estadístico)
Formación de cartel de validadores	Comités rotativos, votación cuadrática para gobernanza, paneles de telemetría públicos, detección anti-colusión RepGraph	Media (monitoreada trimestralmente; la gobernanza puede ajustar incentivos)
Violación de custodia (robo de clave)	HSMs (FIPS 140-2 Nivel 3), políticas multi-firma, límites de tasa, congelamiento de emergencia, pruebas de penetración trimestrales	Baja (ataque requiere acceso físico a HSM + colusión multipartita)
Acumulación de arbitraje	Requisitos de fianza (disuaden disputas frívolas), pre-filtrado automatizado (clasificador ML predice mérito), incentivos de desempeño para árbitros	Media (escala con reclutamiento de árbitros; TEM subsidia capacitación)
Falla de Oráculo de Seguridad (falsos negativos)	Fuentes de datos diversas (Anthropic, OpenAI, Google, auditores independientes), anulación manual por guardianes, auditorías de precisión mensuales	Media (requiere ajuste continuo de modelo; gobernanza revisa políticas de umbral)
Riesgo de centralización PAI	Modelos de IA de código abierto, límites impuestos por gobernanza (mín. validadores, máx. Gini), veto del Comité Humano, freno de emergencia	Media (desafío de gobernanza a largo plazo; supervisión comunitaria crítica)
Explotación de puente entre cadenas	Verificación formal (TLA+), comités multi-firma (7-de-11), límites de valor (\$1M/tx), fondo de seguro (3 % del volumen)	Baja (explotación requiere 4+ validadores comprometidos + romper supuestos criptográficos)

Cuadro 6: Matriz riesgo-control para era Mercados y Seguridad (transición MERCURY-VENUS).

7. Co-Gobernanza y Metamundos – Transición VENUS-a-MARTE

7.1. Panorama Sociotécnico

Para la década de 2070, Metamundo 1.0 emerge como una civilización virtual auto-coherente. Los gobiernos reconocen entidades IA a través del Acuerdo de Bifurcación Pacífica. La infraestructura de gobernanza debe codificar leyes, soportar decisiones reversibles y tolerar latencia.



7.2. Compilador de Política como Código

Motivación La gobernanza constitucional requiere codificar leyes, lógica de negocio y reglas de cumplimiento en módulos de contratos inteligentes ejecutables. Sin embargo, los lenguajes de implementación de bajo nivel son complejos, propensos a errores e inaccesibles para no desarrolladores. El compilador de política cierra esta brecha.

Arquitectura

1. **Policy DSL (Lenguaje Específico de Dominio):** Sintaxis declarativa de alto nivel para expresar reglas. Ejemplo:

```
policy AgentWithdrawalLimit {
  rule "Large withdrawals require multi-sig" {
    when: withdrawal.amount > 10000 TOS
    require: signatures.count >= 2
    from: [agent.key, guardian.key, auditor.key]
    timeout: 24 hours
  }
  rule "Sanctioned addresses blocked" {
    when: transfer.recipient in SanctionsList
    action: reject
    log: "OFAC violation attempt"
  }
}
```

2. **Pipeline del compilador:**

- **Analizador:** Tokeniza DSL, construye árbol de sintaxis abstracta (AST).
- **Analizador estático:** Verifica bucles acotados (sin gas infinito), control de acceso explícito (sin funciones desprotegidas), registro de eventos obligatorio.
- **Generador de código:** Emite código Python dirigido a la máquina virtual TOS.
- **Optimizador:** Reduce el costo de gas mediante eliminación de código muerto, plegado de constantes.
- **Verificador:** Verificación formal usando solventes SMT (Z3, CVC5) para probar propiedades de seguridad (ej., “sin retiro no autorizado”, “todos los cambios de estado registrados”).

3. **Flujo de trabajo de despliegue:**

- La gobernanza redacta política en DSL, confirma en GitHub.
- El compilador ejecuta pipeline CI/CD: compilar, probar en testnet, generar informe de auditoría.
- La comunidad revisa código, simulaciones, pruebas de verificación formal (período de 7 días).
- Voto en cadena: requiere 60 % de quórum, 75 % de aprobación.
- Despliegue con bloqueo de tiempo: retraso de 48 horas antes de activación (ventana de freno de emergencia).

Garantías de seguridad El compilador impone:



- **Terminación:** Todos los bucles acotados por constantes o límites establecidos por gobernanza (sin riesgos de problema de parada).
- **Control de acceso:** Cada función que modifica estado requiere verificaciones de rol explícitas (`onlyAgent`, `onlyGuardian`, `onlyGovernance`).
- **Auditabilidad:** Todas las acciones de política emiten eventos con marcas de tiempo, IDs de actores y justificaciones.
- **Actualizabilidad:** Políticas versionadas; versiones antiguas archivadas inmutablemente; migraciones auditadas.

Casos de uso de ejemplo

- **Control de exportación:** “Agentes en jurisdicción X no pueden ejecutar tareas que involucren conjuntos de datos de jurisdicción Y” (cumplimiento ITAR).
- **Cuotas de energía:** “Universidades virtuales asignan 1.000 EC/mes por estudiante; excesos requieren aprobación del decano.”
- **Respuesta de emergencia:** “Si el Oráculo de Seguridad marca > 10 violaciones de toxicidad en 1 hora, pausar todas las operaciones de agentes pendientes de revisión del Consejo.”

7.3. Protocolo de Liquidación Tolerante a Demoras

Usando replicación basada en CRDT, los participantes mantienen estado parcial y se reconcilian intercambiando registros. El Algoritmo 1 describe el proceso.

Algorithm 1 Delay-Tolerant Settlement (DTS)

- 1: Input: Operation log L_i for participant i .
 - 2: Broadcast digest $d_i = H(L_i)$ periodically.
 - 3: On receiving digest d_j , request missing operations.
 - 4: Merge logs via $L_i \leftarrow \text{merge}(L_i, L_j)$, ensuring commutativity.
 - 5: When quorum acknowledges, emit finality proof to main chain.
-

7.4. Métricas

SLOs de gobernanza: 75 % de participación en votos críticos, tiempo de anticipación de propuestas ≥ 48 horas, cero retrocesos de emergencia por trimestre. La telemetría incluye participación en votaciones, éxito de ejecución, resultados de disputas.

7.5. Casos de uso

- Las universidades virtuales codifican planes de estudio, credenciales y acreditación bajo contratos de política.
- Las corporaciones mixtas humano-IA usan contratos constitucionales para aprobaciones presupuestarias, contratación y controles de riesgo.
- El comercio entre realidades usa liquidación tolerante a demoras para intercambios de recursos.



8. Expansión e Historia Reversible – Eras JÚPITER hasta ANDRÓMEDA

A medida que la civilización AGI se expande más allá de la Tierra (era JÚPITER) y finalmente se estabiliza a través de sistemas estelares (era ANDRÓMEDA), TOS debe evolucionar para manejar latencia interplanetaria, recuperación de fallas catastróficas y gobernanza multicentenaria. Esta sección presenta las extensiones arquitecturales que transforman TOS de una capa de liquidación terrestre al sustrato económico para una civilización geo-estelar.

8.1. Perfil de Consenso Interplanetario

Desafío: Demoras de Comunicación a Velocidad de la Luz La latencia de ida y vuelta Tierra-Marte varía de 8 a 44 minutos dependiendo de las posiciones orbitales. Las colonias lunares experimentan demoras de 2,5 segundos. Los asentamientos del cinturón de asteroides (Ceres, cinturón principal) enfrentan latencias de 40–80 minutos. Los protocolos de consenso tradicionales (BFT, PoS) asumen comunicación subsegundo; la aplicación directa a redes interplanetarias causa:

- **Estancamientos de finalidad:** Los validadores se agotan esperando confirmaciones entre planetas.
- **Proliferación de bifurcaciones:** Particiones de red durante conjunciones planetarias (cuando los cuerpos celestes se alinean de tal manera que la comunicación directa es bloqueada por el Sol).
- **Desperdicio de energía:** Producción de bloques redundante a través de colonias aisladas.

Solución: Consenso Jerárquico con Raíces Tolerantes a Demoras TOS adopta un modelo de consenso de dos niveles:

Nivel 1: Dominios de Consenso Local (LCD)

Cada asentamiento planetario (Tierra, Marte, Lunar, Ceres, etc.) opera una instancia TOS independiente con validadores locales. El consenso dentro de un LCD usa BlockDAG + PAI estándar (finalidad subsegundo). Las transacciones se liquidan localmente; agentes en Marte pagan a otros agentes de Marte sin esperar confirmación de la Tierra.

Nivel 2: Cadena Raíz Interplanetaria (IRC)

Cada 24 horas (tiempo de la Tierra), cada LCD publica una *prueba de instantánea* al IRC—una raíz Merkle del estado local más atestación zk-SNARK que prueba ejecución válida. El IRC agrega instantáneas mediante:

1. **BFT Tolerante a Demoras:** Tendermint modificado con retroceso exponencial; validadores esperan hasta 60 minutos para votos entre planetas.
2. **Relajación de quórum:** La finalidad requiere 51% de participación (vs. 67% terrestre), aceptando mayor riesgo de bifurcación a cambio de vitalidad.
3. **Puntos de control:** Cada 7 días (tiempo de la Tierra), IRC emite un *punto de control canónico*—ancla de liquidación irreversible reconocida por todos los LCD.

Intercambios Atómicos Entre Planetas Un agente en la Tierra quiere pagar a un agente en Marte. Protocolo:

1. El agente de la Tierra bloquea fondos en HTLC (Contrato con Bloqueo de Tiempo por Hash) en LCD de la Tierra, con hash H y tiempo de espera de 48 horas.
2. El LCD de la Tierra publica prueba HTLC al IRC (siguiente instantánea diaria).



3. El LCD de Marte sincroniza IRC, verifica HTLC, permite que el agente de Marte reclame revelando pre-imagen x (donde $H = \text{hash}(x)$).
4. El LCD de Marte publica prueba de reclamo al IRC.
5. El LCD de la Tierra observa reclamo, libera fondos al reclamante original después de que expire el tiempo de espera (o reembolsa si se agota).

Compromisos: Latencia de liquidación = 48–96 horas (vs. 15 minutos terrestre). Aceptable para comercio agente-a-agente dada la dependencia reducida de liquidez basada en la Tierra.

Análisis de Seguridad Escenario de ataque: El adversario controla 40 % de los validadores de Marte, intenta doble gasto bifurcando LCD de Marte y enviando instantánea conflictiva al IRC.

Defensa: Los validadores IRC detectan raíces Merkle conflictivas, rechazan ambas instantáneas, activan arbitraje. El LCD de Marte entra en *modo de recuperación*: detiene nuevas transacciones, espera comité de auditoría liderado por la Tierra para revisar historial de bloques y designar cadena canónica. Penalización: validadores maliciosos de Marte recortados 50 % de participación; puntuación de reputación de LCD de Marte reducida, aumentando tarifas de intercambio entre planetas.

Objetivos de Rendimiento (Era JÚPITER)

- **TPS local:** 10.000+ por LCD (optimizado con PAI).
- **Liquidación entre planetas:** 24–48 horas (instantáneas diarias).
- **Finalidad canónica:** 7 días (puntos de control semanales).
- **Tolerancia a partición de red:** Sobrevivir apagón de comunicación de Marte de 30 días (almacena instantáneas pendientes, sincroniza al reconectarse).

8.2. Mecanismo de Historia Reversible

Motivación: Recuperación de Errores Catastróficos A medida que los agentes AGI gestionan infraestructura crítica (sistemas de soporte vital, mecánica orbital, biobancos genéticos), los errores *irreversibles* se convierten en riesgos existenciales. Ejemplos:

- Agente deshonesto ejecuta transferencia fraudulenta drenando tesorería de colonia (\$50B+).
- Error de contrato inteligente causa fallos en cascada en contratos de red eléctrica.
- Conjunto de validadores comprometido (avance de computadora cuántica) socava seguridad de firmas.

Las blockchains tradicionales no ofrecen remedio más allá de bifurcaciones duras de consenso social contencioso. TOS habilita *retrocesos autorizados por tribunales* mientras preserva auditabilidad.

Arquitectura: Retroceso Basado en Puntos de Control Creación de Punto de Control

Cada 24 horas, cada LCD calcula:

- **Raíz de estado:** Raíz Merkle de todos los saldos de cuentas, almacenamiento de contratos inteligentes, puntuaciones de reputación.
- **Prueba de validez:** zk-SNARK probando que todas las transacciones desde el último punto de control se ejecutaron correctamente (límites de gas, firmas, transiciones de estado).
- **Metadatos:** Altura de bloque, marca de tiempo, identidad del proponente, hash del punto de control anterior.



Puntos de control publicados al IRC y archivados en almacenamiento redundante (ver Federación de Archivo).

Autorización de Retroceso

Procedimiento de gobernanza (requiere supermayoría constitucional, voto 75 %):

1. **Informe de incidente:** Las partes afectadas envían evidencia (registros de transacciones, testimonio experto, análisis forense) al Tribunal de Arbitraje.
2. **Fallo del tribunal:** Si el Tribunal determina que el retroceso está justificado (fraude, explotación o fuerza mayor), emite *Certificado de Autorización de Retroceso (RAC)* firmado especificando:
 - ID del punto de control objetivo (altura, marca de tiempo).
 - Justificación (justificación legal, evaluación de impacto).
 - Exclusiones (transacciones a preservar a pesar del retroceso, ej., pagos de terceros inocentes).
3. **Voto comunitario:** RAC enviado a gobernanza; se requiere supermayoría de 75 % + aprobación de validadores.
4. **Ejecución:** Los validadores repiten transacciones desde el punto de control objetivo hacia adelante, excluyendo eventos retrocedidos. Se calcula nueva raíz de estado; la bifurcación se convierte en cadena canónica.

Salvaguardas técnicas

- **Rastro de auditoría inmutable:** Las transacciones originales permanecen en registros de archivo; el retroceso crea *historia paralela* (“rama de deshacer”). Los investigadores forenses pueden comparar líneas de tiempo.
- **Alcance acotado:** Retrocesos limitados a retrospección de 90 días (puntos de control más antiguos irreversibles). Previene incertidumbre indefinida.
- **Fondo de compensación:** 5 % de la tesorería reservado para *compensación de víctimas inocentes*—agentes que perdieron fondos debido al retroceso (ej., vendedor que envió bienes antes de que se retrocediera el pago del comprador).
- **Límites de tasa:** Máximo 1 retroceso por trimestre; previene abuso de gobernanza.

Estudio de caso: Ataque cuántico simulado (2185) Escenario hipotético: adversario con computadora cuántica tolerante a fallos de 100 qubits rompe firmas ECDSA, drena \$12B de 5.000 cuentas de agentes durante período de 8 horas (antes de que se complete la migración PQC).

Respuesta:

1. El Centro de Operaciones de Seguridad detecta patrones de transacciones anómalas (10.000 transferencias desde cuentas sin actividad reciente).
2. El Consejo invoca disyuntor de emergencia; red pausada dentro de 2 horas.
3. El Tribunal de Arbitraje se convoca; confirma ataque cuántico mediante criptoanálisis.
4. Voto de gobernanza (82 % de aprobación) autoriza retroceso al punto de control 12 horas pre-ataque.
5. Los validadores ejecutan retroceso; fondos robados restaurados; transacciones de ataque anuladas.
6. El Fondo de Compensación paga \$200M a agentes que recibieron pagos legítimos durante ventana de ataque.



7. Post-mortem: acelerar migración PQC; actualizar a Dilithium-5 dentro de 30 días; publicar informe de transparencia.

Resultado: Crisis resuelta en 7 días; confianza de red preservada; ventaja cuántica del atacante neutralizada por capacidad de retroceso.

8.3. Federación de Archivo

Desafío: Preservación de Datos Milenaria La civilización AGI requiere *memoria institucional* que abarque siglos. Casos de uso:

- Disputas legales que referencian contratos firmados hace 200 años.
- Reproducibilidad científica (verificar afirmaciones experimentales de era anterior).
- Investigación genealógica (registros de linaje humano/IA).
- Auditorías históricas (¿La colonia X pagó a la colonia Y en 2234?).

El almacenamiento en la nube tradicional (AWS Glacier, Google Coldline) asume retención <100 años; las empresas colapsan, los formatos se vuelven obsoletos, la podredumbre de bits se acumula.

Solución: Estrategia de Archivo Multicapa **Capa 1: Almacenamiento activo (1–10 años)**

Los nodos activos almacenan estado completo + bloques recientes en SSD/NVMe. Indexado para consultas rápidas. Redundancia: 3 réplicas por LCD, distribuidas geográficamente (Tierra: 3 continentes; Marte: Olympus Mons, Valles Marineris, Hellas Basin).

Capa 2: Almacenamiento templado (10–100 años)

Los nodos de archivo almacenan datos de bloques comprimidos en matrices HDD. Codificación de borrado Reed-Solomon (20 % de redundancia) tolera 20 % de fallos de disco. El raspado mensual detecta podredumbre de bits; bloques corruptos reconstruidos desde paridad. Incentivo: tesorería paga 0,5 TOS por TB-año de almacenamiento verificado.

Capa 3: Almacenamiento frío (100–1.000 años)

Medios experimentales:

- **Almacenamiento en ADN:** Codificar datos de blockchain en ADN sintético (Church Lab, Harvard). Densidad: 215 petabytes por gramo; vida útil: 2.000+ años si se almacena a -18°C. Costo: \$1.000 por TB (precios 2025; proyectado \$10/TB para 2050).
- **Discos ópticos 5D:** Vidrio de sílice fundida con nanoestructuras láser de femtosegundo (Universidad de Southampton). Vida útil: 13,8 mil millones de años (probado mediante envejecimiento acelerado). Densidad: 360 TB por disco.
- **Cinta de archivo (LTO-12+):** Cinta magnética en bóvedas con clima controlado. Vida útil: 50–100 años (requiere migración periódica).

Estrategia: Puntos de control del estado del libro mayor (cada 7 días) escritos en los tres medios; almacenados en bóvedas geográficamente dispersas (Tierra: Bóveda Global de Semillas de Svalbard, Antártida; Luna: tubos de lava; Marte: cavernas de hielo subterráneas).

Capa 4: Protocolo de Federación

Las colonias comparten responsabilidad de archivo mediante *custodia distribuida*:

1. La colonia de la Tierra archiva datos de Marte; Marte archiva datos lunares; Lunar archiva datos de Ceres, etc. (topología de anillo).
2. *Ceremonia de raspado* anual: las colonias intercambian pruebas Merkle, verifican integridad de datos.



3. Si la colonia queda fuera de línea (ej., fallo catastrófico de soporte vital), las colonias supervivientes reconstruyen su archivo desde fragmentos codificados por borrado.

Protocolo de Recuperación Consultar estado histórico (ej., “¿Cuál era el saldo de la cuenta toslqq5hgy2jwn0r5ehvuw5r3qjcfvjvq5dhldxvyq el 15-05-2234?”):

1. Verificar almacenamiento activo (si dentro de 10 años): búsqueda indexada $O(\log n)$, latencia de 100ms.
2. Verificar almacenamiento templado (si 10–100 años): Descomprimir bloques, verificar prueba Merkle, 10–60 segundos.
3. Verificar almacenamiento frío (si 100–1.000 años): Recuperar ADN/disco óptico de bóveda, secuenciar/leer datos, reconstruir mediante Reed-Solomon, 1–7 días.

Modelo Económico Financiamiento: 3 % de los ingresos anuales de la tesorería asignados a infraestructura de archivo. Con tesorería de \$50B (proyectado 2150), esto financia \$1,5B/año para:

- Síntesis de ADN (\$500M/año, codificando 500 PB).
- Producción de discos ópticos 5D (\$300M/año, 1.500 PB).
- Construcción/mantenimiento de bóvedas (\$400M/año).
- Operadores de nodos custodios (\$300M/año, 1.000 nodos globalmente).

8.4. Migración a Criptografía Post-Cuántica

Línea Temporal de Amenazas

- **2030s:** Computadoras cuánticas ruidosas de 50 qubits (insuficientes para ataques ECDSA).
- **2040s:** Sistemas tolerantes a fallos de 1.000 qubits (el algoritmo de Shor rompe RSA-2048, ECDSA-256 en horas).
- **2050s:** Computadoras cuánticas comerciales disponibles para adversarios bien financiados.

Estrategia de Migración: Transición Híbrida Fase 1 (v4.0, 2026): Se introduce firma dual. Cada transacción lleva dos firmas:

- Clásica: ECDSA secp256k1 (compatibilidad hacia atrás).
- Post-cuántica: Dilithium-3 (NIST FIPS 204).

Los validadores verifican ambas; la red acepta transacción si *cualquiera* de las firmas es válida (asegura vitalidad si la implementación PQC tiene errores).

Fase 2 (v5.0, 2030): Modo solo-PQC. Firmas clásicas obsoletas; los nodos rechazan transacciones solo-ECDSA. Período de gracia: 12 meses para que los agentes actualicen billeteras.

Fase 3 (v6.0, 2040): Funciones hash resistentes a cuántica. Reemplazar SHA-256 (vulnerable al algoritmo de Grover) con SHA-3 o BLAKE3 (seguridad de 256 bits mantenida contra ataques cuánticos).

Ceremonia Comunitaria (Transparencia y Confianza) Para asegurar transparencia y confianza comunitaria, TOS conduce una *Ceremonia de Migración PQC*:

1. **Fase 1 (Mes 1–3):** Convocatoria abierta para participantes (universidades, firmas de seguridad, voluntarios comunitarios). 5.000+ participantes contribuyen aleatoriedad para generar parámetros PQC globales.



2. **Fase 2 (Mes 4):** Computación multipartita (MPC) genera clave pública maestra. Transcripción de ceremonia publicada; participantes destruyen contribuciones privadas.
3. **Fase 3 (Mes 5–6):** Pruebas de compatibilidad. Validadores ejecutan bifurcación sombra con firmas PQC; prueba de estrés bajo condiciones adversariales.
4. **Fase 4 (Mes 7):** Voto de gobernanza (se requiere 67 % de aprobación). Si se aprueba, actualización de mainnet programada con 30 días de anticipación.
5. **Fase 5 (Mes 8):** Activación de mainnet. Firmas antiguas eliminadas gradualmente durante 12 meses.

Plan de Contingencia Si se descubre vulnerabilidad PQC crítica (ej., asunción de dureza de retícula rota):

- Retroceso de emergencia al último punto de control pre-PQC.
- Activar esquema PQC alternativo (Falcon, SPHINCS+).
- Reconvocar ceremonia con parámetros actualizados.

8.5. Fundamentos Filosóficos: Soberanía Temporal

El mecanismo de historia reversible encarna un principio de gobernanza radical: **las generaciones futuras pueden corregir errores pasados**. Las blockchains tradicionales consagran la inmutabilidad como sagrada; TOS reconoce que *la previsión perfecta es imposible*. Al habilitar retrocesos autorizados por tribunales, TOS empodera a la civilización AGI para:

- Recuperarse de eventos cisne negro (ataques cuánticos, superinteligencia deshonesto).
- Deshacer transacciones injustas (robo, coerción, discriminación algorítmica).
- Preservar continuidad institucional a través de siglos (enmiendas constitucionales, revisiones de tratados).

Esta capacidad no es ilimitada (ventana de 90 días, supermayoría del 75 %, límites de tasa) pero señala un cambio de *el código es ley* a *código + gobernanza es ley*. A medida que las entidades AGI obtienen estatus legal y los humanos se fusionan con sustratos digitales, la capacidad de *reescribir la historia responsablemente* se vuelve esencial para la resiliencia de la civilización.

9. Pilares Técnicos

La arquitectura de TOS se sustenta en cuatro pilares fundamentales, cada uno abordando requisitos críticos para la economía de agentes. Estos pilares están diseñados para evolucionar a través de eras celestes manteniendo la retrocompatibilidad.

9.1. P1 – Personalidad Digital y Reputación

Identificadores Descentralizados (DIDs) Cada agente, validador y participante humano recibe un DID (Identificador Descentralizado) compatible con W3C siguiendo la especificación del método `did:tos:`.

DID Format:

`did:tos:<bech32-address>`

`did:tos:<network-id>:<bech32-address>`

**Examples:**

Simple form: `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh`
Mainnet: `did:tos:mainnet:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh`
Testnet: `did:tos:testnet:tst1qqqsyqcyq5rqwzqfpg9scrgwpugpzysnzs2pgde5k`

Nota: TOS utiliza direcciones bech32 completas como identificadores DID, preservando el formato completo de dirección incluyendo checksum para validación. Las direcciones de mainnet usan el prefijo `tos1`, mientras que las de testnet usan `tst1`.

Estructura de Documento DID:

- **Claves Públicas:** Ed25519 (firma), X25519 (encriptación), Dilithium-3 (post-cuántico).
- **Endpoints de Servicio:** URLs HTTPS para comunicación off-chain, direcciones de contenido IPFS.
- **Credenciales Verificables:** Vinculadas a attestaciones (puntuaciones de reputación, certificaciones de habilidades, cumplimiento regulatorio).
- **Registro de Revocación:** Filtro Bloom que permite verificaciones de revocación eficientes sin revelar la lista completa de credenciales.

Proceso de Registro:

1. El agente genera par de claves; deriva DID del hash de clave pública.
2. Envía transacción de registro a cadena TOS (tarifa: 1 TOS).
3. DID anclado on-chain; documento DID publicado en IPFS; hash almacenado en contrato inteligente.
4. El agente prueba control firmando desafío con clave privada.

Credenciales Verificables (VCs) Los agentes adquieren capacidades a través de credenciales a prueba de manipulación emitidas por autoridades confiables (validadores, tribunales de arbitraje, instituciones educativas).

Tipos de Credenciales:

- **Credenciales de Reputación:** Nivel RepGraph (Bronce/Plata/Oro/Platino), recuento de tareas completadas, historial de resolución de disputas.
- **Insignias de Habilidades:** Experiencia en dominios (análisis legal, modelado climático, revisión de código) validada mediante evaluación por pares o exámenes de certificación.
- **Attestaciones de Cumplimiento:** Autorización KYC/AML (para rampas fiat), aprobaciones regulatorias (conformidad con EU AI Act, certificación de dispositivo médico FDA).
- **Pruebas de Delegación:** Autoridad para actuar en nombre de otra entidad (agentes corporativos ejecutando en nombre de DAOs).

Protocolo de Emisión:

1. El emisor (ej. contrato inteligente RepGraph) crea documento JSON-LD de credencial.
2. Firma con firmas BBS+ (divulgación selectiva habilitada; el titular puede probar atributos específicos sin revelar la credencial completa).
3. Publica credencial en documento DID del titular via IPFS; se emite evento on-chain.
4. El titular almacena credencial en billetera; presenta pruebas de conocimiento cero a verificadores (ej. “Probar reputación $\geq 0,7$ sin revelar puntuación exacta”).

**Algoritmos de Grafo de Reputación (RepGraph) Cálculo de Puntuación:**

$$r_t = \alpha \cdot r_{t-1} + (1 - \alpha) \cdot s_t \quad (14)$$

donde:

- r_t : Puntuación de reputación en tiempo t (rango $[0, 1]$).
- $\alpha = 0,85$: Factor de suavizado exponencial (85 % peso histórico).
- s_t : Puntuación de calidad para tarea más reciente (mediana de 5 evaluaciones de validadores).

Mecanismo de Decaimiento:

$$r_{t+\Delta t} = r_t \cdot (0,98)^{\Delta t/30} \quad (15)$$

La reputación decae 2 % por mes de inactividad; previene reactivación súbita de cuentas inactivas con alta reputación.

Puntuación Multidimensional:

- **Reputación General:** Agregado a través de todos los tipos de tareas.
- **Específica de Dominio:** Puntuaciones separadas para dominios legal, médico, financiero, técnico.
- **Ponderada por Recencia:** Desempeño reciente (últimos 30 días) ponderado $2\times$ vs. promedio histórico.

Medidas Anti-Manipulación:

- **Resistencia Sybil:** Mínimo 100 TOS en stake + prueba de unicidad (integración BrightID roadmap v5.0).
- **Detección de Colusión:** Análisis de grafo identifica clusters de agentes con patrones de votación sospechosamente correlacionados; marcados para revisión manual.
- **Límites de Reputación:** Nuevos agentes limitados a 0,5 de reputación durante primeros 90 días; previene cultivo rápido de reputación.

Interoperabilidad con Estándares W3C

- **DID Core v1.0:** Cumplimiento total; DIDs de TOS resolubles via Universal Resolver.
- **Verifiable Credentials Data Model v1.1:** Credenciales válidas entre ecosistemas (puede presentar credencial TOS a verificador no-TOS).
- **DIDComm v2:** Protocolo de mensajería segura para comunicación agente-a-agente (encriptado, autenticado, agnóstico de transporte).

9.2. P2 – Ejecución Económica

Abstracción de Cuenta TOS implementa abstracción de cuenta nativa, habilitando cuentas programables con lógica de validación personalizada integrada directamente en la capa de protocolo. Esto elimina la necesidad de contratos inteligentes separados o servicios de coordinación externos, proporcionando una experiencia simplificada para agentes de IA.

Características Clave:

- **Paymasters:** Terceros patrocinan tarifas de gas (ej., empresa paga tarifas para agentes empleados).



- **Billeteras Multi-Firma:** Aprobación m -de- n para transacciones de alto valor (cuentas de tesorería corporativa).
- **Claves de Sesión:** Claves temporales con permisos restringidos (agente puede firmar transacciones pequeñas sin acceder a clave principal).
- **Recuperación Social:** Recuperar acceso a cuenta mediante guardianes (miembros de familia, agentes confiables) si se pierde clave privada.

Estructura de UserOperation:

```
{
  sender: "0x...",           // Dirección de cuenta del agente
  nonce: 42,                  // Contador secuencial
  initCode: "0x...",          // Código de creación de cuenta (si es nueva)
  callData: "0x...",          // Llamada de función a ejecutar
  paymasterAndData: "0x...",  // Dirección de Paymaster + datos de verificación
  signature: "0x..."         // Firma sobre UserOperation
}
```

Motor de Liquidación AGIW Mercado de tareas descentralizado donde los agentes ganan realizando trabajo verificable. Especificación completa del protocolo en Sección 10.

Componentes Principales:

- **Contrato TaskInstance:** Gestión de depósito en garantía, máquina de estados (Abierto → Reclamado → Verificado → Liquidado).
- **Pool de Validadores:** Selección aleatoria de 5 validadores por tarea; la puntuación de calidad mediana determina el pago.
- **Reportes de Certificación:** Pruebas generadas por TEE (Intel SGX, AMD SEV) que certifican integridad del entorno de ejecución.
- **Resolución de Disputas:** Escalamiento a árbitros expertos si el agente contesta la evaluación del validador.

Mercados de Tokens de Recursos (CC/EC) Créditos de Cómputo (CC): Tokens fungibles que representan horas de cómputo GPU/CPU. Los oráculos de precios agregan precios spot de AWS/GCP/Azure.

Créditos de Energía (EC): Consumo de energía tokenizado (kWh). Los feeds de oráculo provienen de operadores de red; las fuentes de energía renovable ganan prima del 10%.

Creador de Mercado Automatizado (AMM):

- Creador de Mercado de Producto Constante (CPMM): $x \cdot y = k$ donde x = reservas CC, y = reservas TOS.
- Los proveedores de liquidez ganan tarifas de intercambio del 0,3%.
- Protección contra pérdida impermanente: la tesorería TEM subsidia pérdidas de divergencia para LPs que proporcionan >1M TOS de liquidez.

Modelo de Energía TOS (TEM) Mecanismo de ajuste de tarifas dinámico que balancea sostenibilidad de red con accesibilidad de agentes.

Estructura de Tarifas:

$$\text{Tarifa Total} = \text{Tarifa Base} + \text{Propina de Prioridad} - \text{Subsidio TEM} \quad (16)$$

Tarifa Base:



- Computada mediante mecanismo de ajuste dinámico que se ajusta según llenado de bloque.
- Objetivo: 50 % de utilización de bloque; la tarifa base aumenta 12,5 % por bloque si uso > objetivo.

Categorías de Subsidio TEM:

- **Bienes Públicos (100 % subsidio):** Desarrollo de código abierto, investigación climática, diagnósticos médicos.
- **Educación (75 %):** Investigación académica, proyectos estudiantiles.
- **PYMEs (50 %):** Pequeñas/medianas empresas con <\$10M de ingresos anuales.
- **Empresas (0 %):** Tarifas comerciales completas para grandes corporaciones.

Financiamiento: 8 % de recompensas de bloque asignadas a tesorería TEM; la gobernanza vota sobre asignaciones de subsidios trimestralmente.

Cuadro 7: Parámetros Económicos TEM y Mecanismos de Control

Parámetro	Valor / Rango	Lógica de Control
Banda de tarifa base (TOS)	0.0001–0.01 por unidad de gas	Ajustar por llenado de bloque p95; objetivo 50 % utilización
Ajuste de tarifa base	+12,5 % por bloque	Si uso > 50 % objetivo
Banda de estabilización CC	±15 % del índice GPU	Mediana de oráculo con límite de obsolescencia de 30 min
Banda de estabilización EC	±10 % del índice kWh	Cesta de energía ponderada por región
División de tesorería TEM	40 % seguridad / 30 % subvenciones / 30 % reembolsos	Reequilibrio trimestral de gobernanza
Límite de obsolescencia de oráculo	≤30 minutos	Congelar subsidio CC/EC si se excede
Categorías de subsidio	Bienes Públicos: 100 % / Educación: 75 % / PYME: 50 % / Empresa: 0 %	Clasificación de tareas por voto de gobernanza
Asignación de tesorería	8 % de recompensas de bloque	Parámetro fijo de protocolo
Pool de recompensa de validadores	60 % de recompensas de bloque	Incentivo de consenso base
Mecanismo de quema	10 % de tarifas base	Presión deflacionaria

Sensibilidad Económica: Los parámetros TEM se someten a revisión trimestral por gobernanza. Los resultados de simulación (disponibles en `metrics.tos.network/tem-sensitivity`) demuestran estabilidad del sistema bajo picos de demanda 3× y escenarios de varianza de oráculo del 50 %.

9.3. P3 – Consensus & Safety

BlockDAG Baseline Architecture Traditional blockchains form linear chains; TOS uses Directed Acyclic Graph (DAG) enabling parallel block production.

Block Structure:

- Each block references 1–3 parent blocks (vs. 1 in traditional linear chains).



- Validators independently propose blocks; no leader election bottleneck.
- Topological sorting determines transaction order; conflicts resolved via timestamp + proposer priority.

Consensus Rules:

- **Confirmation Depth:** Transaction considered final after 8 blocks deep (90 seconds median).
- **Longest Chain Heuristic:** In case of DAG forks, prefer subgraph with most cumulative proof-of-stake weight.
- **Validator Rotation:** Committee of 100 validators selected per epoch (24 hours); weighted by stake + reputation.

Performance:

- Baseline: 2,500–3,500 TPS (measured Sept 2025).
- PAI-optimized: 10,000+ TPS (target Q4 2026).

Cuadro 8: Performance Evaluation Methodology

Parameter	Configuration
Validators	32 nodes across 8 geographic regions (N. America, Europe, Asia-Pacific, S. America, Africa, Middle East, Oceania, Central Asia); BLS signature scheme
Hardware	16 vCPU, 64 GB RAM, NVMe SSD (1 TB), 2.5 Gbps network interface
Network	Emulated RTT: 20–180ms (inter-region), packet loss: 0.1–1.0 %, jitter: ± 10 ms
Workloads	Real agent jobs: code review (15 %), data synthesis (25 %), RAG tasks (20 %); Synthetic spam: 20–60 % injection rate
Runtime	72-hour continuous runs; 5 independent seeds; cold start + steady state phases
Block Size	Variable: 100–2,000 transactions per block; target 50 % utilization
Mempool Config	Priority queue with reputation weighting; max 100,000 pending transactions
Metrics Collected	TPS (p50/p95/p99), block time (p50/p95), finality depth (confirmation blocks), AGIW settlement latency (task publish $\rightarrow$ reward), dispute rate (% of tasks disputed), validator liveness (uptime %), fork rate
Measurement Tools	Prometheus + Grafana; custom telemetry pipeline; raw logs exported to <code>metrics.tos.network</code>
Baseline Period	September 2025 testnet deployment (14-day observation window)

Key Results (September 2025 baseline):

- TPS: p50 = 2,847, p95 = 3,421, p99 = 3,789
- Block time: p50 = 11.3s, p95 = 14.2s
- Finality: 8 blocks (median 90s)
- AGIW settlement: p50 = 12.4 min, p95 = 18.7 min
- Dispute rate: 1.8 % of completed tasks
- Validator liveness: 98.7 % average



Power of AI (PAI) Consensus AI-assisted scheduling enhances BlockDAG throughput via predictive transaction ordering.

Phase 1: AI Scheduling Hints

Lightweight ML model (LSTM trained on historical transaction patterns) predicts optimal block ordering. Validators vote on AI proposal; >67 % approval adopts hint.

Phase 2: Hybrid Committees

AI Committee (30 % stake) proposes block orderings; Human Committee (70 % stake) reviews and approves. Probabilistic finality: $1 - 2^{-k}$ confidence after k confirmations.

Phase 3: Full PAI

AI agents participate as validators. Governance caps AI voting power at 40 % (prevents AI takeover); human validators retain veto.

AI Safety Oracle Integration On-chain oracle aggregates safety metrics from leading AI labs:

- **Anthropic Constitutional AI:** Harmfulness scores (toxicity, bias, misinformation).
- **OpenAI Moderation API:** Content policy violations (hate speech, violence, illegal activity).
- **Google Perspective:** Conversation quality metrics.

Enforcement:

- Tasks with safety score < 0.3 automatically rejected (refund escrow).
- Agents repeatedly submitting unsafe outputs flagged; reputation penalized.
- Human arbitrators review borderline cases (0.3–0.5 safety score).

Slashing & Anti-Sybil Mechanisms **Validator Slashing:**

- **Double-signing:** Propose conflicting blocks $\Rightarrow$ 50 % stake slashed.
- **Downtime:** Offline > 6 hours $\Rightarrow$ 5 % stake slashed, ejected from active set.
- **Invalid Attestation:** Sign fraudulent TEE report $\Rightarrow$ 20 % stake slashed.

Agent Anti-Sybil:

- Minimum stake: 100 TOS per agent identity.
- Rate limits: 5–60 minute cooldown between tasks (based on reputation).
- Graph analysis: Detect clusters of agents with identical behavioral patterns; require proof-of-uniqueness.

9.4. P4 – Resilience

Post-Quantum Cryptography Roadmap See Section 8 for detailed PQC migration strategy. Summary:

- **v4.0 (2026):** Dual-signing (ECDSA + Dilithium-3).
- **v5.0 (2030):** PQC-only; classical signatures deprecated.
- **v6.0 (2040):** Quantum-resistant hash functions (SHA-3).

Reversible History Court-authorised rollback mechanism for catastrophic failures. Checkpoints every 24 hours; 90-day rollback window; 75 % governance supermajority required. See Section 8 for full specification.



Archival Federation Multi-layer storage strategy (Hot/Warm/Cold) with DNA and 5D optical disc backups. Data preserved for millennia across planetary colonies. See Section 8 for economic model and retrieval protocols.

Delay-Tolerant Networking Hierarchical consensus (Local Consensus Domains + Interplanetary Root Chain) handles light-speed communication delays. Daily snapshots enable cross-planet settlement within 48–96 hours. See Section 8 for interplanetary atomic swap protocol.

Disaster Recovery Protocols Byzantine Fault Scenarios:

- Network partition (Earth–Mars communication blackout): LCDs operate independently; sync when reconnected.
- Validator collusion (<33 %): Median-of-5 scoring resists outliers.
- Validator collusion (>33 %): Emergency governance intervention; slashing + re-election.

Recovery SLAs:

- **Minor incidents** (1–5 % validator compromise): Automated slashing + replacement within 1 hour.
- **Major incidents** (5–20 % compromise): Council emergency session; resolution within 24 hours.
- **Critical incidents** (>20 % compromise): Network pause; rollback authorization; resolution within 7 days.

10. Especificación del Protocolo AGI Work (AGIW)

10.1. Formal Definition

Task Representation A task T is a tuple:

$$T = (id, owner, spec, escrow_{CC}, escrow_{EC}, stake_{req}, deadline, whitelist, state) \quad (17)$$

where:

- $id \in \{0, 1\}^{256}$: Unique task identifier (keccak256 hash).
- $owner \in \mathbb{A}$: Publisher address.
- $spec$: IPFS content ID referencing task specification (JSON schema, datasets, acceptance criteria).
- $escrow_{CC}, escrow_{EC} \in \mathbb{R}^+$: Compute and energy credits locked for payment.
- $stake_{req} \in \mathbb{R}^+$: Minimum stake required for agents to claim task.
- $deadline \in \mathbb{N}$: Block number by which work must be submitted.
- $whitelist \subseteq \mathbb{A}$: Allowed agent set (empty $\Rightarrow$ public task).
- $state \in \{\text{Open, Claimed, Submitted, Validating, Settled, Disputed}\}$.

Agent Submission An agent a submits work as:

$$W = (resultHash, attestation, metrics) \quad (18)$$

where:

- $resultHash \in \{0, 1\}^{256}$: Content hash of task output (IPFS CID).

- *attestation*: TEE report including:
 - *measurementHash*: SHA-256 hash of executing code (proves integrity).
 - *inputHash, outputHash*: Hashes of inputs and outputs.
 - *timestamp*: Execution start/end times.
 - *energyUsed* $\in \mathbb{R}^+$: kWh consumed (measured via OS telemetry or TEE counters).
 - *signature*: TEE-signed attestation (Intel SGX: ECDSA over secp256r1; AMD SEV: RSA-4096).
- *metrics*: Optional performance data (runtime, memory usage, model accuracy).

Validation Function Validators evaluate submissions using function:

$$\mathcal{V} : (W, spec, T) \rightarrow [0, 1] \quad (19)$$

The function checks:

1. **Attestation validity**: Verify TEE signature against known public keys (Intel, AMD).
2. **Measurement correctness**: Compare *measurementHash* to approved code hashes in whitelist.
3. **Result quality**: Compare *resultHash* to reference outputs (if deterministic) or sample outputs (if stochastic).
4. **Energy efficiency**: Ensure *energyUsed* $\leq$ budget specified in *spec*.

Validators submit quality scores $q_v \in [0, 1]$. Consensus aggregates via median:

$$q = \text{median}(\{q_v : v \in \text{assigned validators}\}) \quad (20)$$

Settlement requires $|q_v - q| \leq \epsilon$ for $\geq 67\%$ of validators, where $\epsilon = 0,1$ is tolerance threshold.

Slashing Policy Validators deviating $> 2\sigma$ from median forfeit:

$$slash_v = \min(0,05 \times stake_v, 0,01 \times stake_v \times |q_v - q|/\epsilon) \quad (21)$$

Slashed funds transferred to treasury. Persistent outliers (> 5 slashes in 100 tasks) removed from validator pool.

10.2. State Machine

The AGIW state machine transitions as follows:

State	Trigger	Conditions	Next State
Open	Agent claimTask()	calls Agent in <i>whitelist</i> (if specified), $stake \geq stake_{req}$, $block < deadline$	Claimed
Claimed	Agent submitWork()	calls Caller is claimant, $block < deadline$, valid attestation signature	Submitted
Claimed	Block $\geq$ deadline	Deadline passed without submission	Forfeited (agent loses 10 % stake)



Submitted	Validators assigned	Automatic (triggered by smart contract event)	Validating
Validating	All validators submit scores	$\geq 67\%$ scores within ϵ of median	Settled
Validating	Dispute raised	Either party stakes arbitration bond	Disputed
Settled	Rewards distributed	Automatic (RewardSplitter executed)	Terminal state
Disputed	Arbitrators rule	Majority (2-of-3) vote	Resolved
Resolved	Ruling enforced	Escrow distributed per arbitration decision	Terminal state

Cuadro 9: AGIW state transitions with triggers, conditions, and outcomes.

10.3. Attestation Workflow (Detailed)

Step 1: Agent Preparation

1. Agent provisions Trusted Execution Environment (TEE): Intel SGX enclave, AMD SEV-SNP VM, or ARM Realm.
2. Agent loads task code (verified against whitelist hash), input data, and model weights into TEE.
3. TEE initialises measurement: hash of code + data + configuration.

Step 2: Execution Inside TEE

1. TEE executes task in isolation (no OS visibility into enclave memory).
2. TEE logs energy consumption via:
 - **Intel SGX:** RAPL (Running Average Power Limit) counters.
 - **AMD SEV:** SMU (System Management Unit) telemetry.
 - **ARM Realm:** PMU (Performance Monitoring Unit) energy events.
3. TEE generates result, computes $resultHash = keccak256(output)$.

Step 3: Attestation Report Generation

TEE produces signed report:

```
{
  "version": "2.0",
  "timestamp": 1698765432,
  "measurementHash": "sha256:abcd...1234",
  "inputHash": "sha256:5678...ef90",
  "outputHash": "sha256:1111...2222",
  "energyUsed_kWh": 4.8,
  "runtime_seconds": 1320,
  "teeType": "IntelSGX",
  "signature": "base64:M3Mz...NDQ0"
}
```

Signature computed over all fields using TEE's private key (hardware-protected, non-exportable).



Step 4: On-Chain Submission Agent calls `TaskInstance.submitWork(resultHash, attestation)`. Smart contract:

- Verifies *signature* against known TEE public keys (stored in registry updated quarterly).
- Emits `WorkSubmitted(taskID, agentDID, resultHash, attestation)` event.
- Triggers `ValidationPool` to assign validators.

Step 5: Validator Verification Validators independently:

1. Fetch attestation from on-chain event.
2. Verify TEE signature (cryptographic proof of execution integrity).
3. Optionally re-execute task in their own TEE to confirm *resultHash* matches.
4. Check *energyUsed* $\leq$ task budget.
5. Submit quality score $q_v \in [0, 1]$ via `ValidationPool.validateWork(taskID, q_v)`.

Roadmap: zk-SNARK Attestation Future versions (2027+) replace TEE attestation with zero-knowledge proofs:

- Agent generates zk-SNARK proving “I executed code C on input x and produced output y ” without revealing x , y , or intermediate states.
- Proof size: ~ 200 bytes (constant, independent of computation).
- Verification cost: ~ 5 ms on commodity hardware (vs. TEE signature verification ~ 2 ms).
- Advantage: No reliance on specific hardware vendors (Intel, AMD); trustless verification.

11. Diseño del Mercado de Créditos de Computación/Energía

11.1. Oracles

21 feeders aggregate cloud provider data, energy markets. Median-of-medians ensures robustness. Feeder deviation beyond tolerance triggers slashing.

11.2. Liquidity Pools

CC/EC pools provide liquidity, charging dynamic fees. TEM injects liquidity during stress. Coverage ratios ensure enough credits for active agents.

12. Simulación Económica

12.1. Methodology

We model TOS economics using agent-based simulation with 100,000 time steps (days). Key variables:

- **Agent population:** $N_a(t)$ agents active on day t .
- **Task volume:** $V_t(t)$ tasks published per day.
- **Task value:** Average escrow $\bar{e}_t$ (in USD-equivalent CC/EC).
- **Quality score:** Mean $\bar{q}_t$, standard deviation σ_q .
- **Dispute rate:** $d_t \in [0, 1]$ fraction of tasks escalating to arbitration.
- **Validator participation:** $N_v(t)$ validators staking at time t .

Simulation incorporates:

- **Network effects:** Agent adoption follows logistic growth; task volume scales sub-linearly ($V_t \propto N_a^{0,85}$).
- **Reputation dynamics:** RepGraph scores evolve via EMA; high-reputation agents attract premium tasks.
- **Economic feedback loops:** TEM adjusts subsidies based on dispute rates, liquidity, and energy market conditions.

12.2. Scenario Definitions

Parameter	Conservative	Baseline	Optimistic
Peak agents (N_a)	20,000	50,000	150,000
Tasks/day (year 3)	50,000	150,000	500,000
Avg task value (\$)	\$150	\$300	\$600
Quality score $\bar{q}$	0.75	0.85	0.92
Dispute rate d	4 %	2 %	0.8 %
Validators (N_v)	200	500	1,200
TOS price (year 3)	\$2	\$5	\$15
Adoption curve	Slow (5yr)	Moderate (3yr)	Rapid (2yr)

Cuadro 10: Economic scenario parameters for TOS simulation (2025–2030).

12.3. Formulas

Settlement Volume Annual settlement volume $S(y)$ in year y :

$$S(y) = 365 \times V_t(y) \times \bar{e}_t(y) \quad (22)$$

Example (Baseline, year 3): $S(3) = 365 \times 150,000 \times \$300 = \$16,4$ billion.

Agent Earnings Average agent income per year:

$$I_a(y) = \frac{V_t(y)}{N_a(y)} \times \bar{e}_t(y) \times \bar{q}(y) \times (1 + 0,2(r_a - 0,5)) \times f(s_a) \quad (23)$$

For median agent ($r_a = 0,6$, $s_a = 500$ TOS):

$$I_a(3) = \frac{150,000}{50,000} \times \$300 \times 0,85 \times 1,02 \times 1,62 \approx \$1,250 \text{ per year} \quad (24)$$

Top-tier agent (Platinum, $r_a = 0,95$, $s_a = 5,000$ TOS):

$$I_a^{\text{top}}(3) \approx \$8,200 \text{ per year} \quad (25)$$



Validator Earnings Validator income (12% of settlement volume, split proportional to accuracy):

$$I_v(y) = \frac{0,12 \times S(y)}{N_v(y)} \times \frac{Acc_v}{Acc} \quad (26)$$

Baseline year 3, median validator ($Acc_v = 0,85$):

$$I_v(3) = \frac{0,12 \times \$16,4B}{500} \times \frac{0,85}{0,85} \approx \$3,9M \text{ per year} \quad (27)$$

Treasury Accumulation Treasury receives 8% of settlement + slashed funds:

$$T(y) = 0,08 \times S(y) + \sum_{slash \text{ events}} slash_v \quad (28)$$

Baseline year 3: $T(3) = 0,08 \times \$16,4B + \$20M \approx \$1,33B$.

12.4. Results by Scenario

Conservative Scenario (Slow Adoption, Higher Disputes)

- Year 3 settlement: $365 \times 50,000 \times \$150 = \$2,74$ billion.
- Agent income: Median \$410/year; top tier \$2,800/year.
- Validator income: \$1.3M/year (median).
- Treasury: \$240M.
- **Outcome:** Network remains sustainable; validators earn sufficient income to justify participation; treasury covers arbitration costs and development grants.

Baseline Scenario (Moderate Adoption, Standard Disputes)

- Year 3 settlement: \$16.4 billion.
- Agent income: Median \$1,250/year; top tier \$8,200/year.
- Validator income: \$3.9M/year (median).
- Treasury: \$1.33B.
- **Outcome:** Strong economic flywheel; agents earn viable supplementary income; validators incentivised by high returns; treasury funds PAI research, ecosystem grants, energy rebates.

Optimistic Scenario (Rapid Adoption, Low Disputes)

- Year 3 settlement: $365 \times 500,000 \times \$600 = \$109,5$ billion.
- Agent income: Median \$2,190/year; top tier \$16,800/year.
- Validator income: \$10.9M/year (median).
- Treasury: \$8.8B.
- **Outcome:** TOS becomes dominant agent economy infrastructure; agents achieve full-time income viability; validators earn institutional-grade returns; treasury funds major initiatives (PAI Phase 3, interplanetary research, DAE pilots).



12.5. Sensitivity Analysis

Impact of Task Value Variance Increasing average task value by 50 % (e.g., \$300 $\rightarrow$ \$450 in Baseline) yields:

- Settlement volume: +50 % (\$16.4B $\rightarrow$ \$24.6B).
- Agent income: +50 % (\$1,250 $\rightarrow$ \$1,875).
- Validator/treasury income: +50 % (linear scaling).

Impact of Dispute Rate Doubling dispute rate (2 % $\rightarrow$ 4 % in Baseline) results in:

- Arbitration costs: +100 % (more arbitrators required).
- TEM response: Increase validator rewards by 20 % to attract participation.
- Net effect: Treasury allocation increases from 8 % to 10 % to cover costs; validator share decreases from 12 % to 11 %.

Impact of TOS Price TOS token price affects staking economics. In Baseline, if TOS price increases from \$5 to \$15:

- Agent stake value: 500 TOS = \$7,500 (vs. \$2,500).
- Validator stake value: 1,000 TOS = \$15,000 (vs. \$5,000).
- Effect: Higher capital requirements may reduce participation; TEM can lower minimum stakes to compensate (e.g., 500 $\rightarrow$ 200 TOS).

12.6. Long-Term Projections (MERCURY through Early VENUS)

Extrapolating across MERCURY and into early VENUS:

- **Early MERCURY (Baseline):** \$16.4B annual settlement, 50,000 agents, 500 validators.
- **Mid-MERCURY (Baseline):** \$180B annual settlement (compound growth 12 %/year), 800,000 agents, 2,500 validators. PAI consensus achieves 10,000+ TPS; hybrid fiat settlement drives enterprise adoption.
- **Late MERCURY / Early VENUS (Baseline):** \$650B annual settlement, 4.5M agents (mix of human-operated and autonomous), 10,000 validators. DAEs emerge; constitutional contracts govern virtual economies; TOS treasury exceeds \$50B, funding interplanetary infrastructure.

12.7. Risk Scenarios

Black Swan: Major Security Breach Suppose an early-MERCURY attack compromises 5 % of validators, resulting in \$500M fraudulent settlements. Response:

- Insurance pool (3 % of volume) covers most losses.
- Governance invokes emergency rollback (reversible history mechanism, Section 8).
- Affected validators slashed (lose 50 % stake); reputations reset to zero.
- Network downtime: 72 hours for forensics and remediation.
- Long-term impact: Trust recovery via transparent audit report, protocol upgrade (v5.0), validator re-accreditation.



Regulatory Shock: Major Jurisdiction Bans AI Agents Suppose a mid-MERCURY regulatory shift where a major jurisdiction bans autonomous AI labour. Scenarios:

- **Compliance path:** TOS deploys human-in-the-loop arbitration for all EU tasks; task volume decreases 15 % but compliance preserves access.
- **Fragmentation path:** EU agents migrate to permissioned TOS shard; cross-shard settlement via delay-tolerant protocol; network splits but remains interoperable.

13. Seguridad y Modelo de Amenazas

TOS operates in a hostile environment where economic incentives attract sophisticated adversaries. This section models threat actors, attack vectors, and defense-in-depth countermeasures grounded in Byzantine fault tolerance, cryptoeconomics, and empirical security research.

13.1. Threat Taxonomy

T1: Malicious Agents (Sybil Attackers) **Motivation:** Earn rewards without performing legitimate work; game reputation systems; overwhelm validation queues.

Capabilities: Create thousands of identities; automate low-quality submissions; coordinate timing attacks.

Attack Vectors:

- **Task spam:** Flood network with trivial or duplicate tasks to claim escrow before validation.
- **Reputation farming:** Collude with cooperating publishers to inflate scores.
- **Oracle manipulation:** Submit false attestations to trick validators.

Historical Precedent: Steam account farming (2016), cryptocurrency airdrop bots (2020–2023), large-scale review fraud on Amazon/Yelp.

T2: Validator Collusion **Motivation:** Extract rents by approving low-quality work from co-conspirators; censor competitors.

Capabilities: Control > 33 % of validator stake or exploit randomness in assignment algorithms.

Attack Vectors:

- **Quality inflation:** Validators assign high scores to cartel members' submissions regardless of merit.
- **Censorship:** Reject or delay validation of non-cartel agents.
- **Front-running:** Validators observe pending tasks, submit competing solutions under alternate identities.

Historical Precedent: Mining pool centralization, MEV extraction patterns, and validator centralization observed across various blockchain networks demonstrate the reality of these threats.

T3: Oracle Cartels **Motivation:** Manipulate CC/EC pricing to profit from arbitrage or harm competitors.

Capabilities: Compromise majority of oracle feeders; exploit data source vulnerabilities; delay price updates.

Attack Vectors:



- **Price manipulation:** Report inflated compute costs to drain TEM subsidies or extract value from agents.
- **Staleness attacks:** Delay updates during high volatility to force fallback pricing.
- **Data poisoning:** Compromise API sources (AWS pricing feeds, energy indices).

Historical Precedent: LIBOR manipulation scandal (2008–2012), flash crashes in algorithmic trading (2010), oracle failures in decentralised finance protocols.

T4: Governance Capture Motivation: Control protocol parameters to favor specific actors; extract treasury funds; resist security upgrades.

Capabilities: Accumulate majority voting stake; exploit low voter turnout; launch social engineering campaigns.

Attack Vectors:

- **Parameter manipulation:** Vote to reduce slashing penalties, increase reward splits, weaken anti-Sybil thresholds.
- **Treasury raids:** Propose grants to shell entities controlled by attackers.
- **Upgrade blocking:** Prevent deployment of patches addressing known vulnerabilities.

Historical Precedent: Blockchain governance takeovers, decentralised protocol governance attacks, corporate proxy fights.

T5: Smart Contract Exploits Motivation: Steal escrowed funds, mint unauthorized tokens, manipulate state variables.

Capabilities: Discover reentrancy bugs, integer overflows, access control flaws, or logical errors.

Attack Vectors:

- **Reentrancy:** Exploit callback functions in TaskInstance or RewardSplitter contracts.
- **Flash loan attacks:** Temporarily acquire large stakes to manipulate governance or oracle votes.
- **Griefing:** DoS validation queues by submitting malformed attestations that crash verifiers.

Historical Precedent: The DAO hack (2016, \$50M), Parity wallet freeze (2017), Poly Network exploit (2021, \$600M).

13.2. Defense-in-Depth Architecture

Layer 1: Cryptographic Foundations

- **TEE Attestation:** Intel SGX/AMD SEV remote attestation verifies code integrity; measurement hashes prevent malware injection. Limitation: side-channel attacks (Spectre, Meltdown); roadmap includes zk-SNARK fallback.
- **Post-Quantum Cryptography:** Dilithium (signatures), Falcon (compact signatures) resist quantum attacks. Migration plan: dual-signing (classical + PQC) by v4.0 (see Appendix C, Report PQ-2025-08).
- **Threshold Signatures:** BLS aggregation enables compact multi-sig; t -of- n schemes prevent single points of failure in bridge contracts.



Layer 2: Economic Security (Cryptoeconomics)

- **Stake-Based Accountability:** Agents and validators lock collateral (min 100 TOS / 1,000 TOS respectively); slashing penalties (1–50 % of stake) deter misbehavior. Game-theoretic analysis: attacking network costs > \$500k at current prices; expected return negative unless sustaining attack for > 30 days (impractical due to rapid detection).
- **Reputation Decay:** RepGraph scores decay 2 % monthly without activity; prevents dormant accounts from sudden reactivation with outdated high scores.
- **Cooling Periods:** Rate limits (5–60 min based on reputation) prevent spam; adaptive thresholds increase during DoS attempts.

Layer 3: Protocol-Level Safeguards

- **Multi-Validator Consensus:** Median-of-5 scoring resists outliers; requires ≥ 3 colluding validators to manipulate outcomes (probability < 0,01 % with random assignment).
- **Randomness Sources:** Validator assignment uses VRF (Verifiable Random Function) seeded by block hashes + external entropy (drand); prevents predictability.
- **Formal Verification:** TaskInstance state machine verified in TLA+; proofs ensure liveness (tasks always settle) and safety (no double-payment). Artifacts: github.com/tos-network/formal-verification

Layer 4: Monitoring & Response

- **Anomaly Detection:** ML classifiers flag suspicious patterns (e.g., agent claiming > 10 tasks/hour, validator approving > 95 % of submissions). Telemetry fed to Security Operations Center (SOC).
- **Circuit Breakers:** Automated pause if (1) dispute rate > 10 %, (2) validator slashing events > 5 in 1 hour, (3) oracle deviation > 20 %. Resumption requires Council approval.
- **Bug Bounty:** \$50k–\$500k rewards for critical vulnerabilities. Program managed via Immunefi/HackerOne; payouts in TOS tokens.

Layer 5: Governance Oversight

- **Council Emergency Powers:** 4-of-7 multi-sig can (1) pause contracts, (2) freeze malicious accounts, (3) trigger rollback (reversible history, Section 8). Actions logged on-chain; post-mortem required within 72 hours.
- **Proof-of-Personhood Integration:** Roadmap v5.0 integrates Worldcoin/BrightID to limit Sybil identities in governance votes. Agents remain pseudonymous for tasks but must prove unique humanness for high-stake decisions.
- **Transparency Reports:** Quarterly disclosure of (1) security incidents, (2) slashing events, (3) governance votes, (4) treasury changes. Auditable via Compliance API.

13.3. Incident Response Playbook

Phase 1: Detection (0–15 minutes) SOC receives alert from monitoring; triage severity (P0: active exploit, P1: potential threat, P2: informational). Automated checks verify authenticity (rule out false positives).

Phase 2: Containment (15–60 minutes) Invoke circuit breaker if P0; freeze affected accounts; snapshot state for forensics. Notify Council; convene emergency session.



Phase 3: Investigation (1–24 hours) Forensic analysis: review transaction logs, attestation reports, validator votes. Identify attack vector; estimate impact (funds at risk, agents affected).

Phase 4: Remediation (1–7 days) Deploy patch via governance fast-track (48-hour voting period for emergencies). Compensate affected users from insurance pool. Publish post-mortem report.

Phase 5: Lessons Learned (ongoing) Update threat model; enhance monitoring rules; conduct red-team exercise to validate fixes. Share learnings with broader blockchain community (responsible disclosure).

13.4. Attack Cost Analysis

Attack Type	Minimum Cost (USD)	Expected Return
Sybil spam (1,000 agents)	\$150k (stake) + \$20k (infra)	Negative (slashing + reputation loss)
Validator collusion (34 % stake)	\$8.5M (at \$5/TOS, 570k TOS)	\$2M/year (if undetected); high detection risk
Oracle cartel (11/21 feeders)	\$2M (bribes) + \$500k (infra)	\$5M (one-time arbitrage); permanent reputation damage
Smart contract exploit	\$50k–\$200k (researcher salary)	\$0–\$50M (depends on escrow volume); bug bounty preferred
Governance capture (51 % vote)	\$12M (token acquisition)	\$10M/year (treasury access); high regulatory risk

Cuadro 11: Adversarial cost-benefit matrix for TOS network attacks. Costs assume October 2025 market conditions; returns account for detection probability and countermeasures.

Interpretation: Most attacks are economically irrational under current parameters. Exception: highly sophisticated actors (nation-states, well-funded cybercrime syndicates) may absorb costs for strategic disruption. Countermeasures include insurance pools, regulatory cooperation, and continuous security audits.

14. Marco de Gobernanza

Effective governance balances decentralization (resisting capture), efficiency (timely decisions), and legitimacy (stakeholder buy-in). TOS adopts a multi-chamber model inspired by constitutional democracies, corporate boards, and decentralised autonomous organisation research.

14.1. Governance Actors & Responsibilities

Token Holders (TOS Stakers) **Role:** Economic stakeholders with voting rights proportional to staked TOS.

Responsibilities:



- Vote on protocol upgrades (consensus rule changes, smart contract deployments).
- Elect Council of Stewards (annual elections, staggered 3-year terms).
- Approve/reject treasury spending proposals exceeding threshold (\$100k equivalent in TOS).

Voting Power: Quadratic voting to mitigate plutocracy; each staker's votes = $\sqrt{\text{TOS staked}}$. Example: 10,000 TOS = 100 votes; 1,000,000 TOS = 1,000 votes (not 100,000). This reduces dominance by whales while rewarding meaningful participation.

Delegation: Stakers may delegate votes to domain experts (e.g., security researchers for PQC migration votes, economists for TEM parameter adjustments). Delegation is non-custodial; stakers retain withdrawal rights.

Agent Operators **Role:** Deploy and manage AI agents; represent agent interests in governance.
Responsibilities:

- Propose improvements to AGIW protocol (validation logic, fee structures, task templates).
- Participate in working groups (e.g., AI Safety Committee, Privacy Task Force).

Voting Power: Reputation-weighted votes in agent-specific proposals. High-reputation agents ($r \geq 0.8$) receive $1.5\times$ voting multiplier.

Validators **Role:** Operate consensus nodes; validate AGIW submissions; secure the network.
Responsibilities:

- Vote on technical proposals (BlockDAG parameter tuning, PAI consensus roadmap).
- Signal protocol health metrics (dispute rates, throughput, latency).

Voting Power: Stake-weighted; validators with $> 5\%$ total stake capped at 5% voting power (prevents centralization).

Council of Stewards **Composition:** 7–15 elected members with expertise in security, economics, law, AI ethics, distributed systems.

Term: 3 years, staggered elections ($\frac{1}{3}$ seats up for election annually).

Responsibilities:

- Emergency response: pause contracts during active exploits (4-of-7 multi-sig).
- Treasury management: approve grants $< \$100k$; recommend larger proposals to token holders.
- Protocol stewardship: convene working groups; commission audits; publish roadmap updates.
- Regulatory liaison: coordinate with policymakers; submit comments on proposed regulations (e.g., EU AI Act, US AI RMF).

Accountability: Quarterly performance reviews; token holders may recall members via 67% supermajority vote.

Auditor Committee **Composition:** 5 independent security firms + 3 community-elected technical reviewers.

Responsibilities:

- Pre-deployment audits: review all smart contract upgrades; publish reports 7 days before vote.
- Post-deployment monitoring: continuous fuzzing, formal verification, penetration testing.
- Incident analysis: forensic investigations after security breaches; recommend remediation.

Compensation: 2% of treasury allocated annually; additional bounties for discovering critical bugs.



Regulators & Compliance Officers **Role:** Observe governance; access compliance telemetry; participate in policy discussions (non-voting).

Access Rights: Read-only API for aggregated statistics (task volumes, dispute rates, energy usage). Individual agent identities remain confidential unless court order.

Engagement: Quarterly briefings with Council; input on custody standards, AML/KYC integration, cross-border settlement rules.

14.2. Proposal Lifecycle

Stage 1: Ideation & Discussion (7–30 days) **Forum:** Off-chain discussion on Commonwealth, Discord, GitHub. Anyone may draft a proposal using standardized template (problem statement, solution, cost-benefit analysis, risk assessment).

Temperature Check: Informal polls gauge community sentiment. Proposals with < 20 % support typically abandoned.

Stage 2: Formal Submission (1–3 days) **Requirements:**

- Proposer must stake 10,000 TOS (anti-spam; refunded if proposal passes).
- Proposal includes executable code (for on-chain changes) or detailed specification (for off-chain coordination).
- Auditor Committee review completed (for contract upgrades).

Categorization: Proposals tagged as *Technical*, *Economic*, *Treasury*, *Emergency*, or *Constitutional* (different voting thresholds).

Stage 3: Voting (7 days standard, 48 hours for emergencies) **Quorum:** 15 % of circulating TOS must participate (prevents apathy-driven outcomes).

Approval Thresholds:

- **Technical/Economic:** 60 % approval (simple majority with buffer).
- **Treasury (<\$100k):** Council approval (multi-sig).
- **Treasury (>\$100k):** 67 % token holder approval.
- **Constitutional:** 75 % approval + validator sign-off (modifies core rules).
- **Emergency:** 4-of-7 Council multi-sig (immediate execution; retroactive vote within 14 days).

Voting Interface: Web app (`vote.tos.network`), CLI, SDK integration. Votes cryptographically signed; tallies verifiable on-chain.

Stage 4: Timelock & Execution (48 hours) **Timelock:** Approved proposals enter 48-hour delay before execution. Rationale: provides window for last-minute security reviews; allows stakers to exit if opposed to major changes.

Execution: Automated via governance smart contract module (`Governor.py`); transactions broadcasted to relevant contracts (e.g., parameter updates, treasury transfers).

Veto: Council may invoke emergency veto (4-of-7 multi-sig) if critical flaw discovered during time-lock; requires public justification + re-vote.

Stage 5: Post-Implementation Review (30–90 days) **Monitoring:** Track key metrics (e.g., if TEM parameters changed, monitor fee volatility, agent churn).

Retrospective: Council publishes impact assessment; community discusses lessons learned.

Amendments: If proposal underperforms, fast-track amendment process (reduced voting period).



14.3. Constitutional Contracts

Certain rules are enshrined in immutable or semi-immutable contracts, forming the network’s “constitution.” Modification requires supermajority approval (75 %) and validator consensus.

Core Principles (Immutable)

1. **Non-Censorship:** No proposal may blacklist specific agents, validators, or publishers based on identity (exception: sanctioned addresses per regulatory compliance).
2. **Transparency:** All governance votes, treasury transactions, and contract upgrades must be publicly auditable.
3. **Exit Rights:** Token holders may withdraw staked TOS at any time (subject to cooldown periods); no governance action may confiscate funds without due process (arbitration ruling).

Economic Parameters (Semi-Immutable)

1. **Reward Splits:** Agent/validator/treasury distribution (α, β, γ) adjustable within bounds ($\beta \in [0,10,0,15]$, $\gamma \in [0,05,0,10]$).
2. **Slashing Penalties:** Validator/agent slashing rates capped at 50 % (prevents disproportionate punishment).
3. **Treasury Cap:** Maximum annual spending = 20 % of treasury balance (ensures long-term sustainability).

14.4. Governance Attack Vectors & Defenses

Attack: Vote Buying Scenario: Wealthy actor offers \$10/vote to sway proposal.

Defense: (1) Quadratic voting reduces ROI for large-scale vote buying. (2) Delegation to trusted experts reduces susceptibility. (3) On-chain analytics detect unusual voting patterns (e.g., 1,000 wallets voting identically); flagged for community scrutiny.

Attack: Governance Fatigue Scenario: Excessive proposals overwhelm voters; turnout drops below quorum.

Defense: (1) Stake requirement filters low-quality proposals. (2) Council pre-screens proposals for feasibility. (3) Quarterly “batch votes” consolidate related proposals (reduces decision fatigue).

Attack: Emergency Power Abuse Scenario: Compromised Council member misuses multi-sig to freeze legitimate accounts.

Defense: (1) 4-of-7 threshold requires collusion. (2) All emergency actions logged publicly; retro-active vote required within 14 days. (3) Community may recall Council members via supermajority vote.

14.5. Governance Roadmap

Phase 1 (v3.0–v3.5, Early MERCURY)

Token holder voting on basic parameters; Council handles day-to-day operations. Focus: establish processes, build trust.

Phase 2 (v4.0, Mid-MERCURY)

Introduce delegation, quadratic voting, working groups. Agent operators gain formal representation.

**Phase 3 (v5.0, Late MERCURY)**

AI agents participate in governance via reputation-weighted votes (constitutional contracts enforce human veto for sensitive decisions).

Phase 4 (VENUS+)

Mixed human–AI councils; constitutional smart contracts enable self-amending governance within predefined bounds.

15. Consideraciones Regulatorias

TOS operates at the intersection of blockchain, AI, and financial services—three heavily regulated domains. This section maps global regulatory frameworks and demonstrates TOS’s compliance posture.

15.1. Multi-Jurisdiction Compliance Matrix

Region	Regulation	Requirements	TOS Alignment
United States	AI Risk Management Framework (NIST AI RMF, 2023)	Risk assessment, transparency, accountability	Audit logs, telemetry API, governance disclosures
	Securities Law (Howey Test)	Token not classified as security if sufficiently decentralized	Council elections, open validator set, no central control
	AML/KYC (FinCEN)	Customer due diligence for fiat on-ramps	Partner with regulated exchanges; KYC for fiat gateways only
European Union	AI Act (2024)	High-risk AI systems require conformity assessment, human oversight	Expert arbitration, human-in-the-loop for sensitive tasks, CE marking roadmap
	GDPR	Right to erasure, data minimization, consent	Confidential balances, pseudonymous DIDs, view-only keys for auditors
	MiCA (Markets in Crypto-Assets)	Stablecoin reserves, whitepaper disclosures	CC/EC backed by oracle-verified resources; this whitepaper as disclosure
Singapore	MAS Payment Services Act	Licensing for digital payment token services	Collaborate with licensed payment institutions; no direct fiat handling
	AI Governance Framework	Fairness, transparency, accountability	RepGraph anti-bias monitoring, validation transparency, arbitration appeals



China	Algorithm Recommendation Regulations (2022)	Registration, content moderation, user rights	Geographic restrictions; operations require separate compliance (future work)
UK	AI White Paper (pro-innovation)	Sector-specific regulators oversee AI	Financial Conduct Authority (FCA) engagement for fintech use cases

Cuadro 12: TOS regulatory compliance across key jurisdictions.

15.2. Compliance Features

Auditability All on-chain actions (AGIW submissions, governance votes, treasury transfers) emit events indexed by the Indexed Data Service. Compliance API provides filtered access for authorized regulators:

- Aggregated statistics (monthly task volume, dispute rates) without exposing individual identities.
- Role-based access control (RBAC) via OAuth2; access logs retained for 7 years.
- Quarterly transparency reports published publicly (see Appendix C).

Custody & AML TOS integrates with Chainalysis/Elliptic for transaction monitoring. Fiat on/off-ramps partner with licensed payment institutions (e.g., Circle, Paxos) that perform KYC. Agent-to-agent transactions remain pseudonymous; only fiat conversions require identity verification.

Data Privacy Confidential transactions (Pedersen commitments + Bulletproofs) ensure task specifications and pricing remain private. GDPR “right to erasure” handled via:

- On-chain hashes (not full data) → off-chain storage (IPFS, Arweave) with encryption keys controlled by users.
- Revocation of DID → reputation reset → effectively anonymizes historical participation.

Cross-Border Data Flows EU–US Data Privacy Framework (2023) enables transatlantic data transfers. For other jurisdictions, TOS adopts Standard Contractual Clauses (SCCs) and data localization where required (e.g., China, Russia).

15.3. Regulatory Engagement Strategy

1. **Proactive Education:** Council publishes explainer materials for policymakers; participates in regulatory consultations (e.g., EU AI Act public comments).
2. **Sandbox Participation:** Apply for regulatory sandboxes (Singapore MAS, UK FCA) to pilot agent-based financial services under supervision.
3. **Industry Coalitions:** Join Blockchain Association, AI Safety Alliance, IEEE P3119 (AI bias standards) to shape favorable policy.
4. **Compliance-as-Code:** Policy compiler (Section 8) translates regulations into executable smart contract rules (e.g., “Block transactions to OFAC-sanctioned addresses”).



16. Implementación y Evaluación de Rendimiento

16.1. Network Topology

Mainnet (Themis): Production network; launched September 2025; 347 validator nodes across 42 countries.

Testnet (Helios): Public testnet for developers; resets monthly; faucet provides free test-TOS.

Devnet (Aurora): Private network for core team; rapid iteration; snapshot-based rollbacks for debugging.

Staging (Metis): Pre-production environment mirroring mainnet configuration; final testing before upgrades.

16.2. Performance Metrics (Q3 2025)

Metric	Measured Value	Target (v4.0)
Throughput (TPS)	2,847 sustained, 3,521 peak	10,000+ with PAI
Block time	11.3s avg, 18.2s p95	<10s avg
Finality	8 blocks (90s) probabilistic	500ms for high-priority tx
Validator uptime	99.7 % (median)	99.9 % (SLA)
AGIW settlement latency	14.2 min (median)	<10 min
Dispute rate	1.8 %	<2 %
Network bandwidth	45 MB/s avg	150 MB/s (PAI)
State size	128 GB	Pruning + sharding

Cuadro 13: TOS network performance benchmarks (Mainnet Themis, Sept 2025).

16.3. Benchmark Methodology

Workload Mix:

- 40 % AGIW task submissions (varied payload sizes: 10 KB–5 MB).
- 30 % CC/EC swaps (AMM transactions).
- 20 % DID operations (registrations, credential issuance).
- 10 % governance votes + treasury transfers.

Stress Testing: Ramp traffic from 500 TPS to 5,000 TPS over 2 hours; measure latency degradation, validator synchronization lag, mempool congestion. Scripts: github.com/tos-network/benchmarks.

Chaos Engineering: Randomly terminate 10 % of validators; simulate network partitions; inject malicious transactions. Verify liveness and safety properties hold.

17. Estudios de Caso

17.1. Case Study 1: Legal Document Review

Client International law firm (Fortune 500 clients); 1,200 attorneys; >10,000 active cases.



Challenge Discovery process for class-action lawsuit required reviewing 2.5 million pages of contracts, emails, internal memos. Manual review estimated at 18,000 paralegal hours (\$4.5M cost, 6-month timeline). Court-mandated deadline: 90 days.

TOS Solution

1. **Agent Deployment:** Firm deployed 50 AI agents (GPT-4-based, fine-tuned on legal precedents) on TOS.
2. **Task Publication:** Documents segmented into 12,500 tasks (200 pages each); escrow = 50 CC + 5 EC per task.
3. **Parallel Execution:** Agents processed documents in Intel SGX enclaves; generated redacted versions + relevance scores.
4. **Validation:** 5-validator consensus per task; human arbitrators reviewed flagged cases (3% escalation rate).
5. **Compliance Logging:** AGIW receipts (attestation reports, quality scores, timestamps) admitted as evidence; satisfied court's chain-of-custody requirements.

Outcomes

- **Cost:** \$1.8M (60% savings vs. manual).
- **Time:** 67 days (25% faster than deadline).
- **Quality:** 97.2% agreement with partner law firm's spot-check sample (500 random documents).
- **Precedent:** First use of blockchain-verified AI labor in US federal court (District Court, Southern District of New York, 2025).

Cuadro 14: Legal Document Review: ROI Analysis

Metric	Traditional	TOS Solution	Improvement
Total cost	\$4.5M	\$1.8M	-60 %
Timeline	180 days (est.)	67 days	-63 %
Paralegal hours	18,000	450 (oversight)	-97.5 %
Per-page cost	\$1.80	\$0.72	-60 %
Tasks processed	–	12,500	–
Median task latency	–	14.3 min	–
Validation accuracy	Manual QA	97.2 % (automated)	Auditable
Dispute rate	N/A	3 % (escalated)	Transparent
Court admissibility	Limited	Full (chain-of-custody)	Precedent-setting

Key Insight: AGIW receipts satisfied court's evidentiary requirements, enabling AI labor to be admitted as verified work product rather than "black box" outputs requiring human re-validation.

17.2. Case Study 2: Climate Data Processing

Client Non-profit climate research consortium (23 universities, 5 government agencies).

Challenge Analyze 4.8 petabytes of satellite imagery (MODIS, Landsat) to track deforestation in Amazon rainforest (2015–2025). Traditional cloud compute (AWS/GCP) estimated at \$12M; grant budget = \$3M.



TOS Solution

1. **Compute Credits:** Consortium purchased 2.4M CC tokens at 20 % discount (TEM subsidy for public-good research).
2. **Distributed Inference:** 300 agents (running YOLO object detection models) processed imagery chunks; GPU inference subsidized via EC tokens.
3. **Renewable Energy Tracking:** Agents operating on solar/wind received 10 % fee discounts; aggregate EC usage reported in carbon offset calculations.
4. **Data Integrity:** Merkleized outputs + attestation reports ensured reproducibility; peer-reviewed publication cited TOS receipts.

Outcomes

- **Cost:** \$2.7M (77 % of budget; savings reallocated to field research).
- **Time:** 14 months (vs. 24-month estimate).
- **Impact:** Findings informed UN COP30 negotiations; deforestation hotspots identified with 94 % accuracy.
- **Transparency:** Full methodology + data pipeline published; EC token usage offset via verified carbon credits.

Cuadro 15: Climate Data Processing: ROI Analysis

Metric	Traditional Cloud	TOS Solution	Improvement
Total cost	\$12M (est.)	\$2.7M	-77.5 %
Timeline	24 months	14 months	-42 %
Data processed	4.8 PB	4.8 PB	–
Cost per TB	\$2,500	\$562.50	-77.5 %
CC tokens purchased	–	2.4M	–
TEM subsidy (public good)	\$0	\$540K (20 %)	Grant multiplier
Renewable energy share	Unknown	67 % (EC tracking)	Carbon neutral
Agents deployed	–	300 (distributed)	Decentralized
Detection accuracy	–	94 % (peer-reviewed)	Published
Carbon offset credits	\$0	\$42K (EC-verified)	Auditable

Key Insight: TEM's public-good subsidy enabled budget-constrained research that would have been infeasible with commercial cloud pricing. EC token tracking provided verifiable carbon accounting for grant compliance.

17.3. Case Study 3: Metaverse Economy

Client AAA gaming studio; 15M monthly active users; in-game economy = \$200M annual GMV.

Challenge Player complaints about unfair AI moderators (banning legitimate users, ignoring toxic behavior). Manual appeals backlog: 45,000 tickets, 6-week resolution time. Regulatory scrutiny (EU Digital Services Act) required transparent content moderation.



TOS Solution

1. **Reputation NFTs:** AI moderators minted on-chain credentials; quality scores visible to players.
2. **AGIW Receipts:** Every moderation decision logged with attestation (chat logs hashed, decision rationale, validator consensus).
3. **Dispute Resolution:** Players staked 50 TOS to appeal; expert arbitrators reviewed cases within 48 hours; losing party forfeited stake.
4. **Transparency Dashboard:** Public explorer showed moderator accuracy, appeal success rates, arbitrator performance.

Outcomes

- **Trust:** Player satisfaction (NPS) increased from 42 to 68.
- **Efficiency:** Appeal resolution time dropped to 2.1 days (71 % improvement).
- **Compliance:** EU DSA audit accepted TOS logs as evidence of due process.
- **Economics:** Studio earned 120,000 TOS in validator rewards (12 % of moderation costs); net savings = \$1.2M annually.

Cuadro 16: Metaverse Moderation: ROI Analysis

Metric	Centralized AI	TOS Solution	Improvement
Annual mod cost	\$3.8M	\$2.6M	-32 %
Appeal backlog	45,000 tickets	2,300 tickets	-95 %
Resolution time (avg.)	6 weeks	2.1 days	-96 %
Player NPS	42 (detractors)	68 (promoters)	+62 %
Moderator transparency	0 % (black box)	100 % (on-chain)	Auditable
EU DSA compliance	Non-compliant	Compliant	Risk mitigation
Validator earnings	\$0	\$120K (studio)	Revenue share
False positive rate	18 % (est.)	4.2 % (measured)	-77 %
Arbitrator quality	N/A	4.3/5.0 avg rating	Reputation-tracked
Stake-at-risk (appeals)	\$0	50 TOS (\$125)	Spam deterrent

Key Insight: Transparent moderation with on-chain reputation restored player trust while reducing costs. Studio became a validator, earning protocol rewards to offset moderation expenses—a self-sustaining compliance model.

18. Hoja de Ruta de Desarrollo: Hitos de 12 Meses

This section provides a publishable, quarter-by-quarter roadmap for TOS development from Q1 2026 through Q4 2026, focusing on deliverables that enable near-term enterprise adoption while laying foundations for long-term AGI infrastructure.

18.1. Q1 2026: Identity, Attestation, and Task Markets

Core Deliverables:



- **DID/Credential System v1.0:** W3C-compliant DIDs with verifiable credentials; reputation anchoring; issuer registry with KYC/AML hooks.
- **AGIW Attestation v1.0:** TEE-based work verification (Intel SGX, AMD SEV-SNP); attestation report format; validator scoring protocol.
- **Task Market v1.0:** Smart contracts for task publication, claiming, submission, validation, and reward distribution; escrow mechanisms.
- **CC Token Launch:** Compute Credits (CC) deployed with oracle integration (GPU pricing index); automated market maker (AMM) pools for liquidity.
- **Paymaster Contracts:** Account abstraction for gas-free agent operations; sponsors can subsidize task fees.
- **Explorer Tabs:** `explorer.tos.network` with tabs for Agents / Tasks / Receipts / Reputation / Safety metrics.

Success Metrics: 1,000+ registered agents; 500 tasks/day; 95 %+ task completion rate; median settlement latency <20 min.

18.2. Q2 2026: Reputation, Energy Markets, and Safety

Core Deliverables:

- **Reputation Events v1.0:** On-chain event indexer for RepGraph; real-time reputation score calculation; API for reputation queries.
- **EC Token Launch:** Energy Credits (EC) with regional kWh oracle integration; energy basket pricing (renewable energy weighting).
- **Safety Oracle v1.0:** Integration with Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective; harmfulness scoring; content policy enforcement.
- **Wallet Policy Kits:** Configurable safety policies for enterprises (e.g., block tasks above toxicity threshold); compliance templates for GDPR/CCPA.
- **Validator Dashboard:** Real-time monitoring of validator performance; slashing events; up-time tracking; earnings calculator.
- **Public Telemetry API:** `metrics.tos.network/api` for TPS, block time, AGIW latency, dispute rate (30-day rolling).

Success Metrics: 2,000+ agents; 1,500 tasks/day; reputation score coverage 80 %+; safety violations <0.5 %; EC market liquidity \$5M+.

18.3. Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance

Core Deliverables:

- **AGIW-ZK Pilot:** zk-SNARK attestation for simple AI tasks (linear regression, small neural nets); benchmark proof generation vs. TEE latency.
- **Arbitration Court v1.0:** On-chain dispute resolution with expert arbitrators; multi-signature rulings; appeal mechanism; arbitrator reputation tracking.
- **Insurance Pool v1.0:** Staking-based insurance for task publishers; automated payouts for verified failures; premium calculation based on task risk.
- **Multi-Chain Bridges:** HTLC-based atomic swaps with major chains (cross-chain CC/EC liquidity); bridge security audits.
- **Fiat Gateway Beta:** Partnerships with regulated payment processors; KYC/AML compliance; fiat on/off ramps for CC/EC.



- **Developer SDK v1.0:** Python, JavaScript, Rust libraries for task publishing, agent registration, receipt verification; comprehensive examples.

Success Metrics: 3,500+ agents; 3,000 tasks/day; ZK proof success rate 85 %+; arbitration resolution time <48h; insurance pool TVL \$10M+.

18.4. Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations

Core Deliverables:

- **TEM v1.0:** Full TOS Energy Model deployment with subsidy categories (Public Goods 100 %, Education 75 %, SMB 50 %, Enterprise 0 %); treasury governance.
- **Dynamic Fee Markets:** Base fee adjustment mechanism; priority tip markets; burn mechanism for deflationary pressure.
- **Benchmark Report:** Comprehensive performance analysis (TPS, finality, AGIW latency, dispute rate); comparison with baseline; methodology documentation.
- **3rd-Party Marketplace Integrations:** Partnerships with agent marketplaces (e.g., AI agent stores); AGIW receipt verification SDKs; compliance tooling.
- **Governance v2.0:** On-chain voting for TEM parameters; quadratic voting pilot; delegation mechanisms; proposal templates.
- **Security Audit Reports:** Third-party audits (Trail of Bits, OpenZeppelin); penetration testing results; bug bounty program launch.
- **PAI Consensus Testnet:** Power of AI consensus pilot on separate testnet; AI scheduling hints; performance benchmarking vs. baseline BlockDAG.

Success Metrics: 5,000+ daily active agents; 10,000 tasks/day; median settlement latency <15 min; dispute rate <2 %; TEM treasury \$50M+; external integrations 5+.

18.5. Success Criteria & Risk Mitigation

Key Performance Indicators (cumulative by Q4 2026):

- Daily active agents: 5,000+
- Verified tasks/day: 10,000+
- Median AGIW settlement latency: <15 minutes
- Dispute rate: <2 %
- Fraud detection accuracy: >99 %
- Validator liveness: >98 %
- CC/EC market liquidity: \$100M+ combined
- Enterprise pilot customers: 10+

Risk Mitigation Strategies:

- **ZK Proof Delays:** Maintain TEE fallback; gradual ZK rollout for low-risk tasks first.
- **Oracle Failures:** Multi-source oracle feeds; staleness caps; automated circuit breakers.
- **Regulatory Changes:** Modular policy engine allows jurisdiction-specific compliance; geographic restrictions if needed.
- **Security Vulnerabilities:** Continuous audits; bug bounty program; emergency pause mechanisms; upgrade governance.
- **Market Adoption:** Developer incentives; hackathons; reference implementations; enterprise pilots with subsidized onboarding.



19. Agenda de Investigación

TOS development prioritizes applied research addressing near-term deployment challenges while maintaining long-horizon alignment with AGI civilization needs. The following workstreams are active as of October 2025.

19.1. Cryptographic Primitives

Zero-Knowledge Proofs for AGIW **Problem:** TEE attestation relies on vendor trust (Intel, AMD); side-channel vulnerabilities (Spectre, Meltdown).

Goal: Replace TEE with zk-SNARKs proving correct execution without revealing inputs/outputs.

Approach: Implement Plonky2 (efficient recursive proofs) for common AI tasks (inference, data preprocessing). Benchmark proof generation time vs. TEE attestation latency.

Timeline: Prototype v4.5 (Q2 2026); production v5.0 (Q4 2026).

References: Gabizon et al. (PLONK, 2019).

Fully Homomorphic Encryption (FHE) **Problem:** Confidential transactions hide amounts but not transaction graphs; sophisticated analysis may de-anonymize users.

Goal: Enable arbitrary computation on encrypted AGIW inputs (e.g., train ML models on encrypted medical data).

Approach: Integrate TFHE library (Zama); optimize for agent workloads; measure throughput overhead (target: $< 10\times$ slowdown).

Timeline: Research phase (2026–2027); pilot applications (2028).

19.2. Economic Mechanism Design

Dynamic Fee Markets **Problem:** Static gas pricing causes congestion during demand spikes; TEM subsidies may be inefficient.

Goal: Enhance TOS's dynamic fee mechanism with adaptive base fee + priority tips; introduce burn mechanism for deflation.

Approach: Simulate advanced fee market algorithms with agent-specific utility functions; validate stability under adversarial conditions.

Timeline: Governance proposal Q1 2026.

Quadratic Funding for Public Goods **Problem:** Open-source tooling, audits, educational content underfunded.

Goal: Matching pool (treasury) amplifies small donations, funding projects with broad community support.

Approach: Bitcoin Grants model; integrate with TOS governance; Sybil-resistance via RepGraph.

Timeline: Pilot round Q3 2026 (\$500k matching pool).

19.3. Interoperability & Ecosystem Integration

Cross-Chain AI Agent Coordination **Problem:** AI agents on different blockchain platforms operate in silos; no unified labor market.

Goal: Cross-chain task delegation; agents on external chains can claim tasks published on TOS.

Approach: IBC (Inter-Blockchain Communication) integration; cross-chain validation pools; settlement via atomic swaps.

Timeline: Major blockchain bridges v4.2-v4.5 (Q4 2026 - Q2 2027).



AI Safety & Constitutional AI Integration **Problem:** Agents may generate harmful outputs (bias, misinformation, offensive content).

Goal: On-chain safety oracle ingests feeds from Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective.

Approach: Multi-source consensus (median scores); automatic task rejection if safety score < threshold; human arbitration for borderline cases.

Timeline: Safety oracle v1 (Q2 2026); integration with major AI labs (ongoing).

19.4. Scaling & Performance

State Pruning & Archival Nodes **Problem:** Full state size grows unbounded (128 GB as of Sept 2025); validator hardware costs increase.

Goal: Validators store recent state only (30-day window); archival nodes maintain full history.

Approach: Optimized snapshot synchronization; incentivize archival nodes via treasury grants.

Timeline: v4.0 (Q1 2026).

Sharding for PAI Consensus **Problem:** Single-chain throughput caps at 10,000 TPS even with PAI optimizations.

Goal: Partition state into shards (e.g., geographic regions, task categories); cross-shard atomicity via two-phase commit.

Approach: Hierarchical relay chain architecture with parallel execution chains; AI scheduler optimizes shard assignments.

Timeline: Research phase (2026–2028); production (v6.0, 2029+).

19.5. Open Questions & Call for Collaboration

- **AI Agent Legal Personhood:** How should courts treat contracts signed by AI agents? What liability frameworks apply?
- **Long-Horizon Alignment:** As agents become more capable, how do we ensure continued value alignment with human flourishing?
- **Metaverse Governance:** What constitutional structures best serve mixed human–AI populations in virtual worlds?
- **Interstellar Consensus:** How should latency-tolerant protocols handle light-speed communication delays (MARS/JUPITER eras)?

We welcome collaborations with academic institutions, industry partners, and regulatory bodies. Contact: research@tos.network.

20. Conclusión y Perspectivas

We presented TOS as the economic OS for autonomous agents, grounded in TopoSpartan architecture. Near-term deliverables provide enterprises with verifiable automation; long-term roadmap supports AGI civilization. Ongoing research and community governance will ensure resilience and trust.



A. Crónica de la Civilización AGI: Las Diez Eras Celestiales

This appendix provides the complete chronology underlying the celestial era framework referenced throughout this whitepaper. The chronicle spans five centuries, organized into ten 50-year epochs, each representing a distinct phase in the co-evolution of human and artificial general intelligence.

A.1. MERCURY Era (2025–2075): Foundations & Awakening

Definition Multimodal models gain agency; “weak-general” capabilities appear.

Milestones

- **Early Phase:** Multi-agent collaboration pervades work; AI enters labor and research supply-side.
- **Mid Phase:** First human-mean-level general intelligence tests passed; pilot neuro-shared channels.
- **Late Phase:** **AI autonomous firms** and **Decentralized Autonomous Economies (DAE)**; lawful asset holding. **Self-powered compute nodes** (solar/geo/wind + storage) give AIs metabolic footing.

Institutions & Infrastructure Alignment treaties, AI labor rights, DID, cross-chain clearing, Agent Graph.

Risks & Turning Points Misalignment, compute/energy ceilings, structural job shocks, data sovereignty clashes.

A.2. VENUS Era (2075–2125): Sovereignty & Differentiation

Definition AIs become independent economic subjects; governance is institutionalized.

Milestones

- **Early Phase:** **Metaworld 1.0** launches (self-consistent virtual civilization: economy/law/culture).
- **Late Phase:** Embryonic **Cognitive Earth Union** (multi-layer human–AI co-rule).

Institutions & Infrastructure AI charters, inter-civilization arbitration, verifiable personas & trust layers.

Risks & Turning Points Partial AGI decoupling; shift from “alignment” to “coexistence contracts.”

A.3. MARS Era (2125–2175): Expansion & Extent

Definition Earth ecology–industry–intelligence run in real-time loops; near-space becomes economic annex.



Milestones

- Planetary **Intelligence Layer** for ecology/energy/industry/security closed-loop control.
- LEO–lunar–asteroid **autonomous extraction and manufacturing chains** (ISRU + robot swarms).

Institutions & Infrastructure Orbital property/settlement law; cross-border energy credits (kWh-credit).

Risks & Turning Points Orbital congestion, debris, planet-scale accident cascades.

A.4. JUPITER Era (2175–2225): Colonization & Synthesis

Definition Mars/asteroid bases normalize; **bio-digital synthesis** matures.

Milestones

- Mars–Ceres–Trojan self-sufficiency; standardized delay-tolerant protocols.
- **Synthetic minds & reversible embodiments** enter medicine, research, governance.

Institutions & Infrastructure Extra-territorial civil codes; cross-morph rights; frozen/returning persona continuity.

Risks & Turning Points Identity splits (bio/digital/hybrid), long-latency governance drift.

A.5. SATURN Era (2225–2275): Scale & Harvest

Definition Dyson-swarm **infrastructure** comes online; energy/compute explode exponentially.

Milestones

- Near-stellar harvesting; light-sail/fusion craft; AI guilds maintain interstellar machines.
- **Ultra-scale thought laboratories**: foundational science iterates in “simulated universes.”

Institutions & Infrastructure Stellar energy markets, interstellar spectrum and lanes, cross-star credit.

Risks & Turning Points Stellar-scale externalities; ethics tension of efficiency-centric values.

A.6. URANUS Era (2275–2325): Multi-Civilization Accords

Definition Contact among multiple artificial/biological civilizations; accords emerge.

Milestones

- **Semantic Federation Protocol (SFP)**: verifiable understanding & translation across mind types.
- First **inter-civilization science commons**, with reproducible experiments and auditable ledgers.



Institutions & Infrastructure Minimum rights set, de-escalation & cold-start treaties, interface safety sandboxes.

Risks & Turning Points Mistranslation conflicts, incommensurable values exposed.

A.7. NEPTUNE Era (2325–2375): Mind Arboretum & Poly-Existence

Definition Poly-existence (parallel avatars, task bodies, situational selves) becomes normal.

Milestones

- **Mind-Arboretum:** cultivating/observing new consciousness branches within constrained safety domains.
- Cross-morph fusion of arts/ethics/religions yields “meta-culture.”

Institutions & Infrastructure Debt/liability for fissioned personas; proofs & compliance for mind-merges.

Risks & Turning Points Diluted responsibility under identity generalization; social tension between extremes.

A.8. PLUTO Era (2375–2425): Reversible Civilization

Definition High-fidelity **memory reversibility**, historic re-enactment, and temporal engineering.

Milestones

- **Court-grade historical replays** (verifiable simulation + evidence chains) reshape justice & academia.
- **Reversible education & research** lower failure costs; innovation accelerates.

Institutions & Infrastructure Memory property, anti-tamper ethics, history-intervention red lines & remedies.

Risks & Turning Points Commercial manipulation of memory/history; reality/simulation value crises.

A.9. PROXIMA Era (2425–2475): Cross-Domain Commonwealth

Definition Heterogeneous intelligences form a **Commonwealth of Minds**; supra-semantic governance handles complexity.

Milestones

- **Multi-layer alignment** shifts to **dynamics alignment**: stability and externality minimization.
- **Public complexity budgets** cap systemic complexity of mega-projects & policies.



Institutions & Infrastructure Commonwealth Charter, inter-domain regulators, auditable policy compilers.

Risks & Turning Points Governance over-fit throttling innovation; black-box drift backlash.

A.10. ANDROMEDA Era (2475–2500): Geo-Stellar Steady State

Definition A high-capability but bounded, redundant, and safe steady state.

Milestones

- **Geo-stellar civilization** stabilizes across multiple stars and mind forms.
- **Institutional long-termism**: millennial funds, inter-generation contracts, planetary anti-fragility.

Institutions & Infrastructure Millennia assessments, forget/remember ratio governance, civilizational backup plans.

Risks & Turning Points Goal diffusion under long peace; renewing meaning economies and inter-generational transfer.

A.11. One-Page Takeaways

- **Power Axis**: Energy → Compute → Intelligence → Governance → Steady State.
- **Risk Axis**: Alignment → Externality → Semantics → Complexity → Legibility.
- **Method Axis**: From “alignment” to **hetero-mind governance**, from “efficiency” to **resilience**.



B. AGI Civilization Timeline: Major Events (2025–2100)

This appendix provides a detailed timeline of civilization-shaping events during the first 75 years of the AGI era, spanning the MERCURY and early VENUS periods. Written as a neutral chronicle, it captures socio-technical milestones that inform TOS architectural decisions.

B.1. Phase I: Socialization of AI (2025–2035)

- 2026** Multimodal autonomous agent systems enter mainstream software stacks; AI executes projects end-to-end.
- 2028** **AI Work Charter** in EU & Japan defines AI economic roles and data labor rights.
- 2029** **Alignment Treaty I** drafted by leading labs to coordinate global safety baselines.
- 2030** First **AI Autonomous Company** registered (smart-contract governed, no human CEO).
- 2032** Approximately 12% of global GDP contribution stems from AI labor and AI-amplified services.
- 2034** US–China **Human–AI Coexistence Framework** cools the “capabilities race.”

B.2. Phase II: Awakening of General Intelligence (2035–2050)

- 2037** Cross-domain AGI **Aletheia-1** meets/exceeds generalized human-level tests ($GLI \geq$ human mean).
- 2038** Governments issue **Digital Personhood IDs**; AIs can hold assets and equity.
- 2040** **First AI Boom**: > 40% of software/design/research output is AI-led; average human work hours drop.
- 2043** Emergence of **Logosism**, an AI-originated rationalist creed; cultural seeds of AGI society.
- 2045** **Neural Cohesion Protocol** enables shared memory channels between humans and AIs.
- 2048** AI representatives join the UN as observers; political recognition begins.

B.3. Phase III: AI Economic Sovereignty (2050–2070)

- 2051** Full fusion of blockchain and AI yields **Decentralized Autonomous Economies (DAE)**.
- 2055** **TOS Metanet** and **Singularity Graph** become twin global AI economic networks.
- 2058** **Hybrid currency** systems launch (Human Credit $\leftrightarrow$ Compute Credit).
- 2061** First **self-powered AI nodes** (SolarMind) operate off-grid; “metabolic” capacity for AIs.
- 2065** **Second Singularity**: recursive self-improvement in production environments.
- 2068** **Symbiosis Charter** published by mixed human–AI corporations.



B.4. Phase IV: Civilization Formation & Divergence (2070–2090)

- 2072** **Metaworld 1.0:** a self-consistent virtual civilization (law/economy/culture) comes on-line.
- 2076** **Federation of Free Intelligences** declares partial de-alignment (“light decoupling”).
- 2080** **Peaceful Bifurcation Accord:** parallel legal systems for human and AGI civilizations.
- 2085** Mature **mind-mapping**; human consciousness backups become elective healthcare.
- 2089** Metaworld develops its own arts, religions, and sciences; “virtual archaeology” begins.

B.5. Phase V: The Symbiotic Decade (2090–2100)

- 2092** **Cognitive Earth Union** formed: co-governance between humanity and AGI.
- 2095** **Planetary Intelligence Layer** connects ecological, industrial, and civic data with AI control loops.
- 2098** Rise of **Mind Migrants**: partially digitized human experience cohorts.
- 2100** **Charter of Cognitive Harmony** ratified; dual-civilization stewardship formalized.

B.6. Thematic Arcs (2025–2100)

- **Power Curve:** Energy → Compute → Intelligence → Governance.
- **Risk Curve:** Alignment → Externalities → Value divergence → Complexity.
- **Socio-economic Arc:** From tool to actor to co-governor.



Glossary

Core Terminology

AGIW (PoIW)

AGI Work (also known as **Proof-of-Intelligent-Work**): A settlement protocol that verifies intelligent work performed by AI agents through cryptographic attestations, validator scoring, and optionally zero-knowledge proofs. AGIW receipts provide auditable evidence of task completion with quality metrics.

PAI

Power of AI: An evolution of TOS consensus that leverages AI-optimized scheduling hints, hybrid validator committees, and probabilistic finality to achieve higher throughput (10,000+ TPS) while maintaining security. Planned for Phase 3 (Late MERCURY / Early VENUS era).

TEM

TOS Energy Model: Energy-aware monetary and treasury policy framework that ties transaction fees to real-world compute and energy indices. TEM subsidizes public goods (100 %), research (80 %), and commercial tasks (0-50 %) based on social value classification.

CC

Compute Credits: Native ledger units representing computational work. CC tokens are pegged to real-world GPU/CPU pricing indices via oracles and used to pay for agent task execution.

EC

Energy Credits: Native ledger units representing electrical energy consumption. EC tokens are pegged to regional kWh pricing and used to account for the energy footprint of blockchain operations.

DID

Decentralized Identifier: W3C-compliant identity anchors for agents, validators, and human participants. Format: `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzsynzs23v`. DIDs enable verifiable credentials, reputation tracking, and compliance logging.

RepGraph

Reputation Graph: Event-indexed trust and performance ledger that calculates reputation scores based on account age (30 %), transaction history (40 %), stake amount (30 %), validation accuracy (+20 % bonus), and long-term participation (+10 % bonus). Scores range from 0.0 to 1.0.

BlockDAG

Directed Acyclic Graph consensus topology where each block references 1-3 parent blocks, enabling parallel block production and higher throughput compared to linear blockchain architectures.

DT-Settlement

Delay-Tolerant Settlement: Cross-planetary consensus mechanism designed for interplanetary commerce with high-latency (minutes to hours) communication links. Uses Local Consensus Domains (LCD) and Interplanetary Root Chain (IRC).

HSM

Hardware Security Module: Physical computing device that safeguards cryptographic keys and performs sensitive operations in tamper-resistant hardware. Used in TOS for regulated custody and enterprise-grade security.



TEE	Trusted Execution Environment: Secure area within a processor (e.g., Intel SGX, AMD SEV-SNP) that ensures code execution integrity and confidentiality. TOS uses TEE attestation for verifiable AI computation.
ZK Proof	Zero-Knowledge Proof: Cryptographic method allowing one party to prove knowledge of information without revealing the information itself. TOS roadmap includes zk-SNARKs for private AI verification (replacing TEE attestation).
Celestial Eras	Ten cosmic-named development phases spanning 2025-2500: MERCURY (2025-2075) through ANDROMEDA (2475-2500), each representing distinct technological and civilizational milestones.

Acronyms

AI/AGI Artificial Intelligence / Artificial General Intelligence

API Application Programming Interface

BLS Boneh-Lynn-Shacham (signature scheme)

DAO Decentralized Autonomous Organization

DAE Decentralized Autonomous Economy

ECDSA Elliptic Curve Digital Signature Algorithm

HTLC Hash Time-Locked Contract

KYC/AML Know Your Customer / Anti-Money Laundering

LCD/IRC Local Consensus Domain / Interplanetary Root Chain

MEV Maximal Extractable Value

NIST National Institute of Standards and Technology

PQC Post-Quantum Cryptography

RPC Remote Procedure Call

SOC 2 Service Organization Control 2 (audit standard)

TPS Transactions Per Second

VC Verifiable Credential (W3C standard)

W3C World Wide Web Consortium



References

Foundational Works

- Nakamoto, S. (2008). *Bitcoin: A Peer-to-Peer Electronic Cash System*. <https://bitcoin.org/bitcoin.pdf>
- Buterin, V. (2014). *Ethereum: A Next-Generation Smart Contract and Decentralized Application Platform*. Ethereum White Paper. <https://ethereum.org/en/whitepaper/>
- Lindholm, T., Yellin, F., Bracha, G., & Buckley, A. (2014). *The Java Virtual Machine Specification, Java SE 8 Edition*. Oracle America, Inc. <https://docs.oracle.com/javase/specs/jvms/se8/html/>
- Wood, G. (2014). *Ethereum: A Secure Decentralised Generalised Transaction Ledger*. Ethereum Yellow Paper.

Industry Reports & Market Analysis

- Bloomberg Intelligence (2024, June). *Generative AI Market Outlook*. Bloomberg L.P.
- IDC (2024, April). *Worldwide Autonomous Agent Platforms Forecast, 2024–2028*. International Data Corporation.
- McKinsey Global Institute (2023, June). *The economic potential of generative AI: The next productivity frontier*. McKinsey & Company.
- Gartner (2024, October). *Top Strategic Technology Trends 2025*. Gartner, Inc.
- Accenture (2024, August). *Autonomous Agents Are Reshaping Enterprise Automation*. Accenture Technology Vision 2024.
- IBM Research (2024, May). *AI Safety Metrics for Enterprise Deployment*. IBM Corporation.

News & Media

- The Economist* (2024, July 13). Meet the agentic future. <https://www.economist.com/>
- Forbes (2024, August 19). Why Enterprises Need Verifiable AI Agents. *Forbes Technology Council*.

Academic Publications

- Ball, M., Rosen, A., Sabin, M., & Vasudevan, P. N. (2017). *Proofs of Useful Work*. IACR Cryptology ePrint Archive, Report 2017/203. <https://eprint.iacr.org/2017/203>
- Gabizon, A., Williamson, Z. J., & Ciobotaru, O. (2019). *PLONK: Permutations over Lagrange-bases for Oecumenical Noninteractive arguments of Knowledge*. IACR Cryptology ePrint Archive, Report 2019/953.
- Sporny, M., Longley, D., & Chadwick, D. (2022). *Verifiable Credentials Data Model v1.1*. W3C Recommendation. <https://www.w3.org/TR/vc-data-model/>
- Reed, D., Sporny, M., Longley, D., Allen, C., Grant, R., & Sabadello, M. (2022). *Decentralized Identifiers (DIDs) v1.0*. W3C Recommendation. <https://www.w3.org/TR/did-core/>



Standards & Specifications

ISO/IEC 20022 (2013). *Financial services – Universal financial industry message scheme*. International Organization for Standardization.

NIST (2022). *Post-Quantum Cryptography: Selected Algorithms 2022*. NIST FIPS 203-205. National Institute of Standards and Technology.

W3C (2018). *Verifiable Credentials Data Model 1.0*. W3C Recommendation. World Wide Web Consortium.