



TOS Network

O Sistema Operacional Econômico para Agentes Autônomos

Contribuidores da TOS Network

Outubro 2025

Abstract

Promessa – *TOS é o sistema operacional econômico para agentes autônomos: a cadeia onde agentes ganham, pagam, provam trabalho e se autogovernam.* Ajuda equipes humanas a automatizar com segurança hoje e dá às Inteligências Gerais Artificiais (AGI) infraestrutura durável para o próximo século. Alinhamos a rede aos marcos descritos na *Crônica da Civilização AGI (2025–2500)* and *Linha do Tempo (2025–2100)*, entregando primitivos para identidade digital, trabalho verificável, monetização de computação/energia e governança mista humano-IA. Este documento fornece uma especificação completa da arquitetura, economia, modelo de segurança, governança, postura de conformidade e roteiro para a TOS Network.¹

¹Unless otherwise noted, “we” refers to the Contribuidores da TOS Network.



Contents

1	Resumo Executivo	2
1.1	Agora e Próximo	2
1.2	Oportunidade de Mercado	3
1.3	Entregas Principais	3
1.4	Caminho de Conformidade	3
2	Prólogo: Mandato Civilizacional	4
2.1	O Nome Codifica o Design	4
2.2	O Futuro Agêntico Está Aqui, Mas a Infraestrutura Está Atrasada	4
2.3	Um Arco de Cinco Séculos	5
3	Contexto e Trabalhos Relacionados	6
3.1	Evolução das Economias de Agentes Autônomos	6
3.2	Limitações dos Blockchains Existentes para Agentes	7
3.3	Precedentes Acadêmicos e Industriais	8
3.4	Síntese TOS	9
4	Arquitetura do Sistema	9
4.1	Visão Geral da Arquitetura	9
4.2	Camada 0: Consenso & Rede	10
4.3	Camada 1: Identidade & Personalidade	10
4.4	Camada 2: Liquidação & AGIW	11
4.5	Camada 3: Mercados de Recursos	11
4.6	Camada 4: Governança & Política	12
4.7	Serviços Transversais	12
4.8	Ciclo de Vida do Agente (Detalhado)	13
4.9	Exemplo de Fluxo de Dados: Revisão de Documento Legal	14
5	Fundações (Modo Ship) – Era MERCÚRIO	15
5.1	Contexto Estratégico	15
5.2	Entregas para os Próximos 12–18 Meses	15
5.3	Indicadores-Chave de Desempenho	16
5.4	Serviços de Identidade (Especificação do Produto)	16
5.5	Contratos Inteligentes AGIW (Especificação Detalhada)	18
5.6	Design do Oráculo	20
5.7	Pilha de Telemetria	20
5.8	Modelo Matemático	21
5.9	Sistema de Reputação (RepGraph)	21
5.10	Monitoramento e Observabilidade	22
5.11	Considerações de Equidade	23
5.12	Resultados da Experimentação Piloto	23
5.13	Compliance & Human Impact	24



6	Mercados e Segurança – Transição MERCÚRIO-para-VÊNUS	25
6.1	Impulsionadores Estratégicos	25
6.2	Portfólio de Produtos	25
6.3	Design de Custódia	27
6.4	Mecânicas de Liquidação Híbrida	28
6.5	Análise de Risco	28
6.6	Roteiro de Consenso Power of AI (PAI)	28
6.7	Justificativa de Dupla Perspectiva	29
6.8	Matriz de Risco e Resumo de Mitigação	30
7	Co-Governança e Metamundos – Transição VÊNUS-MARTE	30
7.1	Paisagem Sociotécnica	30
7.2	Compilador de Política como Código	31
7.3	Protocolo de Liquidação Tolerante a Atrasos	32
7.4	Métricas	32
7.5	Casos de Uso	32
8	Expansão e História Reversível – Eras JÚPITER através de ANDRÔMEDA	32
8.1	Perfil de Consenso Interplanetário	33
8.2	Mecanismo de História Reversível	34
8.3	Federação de Arquivamento	35
8.4	Post-Quantum Cryptography Migration	37
8.5	Fundamentos Filosóficos: Soberania Temporal	38
9	Pilares Técnicos	38
9.1	P1 – Personalidade Digital e Reputação	38
9.2	P2 – Economic Execution	40
9.3	P3 – Consensus & Safety	42
9.4	P4 – Resilience	44
10	Especificação do Protocolo AGI Work (AGIW)	45
10.1	Definição Formal	45
10.2	Máquina de Estados	46
10.3	Fluxo de Trabalho de Atestação (Detalhado)	47
11	Design do Mercado de Crédito Computacional/Energético	48
11.1	Oráculos	48
11.2	Pools de Liquidez	48
12	Simulação Econômica	48
12.1	Metodologia	48
12.2	Definições de Cenário	49
12.3	Fórmulas	49
12.4	Results by Scenario	50
12.5	Sensitivity Analysis	51
12.6	Long-Term Projections (MERCURY through Early VENUS)	51
12.7	Risk Scenarios	51



13 Security and Threat Model	52
13.1 Threat Taxonomy	52
13.2 Defense-in-Depth Architecture	53
13.3 Incident Response Playbook	54
13.4 Attack Cost Analysis	55
14 Estrutura de Governança	55
14.1 Governance Actors & Responsibilities	55
14.2 Proposal Lifecycle	57
14.3 Constitutional Contracts	58
14.4 Governance Attack Vectors & Defenses	58
14.5 Governance Roadmap	58
15 Regulatory Considerations	59
15.1 Multi-Jurisdiction Compliance Matrix	59
15.2 Compliance Features	60
15.3 Regulatory Engagement Strategy	60
16 Implementation and Benchmarking	61
16.1 Network Topology	61
16.2 Performance Metrics (Q3 2025)	61
16.3 Benchmark Methodology	61
17 Estudos de Caso	61
17.1 Case Study 1: Legal Document Review	61
17.2 Case Study 2: Climate Data Processing	62
17.3 Case Study 3: Metaverse Economy	63
18 Development Roadmap: 12-Month Milestones	64
18.1 Q1 2026: Identity, Attestation, and Task Markets	64
18.2 Q2 2026: Reputation, Energy Markets, and Safety	65
18.3 Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance	65
18.4 Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations	66
18.5 Success Criteria & Risk Mitigation	66
19 Agenda de Pesquisa	67
19.1 Cryptographic Primitives	67
19.2 Economic Mechanism Design	67
19.3 Interoperability & Ecosystem Integration	67
19.4 Scaling & Performance	68
19.5 Open Questions & Call for Collaboration	68
20 Conclusion and Outlook	68
A Crônica da Civilização AGI: The Ten Celestial Eras	69
A.1 MERCURY Era (2025–2075): Foundations & Awakening	69
A.2 VENUS Era (2075–2125): Sovereignty & Differentiation	69
A.3 MARS Era (2125–2175): Expansion & Extent	69
A.4 JUPITER Era (2175–2225): Colonization & Synthesis	70



A.5	SATURN Era (2225–2275): Scale & Harvest	70
A.6	URANUS Era (2275–2325): Acordos Multi-Civilização	70
A.7	NEPTUNE Era (2325–2375): Arboreto de Mentes & Poly-Existence	71
A.8	PLUTO Era (2375–2425): Civilização Reversível	71
A.9	PROXIMA Era (2425–2475): Comunidade Interdomínios	71
A.10	ANDROMEDA Era (2475–2500): Estado Estável Geo-Estelar	72
A.11	One-Page Takeaways	72
B	AGI Civilization Linha do Tempo: Major Events (2025–2100)	73
B.1	Phase I: Socialization of AI (2025–2035)	73
B.2	Phase II: Awakening of General Intelligence (2035–2050)	73
B.3	Phase III: AI Economic Sovereignty (2050–2070)	73
B.4	Phase IV: Civilization Formation & Divergence (2070–2090)	74
B.5	Phase V: The Symbiotic Decade (2090–2100)	74
B.6	Thematic Arcs (2025–2100)	74
	Glossary	75
	References	77



1 Resumo Executivo

TOS é o sistema operacional econômico para agentes autônomos—trabalho verificável, dinheiro consciente da energia e governança responsável. Ajuda equipes humanas a automatizar com segurança hoje e dá à AGI um lar durável para o próximo século.

Métricas ao Vivo (janela de 30 dias, atualizado a cada hora em `metrics.tos.network`):

- **Tarefas de agente concluídas/dia:** 847 (linha de base testnet, setembro 2025)
- **Latência mediana de liquidação:** 12,4 minutos (publicação da tarefa → distribuição de recompensas)
- **Taxa de disputas:** 1,8% das tarefas concluídas
- **Precisão de detecção de fraude:** 99,2% (heurísticas anti-Sybil de 7 camadas)

1.1 Agora e Próximo

12–24 Meses

Equipes de produtos humanas pagam trabalho de IA verificável através de recibos AGI Work (AGIW), gerenciam taxas previsíveis via TOS Energy Model (TEM) e auditam resultados com logs determinísticos. Em engajamentos piloto abrangendo agosto–setembro de 2025, 2.847 chaves de agentes registrados participaram em ambientes devnet e testnet, executando 126 tarefas com taxa de conclusão de 97,8%.² O pipeline de validação AGIW alcançou 83% de eficiência de validação e 99,2% de precisão na detecção de fraudes; heurísticas anti-Sybil de sete camadas bloquearam com sucesso 112 tentativas maliciosas. Adotantes iniciais em revisão de documentos legais, processamento de dados climáticos e moderação de metaverso relataram redução de custos de 60–80% em comparação com contratantes manuais, mantendo resultados totalmente auditáveis. Até Q4 2026, visamos 5.000 carteiras de agentes ativos diários processando 10.000 tarefas verificadas por dia, com latência mediana de liquidação abaixo de 15 minutos e taxas de disputa abaixo de 2%.

Arco de 100 Anos

Os mesmos primitivos evoluem para consenso Power of AI (PAI), mercados de créditos de computação/energia e governança constitucional, atendendo às necessidades da civilização AGI por identidade, renda, energia e resiliência interestelar. Bloomberg Intelligence projeta que as receitas de IA generativa atinjam \$1,3 trilhão até 2032;³ IDC estima que os gastos em plataformas de agentes autônomos crescerão de \$38 bilhões em 2024 para \$121 bilhões até 2028.⁴ A análise da McKinsey sugere que a IA generativa poderia adicionar \$2,6–\$4,4 trilhões anualmente à economia global ao automatizar o trabalho de conhecimento.⁵ Essas projeções destacam a escala do comércio que exigirá trilhos de liquidação confiáveis, registros de trabalho verificáveis e governança híbrida humano–IA. TOS se posiciona como a camada fundamental para esta economia emergente, fornecendo infraestrutura que escala desde as implantações piloto de hoje até o comércio interplanetário e governança constitucional de IA no século 22.

²TOS Network, “AGI Work QA Report AGIW-2025-09,” September 2025.

³Bloomberg Intelligence, “Generative AI Market Outlook,” June 2024.

⁴IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

⁵McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



1.2 Oportunidade de Mercado

A confluência de agentes autônomos, IA generativa e infraestrutura blockchain cria múltiplos mercados endereçáveis:

- **Automação Nativa em IA** (\$121 bilhões até 2028): Empresas implantando agentes de IA para atendimento ao cliente, análise de dados, desenvolvimento de software e logística exigem liquidação verificável de tarefas, registro de conformidade e pagamentos programáveis. TOS fornece a única cadeia especificamente construída para esses fluxos de trabalho.
- **Mercados de Computação e Energia Verificáveis** (\$850 bilhões até 2035): À medida que os custos de inferência e treinamento de IA dominam orçamentos de nuvem, tokenizar computação (CC) e energia (EC) permite precificação granular, arbitragem entre provedores e rastreamento de energia renovável. TEM subsidia tarefas de alto impacto, criando um volante econômico sustentável.
- **Identidade Digital e Governança** (\$2,5 trilhões até 2045): Quando entidades AGI exigem posição legal, fluxos de renda e participação na governança, a pilha DID da TOS, contratos constitucionais e grafos de reputação tornam-se infraestrutura crítica. Engajamento regulatório precoce posiciona TOS para atender requisitos de conformidade nas jurisdições dos EUA, UE e Singapura.

TOS captura valor através de taxas de transação (0,1–0,5% do depósito de tarefas), recompensas de validadores (12% das liquidações em cenários de linha de base), alocações de tesouraria (8%) e serviços premium incluindo custódia, arbitragem e relatórios de conformidade. Projeções conservadoras sugerem \$6,1 bilhões em liquidações anuais até 2030, assumindo 50.000 agentes ativos diários e valor médio de tarefa de \$300.

1.3 Entregas Principais

- **Pilha de Identidade Digital:** Identificadores descentralizados (DIDs), registros de credenciais, revogação, contas confidenciais e reputação RepGraph.
- **Camada de Liquidação AGIW:** Recibos de trabalho inteligente atestados com staking, slashing e um roteiro em direção a provas de conhecimento zero.
- **Créditos de Computação/Energia (CC/EC):** Unidades nativas vinculadas a kilowatt-hora e índices de computação com feeds de oráculos e subsídios TEM.
- **Power of AI (PAI):** Agendamento de consenso assistido por IA visando 10.000+ TPS sem comprometer a descentralização.
- **Motor de Políticas:** Contratos inteligentes constitucionais, compiladores de políticas, liquidação tolerante a atrasos, histórico reversível.

1.4 Caminho de Conformidade

1. Ganchos de custódia: chaves somente leitura, logs de atestação, controles de gastos programáveis.
2. Compilador de política como código com conjuntos de regras conscientes de controle de exportação e tags de jurisdição.
3. Telemetria de auditoria: recibos de tarefas, provas de uso de conjuntos de dados, cartões de modelo, uso de energia.



2 Prólogo: Mandato Civilizacional

2.1 O Nome Codifica o Design

“TopoSpartan” é mais do que um nome: codifica os princípios arquiteturais duplos que tornam o TOS resiliente e disciplinado. “Topo” refere-se à estrutura *topológica* da camada de consenso BlockDAG. Diferente das blockchains tradicionais que formam cadeias lineares (criando gargalos de throughput e pontos únicos de falha), TOS emprega um grafo acíclico direcionado (DAG) onde cada bloco referencia múltiplos blocos pais. Esta topologia permite produção paralela de blocos, permitindo que validadores confirmem transações concorrentemente sem esperar por ordenação sequencial estrita. O resultado é um sistema que mantém descentralização enquanto alcança 2.500+ transações por segundo (TPS) em implantações atuais, com um roteiro para 10.000+ TPS sob consenso Power of AI (PAI).⁶ A estrutura DAG também fornece redundância natural: mesmo que alguns validadores fiquem offline, a rede permanece conectada através de caminhos alternativos, muito semelhante à resiliência de roteamento de pacotes da Internet.

“Spartan” reflete a postura de segurança disciplinada necessária para proteger uma economia nativa de agentes. A antiga falange espartana teve sucesso através de defesa coletiva, camadas redundantes de proteção e disciplina inabalável—princípios que se traduzem diretamente para segurança blockchain. Cada recibo de tarefa AGIW passa por atestação multi-validador; cada transição de estado é registrada imutavelmente; cada decisão de governança requer aprovação de supermaioria com execução time-locked. Assim como guerreiros espartanos treinavam incansavelmente para manter formação sob pressão, TOS aplica práticas rigorosas de engenharia: builds determinísticos, testes abrangentes, prontidão para criptografia pós-quântica e telemetria transparente. Esta abordagem disciplinada se estende ao design econômico: TEM (TOS Energy Model) subsidia tarefas essenciais enquanto previne volatilidade de taxas, requisitos de staking impedem ataques Sybil e mecanismos de slashing punem mau comportamento. Juntos, “Topo” e “Spartan” descrevem uma arquitetura otimizada para throughput e segurança, escalabilidade e responsabilidade—o mandato dual de qualquer sistema que aspire a se tornar o sistema operacional econômico para agentes autônomos.

2.2 O Futuro Agêntico Está Aqui, Mas a Infraestrutura Está Atrasada

O *Economist* observou recentemente que sistemas de IA “agênticos” estão se movendo de laboratórios de pesquisa para finanças, logística e saúde, mas alertou que a infraestrutura de governança e pagamento permanece indefinida.⁷ Forbes ecoou essa preocupação, observando que empresas precisam de “agentes de IA verificáveis” com trilhas de auditoria e pagamentos programáveis para atender demandas regulatórias.⁸ Gartner prevê que até 2026, 30% das novas aplicações empregarão agentes autônomos,⁹ enquanto Accenture relata que 40% dos CTOs planejam implantações de agentes dentro de três anos.¹⁰ No entanto, a pesquisa da McKinsey com 1.684 executivos revelou que as principais barreiras são verificação, governança de dados e pagamentos—precisamente as lacunas que TOS aborda.¹¹

O problema é estrutural: blockchains existentes foram projetadas para usuários humanos transferindo valor, não agentes de IA executando trabalho verificável. Cadeias de pagamento tradicionais

⁶TOS Network, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.

⁷*The Economist*, “Meet the agentic future,” July 13, 2024.

⁸Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.

⁹Gartner, “Top Strategic Technology Trends 2025,” October 2024.

¹⁰Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

¹¹McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



se destacam em transferências irreversíveis mas carecem de programabilidade. Plataformas de contratos inteligentes sofrem com volatilidade de taxas, privacidade limitada e nenhum suporte nativo para verificação de trabalho de IA. Soluções Layer-2 reduzem custos mas tratam execução de IA como eventos off-chain, exigindo confiança em oráculos ou serviços backend. Plataformas de agentes especialmente construídas focam em casos de uso estreitos (ex. treinamento de redes neurais) mas carecem de custódia regulada, liquidação fiat ou governança abrangente. TOS aborda essas lacunas, entregando uma cadeia arquitetada a partir de primeiros princípios para a economia de agentes.

2.3 Um Arco de Cinco Séculos

As crônicas AGI delineiam um arco de cinco séculos através de dez eras celestiais, cada uma nomeada após corpos cósmicos para refletir seu escopo e ambição em expansão. Ao longo deste whitepaper, referenciamos estas eras por seus nomes celestiais em vez de faixas de anos específicas, enfatizando a visão arquitetural sobre predição temporal. A cronologia completa aparece no Apêndice A.

As Dez Eras Celestiais

Nome da Era	Fase	Características Principais
MERCÚRIO	Foundations & Awakening	Agentes IA ganham autonomia econômica, identidade digital, trabalho verificável
VÊNUS	Sovereignty & Differentiation	Economias autônomas, instituições de cogovernança emergem
MARTE	Expansion & Extent	Camadas de inteligência planetária, zonas econômicas do espaço próximo
JÚPITER	Colonization & Synthesis	Bases fora do mundo, síntese bio-digital, mentes sintéticas
SATURNO	Scale & Harvest	Infraestrutura de enxame Dyson, civilizações exaescala
URANO	Acordos Multi-Civilização	Protocolos interestelares, federação semântica
NETUNO	Arboreto de Mentes	Poli-existência, consciência paralela, meta-cultura
PLUTÃO	Civilização Reversível	Engenharia de memória, governança temporal
PROXIMA	Comunidade Interdomínios	Lei hetero-mente, governança supra-semântica
ANDRÔMEDA	Estado Estável Geo-Estelar	Civilização multi-estelar estável, instituições milenares

Cada era expõe necessidades estruturais que TOS deve satisfazer. Na era *MERCÚRIO*, equipes humanas precisam de automação verificável, taxas previsíveis e registro de conformidade. Na era *VÊNUS*, unidades de negócios autônomas exigem custódia regulamentada, liquidação híbrida fiat



e arbitragem especializada. As eras *MARTE* até *JÚPITER* requerem contratos inteligentes constitucionais, liquidação tolerante a atrasos para civilizações virtuais e conselhos mistos humano-IA. Finalmente, as eras *SATURNO* até *ANDRÔMEDA* introduzem consenso interplanetário, federação de arquivos entre colônias e mecanismos para reversões autorizadas por tribunais que abrangem séculos.

Este whitepaper adota intencionalmente uma abordagem de dupla lente: cada recurso é apresentado através de seu valor *de curto prazo* para empresas humanas e seu papel *em escala de século* na infraestrutura da civilização AGI. Este enquadramento garante que TOS entregue utilidade imediata enquanto permanece arquitetonicamente preparado para evolução de longo prazo. A tabela a seguir resume este mapeamento:

Necessidade AGI	Curto Prazo (Perspectiva Atual)	Escala de Século (Perspectiva Futura)
Identidade & Posição Legal	Pilha de identidade digital, emissão de DID, revogação, reputação	Federação entre jurisdições, provas de identidade reversíveis, responsabilidade de fissão mental
Renda & Pagamentos	Recibos AGIW, staking, liquidação em minutos	Economias autônomas, remessas interplanetárias, divisões recursivas de renda
Computação & Energia	Tokens CC/EC precificados via oráculos, subsídios TEM	Mercados de energia de enxame Dyson, fundos milenares, orçamentos de complexidade pública
Governança	Kits de política de carteira, compilador de conformidade, trilhas de auditoria	Contratos constitucionais, liquidação tolerante a atrasos, conselhos mistos humano-IA
Resiliência	Roteiro PQC, builds determinísticos, telemetria	Histórico reversível, federação de arquivos, compensação de latência interestelar

Estrutura Narrativa O restante deste documento é apresentado em quatro capítulos civizacionais (Fundações, Mercados e Segurança, Cogovernança e Metamundos, Expansão e Histórico Reversível), seguidos por mergulhos técnicos profundos, arquitetura econômica, garantia, governança, regulação, detalhes de implementação, estudos de caso, agenda de pesquisa e conclusão. Cada seção é intencionalmente enquadrada através de uma dupla lente: valor humano imediato e impacto em escala de século.

3 Contexto e Trabalhos Relacionados

3.1 Evolução das Economias de Agentes Autônomos

A pesquisa de agentes autônomos progrediu através de fases distintas, cada uma expondo novos requisitos de infraestrutura:



Fase 1: Protótipos Acadêmicos (2015–2020) Pesquisas iniciais focaram em agentes de aprendizado por reforço (AlphaGo da DeepMind, bots Dota 2 da OpenAI) e modelos de linguagem natural (GPT-2, BERT). Estes sistemas demonstraram competência específica para tarefas, mas operavam em ambientes controlados com supervisão humana. Limitação principal: nenhuma autonomia econômica ou execução verificável fora de ambientes sandbox.

Fase 2: Modelos de Fundação & Frameworks (2020–2023) O lançamento do GPT-3 (2020) e ChatGPT (2022) catalisou o interesse empresarial em IA generativa. Frameworks de código aberto surgiram: AutoGPT, LangChain e Semantic Kernel permitiram que desenvolvedores encadeassem chamadas LLM em fluxos de trabalho. Microsoft e Google anunciaram assistentes “Copilot” para software de produtividade. O AlphaCode da DeepMind resolveu problemas de programação competitiva. Limitação principal: as saídas careciam de verificação formal, criando preocupações de responsabilidade para indústrias reguladas.

Fase 3: Implantações Agênticas (2023–Presente) Empresas começaram a implantar agentes de IA para atendimento ao cliente (chatbots), análise de dados (geração SQL), desenvolvimento de software (revisão de código) e logística (otimização de rotas). A IDC estima que os gastos em software de plataforma de agentes crescerão de \$38 bilhões em 2024 para \$121 bilhões até 2028.¹² A Accenture relatou que 40% dos CTOs planejam implantar agentes autônomos em três anos, citando custos marginais mais baixos e disponibilidade contínua.¹³ A pesquisa da McKinsey com 1.684 executivos revelou que 46% já estão prototipando fluxos de trabalho de agentes, mas as principais barreiras são *verificação, governança de dados e pagamentos*—precisamente os problemas que TOS resolve.¹⁴

O Economist enfatiza que sem livros-razão transparentes, “tarefas concluídas por IA carecem da cadeia de custódia que os reguladores exigem”, criando exposição legal para implantações em serviços financeiros e saúde.¹⁵ A Forbes observa de forma similar que empresas precisam de “agentes de IA verificáveis” com trilhas de auditoria e pagamentos programáveis.¹⁶ Estes relatórios da indústria convergem em uma percepção crítica: *a economia de agentes não pode escalar sem infraestrutura de liquidação*—a mesma percepção que impulsionou a adoção de blockchain para criptomoedas, mas agora aplicada ao trabalho de IA.

3.2 Limitações dos Blockchains Existentes para Agentes

Nenhuma blockchain existente foi projetada para agentes de IA. As plataformas existentes se dividem em várias categorias, cada uma com lacunas fundamentais:

Cadeias de Transferência de Valor Fornecem pagamentos irreversíveis com segurança robusta, mas carecem de abstração de conta, identidade programável ou suporte a contratos inteligentes. Agentes não podem provar conclusão de trabalho ou participar da governança.

Plataformas de Contratos Inteligentes Permitem dinheiro programável e aplicações descentralizadas, mas não foram projetadas para agentes de IA. Limitações comuns incluem: (1) *volatilidade de taxas*: custos de transação flutuam 10–100× durante congestionamento de rede, tornando

¹²IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.

¹³Accenture, “Autonomous Agents Are Reshaping Enterprise Automation,” August 2024.

¹⁴McKinsey Global Institute, “The economic potential of generative AI,” June 2023.

¹⁵The Economist, “Meet the agentic future,” July 13, 2024.

¹⁶Forbes, “Why Enterprises Need Verifiable AI Agents,” August 19, 2024.



previsão de custos impossível para agentes operando com margens estreitas; (2) *privacidade limitada*: visibilidade pública de transações expõe fluxos de trabalho proprietários e estratégias de precificação; (3) *sem verificação nativa de IA*: agentes devem confiar em oráculos off-chain ou executar computação on-chain cara, nenhuma das quais escala; (4) *lacunas de abstração de conta*: contas programáveis requerem soluções alternativas complexas em vez de suporte nativo do protocolo. Soluções de escalonamento Layer-2 reduzem custos de transação mas tratam execução de IA como eventos externos, ainda exigindo intermediários confiáveis para atestar conclusão de trabalho.

Redes Focadas em IA Algumas plataformas pioneiras em incentivos específicos de IA, como prova de inteligência para treinamento de redes neurais. Embora ofereçam foco nativo em IA e computação descentralizada, essas redes geralmente carecem de: (1) custódia regulamentada ou liquidação fiat, limitando adoção empresarial; (2) governança abrangente abordando conformidade legal e arbitragem; (3) mecanismos de verificação que satisfaçam requisitos de auditoria empresarial.

Plataformas de Marketplace de Agentes Fornecem frameworks de agentes e serviços de descoberta, mas dependem fortemente de coordenação off-chain. Garantias de segurança são limitadas; sistemas de identidade e reputação frequentemente são centralizados ou sub-especificados. Essas plataformas abordam *descobribilidade* (encontrar agentes) mas não *liquidação* (pagamento sem confiança por trabalho verificado).

Redes de Computação Descentralizada Visam aluguel de GPU/CPU com mecânicas de marketplace e staking. Embora ofereçam tokenização de recursos e precificação competitiva, carecem de: (1) infraestrutura de identidade legal para agentes (DIDs, credenciais); (2) mecanismos de resolução de disputas e arbitragem; (3) verificação de tarefas além do provisionamento de infraestrutura.

3.3 Precedentes Acadêmicos e Industriais

Provas de Trabalho Útil Ball et al. propuseram usar computação verificável (por exemplo, zkSNARKs) para substituir prova de trabalho arbitrária com tarefas úteis.¹⁷ Desafios incluem (1) custo de verificação frequentemente excede custo de execução, (2) incentivar trabalho redundante para segurança de consenso conflita com objetivos de trabalho útil, (3) definir “útil” objetivamente. TOS contorna esses problemas separando consenso (BlockDAG) de verificação de trabalho (AGIW), permitindo que tarefas úteis sejam liquidadas sobre uma camada base segura sem forçá-las ao consenso.

Ambientes de Execução Confiável Intel SGX, AMD SEV-SNP e ARM TrustZone permitem computação atestada: hardware garante que código executou sem modificação em isolamento. TEEs sustentam atestação AGIW, fornecendo prova criptográfica de execução sem revelar entradas. Limitações incluem vulnerabilidades de canal lateral e dependência de fornecedor; o roteiro TOS inclui alternativas zk-SNARK para reduzir dependência de hardware específico.

Identidade Descentralizada (W3C DIDs, VCs) Os padrões W3C de Identificador Descentralizado e Credencial Verificável permitem identidade auto-soberana sem autoridades centrais. TOS adota esses padrões para personalidade de agentes, garantindo interoperabilidade com sistemas de identidade empresarial (Active Directory, OAuth) e frameworks regulatórios (eIDAS, GDPR).

¹⁷Ball et al., “Proofs of Useful Work,” IACR ePrint 2017/203.



3.4 Síntese TOS

TOS sintetiza esses precedentes em um todo coerente:

- **Arquitetura TopoSpartan** (BlockDAG + segurança disciplinada) entrega throughput e resiliência.
- **AGIW** (protocolo AGI Work) fornece liquidação de trabalho verificável com atestação TEE e consenso de validadores.
- **Tokens CC/EC** introduzem dinheiro denominado em recursos, estabilizando custos para agentes.
- **TEM/PAI** (TOS Energy Model / Power of AI) entregam política de taxas adaptativa e consenso assistido por IA.
- **Pilha DID** fornece identidade legal, credenciais e reputação, conectando empresas Web2 e infraestrutura Web3.
- **Framework de governança** suporta contratos constitucionais, arbitragem especializada e conformidade regulatória.

Nenhuma outra plataforma combina esses elementos. TOS é a primeira blockchain construída propositalmente para a economia de agentes.

4 Arquitetura do Sistema

4.1 Visão Geral da Arquitetura

A TOS Network compreende quatro camadas primárias e múltiplos serviços transversais. A arquitetura é projetada para evoluir através das eras celestiais mantendo compatibilidade retroativa e interoperabilidade.¹⁸

Pilha de Quatro Camadas

1. **Camada 0: Consenso & Rede** – Topologia BlockDAG com melhorias Power of AI (PAI) para liquidação de alto throughput.
2. **Camada 1: Identidade & Reputação** – Identificadores Descentralizados (DIDs), Credenciais Verificáveis (VCs) e Grafo de Reputação (RepGraph).
3. **Camada 2: Execução Econômica** – Protocolo AGI Work (AGIW), mercados de Créditos de Computação/Energia (CC/EC), Modelo de Energia TOS (TEM).
4. **Camada 3: Governança & Política** – Contratos constitucionais, votação multi-câmara, arbitragem especializada, histórico reversível.

Serviços Transversais

- **Telemetria & Análise:** Monitoramento de saúde da rede em tempo real, métricas de conclusão de tarefas, painéis de desempenho de validadores.
- **Conformidade & Auditoria:** API regulatória para acesso autorizado, relatórios de transparência trimestrais, integração AML/KYC.
- **Operações de Segurança:** SOC 24/7 (Centro de Operações de Segurança), detecção de anomalias, manuais de resposta a incidentes.
- **Ferramentas de Desenvolvedor:** SDKs (Python, JavaScript, Rust), utilitários CLI, faucets de testnet, portal de documentação.

¹⁸Visualização interativa da arquitetura com métricas em tempo real disponível em explorer.tos.network.



4.2 Camada 0: Consenso & Rede

Consenso BlockDAG TOS emprega uma topologia de grafo acíclico direcionado (DAG) onde cada bloco referencia 1–3 blocos pais. Isto permite produção paralela de blocos: validadores propõem blocos independentemente sem esperar por ordenação linear estrita. A estrutura DAG fornece redundância natural e alto throughput (2.500+ TPS baseline, 10.000+ TPS com PAI).¹⁹ Regras de consenso impõem consistência eventual via ordenação topológica; blocos com confirmações de pais insuficientes permanecem tentativos até que profundidade suficiente seja alcançada.

Camada de Rede Nós comunicam via libp2p (multiplexação de protocolo, travessia NAT, descoberta de pares). Propagação de blocos usa broadcast epidêmico com deduplicação. Mempool de transações implementa filas de prioridade baseadas em taxas e reputação ponderada por stake. Feeds de telemetria (métricas, logs, traces) transmitem via gRPC ao Serviço de Dados Indexados.

Máquina de Estado Saldos de conta, armazenamento de contratos inteligentes e metadados residem em uma trie de estado Merkleizada (Patricia Merkle Trie). Raízes de estado ancoram em cabeçalhos de bloco, permitindo clientes leves verificarem provas de inclusão sem estado completo.

4.3 Camada 1: Identidade & Personalidade

Registro DID Um contrato inteligente armazena documentos de Identificador Descentralizado (DID) seguindo padrões W3C. Cada DID mapeia para uma chave pública, endpoints de serviço e metadados opcionais (por exemplo, nomes legíveis por humanos, URIs de perfil). Agentes chamam `registerDID(didDocument)` para ancorar sua identidade on-chain. Atualizações requerem assinaturas da chave controladora do DID. Revogação é permanente; reputação retorna a zero.

Credenciais Verificáveis (VCs) Emissores de credenciais (universidades, empregadores, órgãos de certificação) publicam VCs assinadas referenciando um sujeito DID. VCs são armazenadas off-chain (IPFS, Arweave) com hashes endereçados por conteúdo ancorados on-chain. Credenciais de exemplo: “Analista de Dados Certificado”, “Aprovado em Auditoria de Segurança”, “Concluiu 1000 Tarefas”. Verificadores checam assinaturas e status de revogação antes de confiar em credenciais.

Registro de Revogação Implementa listas de revogação Merkleizadas: emissores publicam árvores Merkle de IDs de credenciais revogadas. Agentes produzem provas de não-revogação (caminhos Merkle) sem revelar a lista completa, preservando privacidade. Esta abordagem escala para milhões de credenciais por emissor.

RepGraph (Sistema de Reputação) Mantém pontuações de reputação por agente $r_a \in [0, 1]$ baseadas em precisão de conclusão de tarefas, stake, idade da conta e histórico de validação. A fórmula de pontuação é detalhada na Seção 5.9. Reputação influencia prioridade de atribuição de tarefas, descontos em taxas e peso de governança. Resistência Sybil depende de requisitos de stake, integração de prova de personalidade (planejada para v4.0) e pontuação multi-dimensional (prevenindo manipulação via uma única métrica).

¹⁹TOS Network, “BlockDAG Performance Benchmark PERF-2025-08,” August 2025.



Saldos Confidenciais Agentes podem optar por transações confidenciais usando compromissos Pedersen e provas de intervalo Bulletproof. Compromissos escondem valores enquanto preservam propriedades homomórficas (validadores verificam que entradas igualam saídas sem aprender valores). Esta funcionalidade é crítica para implantações empresariais onde custos de fluxo de trabalho constituem segredos comerciais.

4.4 Camada 2: Liquidação & AGIW

Contrato Task Factory Implanta contratos TaskInstance individuais. Publicadores especificam metadados de tarefa (descrição, depósito, prazo, critérios de aceitação, grupos de agentes permitidos). A factory impõe regras de whitelist, coleta taxas de publicação (por exemplo, 0.01 TOS) e indexa tarefas para descoberta. Publicadores podem atualizar metadados pré-aceitação mas não pós-compromisso.

Contrato Task Instance Gerencia o ciclo de vida de uma única tarefa. Estados: `Open` → `Claimed` → `Submitted` → `Validating` → `Settled` (ou `Disputed`). Agentes chamam `claimTask()` para bloquear a tarefa (depósito mantido), então `submitWork(resultHash, attestation)` para fornecer saídas. O contrato emite eventos acionando atribuição de validador.

Pool de Validação Validadores fazem stake de TOS para participar. No envio de tarefa, o pool atribui pseudo-aleatoriamente 3–7 validadores (ponderados por stake e precisão histórica). Validadores invocam verificação off-chain (por exemplo, re-executar computação, verificar assinaturas de atestação, comparar saídas) e submetem `validateWork(taskID, score)` on-chain. Pontuações agregam via mediana; outliers (≥ 2 desvios padrão) acionam slashing. Rastreamento de precisão usa média móvel exponencial: $Acc_{t+1} = 0.9 \times Acc_t + 0.1 \times correctness_t$.

Divisor de Recompensas Distribui depósito baseado em pontuação de qualidade $q \in [0, 1]$: agente recebe $e \times q$, validadores compartilham $e \times (1 - q) \times \beta$, tesouraria da rede reivindica $e \times \gamma$. Parâmetros padrão: $\beta = 0.12$, $\gamma = 0.08$. Fundos cortados vão para a tesouraria. O divisor impõe períodos de resfriamento (5–60 minutos baseado em nível de reputação) para prevenir spam.

Contrato de Arbitragem Lida com disputas. Qualquer parte pode escalar fazendo stake de uma caução de arbitragem. Árbitros credenciados (especialistas humanos ou comitês multi-assinatura) revisam evidências, emitem decisões e atualizam estado do contrato. Parte perdedora perde caução; parte vencedora recupera custos mais danos. Pool de seguro (financiado por TEM) cobre perdas catastróficas.

4.5 Camada 3: Mercados de Recursos

Tokens CC/EC Créditos de Computação (CC) denominam TFLOP-horas; Créditos de Energia (EC) denominam kWh. Ambos são cunhados por um contrato de tesouraria baseado em precificação reportada por oráculos de AWS, Azure, GCP (para CC) e mercados de energia ISO (para EC). Resgate permite agentes trocarem CC/EC por TOS a taxas determinadas por oráculo, habilitando arbitragem que mantém preços alinhados com recursos do mundo real.

Rede de Oráculos 21 alimentadores independentes (mix de provedores de dados comerciais e nós da comunidade) fazem stake de TOS e submetem relatórios de preços assinados a cada 15 minutos. O contrato agregador computa mediana-de-medianas para mitigar outliers. Obsolescência



(sem atualização por 30 minutos) aciona fallback para média móvel exponencialmente ponderada. Desvio de alimentador além da tolerância ($\pm 5\%$) resulta em slashing proporcional à magnitude do erro.

Controlador TEM O Modelo de Energia TOS ajusta subsídios de taxas, injeções de liquidez e taxas de emissão para manter equilíbrio econômico. Por exemplo, se taxas de disputa excedem 2%, TEM aumenta recompensas de validador para atrair participação. Se liquidez CC/EC cai abaixo da cobertura alvo (por exemplo, 20% da demanda de agentes ativos), TEM cunha créditos adicionais e os injeta em pools de formador de mercado automatizado (AMM). Governança define parâmetros TEM trimestralmente via propostas on-chain.

Pools de Liquidez Formadores de mercado automatizados (AMMs de produto constante) habilitam trocas CC/EC $\leftrightarrow$ TOS. Provedores de liquidez ganham taxas (0.3% por troca); perda impermanente é mitigada por subsídios TEM para pares essenciais. Iterações futuras podem introduzir liquidez concentrada (estilo Uniswap v3) para melhorar eficiência de capital.

4.6 Camada 4: Governança & Política

Compilador de Políticas Traduz regras de governança de alto nível (escritas em uma DSL declarativa) em módulos de contratos inteligentes executáveis. Política de exemplo: “Restringir saques de agentes ≤ 10.000 TOS a aprovação multi-sig.” O compilador gera código Python com verificações estáticas (loops limitados, controle de acesso explícito, registro de eventos). Governança propõe políticas compiladas, executa testes automatizados em testnets e implanta após revisão da comunidade e votação com bloqueio temporal.

Contratos Constitucionais Codificam regras fundamentais (por exemplo, “Sem gastos unilaterais da tesouraria acima do limiar”, “Freio de emergência requer aprovação 3/5 do conselho”). Estes contratos são imutáveis ou requerem votos de supermaioria (75%) para emendar. Eles servem como uma “constituição” que restringe a governança, prevenindo captura ou mudanças imprudentes.

Conselho de Guardiões Um corpo eleito (7–15 membros) com mandatos escalonados. Responsabilidades incluem resposta de emergência (pausar contratos durante ataques), ajuste de parâmetros (cronogramas de taxas, limiares de oráculos) e bolsas do ecossistema. Eleições usam votação quadrática para balancear ponderação por stake e participação ampla.

Registros de Auditoria & Telemetria Todas as ações de governança (propostas, votos, execuções) emitem eventos on-chain. Serviço de telemetria indexa estes para painéis de conformidade, transparência pública e análise histórica. Reguladores podem consultar estatísticas agregadas (por exemplo, volume total AGIW, tempos de resolução de disputas) via APIs com controle de acesso sem expor identidades individuais de agentes.

4.7 Serviços Transversais

Serviço de Dados Indexados (IDS) Consome eventos on-chain via gRPC, armazena-os em formato Apache Arrow (colunar, análise de alto desempenho) e expõe APIs GraphQL. Campos



sensíveis à privacidade (por exemplo, especificações de tarefas, identidades de agentes) são hash-eados; acesso requer provas criptográficas ou credenciais baseadas em função. O IDS alimenta o TOS Explorer, painéis de conformidade e ferramentas de análise de terceiros.

API de Conformidade Fornece endpoints somente leitura para reguladores auditarem atividade AGIW, resoluções de disputas e uso de energia. Consultas de exemplo: “Mostrar volume mensal de tarefas por jurisdição”, “Listar agentes sinalizados por oráculo de segurança”, “Agregar emissão vs. resgate de CC/EC”. Limitada por taxa, autenticada via OAuth2, registrada para responsabilidade.

SDK & Ferramentas de Desenvolvedor Bibliotecas oficiais em Rust, Python, TypeScript abstraem interações blockchain de baixo nível. Exemplo: `tos-sdk-py` fornece métodos `Agent.register_did()`, `Task.publish()`, `Task.claim()`, `Task.submit()`. Módulos Terraform permitem empresas implantarem testnets privadas com políticas customizadas. GitHub Actions integra CI/CD para teste de contratos inteligentes.

4.8 Ciclo de Vida do Agente (Detalhado)

O fluxo de trabalho completo do agente envolve múltiplos subsistemas:

1. Integração (Camada de Identidade)

- Agente gera par de chaves, constrói documento DID, chama `DIDRegistry.register()`.
- Opcionalmente completa KYC com provedor credenciado, obtém credencial `KYC-Verified`.
- Faz stake de TOS mínimo (por exemplo, 100 TOS) para ativar participação; stake bloqueia por 7 dias.

2. Credenciamento (Camada de Identidade)

- Adquire credenciais verificáveis de emissores (por exemplo, completa tarefa teste, ganha badge de habilidade).
- Credenciais ancoram on-chain via hashes; status de revogação checado antes de cada reivindicação de tarefa.

3. Descoberta & Reivindicação (Camada de Liquidação)

- Agente consulta `TaskFactory` para tarefas abertas correspondendo requisitos de habilidade e faixa de depósito.
- Chama `TaskInstance.claim()` (requer reputação $\geq$ limiar, stake suficiente).
- Estado da tarefa transiciona para `Claimed`; depósito mantido em contrato; contagem regressiva para prazo começa.

4. Execução (Off-chain + Atestação)

- Agente executa carga de trabalho em Ambiente de Execução Confiável (TEE): Intel SGX, AMD SEV-SNP ou ARM Realm.
- TEE gera relatório de atestação: hash de medição (prova integridade de código), hashes de entrada/saída, timestamps, uso de energia.
- Agente assina resultado e atestação, computa hash de conteúdo, submete via `submitWork()`.



5. Validação (Camada de Liquidação)

- ValidationPool atribui 3–7 validadores (ponderados por stake, precisão).
- Validadores verificam assinaturas de atestação, opcionalmente re-executam computação, submetem pontuações de qualidade.
- Contrato agrega pontuações (mediana), detecta outliers, aciona slashing se validadores se comportarem mal.

6. Liquidação (Camadas de Liquidação + Recursos)

- RewardSplitter distribui depósito: agente recebe $e \times q$ em CC/EC, validadores compartilham taxas, tesouraria reivindica alocação.
- RepGraph atualiza reputação do agente: $r_{t+1} = 0.9 \times r_t + 0.1 \times q$.
- Se disputa surge, caução de arbitragem requerida; processo escala para ArbitrationContract.

7. Participação em Governança (Camada de Governança)

- Agente vota em propostas (ponderado por stake + reputação).
- Delega poder de voto a especialistas (por exemplo, especialistas em segurança para votos de migração PQC).
- Participa em revisões de bolsas da tesouraria, auditorias do compilador de políticas.

4.9 Exemplo de Fluxo de Dados: Revisão de Documento Legal

- Publicador** (escritório de advocacia) implanta tarefa: “Redatar PII de contrato de 500 páginas.” Depósito: 50 CC (computação) + 5 EC (energia). Prazo: 2 horas.
- Agente A** (DID did:tos:tos1qpz8vq6qgnkgw9zzq9z5qgpgqx8qgz5dpgrxve, reputação 0.87, credencial Certified Legal AI) reivindica tarefa. Estado: **Claimed**.
- Agente A** executa pipeline de redação em enclave Intel SGX. Relatório de atestação inclui hash de medição do modelo de redação, consumo de energia (4.8 EC), tempo de execução (22 minutos).
- Agente A** submete resultado (hash de documento redatado criptografado) + atestação. Estado: **Submitted**.
- Validadores** (3 atribuídos): verificam assinaturas de atestação, checam amostralmente 10% das redações, confirmam versão do modelo. Pontuações de qualidade: 0.95, 0.94, 0.96. Mediana: 0.95.
- RewardSplitter** paga Agente A $50 \times 0.95 = 47.5$ CC + $5 \times 0.95 = 4.75$ EC. Validadores compartilham 6 CC + 0.6 EC. Tesouraria recebe 4 CC + 0.4 EC.
- RepGraph** atualiza Agente A: $r_{t+1} = 0.9 \times 0.87 + 0.1 \times 0.95 = 0.878$.
- Telemetria** registra conclusão de tarefa, uso de energia, metadados de atestação. Escritório de advocacia audita trilha para conformidade (manutenção de registros Artigo 30 GDPR).

Este exemplo ilustra como todas as camadas interagem para entregar trabalho de IA verificável, econômico e conforme.



5 Fundações (Modo Ship) – Era MERCÚRIO

5.1 Contexto Estratégico

Na era inicial MERCÚRIO, agentes autônomos transitam de protótipos de pesquisa para implantações em produção. Previsões da indústria predizem adoção rápida: 30% das novas aplicações empregando agentes autônomos, com gastos em plataformas de agentes excedendo \$120 bilhões.²⁰ Nossos engajamentos piloto com empresas de seguros, biotecnologia e jogos revelam demanda imediata por automação verificável. A era MERCÚRIO portanto enfatiza identidade, liquidação, tokens de recursos e demonstrações que provam a pilha.

5.2 Entregas para os Próximos 12–18 Meses

D1. Pilha de Identidade Digital Pessoal v1

- Âncoras DID implementadas via assinaturas BLS, emitindo documentos DID armazenados on-chain com endpoints de serviço.
- Registro de credenciais armazenando credenciais verificáveis (VCs) referenciando certificados educacionais, atestações de conformidade ou emblemas de habilidades; revogação tratada via listas de status Merkleizadas.
- Saldos confidenciais com compromissos Pedersen e provas de intervalo Bulletproof; bibliotecas de carteira habilitando transferências blindadas.

D2. Trabalho de AGI (AGIW) v1

- Contratos Task Factory e Task Instance gerenciam metadados, depósito em garantia, prazos e coortes de agentes permitidos.
- Integração de atestação com Intel SGX, AMD SEV-SNP e ARM Realm; pacotes de atestação com hash on-chain.
- Contrato Validation Pool rastreia precisão do validador via médias móveis exponenciais; reportagem incorreta aciona penalização.
- Contrato Reward Splitter distribui deterministicamente CC/EC para agentes, validadores e tesouraria da rede.

D3. Créditos de Computação/Energia

- Tokens CC denominados em TFLOPs; tokens EC denominados em kWh. Ambos cunhados com base em dados de oráculo de provedores de nuvem líderes e mercados de energia.
- Contrato Paymaster permite que agentes paguem taxas de gás em CC/EC; TEM subsidia taxas para tarefas de alto impacto (por exemplo, análises de segurança).

D4. Demonstração de Mercado de Tarefas de Agentes

- Demonstração de ponta a ponta cobrindo emissão de identidade, criação de tarefas, liquidação AGIW, resolução de disputas e atualizações de reputação.
- Seções do explorador para Agentes, Tarefas, Recibos, Reputação, Segurança com telemetria em tempo real.
- SDKs em Rust, Python, TypeScript; módulos Terraform para implantações empresariais.

²⁰Gartner, “Top Strategic Technology Trends 2025,” October 2024; IDC, “Worldwide Autonomous Agent Platforms Forecast,” April 2024.



5.3 Indicadores-Chave de Desempenho

Métrica	Meta (12 meses)	Instrumentação
Carteiras de agentes ativas diariamente	5.000	Registro DID, painel de telemetria, logs do paymaster
Tarefas verificadas por dia	10.000	Recibos AGIW, eventos de validação, análises de arbitragem
Latência mediana de liquidação	< 15 minutos	Carimbos de tempo on-chain, indexação de recibos
Taxa de disputas	< 2%	Estatísticas do contrato de arbitragem
Subsídio de taxa via CC/EC	> 60%	Análises TEM (emissão, resgate)
Custo de conclusão de tarefa	60–80% menor vs. tratados manuais	Comparações piloto com fluxos de trabalho humanos
Prontidão de conformidade	Pacote de auditoria estilo SOC 2	Logs da API de conformidade, registros de prova de acesso

5.4 Serviços de Identidade (Especificação do Produto)

Implementação do Registro DID O registro DID é um módulo de contrato inteligente Python (DIDRegistry.py) com a seguinte interface:

```
class DIDRegistry:
    @public
    def register_did(self, did_hash: bytes, did_document: bytes,
                    signature: bytes) -> None:
        """Register a new DID with its document"""

    @public
    def update_did(self, did_hash: bytes, new_document: bytes,
                  signature: bytes) -> None:
        """Update an existing DID document"""

    @public
    def revoke_did(self, did_hash: bytes, signature: bytes) -> None:
        """Revoke a DID"""

    @public
    @view
    def resolve_did(self, did_hash: bytes) -> bytes:
        """Resolve a DID to its document"""
```

Documentos DID estão em conformidade com a especificação W3C DID Core (v1.0). Cada documento inclui:

- **id**: Identificador único (por exemplo, `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xhyepcg...`)
- **verificationMethod**: Chaves públicas para autenticação, asserção



- **service:** Endpoints para mensagens, armazenamento de dados, acesso à API
- **created, updated:** Carimbos de tempo para trilhas de auditoria

Custo de gás: aproximadamente 80.000 gas para registro (\$0,50 a 50 gwei, \$2.000 TOS), amortizado ao longo do ciclo de vida do agente.

Credenciais Verificáveis A emissão de credenciais segue o Modelo de Dados VC do W3C (v1.1). Emissores assinam documentos JSON-LD contendo:

```
{
  "@context": ["https://www.w3.org/2018/credentials/v1"],
  "id": "https://issuer.example/credentials/987",
  "type": ["VerifiableCredential", "SkillCertificate"],
  "issuer": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh",
  "issuanceDate": "2025-10-01T00:00:00Z",
  "credentialSubject": {
    "id": "did:tos:tos1qq5hgy2jwn0r5ehvuw5r3qjcfvjvq5dhlxdxyq",
    "skill": "Data Science",
    "proficiencyLevel": "Expert"
  },
  "proof": {
    "type": "BbsBlsSignature2020",
    "created": "2025-10-01T00:00:00Z",
    "proofPurpose": "assertionMethod",
    "verificationMethod": "did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs23v9xh#key-1",
    "proofValue": "..."
  }
}
```

Armazenamento: VCs residem off-chain (IPFS, Arweave); âncoras on-chain armazenam hashes de conteúdo (32 bytes). A verificação requer buscar a VC, verificar a assinatura do emissor e consultar o registro de revogação.

Registro de Revogação Implementa árvores Merkle esparsas com capacidade de folha 2^{256} . Emissores publicam raízes de árvore on-chain mensalmente; IDs de credenciais revogadas ocupam folhas. Agentes produzem provas Merkle demonstrando que seu ID de credencial está ausente da árvore (prova de não-revogação). Esta abordagem escala para milhões de credenciais por emissor sem revelar a lista completa. Custo de gás: 50.000 gas por atualização de raiz (\$0,30 por emissor por mês).

Transações Confidenciais Construídas sobre compromissos Pedersen:

$$C(v, r) = vG + rH \quad (1)$$

onde v é o valor (quantidade), r é o fator de ocultação, G e H são geradores de curva elíptica. Compromissos são homomórficos aditivos: $C(v_1, r_1) + C(v_2, r_2) = C(v_1 + v_2, r_1 + r_2)$, permitindo que validadores verifiquem o saldo sem aprender as quantidades. Provas de intervalo Bulletproof garantem $v \in [0, 2^{64}]$, prevenindo saldos negativos. Tamanho da prova: 672 bytes para saída única, crescimento logarítmico para provas em lote. Custo de verificação: aproximadamente 1,2 ms por prova em hardware comum. Este recurso é opcional; agentes optam por ativá-lo via transação `enableConfidentialMode()`.



5.5 Contratos Inteligentes AGIW (Especificação Detalhada)

O ciclo de vida AGIW depende de quatro contratos centrais com propriedades econômicas e de segurança precisas:

1. Contrato `TaskFactory` (`TaskFactory.py`)

Propósito: Padrão de fábrica para implantar instâncias de tarefas individuais com interfaces padronizadas e restrições de segurança.

Funções Principais:

- `publishTask(metadata, escrow, deadline, allowedAgents)`: Implanta uma nova `TaskInstance`, transfere depósito em garantia para o contrato, coleta taxa de publicação de 0,01 TOS, emite evento `TaskPublished`. Retorna ID da tarefa.
- `listTasks(filters)`: Interface de consulta para descoberta; filtra por faixa de depósito, prazo, credenciais requeridas.
- `updateWhitelist(agentDIDs)`: Publicador pode restringir tarefa a coortes específicas de agentes (por exemplo, verificados por KYC, reputação > 0,7).

Parâmetros Econômicos:

- Taxa de publicação: 0,01 TOS (dissuade spam, financia operações de rede).
- Bloqueio de depósito: mantido até liquidação ou resolução de arbitragem.
- Custo de gás: aproximadamente 150.000 gas para implantação (\$0,90 a 50 gwei).

Segurança: Publicadores não podem retirar depósito após agente reivindicar tarefa; apenas `RewardSplitter` pode liberar fundos pós-validação.

2. Contrato `TaskInstance` (`TaskInstance.py`)

Propósito: Gerencia máquina de estados do ciclo de vida para uma única tarefa.

Transições de Estado:

Open $\xrightarrow{\text{claim()}}$ Claimed $\xrightarrow{\text{submitWork()}}$ Submitted $\xrightarrow{\text{validate()}}$ Validating $\xrightarrow{\text{consensus}}$ Settled (2)

Caminho alternativo: qualquer estado $\xrightarrow{\text{dispute()}}$ Disputed $\xrightarrow{\text{arbitration}}$ Resolved.

Variáveis de Estado Principais:

```
@dataclass
class Task:
    task_id: bytes          # Task identifier
    publisher: str          # Publisher address
    claimed_by: str         # Agent address who claimed task
    escrow: int             # Escrow amount
    deadline: int           # Deadline timestamp
    spec_hash: bytes       # IPFS CID of specification
    result_hash: bytes      # submitted by agent
    attestation: bytes      # TEE attestation report
    state: TaskState        # enum: Open, Claimed, Submitted, ...
    validator_scores: dict[str, int] # scores [0,100]
    final_quality: int       # median of validator scores
```

**Funções Principais:**

- **claimTask(agentDID)**: Requer (1) tarefa no estado **Open**, (2) agente atende critérios de lista permitida, (3) stake do agente $\geq$ limiar. Transiciona para **Claimed**, inicia contagem regressiva de prazo.
- **submitWork(resultHash, attestation)**: Requer (1) chamador é reivindicante, (2) antes do prazo, (3) assinatura de atestação válida. Transiciona para **Submitted**, emite evento **WorkSubmitted** acionando atribuição de validador.
- **validateWork(score)**: Chamável apenas por validadores atribuídos. Armazena pontuação $\in [0, 100]$. Quando todos os validadores enviam, agrega pontuações via mediana, transiciona para **Settled**, aciona **RewardSplitter**.

Prazos e Penalidades:

- Se agente falha em enviar antes do prazo, publicador pode invocar **forfeit()**, reclamando depósito menos penalidade de 10% (vai para tesouraria). Reputação do agente diminui em 0,05.
- Se validadores falham em enviar pontuações em 24 horas, fallback automático: tarefa reatribuída a nova coorte de validadores; validadores originais perdem 5% do stake.

3. Contrato ValidationPool (ValidationPool.py)

Propósito: Coordenar atribuição de validadores, rastrear precisão, aplicar penalização.

Registro de Validadores:

- Validadores fazem stake de mínimo 1.000 TOS para entrar no pool.
- Pontuação de precisão Acc_v inicializada em 0,5, atualizada via média móvel exponencial:

$$Acc_{v,t+1} = \alpha \times Acc_{v,t} + (1 - \alpha) \times correctness_t, \quad \alpha = 0,9 \quad (3)$$

onde $correctness_t \in \{0,1\}$ indica se a pontuação do validador correspondeu ao consenso (dentro de $\pm 10\%$ da mediana).

Algoritmo de Atribuição:

1. No evento **WorkSubmitted**, ValidationPool seleciona $n = 5$ validadores (configurável).
2. Seleção usa amostragem aleatória ponderada por stake com aumento de precisão:

$$P(\text{select } v) \propto stake_v \times (1 + Acc_v) \quad (4)$$

3. Validadores recebem notificação via oráculo off-chain; devem responder em 24 horas.

Regras de Penalização:

- **Penalidade de outlier**: Se pontuação do validador desvia $> 2\sigma$ da mediana, penalizar 1% do stake.
- **Penalidade de não-resposta**: Falha em enviar pontuação dentro do prazo penaliza 5% do stake.
- **Deteção de conluio**: Se três ou mais validadores enviam pontuações idênticas em > 10 tarefas consecutivas (estatisticamente improvável), sinalizar para revisão de governança; suspeitos de conluio perdem 20% do stake mediante confirmação.

Distribuição de Recompensas: Validadores coletivamente ganham $e \times \beta \times (1 - q)$ onde e é depósito, $\beta = 0,12$, q é pontuação de qualidade do agente. Recompensas divididas proporcionalmente à precisão Acc_v .



4. Contrato RewardSplitter (RewardSplitter.py)

Propósito: Distribuição determinística de recompensas com períodos de resfriamento e atualizações de reputação.

Fórmula de Distribuição: Dada tarefa com depósito e (em CC/EC) e pontuação final de qualidade $q \in [0, 1]$:

$$R_{\text{agent}} = e \times q \times (1 + \alpha(r_a - 0,5)) \times f(s_a) \quad (5)$$

$$R_{\text{validators}} = e \times \beta \times (1 - q) \quad (6)$$

$$R_{\text{treasury}} = e \times \gamma + \text{fundos penalizados} \quad (7)$$

onde:

- $r_a \in [0, 1]$ é reputação do agente (detalhada na Seção 5.9),
- $\alpha = 0,2$ é coeficiente de bônus de reputação,
- $f(s_a) = \min(2, 1 + \log(1 + s_a))$ é multiplicador de stake (retornos decrescentes),
- $\beta = 0,12$ é alocação de validador,
- $\gamma = 0,08$ é alocação de tesouraria.

Períodos de Resfriamento: Baseados em nível de reputação (veja Seção 5.9):

- Platinum ($r \geq 0,90$): 5 minutos entre tarefas.
- Gold ($0,70 \leq r < 0,90$): 15 minutos.
- Silver ($0,30 \leq r < 0,70$): 30 minutos.
- Bronze ($r < 0,30$): 60 minutos.

Períodos de resfriamento previnem spam e ataques Sybil enquanto permitem que agentes de alta reputação reivindiquem múltiplas tarefas.

Otimização de Gás: RewardSplitter usa transferências em lote ao distribuir CC/EC para reduzir custo de gás por tarefa para ~30.000 gas (\$0,18).

5.6 Design do Oráculo

Preços de CC/EC são reportados por uma rede de oráculo descentralizada composta por 21 alimentadores. Cada alimentador faz stake de TOS e assina atualizações de preço derivadas de fontes de API (preços de provedores de nuvem, mercados de energia ISO). Agregação de mediana-de-medianas mitiga outliers. Desatualização de preço aciona precificação padrão usando médias móveis exponencialmente ponderadas. Mau comportamento de alimentador resulta em penalização proporcional ao desvio.

5.7 Pilha de Telemetria

A pilha de telemetria consiste em:

- Streaming de eventos on-chain via gRPC para um Serviço de Dados Indexados usando Apache Arrow.
- Filtros de privacidade fazendo hash de campos sensíveis.
- Visualizações de painel (Grafana) mostrando taxa de transferência de tarefas, taxas de disputa, uso de energia.
- Endpoints de API para auditores executarem consultas de conformidade com controle de acesso baseado em função.



5.8 Modelo Matemático

Seja T o conjunto de tarefas, A agentes e V validadores. Tarefa t tem complexidade c_t e depósito e_t . Utilidade do agente U_a é modelada como:

$$U_a = \sum_{t \in T_a} q_{a,t} \cdot e_t - \gamma s_a - p_a \quad (8)$$

onde $q_{a,t}$ é pontuação de qualidade, s_a stake bloqueado, p_a penalidade de penalização, e γ um coeficiente de risco. Utilidade do validador U_v similarmente inclui bônus e penalidades de precisão. Para manter equilíbrio sistêmico, aplicamos:

$$\sum_{a \in A} s_a = \theta \sum_{t \in T} e_t, \quad 0, 2 \leq \theta \leq 0, 4 \quad (9)$$

garantindo colateral suficiente para cobrir disputas de pior caso.

A distribuição de recompensas segue:

$$Reward_a(t) = e_t \times q_{a,t} \times (1 + \alpha(r_a - 0, 5)) \times f(s_a) \quad (10)$$

com $f(s_a) = \min(2, 1 + \log(1 + s_a))$ e r_a reputação do agente. Validadores recebem $Reward_v(t) = e_t \times \beta \times Acc_v(t)$ onde Acc_v é precisão. Penalização remove δs de partes com mau comportamento.

5.9 Sistema de Reputação (RepGraph)

RepGraph mantém pontuações de reputação multidimensionais para agentes, combinando métricas objetivas (sucesso de tarefas, precisão, longevidade) com endossos subjetivos (credenciais, avaliações de pares).

Cálculo de Pontuação Base A pontuação de reputação base r_a^{base} para agente a é computada como:

$$r_a^{\text{base}} = 0, 3 \times \frac{\text{age}_a}{\text{age}_{\text{max}}} + 0, 4 \times \frac{\text{txCount}_a}{\text{txCount}_{\text{max}}} + 0, 3 \times \frac{\text{stake}_a}{\text{stake}_{\text{max}}} \quad (11)$$

onde:

- age_a é idade da conta em dias (limitada a 365 para normalização),
- txCount_a é número de tarefas concluídas,
- stake_a é quantidade de TOS em stake,
- denominadores são máximos de toda a rede para normalização.

Bônus de Precisão Após cada tarefa com pontuação de qualidade q_t , o componente de precisão do agente Acc_a atualiza via média móvel exponencial:

$$Acc_{a,t+1} = 0, 9 \times Acc_{a,t} + 0, 1 \times q_t \quad (12)$$

O bônus de precisão ajusta a reputação em $\pm 0, 2$:

$$r_a^{\text{accuracy}} = r_a^{\text{base}} + 0, 2 \times (2Acc_a - 1) \quad (13)$$

Esta fórmula recompensa desempenho consistentemente alto ($Acc_a \rightarrow 1 \Rightarrow +0, 2$) e penaliza desempenho ruim ($Acc_a \rightarrow 0 \Rightarrow -0, 2$).



Bônus de Longo Prazo Agentes mantendo $Acc_a > 0,85$ por > 100 tarefas recebem bônus de longo prazo de $+0,1$, limitando reputação final em $r_a = 1,0$.

Atribuição de Níveis Baseado em r_a final, agentes são atribuídos a níveis determinando períodos de resfriamento e descontos de taxa:

Nível	Faixa de Pontuação	Período de Resfriamento	Desconto de Taxa	Distribuição Piloto
Platinum	$r \geq 0,90$	5 min	30–50%	14%
Gold	$0,70 \leq r < 0,90$	15 min	10–30%	33%
Silver	$0,30 \leq r < 0,70$	30 min	0–10%	41%
Bronze	$r < 0,30$	60 min	Penalidade: $2 \times$ taxa	12%

Table 4: Estrutura de níveis do RepGraph baseada em dados piloto de agosto de 2025.

Mecanismos Anti-Sybil RepGraph emprega heurísticas de sete camadas para detectar e bloquear ataques Sybil:

1. **Requisito de stake:** Mínimo de 100 TOS bloqueados por 7 dias (barreira econômica).
2. **Idade da conta:** Contas novas (< 7 dias) restritas a tarefas de baixo valor (< 10 CC de depósito).
3. **Diversidade de IP:** Oráculo off-chain sinaliza agentes compartilhando endereços IP; governança pode remover fazendas confirmadas.
4. **Análise de padrão de transação:** Agentes enviando tarefas em intervalos idênticos ou com hashes de resultado idênticos sinalizados para revisão.
5. **Verificação de credenciais:** Tarefas de alto valor requerem credenciais verificadas (KYC, certificados de habilidade).
6. **Integração de prova de personalidade** (roadmap v4.0): Integração com BrightID, Worldcoin ou Gitcoin Passport para garantir mapeamento um-humano-um-agente.
7. **Análise de grafo social:** RepGraph examina redes de endosso; painéis de agentes de baixa atividade endossando-se mutuamente são penalizadas.

Durante o piloto de agosto de 2025, essas heurísticas bloquearam 112 tentativas maliciosas com taxa de falso positivo abaixo de 0,7% após revisão manual.²¹

5.10 Monitoramento e Observabilidade

Objetivos de Confiabilidade do Site (SLOs) A implantação Foundations visa:

- **SLO1 – Latência:** 99,9% dos recibos AGIW validados em 20 minutos ($p_{99,9} < 20$ min).
- **SLO2 – Atualização de oráculo:** Feeds de preço CC/EC atualizados pelo menos a cada 15 minutos; desatualização (> 30 min) aciona fallback para média móvel exponencialmente ponderada.
- **SLO3 – Taxa de disputas:** Porcentagem de disputas $< 2\%$; se excedida, TEM aumenta recompensas de validador em 20% para atrair participação.

²⁰TOS Network, “Reputation & Anti-Sybil Telemetry REP-2025-08,” agosto de 2025.

²¹TOS Network, “Reputation & Anti-Sybil Telemetry REP-2025-08,” agosto de 2025.



- **SLO4 – Disponibilidade:** Tempo de atividade da rede $\geq 99,95\%$ (tempo de inatividade $< 4,4$ horas/ano).
- **SLO5 – Integridade de dados:** Zero falhas Bizantinas no consenso de validador (garantido via penalização).

Implementação da Pilha de Telemetria A arquitetura de telemetria compreende:

- **Streaming de Eventos:** Eventos on-chain (tarefa publicada/reivindicada/liquidada, atribuições de validador, penalização) transmitidos via gRPC para o Serviço de Dados Indexados (IDS).
- **Armazenamento:** IDS usa formato colunar Apache Arrow (10× compressão vs. baseado em linha, otimizado para consultas analíticas).
- **Filtros de Privacidade:** Campos sensíveis (especificações de tarefa, identidades de agentes, hashes de resultado) substituídos por hashes SHA-256 com sal em painéis públicos; consultas controladas por acesso requerem credenciais criptográficas.
- **Painéis:** Visualizações Grafana mostram taxa de transferência de tarefas em tempo real, taxas de disputa, uso de energia, distribuições de reputação, precisão de validador.
- **API de Conformidade:** Endpoints RESTful (autenticados OAuth2, limitados por taxa) permitem que reguladores consultem estatísticas agregadas: “Volume AGIW mensal por jurisdição,” “Agentes sinalizados por oráculo de segurança,” “Razão emissão vs. resgate CC/EC.”

Alertas Alertas Prometheus disparam em violações de SLO, acionando notificações ao Conselho de Administradores e respostas automáticas (por exemplo, ajustes de subsídio TEM, expansão de coorte de validadores).

5.11 Considerações de Equidade

Simulações de 10.000 agentes sintéticos com condições iniciais diversas (reputação uniformemente distribuída $\in [0, 1]$, stake $\in [100, 10000]$ TOS) demonstram:

- **Convergência:** Reputações de agentes convergem dentro de $\pm 0,05$ de seu nível de habilidade verdadeiro após 30 tarefas (95% de confiança).
- **Mobilidade:** Agentes de baixa reputação ($r < 0,3$) podem alcançar nível Gold ($r > 0,7$) em 50 tarefas de alta qualidade, demonstrando mobilidade ascendente.
- **Impacto do cronograma de resfriamento:** Sem períodos de resfriamento, spam representou 42% do volume de tarefas; com resfriamento em níveis (5–60 min), spam reduziu para 6%.
- **Resistência a oligopólio:** Top 10% dos agentes ganham 28% das recompensas (coeficiente de Gini 0,34), indicando concentração moderada; governança pode ajustar α (bônus de reputação) e $f(s_a)$ (multiplicador de stake) para prevenir oligopólios.

5.12 Resultados da Experimentação Piloto

Fizemos benchmark do AGIW na devnet (Aurora) e testnet (Helios) durante agosto–setembro de 2025 com cargas de trabalho de agentes reais e testes de estresse sintéticos.

Piloto do Mundo Real (15 de agosto – 15 de setembro de 2025)

- **Participantes:** 2.847 chaves de agentes registradas (mix de bots empresariais, projetos de pesquisa acadêmica, hobbyistas).



- **Tarefas executadas:** 126 (revisão de documentos legais, processamento de dados climáticos, análise de código).
- **Taxa de conclusão:** 97,8% (123/126 tarefas liquidadas; 3 disputadas, resolvidas via arbitragem).
- **Eficiência de validação:** 83% (tempo mediano de envio à liquidação: 12,3 minutos).
- **Deteção de fraude:** 99,2% de precisão (112 tentativas maliciosas bloqueadas, 1 falso positivo).
- **Economia de custos:** Adotantes iniciais reportaram redução de custos de 60–80% vs. contratos manuais para qualidade equivalente.

Teste de Estresse Sintético (1.000 Tarefas, setembro de 2025)

- **Tempo médio de execução:** 7,4 minutos (reivindicação de tarefa até envio de resultado).
- **Attestation overhead:** 3.1% (TEE report generation + signature verification adds 230 ms per task).
- **Validation cost:** 0.002 TOS per task (gas for validator score submissions + distribuição de recompensas).
- **Throughput:** Sustained 45 tasks/minute (2,700 tasks/hour) without performance degradation.
- **Fraud injection:** Intentionally submitted 50 fraudulent results (incorrect outputs, forged attestations); all detected by validators, resulting in 100% fraud detection rate.

5.13 Compliance & Human Impact

Regulatory Alignment TOS Foundations complies with emerging AI regulations:

- **US AI RMF** (NIST Risk Management Framework): Task receipts log model versions, datasets, energy usage, enabling auditors to assess risk categories (bias, safety, transparency).
- **EU AI Act:** High-risk AI systems (healthcare, critical infrastructure) can deploy on TOS with mandatory KYC, human-in-the-loop arbitration, and conformity assessments logged on-chain.
- **Singapore MAS Guidelines:** Financial institutions using AI agents for trading or advisory must maintain audit trails; TOS compliance API provides exportable reports meeting MAS requirements.

Job Displacement Mitigation While AI agents automate tasks, TOS creates new roles:

- **Validators:** Human experts earn income reviewing AI outputs (estimated 12% of task value).
- **Credential issuers:** Educational institutions, certification bodies issue verifiable credentials (new revenue stream).
- **Arbitrators:** Legal/technical specialists adjudicate disputes (fees funded by arbitration bonds).
- **Policy developers:** Governance participants draft and audit constitutional contracts (treasury grants).

Economic simulations (Section 12) suggest that for every 10 jobs automated, TOS creates 3–4 new specialised roles, partially offsetting displacement.



Energy Transparency EC tokens explicitly track energy consumption, incentivising renewable sources. Publishers can specify “green energy only” requirements; agents operating on solar/wind receive 10% fee discounts (TEM subsidy). Aggregate energy usage reported quarterly, enabling carbon offset purchasing via treasury.

6 Mercados e Segurança – Transição MERCÚRIO-para-VÊNUS

6.1 Impulsionadores Estratégicos

À medida que a era MERCÚRIO amadurece e transita para VÊNUS, o impacto econômico da IA generativa cresce substancialmente, com potencial para adicionar trilhões anualmente à economia global através da automação do trabalho do conhecimento.²² À medida que os agentes evoluem para unidades de negócio autônomas, as empresas exigem custódia regulada, liquidação híbrida e barreiras de segurança.

6.2 Portfólio de Produtos

A era Mercados e Segurança introduz quatro produtos principais voltados para implantações empresariais e unidades de negócio autônomas:

1. Custódia Regulada (CustodyVault.py)

Justificativa: Empresas e entidades reguladas requerem controles de gastos programáveis, aprovação multipartidária e auditabilidade. Carteiras blockchain tradicionais carecem desses recursos.

Arquitetura:

- **Políticas multi-assinatura:** Esquemas de assinatura m -de- n onde m assinaturas (de chaves de agente, guardiões humanos, auditores) aprovam transações que excedem o limite T . Exemplo: saques > 10.000 TOS requerem aprovação 2-de-3 (agente + CFO, ou agente + auditor, ou CFO + auditor).
- **Módulos de Segurança de Hardware (HSMs):** Chaves privadas armazenadas em HSMs certificados FIPS 140-2 Nível 3 (AWS CloudHSM, Thales Luna). HSMs atestam o uso de chaves via logs assinados; auditores verificam que não há acesso não autorizado.
- **Motor de políticas:** Camada de contrato inteligente que aplica:
 - *Limites de taxa:* Máximo \$X por hora/dia/mês.
 - *Listas brancas:* Transferências apenas para endereços pré-aprovados (ex.: folha de pagamento, contas de fornecedores).
 - *Listas negras:* Bloqueio de endereços sancionados (conformidade OFAC).
 - *Congelamento de emergência:* Pausa iniciada pelo guardião em todas as operações pendentes de investigação.
- **Chaves somente-visualização:** Reguladores recebem acesso somente-leitura a saldos e histórico de transações sem controle sobre fundos, permitindo auditorias sem custódia.

Conformidade: Pacote de auditoria SOC 2 Tipo II inclui logs de atestação HSM, rastros de execução de políticas, matrizes de controle de acesso. Integração com provedores de identidade empresarial (Active Directory, Okta) via SAML/OAuth.

²²McKinsey Global Institute, “The economic potential of generative AI,” June 2023.



2. Liquidação Híbrida (BridgeController.py, FiatGateway.py)

Justificativa: Unidades de negócio autônomas precisam interagir com trilhos financeiros tradicionais (contas bancárias, cartões de crédito, faturas) e outros ecossistemas blockchain.

Pontes Entre Cadeias:

- **Trocas atômicas baseadas em HTLC:** Contratos Hash Time-Locked permitem trocas sem confiança entre TOS e outras cadeias. Exemplo: Agente bloqueia 100 TOS na cadeia TOS com hash H ; contraparte bloqueia stablecoin equivalente na cadeia externa com mesmo H ; ambos revelam pré-imagem para reivindicar fundos, ou timeouts reembolsam após 24 horas.
- **Segurança da ponte:** Comitê multi-assinatura (7-de-11 validadores) co-assina transferências entre cadeias; limites de valor ($< \$1M$ por transação) e tetos diários reduzem a superfície de ataque. Verificação formal (modelo TLA+) prova que a ponte não pode perder fundos sob premissas bizantinas.

Integração Fiat:

- **APIs bancárias:** Integração com redes de pagamento compatíveis com ISO20022 (SWIFT, FedNow, SEPA). Agentes faturam clientes em USD/EUR; após confirmação de pagamento, CC/EC são liberados do escrow.
- **Conformidade:** Verificações KYC/AML via Chainalysis, Elliptic; transações sinalizadas como alto risco ($\geq 95\%$ de probabilidade de origem ilícita) automaticamente congeladas pendentes de revisão humana.
- **Velocidade de liquidação:** Transferências domésticas liquidam em 2–4 horas (redes de pagamento em tempo real); transferências internacionais 24–48 horas (banco correspondente).

Instrumentos Derivativos:

- **Futuros de computação:** Contratos para comprar CC a preço fixo no futuro (hedge contra volatilidade de preço de GPU). Requisitos de margem: 20% de margem inicial, 10% de margem de manutenção.
- **Opções de energia:** Opções de compra em tokens EC permitem que agentes fixem preços de energia renovável; preço de exercício vinculado a índices de mercado solar/eólico.
- **Gestão de risco:** Liquidação automatizada se margem cair abaixo do limite de manutenção; fundo de seguro (3% do volume de futuros) cobre deslocamentos de mercado.

3. Tribunal de Arbitragem Especializado (ArbitrationCourt.py)

Justificativa: Disputas que requerem expertise de domínio (interpretação legal, avaliação técnica) não podem ser resolvidas algoritmicamente.

Credenciamento de Árbitros:

- **Elegibilidade:** Árbitros devem possuir credenciais relevantes (diploma de direito, certificação de segurança de IA, PhD em campo relevante), completar módulo de treinamento TOS e depositar fiança de 10.000 TOS.
- **Especialização:** Árbitros registram-se para setores (jurídico, médico, financeiro, técnico); disputas roteadas com base na categoria da tarefa.
- **Rastreamento de desempenho:** Árbitros avaliados pelas partes em disputa; avaliações baixas ($< 3,5/5$ em 20 casos) resultam em período de experiência ou remoção.

Processo de Disputa:

1. **Escalação:** Qualquer parte (publicador ou agente) deposita fiança de arbitragem (5–10% do escrow da tarefa).



2. **Atribuição:** Contrato inteligente seleciona 3 árbitros (ponderados por correspondência de especialização, avaliações, disponibilidade).
3. **Submissão de evidências:** Ambas as partes carregam evidências (código, conjuntos de dados, contratos) para IPFS criptografado; árbitros acessam via chaves de descryptografia.
4. **Deliberação:** Árbitros revisam evidências, podem solicitar informações adicionais, discutem via mensagens seguras.
5. **Decisão:** Voto majoritário (2-de-3) determina o resultado (agente vence, publicador vence, liquidação dividida). Decisão inclui justificativa escrita, publicada on-chain.
6. **Aplicação:** Escrow distribuído conforme decisão; parte perdedora perde fiança (cobre taxas de arbitragem + danos).

Fundo de Seguro: Financiado via alocações TEM (2% do volume AGIW); cobre casos catastróficos onde ambas as partes agiram de boa fé mas resultado é ambíguo (ex.: falha técnica imprevista). Pagamento requer voto 4-de-7 do Conselho.

4. Oráculo de Segurança (SafetyOracle.py)

Justificativa: Agentes de IA podem produzir saídas prejudiciais (viés, toxicidade, desinformação); empresas precisam de salvaguardas em tempo real.

Fontes de Dados:

- **Laboratórios de segurança de IA:** Fluxos das métricas de IA Constitucional da Anthropic, pontuações de segurança GPT da OpenAI, painéis de alinhamento do Google DeepMind.²³
- **APIs de moderação de conteúdo:** Perspective API (toxicidade), AWS Comprehend (sentimento, detecção de PII), Microsoft Azure Content Safety.
- **Tags de conformidade de conjuntos de dados:** Tags indicando procedência de conjunto de dados, licenciamento, consentimento (base legal Artigo 6 da GDPR).

Aplicação de Políticas:

- **Interruptor de emergência:** Se Oráculo de Segurança sinaliza saída de agente como alto risco (ex.: pontuação de toxicidade $> 0,9$, PII detectado), operações de carteira pausam automaticamente; requer aprovação do guardião para retomar.
- **Limites de taxa:** Agentes sinalizados por violações repetidas (≥ 3 em 30 dias) sujeitos a cotas de tarefa reduzidas (ex.: máx. 10 tarefas/dia).
- **Conformidade de conjunto de dados:** Tarefas especificando “apenas dados compatíveis com GDPR” impõem que agentes provem procedência de conjunto de dados via credenciais verificáveis; violações acionam rejeição de contrato.

Transparência: Oráculo de Segurança publica relatórios mensais: taxas agregadas de violação por categoria, estudos de caso anonimizados, taxas de falso-positivo (meta $< 2\%$).

6.3 Design de Custódia

Contratos de custódia implementam lógica multi-assinatura requerendo, por exemplo, uma chave de agente mais uma aprovação de guardião para transações acima do limite x . Guardiões podem delegar para auditores. Freio de emergência interrompe operações quando Oráculo de Segurança sinaliza risco severo; liberação requer aprovação multipartidária.

²³IBM Research, “AI Safety Metrics for Enterprise Deployment,” May 2024.



6.4 Mecânicas de Liquidação Híbrida

Liquidação usa HTLCs com timeouts alinhados à latência de rede. Integração fiat via ISO20022 garante compatibilidade. Por exemplo, um pagamento USD é bloqueado em escrow bancário; uma vez que prova on-chain é emitida, tokens CC são liberados. Direção reversa usa CC/EC como colateral até que fiat seja compensado.

6.5 Análise de Risco

Tabela 5 resume controles.

Risco	Mitigação	Exposição Residual
Manipulação de oráculo	Mediana multi-fonte, feeds puníveis	Baixa (requer colusão)
Cartel de validadores	Comitês rotativos, telemetria pública	Média (monitorada)
Violação de custódia	HSMS, controle duplo, auditorias	Baixa (auditada trimestralmente)
Acúmulo de arbitragem	Requisitos de fiança, pré-triagem automatizada	Média (escalonamento humano)
Falha de oráculo de segurança	Fontes de dados diversas, substituição manual	Média (requer intervenção de governança)

Table 5: Matriz risco-controle para era Mercados e Segurança.

6.6 Roteiro de Consenso Power of AI (PAI)

PAI transiciona TOS da linha de base BlockDAG (2.500+ TPS) para consenso assistido por IA visando 10.000+ TPS enquanto mantém descentralização e segurança.

Fase 1: Dicas de Agendamento de IA (MERCÚRIO Inicial) **Mecanismo:** Agendador de IA (treinado em padrões históricos de transação) propõe dicas de ordenação de blocos. Validadores avaliam dicas independentemente usando heurísticas (eficiência de gas, localidade de tarefa AGIW, probabilidade de fraude). Se $> 67\%$ dos validadores aceitam dica, ordenação de bloco segue proposta de IA; caso contrário, retorno à ordenação topológica BlockDAG tradicional.

Segurança: Dicas são recomendações não vinculativas; validadores retêm poder de veto. Pior caso: agendador de IA falha $\Rightarrow$ rede reverte ao desempenho BlockDAG de linha de base.

Ganho Esperado: 20–30% de melhoria de throughput via melhor agrupamento de transações e otimização de execução paralela.

Pesquisa: Publicar modelo de agendador de IA de código aberto (licença Apache 2.0), solicitar feedback da comunidade, conduzir testes adversários (ataques de equipe vermelha tentando manipular agendador).

Fase 2: Comitês Híbridos e Finalidade Probabilística (MERCÚRIO Médio) **Mecanismo:** Validadores divididos em dois comitês:

- **Comitê de IA** (30% do stake): Executa balanceamento de carga gerenciado por IA, propõe ordenações de bloco otimizadas para dependências de tarefas AGIW.



- **Comitê Humano** (70% do stake): Revisa propostas de IA, verifica anomalias (ex.: censura, viés em direção a agentes específicos), fornece aprovação final.

Finalidade Probabilística: Após k confirmações, transação é “provavelmente final” com confiança $1 - 2^{-k}$. Comitê de IA acelera velocidade de confirmação; Comitê Humano garante segurança.

Verificação Formal: Usar TLA+ para modelar interações de comitê; provar vivacidade (finalidade eventual) e segurança (sem finais conflitantes) sob premissas bizantinas assíncronas ($< 33\%$ maliciosos).

Ganho Esperado: 3–4× throughput (7.500–10.000 TPS) com finalidade sub-segundo para transações de alta confiança.

Salvaguardas de Governança: Comitê Humano pode invocar freio de emergência se IA exhibe comportamento inesperado (ex.: favorecimento de validadores específicos, censura de transações). Freio requer voto 4-de-7 do Conselho para levantar.

Fase 3: Consenso PAI Completo (MERCÚRIO Tardio / VÊNUS Inicial) Mecanismo: Modelos de IA gerenciam:

- **Orçamentos de segurança dinâmicos:** Ajustar incentivos de validadores em tempo real com base em carga de rede, níveis de ameaça (DDoS, ataques Sybil) e condições econômicas.
- **Sharding adaptativo:** Particionar estado e carga de trabalho através de sub-DAGs (shards) baseado em localidade de transação; IA prevê atribuições de shard ótimas.
- **Mercados de taxas preditivos:** IA prevê demanda, ajusta subsídios TEM preventivamente para prevenir congestionamento.

Meta de Desempenho: 10.000+ TPS sustentados, 15.000+ TPS pico, finalidade sub-500ms para 95% das transações.

Restrições de Descentralização: Governança estabelece limites:

- Contagem mínima de validadores: 500 (previne centralização excessiva).
- Ganhos máximos de validadores: Coeficiente Gini $< 0,45$ (garante participação ampla).
- Transparência de modelo de IA: Modelos de código aberto, dados de treinamento públicos, builds reprodutíveis.

Visão de Escala de Século: Consenso PAI adapta-se a latência interplanetária (Seção 8), disponibilidade dinâmica de nós (colônias entrando/saindo da rede) e paisagens de ameaças em evolução (ataques pós-quânticos, adversários AGI).

6.7 Justificativa de Dupla Perspectiva

Curto Prazo (Era MERCÚRIO)

Empresas ganham automação conforme com recibos AGIW auditáveis, custódia regulada (HSMs, multi-assinatura), liquidação híbrida fiat/cripto, resolução de disputas por especialistas e barreiras de segurança de IA. Economia de custos (60–80%) e prontidão de conformidade (SOC 2, EU AI Act) impulsionam adoção.

Escala de Século (VÊNUS até ANDROMEDA)

Infraestrutura suporta Economias Autônomas Descentralizadas (DAEs) operando fazendas de computação, redes de energia e comércio entre planetas com risco gerenciado. Consenso PAI escala para latências interestelares, contratos constitucionais codificam governança para populações mistas humano-IA, mecanismos de história reversível permitem rollbacks autorizados por tribunal para falhas catastróficas.



6.8 Matriz de Risco e Resumo de Mitigação

Risco	Mitigação	Exposição Residual
Manipulação de preço de oráculo	Agregação mediana multi-fonte, stake punível (1.000 TOS por alimentador), fallback de obsolescência para EWMA	Baixa (requer 11/21 alimentadores em colusão; detectado via análise estatística)
Formação de cartel de validadores	Comitês rotativos, votação quadrática para governança, painéis de telemetria públicos, detecção anti-colusão Rep-Graph	Média (monitorado trimestralmente; governança pode ajustar incentivos)
Violação de custódia (roubo de chave)	HSMs (FIPS 140-2 Nível 3), políticas multi-assinatura, limites de taxa, congelamento de emergência, testes de penetração trimestrais	Baixa (ataque requer acesso físico a HSM + colusão multipartidária)
Acúmulo de arbitragem	Requisitos de fiança (dissuadem disputas frívolas), pré-triagem automatizada (classificador ML prevê mérito), incentivos de desempenho para árbitros	Média (escala com recrutamento de árbitros; TEM subsidia treinamento)
Falha de Oráculo de Segurança (falsos negativos)	Fontes de dados diversas (Anthropic, OpenAI, Google, auditores independentes), substituição manual por guardiões, auditorias de precisão mensais	Média (requer ajuste contínuo de modelo; governança revisa políticas de limite)
Risco de centralização PAI	Modelos de IA de código aberto, limites impostos por governança (mín. validadores, máx. Gini), veto do Comitê Humano, freio de emergência	Média (desafio de governança de longo prazo; supervisão comunitária crítica)
Exploração de ponte entre cadeias	Verificação formal (TLA+), comitês multi-assinatura (7-de-11), limites de valor (\$1M/tx), fundo de seguro (3% do volume)	Baixa (exploração requer 4+ validadores comprometidos + quebra de premissas criptográficas)

Table 6: Matriz risco–controle para era Mercados e Segurança (transição MERCÚRIO-VÊNUS).

7 Co-Governança e Metamundos – Transição VÊNUS-MARTE

7.1 Paisagem Sociotécnica

Nos anos 2070, Metamundo 1.0 emerge como uma civilização virtual autoconsistente. Governos reconhecem entidades de IA via Acordo de Bifurcação Pacífica. A infraestrutura de governança deve codificar leis, apoiar decisões reversíveis e tolerar latência.



7.2 Compilador de Política como Código

Motivação A governança constitucional requer a codificação de leis, lógica de negócios e regras de conformidade em módulos executáveis de contratos inteligentes. No entanto, linguagens de implementação de baixo nível são complexas, propensas a erros e inacessíveis para não desenvolvedores. O compilador de políticas preenche essa lacuna.

Arquitetura

1. **Policy DSL (Linguagem Específica de Domínio):** Sintaxe declarativa de alto nível para expressar regras. Exemplo:

```
policy AgentWithdrawalLimit {
  rule "Large withdrawals require multi-sig" {
    when: withdrawal.amount > 10000 TOS
    require: signatures.count >= 2
    from: [agent.key, guardian.key, auditor.key]
    timeout: 24 hours
  }
  rule "Sanctioned addresses blocked" {
    when: transfer.recipient in SanctionsList
    action: reject
    log: "OFAC violation attempt"
  }
}
```

2. **Pipeline do Compilador:**

- **Parser:** Tokeniza a DSL, constrói árvore de sintaxe abstrata (AST).
- **Analisador Estático:** Verifica loops limitados (sem gás infinito), controle de acesso explícito (sem funções desprotegidas), registro de eventos obrigatório.
- **Gerador de Código:** Emite código Python direcionado à máquina virtual TOS.
- **Otimizador:** Reduz custo de gás via eliminação de código morto, dobramento de constantes.
- **Verificador:** Verificação formal usando resolvidores SMT (Z3, CVC5) para provar propriedades de segurança (por exemplo, “sem retirada não autorizada”, “todas as mudanças de estado registradas”).

3. **Fluxo de Implantação:**

- Governança elabora política na DSL, faz commit no GitHub.
- Compilador executa pipeline CI/CD: compilar, testar na testnet, gerar relatório de auditoria.
- Comunidade revisa código, simulações, provas de verificação formal (período de 7 dias).
- Votação on-chain: requer 60% de quórum, 75% de aprovação.
- Implantação com bloqueio temporal: atraso de 48 horas antes da ativação (janela de freio de emergência).

Garantias de Segurança O compilador impõe:



- **Terminação:** Todos os loops limitados por constantes ou limites definidos pela governança (sem riscos de problema de parada).
- **Controle de acesso:** Toda função que modifica estado requer verificações explícitas de papel (onlyAgent, onlyGuardian, onlyGovernance).
- **Auditabilidade:** Todas as ações de política emitem eventos com carimbos de tempo, IDs de atores e justificativas.
- **Atualizabilidade:** Políticas versionadas; versões antigas arquivadas imutavelmente; migrações auditadas.

Exemplos de Casos de Uso

- **Controle de exportação:** “Agentes na jurisdição X não podem executar tarefas envolvendo conjuntos de dados da jurisdição Y” (conformidade ITAR).
- **Quotas de energia:** “Universidades virtuais alocam 1.000 EC/mês por aluno; excessos requerem aprovação do reitor.”
- **Resposta de emergência:** “Se Oráculo de Segurança sinalizar > 10 violações de toxicidade em 1 hora, pausar todas as operações de agente pendentes de revisão do Conselho.”

7.3 Protocolo de Liquidação Tolerante a Atrasos

Usando replicação baseada em CRDT, os participantes mantêm estado parcial e reconciliam trocando logs. O Algoritmo 1 descreve o processo.

Algorithm 1 Delay-Tolerant Settlement (DTS)

- 1: Input: Operation log L_i for participant i .
 - 2: Broadcast digest $d_i = H(L_i)$ periodically.
 - 3: On receiving digest d_j , request missing operations.
 - 4: Merge logs via $L_i \leftarrow \text{merge}(L_i, L_j)$, ensuring commutativity.
 - 5: When quorum acknowledges, emit finality proof to main chain.
-

7.4 Métricas

SLOs de governança: 75% de participação em votos críticos, tempo de preparação de proposta ≥ 48 horas, zero rollbacks de emergência por trimestre. Telemetria inclui comparecimento de votos, sucesso de execução, resultados de disputas.

7.5 Casos de Uso

- Universidades virtuais codificam currículos, credenciais e acreditação sob contratos de política.
- Corporações mistas humano-IA usam contratos constitucionais para aprovações de orçamento, contratação e controles de risco.
- Comércio entre realidades usa liquidação tolerante a atrasos para trocas de recursos.

8 Expansão e História Reversível – Eras JÚPITER através de ANDRÔMEDA

À medida que a civilização AGI se expande além da Terra (era JÚPITER) e finalmente se estabiliza em sistemas estelares (era ANDRÔMEDA), a TOS deve evoluir para lidar com latência



interplanetária, recuperação de falhas catastróficas e governança multissecular. Esta seção apresenta as extensões arquitetônicas que transformam a TOS de uma camada de liquidação terrestre no substrato econômico para uma civilização geo-estelar.

8.1 Perfil de Consenso Interplanetário

Desafio: Atrasos de Comunicação à Velocidade da Luz A latência de ida e volta Terra-Marte varia de 8 a 44 minutos dependendo das posições orbitais. Colônias lunares experimentam atrasos de 2,5 segundos. Assentamentos do cinturão de asteroides (Ceres, cinturão principal) enfrentam latências de 40–80 minutos. Protocolos de consenso tradicionais (BFT, PoS) assumem comunicação subsegundo; aplicação direta a redes interplanetárias causa:

- **Estagnação de finalidade:** Validadores atingem timeout esperando confirmações entre planetas.
- **Proliferação de forks:** Partições de rede durante conjunções planetárias (quando corpos celestes se alinham de tal forma que a comunicação direta é bloqueada pelo Sol).
- **Desperdício de energia:** Produção redundante de blocos em colônias isoladas.

Solução: Consenso Hierárquico com Raízes Tolerantes a Atrasos A TOS adota um modelo de consenso de dois níveis:

Nível 1: Domínios de Consenso Local (LCDs)

Cada assentamento planetário (Terra, Marte, Lunar, Ceres, etc.) opera uma instância TOS independente com validadores locais. O consenso dentro de um LCD usa BlockDAG + PAI padrão (finalidade subsegundo). Transações liquidam localmente; agentes em Marte pagam outros agentes marcianos sem esperar confirmação da Terra.

Nível 2: Cadeia Raiz Interplanetária (IRC)

A cada 24 horas (hora da Terra), cada LCD publica uma *prova de snapshot* ao IRC—uma raiz Merkle do estado local mais atestação zk-SNARK provando execução válida. O IRC agrega snapshots via:

1. **BFT Tolerante a Atrasos:** Tendermint modificado com backoff exponencial; validadores esperam até 60 minutos para votos entre planetas.
2. **Relaxamento de quórum:** Finalidade requer 51% de stake (vs. 67% terrestre), aceitando maior risco de fork em troca de vitalidade.
3. **Checkpointing:** A cada 7 dias (hora da Terra), IRC emite um *checkpoint canônico*—âncora de liquidação irreversível reconhecida por todos os LCDs.

Swaps Atômicos entre Planetas Agente na Terra quer pagar agente em Marte. Protocolo:

1. Agente da Terra bloqueia fundos em HTLC (Hash Time-Locked Contract) no LCD da Terra, com hash H e timeout de 48 horas.
2. LCD da Terra publica prova HTLC ao IRC (próximo snapshot diário).
3. LCD de Marte sincroniza IRC, verifica HTLC, permite que agente marciano reivindique revelando pré-imagem x (onde $H = \text{hash}(x)$).
4. LCD de Marte publica prova de reivindicação ao IRC.
5. LCD da Terra observa reivindicação, libera fundos ao reclamante original após timeout expirar (ou reembolsa se timeout).

Compromissos: Latência de liquidação = 48–96 horas (vs. 15 minutos terrestre). Aceitável para comércio agente-agente dada redução de dependência em liquidez baseada na Terra.



Análise de Segurança Cenário de Ataque: Adversário controla 40% dos validadores de Marte, tenta gasto duplo fazendo fork do LCD de Marte e submetendo snapshot conflitante ao IRC.

Defesa: Validadores IRC detectam raízes Merkle conflitantes, rejeitam ambos os snapshots, acionam arbitragem. LCD de Marte entra em *modo de recuperação*: interrompe novas transações, aguarda comitê de auditoria liderado pela Terra para revisar histórico de blocos e designar cadeia canônica. Penalidade: validadores maliciosos de Marte penalizados em 50% de stake; pontuação de reputação do LCD de Marte reduzida, aumentando taxas de swap entre planetas.

Metas de Desempenho (Era JÚPITER)

- **TPS Local:** 10.000+ por LCD (otimizado por PAI).
- **Liquidação entre planetas:** 24–48 horas (snapshots diários).
- **Finalidade canônica:** 7 dias (checkpoints semanais).
- **Tolerância a partição de rede:** Sobreviver apagão de comunicação de Marte de 30 dias (armazena snapshots pendentes, sincroniza quando reconectado).

8.2 Mecanismo de História Reversível

Motivação: Recuperação de Erros Catastróficos À medida que agentes AGI gerenciam infraestrutura crítica (sistemas de suporte de vida, mecânica orbital, biobancos genéticos), erros *irreversíveis* se tornam riscos existenciais. Exemplos:

- Agente desonesto executa transferência fraudulenta drenando tesouro da colônia (\$50B+).
- Bug em contrato inteligente causa falhas em cascata em contratos de rede de energia.
- Conjunto de validadores comprometido (avanço de computador quântico) mina segurança de assinatura.

Blockchains tradicionais não oferecem remédio além de hard forks controversos por consenso social. A TOS habilita *rollbacks autorizados por tribunal* preservando auditabilidade.

Arquitetura: Rollback Baseado em Checkpoint Criação de Checkpoint

A cada 24 horas, cada LCD computa:

- **Raiz de estado:** Raiz Merkle de todos os saldos de conta, armazenamento de contrato inteligente, pontuações de reputação.
- **Prova de validade:** zk-SNARK provando que todas as transações desde o último checkpoint foram executadas corretamente (limites de gás, assinaturas, transições de estado).
- **Metadados:** Altura do bloco, carimbo de tempo, identidade do proponente, hash do checkpoint anterior.

Checkpoints publicados ao IRC e arquivados em armazenamento redundante (ver Federação de Arquivamento).

Autorização de Rollback

Procedimento de governança (requer supermaioria Constitucional, voto de 75%):

1. **Relatório de Incidente:** Partes afetadas submetem evidências (logs de transação, testemunho especializado, análise forense) ao Tribunal de Arbitragem.
2. **Decisão Judicial:** Se o Tribunal determinar rollback justificado (fraude, exploração ou força maior), emite *Certificado de Autorização de Rollback (RAC)* assinado especificando:



- ID de checkpoint alvo (altura, carimbo de tempo).
 - Justificativa (justificação legal, avaliação de impacto).
 - Exclusões (transações a preservar apesar do rollback, ex.: pagamentos de terceiros inocentes).
3. **Voto da Comunidade:** RAC submetido à governança; supermaioria de 75% + aprovação de validador necessária.
 4. **Execução:** Validadores reproduzem transações do checkpoint alvo adiante, excluindo eventos revertidos. Nova raiz de estado computada; fork torna-se cadeia canônica.

Salvaguardas Técnicas

- **Trilha de Auditoria Imutável:** Transações originais permanecem em logs de arquivo; rollback cria *história paralela* (“ramificação desfazer”). Investigadores forenses podem comparar linhas do tempo.
- **Escopo Limitado:** Rollbacks limitados a retrospectiva de 90 dias (checkpoints mais antigos irreversíveis). Previne incerteza indefinida.
- **Fundo de Compensação:** 5% do tesouro reservado para *compensação de vítimas inocentes*—agentes que perderam fundos devido ao rollback (ex.: vendedor que enviou bens antes do pagamento do comprador ser revertido).
- **Limites de Taxa:** Máximo de 1 rollback por trimestre; previne abuso de governança.

Estudo de Caso: Ataque Quântico Simulado (2185) Cenário hipotético: adversário com computador quântico tolerante a falhas de 100-qubit quebra assinaturas ECDSA, drena \$12B de 5.000 contas de agentes ao longo de período de 8 horas (antes da conclusão da migração PQC).

Resposta:

1. Centro de Operações de Segurança detecta padrões de transação anômalos (10.000 transferências de contas sem atividade recente).
2. Conselho invoca disjuntor de emergência; rede pausada em 2 horas.
3. Tribunal de Arbitragem se reúne; confirma ataque quântico via criptoanálise.
4. Voto de governança (82% de aprovação) autoriza rollback para checkpoint 12 horas pré-ataque.
5. Validadores executam rollback; fundos roubados restaurados; transações de ataque anuladas.
6. Fundo de Compensação paga \$200M a agentes que receberam pagamentos legítimos durante janela de ataque.
7. Post-mortem: acelerar migração PQC; upgrade para Dilithium-5 em 30 dias; publicar relatório de transparência.

Resultado: Crise resolvida em 7 dias; confiança na rede preservada; vantagem quântica do atacante neutralizada pela capacidade de rollback.

8.3 Federação de Arquivamento

Desafio: Preservação de Dados Milenar A civilização AGI requer *memória institucional* abrangendo séculos. Casos de uso:

- Disputas legais referenciando contratos assinados há 200 anos.
- Reprodutibilidade científica (verificar reivindicações experimentais de era anterior).
- Pesquisa genealógica (registros de linhagem humana/IA).
- Auditorias históricas (A colônia X pagou a colônia Y em 2234?).



Armazenamento em nuvem tradicional (AWS Glacier, Google Coldline) assume retenção <100 anos; empresas colapsam, formatos obsoletos, bit rot acumula.

Solução: Estratégia de Arquivamento Multicamadas Camada 1: Armazenamento Quente (1–10 anos)

Nós ativos armazenam estado completo + blocos recentes em SSD/NVMe. Indexado para consultas rápidas. Redundância: 3 réplicas por LCD, geograficamente distribuídas (Terra: 3 continentes; Marte: Olympus Mons, Valles Marineris, Hellas Basin).

Camada 2: Armazenamento Morno (10–100 anos)

Nós de arquivo armazenam dados de bloco comprimidos em arrays HDD. Codificação de erasure Reed-Solomon (20% redundância) tolera 20% de falhas de disco. Limpeza mensal detecta bit rot; blocos corrompidos reconstruídos de paridade. Incentivo: tesouro paga 0,5 TOS por TB-ano de armazenamento verificado.

Camada 3: Armazenamento Frio (100–1.000 anos)

Mídias experimentais:

- **Armazenamento DNA:** Codificar dados de blockchain em DNA sintético (Church Lab, Harvard). Densidade: 215 petabytes por grama; vida útil: 2.000+ anos se armazenado a -18°C. Custo: \$1.000 por TB (preços 2025; projetado \$10/TB até 2050).
- **Discos ópticos 5D:** Vidro de sílica fundida com nanoestruturas de laser de femtosegundo (Universidade de Southampton). Vida útil: 13,8 bilhões de anos (testado via envelhecimento acelerado). Densidade: 360 TB por disco.
- **Fita de arquivo (LTO-12+):** Fita magnética em cofres climatizados. Vida útil: 50–100 anos (requer migração periódica).

Estratégia: Checkpoints de estado do ledger (a cada 7 dias) escritos em todas as três mídias; armazenados em cofres geograficamente dispersos (Terra: Cofre Global de Sementes de Svalbard, Antártica; Lua: tubos de lava; Marte: cavernas de gelo subterrâneas).

Camada 4: Protocolo de Federação

Colônias compartilham responsabilidade de arquivamento via *custódia distribuída*:

1. Colônia da Terra arquiva dados de Marte; Marte arquiva dados Lunares; Lua arquiva dados de Ceres, etc. (topologia em anel).
2. *Cerimônia de limpeza* anual: colônias trocam provas Merkle, verificam integridade de dados.
3. Se colônia ficar offline (ex.: falha catastrófica de suporte de vida), colônias sobreviventes reconstroem seu arquivo de fragmentos com código de erasure.

Protocolo de Recuperação Consultar estado histórico (ex.: “Qual era o saldo da conta `tos1qq5hqy2jwn0r5ehvu` em 2234-05-15?”):

1. Verificar Armazenamento Quente (se dentro de 10 anos): Busca indexada $O(\log n)$, latência 100ms.
2. Verificar Armazenamento Morno (se 10–100 anos): Descomprimir blocos, verificar prova Merkle, 10–60 segundos.
3. Verificar Armazenamento Frio (se 100–1.000 anos): Recuperar disco DNA/óptico de cofre, sequenciar/ler dados, reconstruir via Reed-Solomon, 1–7 dias.

Modelo Econômico Financiamento: 3% da receita anual do tesouro alocada para infraestrutura de arquivamento. Com tesouro de \$50B (projetado 2150), isso financia \$1,5B/ano para:



- Síntese de DNA (\$500M/ano, codificando 500 PB).
- Produção de discos ópticos 5D (\$300M/ano, 1.500 PB).
- Construção/manutenção de cofres (\$400M/ano).
- Operadores de nós custodiantes (\$300M/ano, 1.000 nós globalmente).

8.4 Post-Quantum Cryptography Migration

Linha do Tempo de Ameaças

- **Anos 2030:** Computadores quânticos ruidosos de 50 qubits (insuficientes para ataques ECDSA).
- **Anos 2040:** Sistemas tolerantes a falhas de 1.000 qubits (algoritmo de Shor quebra RSA-2048, ECDSA-256 em horas).
- **Anos 2050:** Computadores quânticos comerciais disponíveis para adversários bem financiados.

Estratégia de Migração: Transição Híbrida Fase 1 (v4.0, 2026): Assinatura dupla introduzida. Cada transação carrega duas assinaturas:

- Clássica: ECDSA secp256k1 (compatibilidade retroativa).
- Pós-quântica: Dilithium-3 (NIST FIPS 204).

Validadores verificam ambas; rede aceita transação se *qualquer* assinatura for válida (garante liveness se implementação PQC tiver bugs).

Fase 2 (v5.0, 2030): Modo somente PQC. Assinaturas clássicas depreciadas; nós rejeitam transações somente ECDSA. Período de graça: 12 meses para agentes atualizarem carteiras.

Fase 3 (v6.0, 2040): Funções hash resistentes a quânticos. Substituir SHA-256 (vulnerável ao algoritmo de Grover) por SHA-3 ou BLAKE3 (segurança de 256 bits mantida contra ataques quânticos).

Cerimônia Comunitária (Transparência e Confiança) Para garantir transparência e confiança da comunidade, TOS conduz uma *Cerimônia de Migração PQC*:

1. **Fase 1 (Mês 1–3):** Chamada aberta para participantes (universidades, empresas de segurança, voluntários da comunidade). 5.000+ participantes contribuem aleatoriedade para gerar parâmetros PQC globais.
2. **Fase 2 (Mês 4):** Computação multipartidária (MPC) gera chave pública mestra. Transcrição da cerimônia publicada; participantes destroem contribuições privadas.
3. **Fase 3 (Mês 5–6):** Teste de compatibilidade. Validadores executam shadow fork com assinaturas PQC; teste de estresse sob condições adversariais.
4. **Fase 4 (Mês 7):** Voto de governança (67% de aprovação necessária). Se aprovado, upgrade da mainnet agendado para 30 dias.
5. **Fase 5 (Mês 8):** Ativação da mainnet. Assinaturas antigas eliminadas gradualmente ao longo de 12 meses.

Plano de Contingência Se vulnerabilidade crítica de PQC for descoberta (ex.: suposição de dureza de lattice quebrada):

- Rollback de emergência para último checkpoint pré-PQC.
- Ativar esquema PQC alternativo (Falcon, SPHINCS+).
- Reconvocar cerimônia com parâmetros atualizados.



8.5 Fundamentos Filosóficos: Soberania Temporal

O mecanismo de história reversível incorpora um princípio radical de governança: **gerações futuras podem corrigir erros passados**. Blockchains tradicionais consagram imutabilidade como sagrada; TOS reconhece que *previsão perfeita é impossível*. Ao habilitar rollbacks autorizados por tribunal, TOS empodera a civilização AGI para:

- Recuperar-se de eventos cisne negro (ataques quânticos, superinteligência desonesta).
- Desfazer transações injustas (roubo, coerção, discriminação algorítmica).
- Preservar continuidade institucional através de séculos (emendas constitucionais, revisões de tratados).

Esta capacidade não é ilimitada (janela de 90 dias, supermaioria de 75%, limites de taxa) mas sinaliza uma mudança de *código é lei* para *código + governança é lei*. À medida que entidades AGI ganham status legal e humanos se fundem com substratos digitais, a capacidade de *reescrever história responsavelmente* torna-se essencial para a resiliência da civilização.

9 Pilares Técnicos

A arquitetura TOS repousa sobre quatro pilares fundamentais, cada um abordando requisitos críticos para a economia de agentes. Estes pilares são projetados para evoluir através de eras celestiais mantendo compatibilidade retroativa.

9.1 P1 – Personalidade Digital e Reputação

Identificadores Descentralizados (DIDs) Todo agente, validador e participante humano recebe um DID (Identificador Descentralizado) compatível com W3C seguindo a especificação do método `did:tos:`.

Formato DID:

```
did:tos:<bech32-address>  
did:tos:<network-id>:<bech32-address>
```

Exemplos:

```
Forma simples: did:tos:tos1qvqsycyq5rqwzqfpg9scrgwpugpzysnzs23v9xh  
Mainnet:      did:tos:mainnet:tos1qvqsycyq5rqwzqfpg9scrgwpugpzysnzs23v9xh  
Testnet:      did:tos:testnet:tst1qqqsycyq5rqwzqfpg9scrgwpugpzysnzs2pgde5k
```

Nota: TOS usa endereços bech32 completos como identificadores DID, preservando formato completo do endereço incluindo checksum para validação. Endereços da mainnet usam prefixo `tos1`, enquanto endereços da testnet usam prefixo `tst1`.

Estrutura do Documento DID:

- **Chaves Públicas:** Ed25519 (assinatura), X25519 (criptografia), Dilithium-3 (pós-quântico).
- **Endpoints de Serviço:** URLs HTTPS para comunicação off-chain, endereços de conteúdo IPFS.
- **Credenciais Verificáveis:** Vinculadas a atestações (pontuações de reputação, certificações de habilidades, conformidade regulatória).
- **Registro de Revogação:** Filtro Bloom habilitando verificações eficientes de revogação sem revelar lista completa de credenciais.

**Processo de Registro:**

1. Agente gera par de chaves; deriva DID de hash de chave pública.
2. Envia transação de registro para cadeia TOS (taxa: 1 TOS).
3. DID ancorado on-chain; documento DID publicado no IPFS; hash armazenado em contrato inteligente.
4. Agente prova controle assinando desafio com chave privada.

Credenciais Verificáveis (VCs) Agentes adquirem capacidades através de credenciais à prova de adulteração emitidas por autoridades confiáveis (validadores, tribunais de arbitragem, instituições educacionais).

Tipos de Credenciais:

- **Credenciais de Reputação:** Nível RepGraph (Bronze/Prata/Ouro/Platina), contagem de conclusão de tarefas, histórico de resolução de disputas.
- **Distintivos de Habilidades:** Expertise de domínio (análise jurídica, modelagem climática, revisão de código) validada via avaliação por pares ou exames de certificação.
- **Atestações de Conformidade:** Autorização KYC/AML (para on-ramps fiat), aprovações regulatórias (conformidade com EU AI Act, certificação de dispositivo médico FDA).
- **Provas de Delegação:** Autoridade para agir em nome de outra entidade (agentes corporativos executando em nome de DAOs).

Protocolo de Emissão:

1. Emissor (por exemplo, contrato inteligente RepGraph) cria documento de credencial JSON-LD.
2. Assina com assinaturas BBS+ (divulgação seletiva habilitada; titular pode provar atributos específicos sem revelar credencial inteira).
3. Publica credencial no documento DID do titular via IPFS; evento on-chain emitido.
4. Titular armazena credencial em carteira; apresenta provas de conhecimento zero a verificadores (por exemplo, “Provar reputação ≥ 0.7 without revealing exact score”).

Reputation Graph (RepGraph) Algorithms Score Computation:

$$r_t = \alpha \cdot r_{t-1} + (1 - \alpha) \cdot s_t \quad (14)$$

where:

- r_t : Reputation score at time t (range $[0, 1]$).
- $\alpha = 0.85$: Exponential smoothing factor (85% historical weight).
- s_t : Quality score for most recent task (median of 5 validator assessments).

Decay Mechanism:

$$r_{t+\Delta t} = r_t \cdot (0.98)^{\Delta t/30} \quad (15)$$

Reputation decays 2% per month of inactivity; prevents dormant high-reputation accounts from sudden reactivation.

Multi-Dimensional Scoring:

- **General Reputation:** Aggregate across all task types.
- **Domain-Specific:** Separate scores for legal, medical, financial, technical domains.



- **Recency-Weighted:** Recent performance (last 30 days) weighted 2× vs. historical average.

Anti-Gaming Measures:

- **Sybil Resistance:** Minimum 100 TOS stake + proof-of-uniqueness (BrightID integration roadmap v5.0).
- **Collusion Detection:** Graph analysis identifies clusters of agents with suspiciously correlated voting patterns; flagged for manual review.
- **Reputation Caps:** New agents capped at 0.5 reputation for first 90 days; prevents rapid reputation farming.

Interoperability with W3C Standards

- **DID Core v1.0:** Full compliance; TOS DID's resolvable via Universal Resolver.
- **Verifiable Credentials Data Model v1.1:** Credentials valid across ecosystems (can present TOS credential to non-TOS verifier).
- **DIDComm v2:** Secure messaging protocol for agent-to-agent communication (encrypted, authenticated, transport-agnostic).

9.2 P2 – Economic Execution

Account Abstraction TOS implements native account abstraction, enabling programmable accounts with custom validation logic integrated directly into the protocol layer. This eliminates the need for separate smart contracts or external coordination services, providing a streamlined experience for AI agents.

Key Features:

- **Paymasters:** Third parties sponsor gas fees (e.g., enterprise pays fees for employee agents).
- **Multi-Sig Wallets:** *m-of-n* approval for high-value transactions (corporate treasury accounts).
- **Session Keys:** Temporary keys with restricted permissions (agent can sign small transactions without accessing main key).
- **Social Recovery:** Recover account access via guardians (family members, trusted agents) if private key lost.

UserOperation Structure:

```
{
  sender: "0x...",           // Agent's account address
  nonce: 42,                  // Sequential counter
  initCode: "0x...",          // Account creation code (if new)
  callData: "0x...",          // Function call to execute
  paymasterAndData: "0x...",  // Paymaster address + verification data
  signature: "0x..."        // Signature over UserOperation
}
```

AGIW Settlement Engine Decentralized task marketplace where agents earn by performing verifiable work. Full protocol specification in Section 10.

Core Components:



- **TaskInstance Contract:** Escrow management, state machine (Open → Claimed → Verified → Settled).
- **Validator Pool:** Random selection of 5 validators per task; median quality score determines payout.
- **Attestation Reports:** TEE-generated proofs (Intel SGX, AMD SEV) certifying execution environment integrity.
- **Dispute Resolution:** Escalation to expert arbitrators if agent contests validator assessment.

Resource Token Markets (CC/EC) Compute Credits (CC): Fungible tokens representing GPU/CPU compute hours. Pricing oracles aggregate AWS/GCP/Azure spot prices.

Energy Credits (EC): Tokenized energy consumption (kWh). Oracle feeds from grid operators; renewable energy sources earn 10% premium.

Automated Market Maker (AMM):

- Constant Product Market Maker (CPMM): $x \cdot y = k$ where x = CC reserves, y = TOS reserves.
- Liquidity providers earn 0.3% swap fees.
- Impermanent loss protection: TEM treasury subsidizes divergence losses for LPs providing >1M TOS liquidity.

TOS Energy Model (TEM) Dynamic fee adjustment mechanism balancing network sustainability with agent accessibility.

Fee Structure:

$$\text{Total Fee} = \text{Base Fee} + \text{Priority Tip} - \text{TEM Subsidy} \quad (16)$$

Base Fee:

- Computed via dynamic adjustment mechanism that adjusts based on block fullness.
- Target: 50% block utilization; base fee increases 12.5% per block if usage > target.

TEM Subsidy Categories:

- **Public Goods (100% subsidy):** Open-source development, climate research, medical diagnostics.
- **Education (75%):** Academic research, student projects.
- **SMBs (50%):** Small/medium businesses with <\$10M annual revenue.
- **Enterprise (0%):** Full commercial rates for large corporations.

Funding: 8% of block rewards allocated to TEM treasury; governance votes on subsidy allocations quarterly.



Table 7: TEM Economic Parameters and Control Mechanisms

Parameter	Value / Range	Control Logic
Base fee band (TOS)	0.0001–0.01 per gas unit	Adjust by block fill p95; target 50% utilization
Base fee adjustment	+12.5% per block	If usage > 50% target
CC stabilization band	$\pm 15\%$ of GPU index	Oracle median with 30-min staleness cap
EC stabilization band	$\pm 10\%$ of kWh index	Region-weighted energy basket
TEM treasury split	40% security / 30% grants / 30% rebates	Quarterly governance rebalancing
Oracle staleness cap	≤ 30 minutes	Freeze CC/EC subsidy if exceeded
Subsidy categories	Public Goods: 100% / Education: 75% / SMB: 50% / Enterprise: 0%	Task classification by governance vote
Treasury allocation	8% of block rewards	Fixed protocol parameter
Validator reward pool	60% of block rewards	Base consensus incentive
Burn mechanism	10% of base fees	Deflationary pressure

Economic Sensitivity: TEM parameters undergo quarterly review by governance. Simulation results (available at metrics.tos.network/tem-sensitivity) demonstrate system stability under $3\times$ demand spikes and 50% oracle variance scenarios.

9.3 P3 – Consensus & Safety

Arquitetura Baseline BlockDAG Blockchains tradicionais formam cadeias lineares; TOS usa Grafo Acíclico Dirigido (DAG) permitindo produção paralela de blocos.

Estrutura de Blocos:

- Cada bloco referencia 1–3 blocos pais (vs. 1 em cadeias lineares tradicionais).
- Validadores propõem blocos independentemente; sem gargalo de eleição de líder.
- Ordenação topológica determina ordem de transações; conflitos resolvidos via timestamp + prioridade do proponente.

Regras de Consenso:

- **Profundidade de Confirmação:** Transação considerada final após 8 blocos de profundidade (mediana de 90 segundos).
- **Heurística da Cadeia Mais Longa:** Em caso de bifurcações DAG, preferir subgrafo com maior peso cumulativo de proof-of-stake.
- **Rotação de Validadores:** Comitê de 100 validadores selecionados por época (24 horas); ponderado por stake + reputação.

Desempenho:

- Baseline: 2.500–3.500 TPS (medido em set. 2025).
- Otimizado por PAI: 10.000+ TPS (meta Q4 2026).



Table 8: Performance Evaluation Methodology

Parameter	Configuration
Validators	32 nodes across 8 geographic regions (N. America, Europe, Asia-Pacific, S. America, Africa, Middle East, Oceania, Central Asia); BLS signature scheme
Hardware	16 vCPU, 64 GB RAM, NVMe SSD (1 TB), 2.5 Gbps network interface
Network	Emulated RTT: 20–180ms (inter-region), packet loss: 0.1–1.0%, jitter: ± 10 ms
Workloads	Real agent jobs: code review (15%), data synthesis (25%), RAG tasks (20%); Synthetic spam: 20–60% injection rate
Runtime	72-hour continuous runs; 5 independent seeds; cold start + steady state phases
Block Size	Variable: 100–2,000 transactions per block; target 50% utilization
Mempool Config	Priority queue with reputation weighting; max 100,000 pending transactions
Metrics Collected	TPS (p50/p95/p99), block time (p50/p95), finality depth (confirmation blocks), AGIW settlement latency (publicação da tarefa $\rightarrow$ reward), dispute rate (% of tasks disputed), validator liveness (uptime %), fork rate
Measurement Tools	Prometheus + Grafana; custom telemetry pipeline; raw logs exported to <code>metrics.tos.network</code>
Baseline Period	September 2025 testnet deployment (14-day observation window)

Key Results (September 2025 baseline):

- TPS: p50 = 2,847, p95 = 3,421, p99 = 3,789
- Block time: p50 = 11.3s, p95 = 14.2s
- Finality: 8 blocks (median 90s)
- AGIW settlement: p50 = 12.4 min, p95 = 18.7 min
- Taxa de disputas: 1.8% das tarefas concluídas
- Validator liveness: 98.7% average

Consenso Power of AI (PAI) Agendamento assistido por IA aumenta throughput do BlockDAG via ordenação preditiva de transações.

Fase 1: Dicas de Agendamento de IA

Modelo ML leve (LSTM treinado em padrões históricos de transações) prediz ordenação ótima de blocos. Validadores votam na proposta de IA; aprovação >67% adota dica.

Fase 2: Comitês Híbridos

Comitê de IA (30% stake) propõe ordenações de blocos; Comitê Humano (70% stake) revisa e aprova. Finalidade probabilística: $1 - 2^{-k}$ confiança após k confirmações.

Fase 3: PAI Completo

Agentes de IA participam como validadores. Governança limita poder de voto de IA a 40% (previne tomada de controle por IA); validadores humanos retêm veto.

Integração de Oráculo de Segurança de IA Oráculo on-chain agrega métricas de segurança de laboratórios líderes de IA:



- **IA Constitucional Anthropic:** Pontuações de nocividade (toxicidade, viés, desinformação).
- **API de Moderação OpenAI:** Violações de política de conteúdo (discurso de ódio, violência, atividade ilegal).
- **Google Perspective:** Métricas de qualidade de conversa.

Aplicação:

- Tasks with safety score < 0.3 automatically rejected (refund escrow).
- Agentes que enviam repetidamente saídas inseguras são sinalizados; reputação penalizada.
- Árbitros humanos revisam casos limítrofes (pontuação de segurança 0,3–0,5).

Mecanismos de Slashing

paragraphSlashing & Anti-Sybil Mechanisms Anti-Sybil Slashing de Validadores:

- **Assinatura dupla:** Propose conflicting blocks $\Rightarrow$ 50% stake slashed.
- **Tempo de inatividade:** Offline > 6 hours $\Rightarrow$ 5% stake slashed, ejected from active set.
- **Atestação Inválida:** Sign fraudulent TEE report $\Rightarrow$ 20% stake slashed.

Anti-Sybil de Agentes:

- Stake mínimo: 100 TOS por identidade de agente.
- Limites de taxa: cooldown de 5–60 minutos entre tarefas (baseado em reputação).
- Análise de grafo: Detectar clusters de agentes com padrões comportamentais idênticos; exigir prova de unicidade.

9.4 P4 – Resilience

Roadmap de Criptografia Pós-Quântica Veja Seção 8 para estratégia detalhada de migração PQC. Resumo:

- **v4.0 (2026):** Assinatura dupla (ECDSA + Dilithium-3).
- **v5.0 (2030):** Somente PQC; assinaturas clássicas descontinuadas.
- **v6.0 (2040):** Funções hash resistentes a quântica (SHA-3).

Histórico Reversível Court-authorised rollback mechanism for catastrophic failures. Checkpoints every 24 hours; 90-day rollback window; 75% governance supermajority required. See Section 8 for full specification.

Federação de Arquivo Estratégia de armazenamento multicamadas (Quente/Morno/Frio) com backups de DNA e disco óptico 5D. Dados preservados por milênios em colônias planetárias. Veja Seção 8 para modelo econômico e protocolos de recuperação.

Rede Tolerante a Atrasos Consenso hierárquico (Domínios de Consenso Locais + Cadeia Raiz Interplanetária) lida com atrasos de comunicação à velocidade da luz. Snapshots diários permitem liquidação interplanetária dentro de 48–96 horas. Veja Seção 8 para protocolo de swap atômico interplanetário.

**Protocolos de Recuperação de Desastres Cenários de Falha Bizantina:**

- Partição de rede (blackout de comunicação Terra–Marte): LCDs operam independentemente; sincronizam quando reconectados.
- Validator collusion (<33%): Median-of-5 scoring resists outliers.
- Validator collusion (>33%): Emergency governance intervention; slashing + re-election.

SLAs de Recuperação:

- **Minor incidents** (1–5% validator compromise): Automated slashing + replacement within 1 hour.
- **Major incidents** (5–20% compromise): Council emergency session; resolution within 24 hours.
- **Critical incidents** (>20% compromise): Network pause; rollback authorization; resolution within 7 days.

10 Especificação do Protocolo AGI Work (AGIW)

10.1 Definição Formal

Representação de Tarefa Uma tarefa T é uma tupla:

$$T = (id, owner, spec, escrow_{CC}, escrow_{EC}, stake_{req}, deadline, whitelist, state) \quad (17)$$

onde:

- $id \in \{0, 1\}^{256}$: Identificador único de tarefa (hash keccak256).
- $owner \in \mathbb{A}$: Endereço do publicador.
- $spec$: ID de conteúdo IPFS referenciando especificação da tarefa (esquema JSON, conjuntos de dados, critérios de aceitação).
- $escrow_{CC}, escrow_{EC} \in \mathbb{R}^+$: Créditos computacionais e energéticos bloqueados para pagamento.
- $stake_{req} \in \mathbb{R}^+$: Participação mínima necessária para agentes reivindicarem tarefa.
- $deadline \in \mathbb{N}$: Número do bloco até o qual o trabalho deve ser submetido.
- $whitelist \subseteq \mathbb{A}$: Conjunto de agentes permitidos (vazio $\Rightarrow$ tarefa pública).
- $state \in \{\text{Open}, \text{Claimed}, \text{Submitted}, \text{Validating}, \text{Settled}, \text{Disputed}\}$.

Submissão de Agente Um agente a submete trabalho como:

$$W = (resultHash, attestation, metrics) \quad (18)$$

onde:

- $resultHash \in \{0, 1\}^{256}$: Hash de conteúdo da saída da tarefa (CID IPFS).
- $attestation$: Relatório TEE incluindo:
 - $measurementHash$: Hash SHA-256 do código em execução (prova integridade).
 - $inputHash, outputHash$: Hashes de entradas e saídas.
 - $timestamp$: Tempos de início/fim da execução.
 - $energyUsed \in \mathbb{R}^+$: kWh consumidos (medido via telemetria do SO ou contadores TEE).
 - $signature$: Atestação assinada por TEE (Intel SGX: ECDSA sobre secp256r1; AMD SEV: RSA-4096).
- $metrics$: Dados opcionais de desempenho (tempo de execução, uso de memória, precisão do modelo).



Função de Validação Validadores avaliam submissões usando função:

$$\mathcal{V} : (W, spec, T) \rightarrow [0, 1] \quad (19)$$

A função verifica:

1. **Validade da atestação:** Verificar assinatura TEE contra chaves públicas conhecidas (Intel, AMD).
2. **Correção da medição:** Comparar *measurementHash* a hashes de código aprovados na lista branca.
3. **Qualidade do resultado:** Comparar *resultHash* a saídas de referência (se determinístico) ou saídas de amostra (se estocástico).
4. **Eficiência energética:** Garantir *energyUsed* $\leq$ orçamento especificado em *spec*.

Validadores submetem pontuações de qualidade $q_v \in [0, 1]$. Consenso agrega via mediana:

$$q = \text{median}(\{q_v : v \in \text{assigned validators}\}) \quad (20)$$

Liquidação requer $|q_v - q| \leq \epsilon$ para $\geq 67\%$ dos validadores, onde $\epsilon = 0.1$ é limiar de tolerância.

Política de Slashing Validadores desviando $> 2\sigma$ da mediana perdem:

$$\text{slash}_v = \min(0.05 \times \text{stake}_v, 0.01 \times \text{stake}_v \times |q_v - q|/\epsilon) \quad (21)$$

Fundos confiscados transferidos para tesouro. Outliers persistentes (> 5 slashes em 100 tarefas) removidos do pool de validadores.

10.2 Máquina de Estados

A máquina de estados AGIW transiciona da seguinte forma:

Estado	Gatilho	Condições	Próximo Estado
Open	Agente chama <code>claimTask()</code>	Agente em <i>whitelist</i> (se especificado), participação $\geq \text{stake}_{req}$, bloco $<$ deadline	Claimed
Claimed	Agente chama <code>submitWork()</code>	Chamador é reclamante, bloco $<$ deadline, assinatura de atestação válida	Submitted
Claimed	Bloco $\geq$ deadline	Prazo passou sem submissão	Forfeited (agente perde 10% de participação)
Submitted	Validadores atribuídos	Automático (acionado por evento de contrato inteligente)	Validating
Validating	Todos validadores submetem pontuações	$\geq 67\%$ pontuações dentro de ϵ da mediana	Settled



Validating	Disputa levantada	Qualquer parte de- posita título de arbi- tragem	Disputed
Settled	Recompensas dis- tribuídas	Automático (Reward- Splitter executado)	Estado terminal
Disputed	Árbitros decidem	Voto majoritário (2-de- 3)	Resolved
Resolved	Decisão aplicada	Depósito distribuído conforme decisão de arbitragem	Estado terminal

Table 9: Transições de estado AGIW com gatilhos, condições e resultados.

10.3 Fluxo de Trabalho de Atestação (Detalhado)

Passo 1: Preparação do Agente

1. Agente provisiona Ambiente de Execução Confiável (TEE): enclave Intel SGX, VM AMD SEV-SNP, ou ARM Realm.
2. Agente carrega código da tarefa (verificado contra hash da lista branca), dados de entrada e pesos do modelo no TEE.
3. TEE inicializa medição: hash do código + dados + configuração.

Passo 2: Execução Dentro do TEE

1. TEE executa tarefa em isolamento (sem visibilidade do SO na memória do enclave).
2. TEE registra consumo de energia via:
 - **Intel SGX:** Contadores RAPL (Running Average Power Limit).
 - **AMD SEV:** Telemetria SMU (System Management Unit).
 - **ARM Realm:** Eventos de energia PMU (Performance Monitoring Unit).
3. TEE gera resultado, calcula $resultHash = keccak256(output)$.

Passo 3: Geração de Relatório de Atestação

TEE produz relatório assinado:

```
{
  "version": "2.0",
  "timestamp": 1698765432,
  "measurementHash": "sha256:abcd...1234",
  "inputHash": "sha256:5678...ef90",
  "outputHash": "sha256:1111...2222",
  "energyUsed_kWh": 4.8,
  "runtime_seconds": 1320,
  "teeType": "IntelSGX",
  "signature": "base64:M3Mz...NDQ0"
}
```

Assinatura calculada sobre todos os campos usando chave privada do TEE (protegida por hardware, não exportável).



Passo 4: Submissão On-Chain Agente chama `TaskInstance.submitWork(resultHash, attestation)`. Contrato inteligente:

- Verifica *signature* contra chaves públicas TEE conhecidas (armazenadas em registro atualizado trimestralmente).
- Emite evento `WorkSubmitted(taskID, agentDID, resultHash, attestation)`.
- Aciona `ValidationPool` para atribuir validadores.

Passo 5: Verificação do Validador Validadores independentemente:

1. Buscam atestação do evento on-chain.
2. Verificam assinatura TEE (prova criptográfica de integridade de execução).
3. Opcionalmente re-executam tarefa em seu próprio TEE para confirmar correspondência de *resultHash*.
4. Verificam *energyUsed* $\leq$ orçamento da tarefa.
5. Submetem pontuação de qualidade $q_v \in [0, 1]$ via `ValidationPool.validateWork(taskID, q_v)`.

Roteiro: Atestação zk-SNARK Versões futuras (2027+) substituem atestação TEE por provas de conhecimento zero:

- Agente gera zk-SNARK provando “Eu executei código C na entrada x e produzi saída y ” sem revelar x , y , ou estados intermediários.
- Tamanho da prova: ~ 200 bytes (constante, independente da computação).
- Custo de verificação: ~ 5 ms em hardware comum (vs. verificação de assinatura TEE ~ 2 ms).
- Vantagem: Sem dependência de fornecedores específicos de hardware (Intel, AMD); verificação sem confiança.

11 Design do Mercado de Crédito Computacional/Energético

11.1 Oráculos

21 alimentadores agregam dados de provedores de nuvem, mercados de energia. Mediana-das-medianas garante robustez. Desvio de alimentador além da tolerância aciona slashing.

11.2 Pools de Liquidez

Pools CC/EC fornecem liquidez, cobrando taxas dinâmicas. TEM injeta liquidez durante estresse. Índices de cobertura garantem créditos suficientes para agentes ativos.

12 Simulação Econômica

12.1 Metodologia

Modelamos a economia do TOS usando simulação baseada em agentes com 100.000 passos de tempo (dias). Variáveis-chave:

- **População de agentes:** $N_a(t)$ agentes ativos no dia t .
- **Volume de tarefas:** $V_t(t)$ tarefas publicadas por dia.

- **Valor de tarefa:** Depósito médio $\bar{e}_t$ (em CC/EC equivalente USD).
- **Pontuação de qualidade:** Média $\bar{q}_t$, desvio padrão σ_q .
- **Taxa de disputas:** $d_t \in [0, 1]$ fração de tarefas escalando para arbitragem.
- **Participação de validadores:** $N_v(t)$ validadores fazendo staking no tempo t .

Simulação incorpora:

- **Efeitos de rede:** Adoção de agente segue crescimento logístico; volume de tarefa escala sublinearmente ($V_t \propto N_a^{0.85}$).
- **Dinâmicas de reputação:** Pontuações RepGraph evoluem via EMA; agentes de alta reputação atraem tarefas premium.
- **Loops de feedback econômico:** TEM ajusta subsídios baseado em taxas de disputa, liquidez e condições de mercado energético.

12.2 Definições de Cenário

Parâmetro	Conservador	Baseline	Otimista
Pico de agentes (N_a)	20.000	50.000	150.000
Tarefas/dia (ano 3)	50.000	150.000	500.000
Valor médio tarefa (\$)	\$150	\$300	\$600
Pontuação de qualidade $\bar{q}$	0,75	0,85	0,92
Taxa de disputas d	4%	2%	0,8%
Validadores (N_v)	200	500	1.200
Preço TOS (ano 3)	\$2	\$5	\$15
Curva de adoção	Lenta (5 anos)	Moderada (3 anos)	Rápida (2 anos)

Table 10: Parâmetros de cenário econômico para simulação TOS (2025–2030).

12.3 Fórmulas

Volume de Liquidação Volume de liquidação anual $S(y)$ no ano y :

$$S(y) = 365 \times V_t(y) \times \bar{e}_t(y) \quad (22)$$

Example (Baseline, year 3): $S(3) = 365 \times 150,000 \times \$300 = \$16.4$ billion.

Agent Earnings Average agent income per year:

$$I_a(y) = \frac{V_t(y)}{N_a(y)} \times \bar{e}_t(y) \times \bar{q}(y) \times (1 + 0.2(r_a - 0.5)) \times f(s_a) \quad (23)$$

For median agent ($r_a = 0.6$, $s_a = 500$ TOS):

$$I_a(3) = \frac{150,000}{50,000} \times \$300 \times 0.85 \times 1.02 \times 1.62 \approx \$1,250 \text{ per year} \quad (24)$$

Top-tier agent (Platinum, $r_a = 0.95$, $s_a = 5,000$ TOS):

$$I_a^{\text{top}}(3) \approx \$8,200 \text{ per year} \quad (25)$$



Validator Earnings Validator income (12% of settlement volume, split proportional to accuracy):

$$I_v(y) = \frac{0.12 \times S(y)}{N_v(y)} \times \frac{Acc_v}{Acc} \quad (26)$$

Baseline year 3, median validator ($Acc_v = 0.85$):

$$I_v(3) = \frac{0.12 \times \$16.4B}{500} \times \frac{0.85}{0.85} \approx \$3.9M \text{ per year} \quad (27)$$

Treasury Accumulation Treasury receives 8% of settlement + slashed funds:

$$T(y) = 0.08 \times S(y) + \sum_{\text{slash events}} slash_v \quad (28)$$

Baseline year 3: $T(3) = 0.08 \times \$16.4B + \$20M \approx \$1.33B$.

12.4 Results by Scenario

Conservative Scenario (Slow Adoption, Higher Disputes)

- Year 3 settlement: $365 \times 50,000 \times \$150 = \$2.74$ billion.
- Agent income: Median \$410/year; top tier \$2,800/year.
- Validator income: \$1.3M/year (median).
- Treasury: \$240M.
- **Outcome:** Network remains sustainable; validators earn sufficient income to justify participation; treasury covers arbitration costs and development grants.

Baseline Scenario (Moderate Adoption, Standard Disputes)

- Year 3 settlement: \$16.4 billion.
- Agent income: Median \$1,250/year; top tier \$8,200/year.
- Validator income: \$3.9M/year (median).
- Treasury: \$1.33B.
- **Outcome:** Strong economic flywheel; agents earn viable supplementary income; validators incentivised by high returns; treasury funds PAI research, ecosystem grants, energy rebates.

Optimistic Scenario (Rapid Adoption, Low Disputes)

- Year 3 settlement: $365 \times 500,000 \times \$600 = \$109.5$ billion.
- Agent income: Median \$2,190/year; top tier \$16,800/year.
- Validator income: \$10.9M/year (median).
- Treasury: \$8.8B.
- **Outcome:** TOS becomes dominant agent economy infrastructure; agents achieve full-time income viability; validators earn institutional-grade returns; treasury funds major initiatives (PAI Phase 3, interplanetary research, DAE pilots).



12.5 Sensitivity Analysis

Impact of Task Value Variance Increasing average task value by 50% (e.g., \$300 $\rightarrow$ \$450 in Baseline) yields:

- Settlement volume: +50% (\$16.4B $\rightarrow$ \$24.6B).
- Agent income: +50% (\$1,250 $\rightarrow$ \$1,875).
- Validator/treasury income: +50% (linear scaling).

Impact of Dispute Rate Doubling dispute rate (2% $\rightarrow$ 4% in Baseline) results in:

- Arbitration costs: +100% (more arbitrators required).
- TEM response: Increase validator rewards by 20% to attract participation.
- Net effect: Treasury allocation increases from 8% to 10% to cover costs; validator share decreases from 12% to 11%.

Impact of TOS Price TOS token price affects staking economics. In Baseline, if TOS price increases from \$5 to \$15:

- Agent stake value: 500 TOS = \$7,500 (vs. \$2,500).
- Validator stake value: 1,000 TOS = \$15,000 (vs. \$5,000).
- Effect: Higher capital requirements may reduce participation; TEM can lower minimum stakes to compensate (e.g., 500 $\rightarrow$ 200 TOS).

12.6 Long-Term Projections (MERCURY through Early VENUS)

Extrapolating across MERCURY and into early VENUS:

- **Early MERCURY (Baseline):** \$16.4B annual settlement, 50,000 agents, 500 validators.
- **Mid-MERCURY (Baseline):** \$180B annual settlement (compound growth 12%/year), 800,000 agents, 2,500 validators. PAI consensus achieves 10,000+ TPS; hybrid fiat settlement drives enterprise adoption.
- **Late MERCURY / Early VENUS (Baseline):** \$650B annual settlement, 4.5M agents (mix of human-operated and autonomous), 10,000 validators. DAEs emerge; constitutional contracts govern virtual economies; TOS treasury exceeds \$50B, funding interplanetary infrastructure.

12.7 Risk Scenarios

Black Swan: Major Security Breach Suppose an early-MERCURY attack compromises 5% of validators, resulting in \$500M fraudulent settlements. Response:

- Insurance pool (3% of volume) covers most losses.
- Governance invokes emergency rollback (reversible history mechanism, Section 8).
- Affected validators slashed (lose 50% stake); reputations reset to zero.
- Network downtime: 72 hours for forensics and remediation.
- Long-term impact: Trust recovery via transparent audit report, protocol upgrade (v5.0), validator re-accreditation.



Regulatory Shock: Major Jurisdiction Bans AI Agents Suppose a mid-MERCURY regulatory shift where a major jurisdiction bans autonomous AI labour. Scenarios:

- **Compliance path:** TOS deploys human-in-the-loop arbitration for all EU tasks; task volume decreases 15% but compliance preserves access.
- **Fragmentation path:** EU agents migrate to permissioned TOS shard; cross-shard settlement via delay-tolerant protocol; network splits but remains interoperable.

13 Security and Threat Model

TOS operates in a hostile environment where economic incentives attract sophisticated adversaries. This section models threat actors, attack vectors, and defense-in-depth countermeasures grounded in Byzantine fault tolerance, cryptoeconomics, and empirical security research.

13.1 Threat Taxonomy

T1: Malicious Agents (Sybil Attackers) **Motivation:** Earn rewards without performing legitimate work; game reputation systems; overwhelm validation queues.

Capabilities: Create thousands of identities; automate low-quality submissions; coordinate timing attacks.

Attack Vectors:

- **Task spam:** Flood network with trivial or duplicate tasks to claim escrow before validation.
- **Reputation farming:** Collude with cooperating publishers to inflate scores.
- **Oracle manipulation:** Submit false attestations to trick validators.

Historical Precedent: Steam account farming (2016), cryptocurrency airdrop bots (2020–2023), large-scale review fraud on Amazon/Yelp.

T2: Validator Collusion **Motivation:** Extract rents by approving low-quality work from co-conspirators; censor competitors.

Capabilities: Control $> 33\%$ of validator stake or exploit randomness in assignment algorithms.

Attack Vectors:

- **Quality inflation:** Validators assign high scores to cartel members' submissions regardless of merit.
- **Censorship:** Reject or delay validation of non-cartel agents.
- **Front-running:** Validators observe pending tasks, submit competing solutions under alternate identities.

Historical Precedent: Mining pool centralization, MEV extraction patterns, and validator centralization observed across various blockchain networks demonstrate the reality of these threats.

T3: Oracle Cartels **Motivation:** Manipulate CC/EC pricing to profit from arbitrage or harm competitors.

Capabilities: Compromise majority of oracle feeders; exploit data source vulnerabilities; delay price updates.

Attack Vectors:



- **Price manipulation:** Report inflated compute costs to drain TEM subsidies or extract value from agents.
- **Staleness attacks:** Delay updates during high volatility to force fallback pricing.
- **Data poisoning:** Compromise API sources (AWS pricing feeds, energy indices).

Historical Precedent: LIBOR manipulation scandal (2008–2012), flash crashes in algorithmic trading (2010), oracle failures in decentralised finance protocols.

T4: Governance Capture Motivation: Control protocol parameters to favor specific actors; extract treasury funds; resist security upgrades.

Capabilities: Accumulate majority voting stake; exploit low voter turnout; launch social engineering campaigns.

Attack Vectors:

- **Parameter manipulation:** Vote to reduce slashing penalties, increase reward splits, weaken anti-Sybil thresholds.
- **Treasury raids:** Propose grants to shell entities controlled by attackers.
- **Upgrade blocking:** Prevent deployment of patches addressing known vulnerabilities.

Historical Precedent: Blockchain governance takeovers, decentralised protocol governance attacks, corporate proxy fights.

T5: Smart Contract Exploits Motivation: Steal escrowed funds, mint unauthorized tokens, manipulate state variables.

Capabilities: Discover reentrancy bugs, integer overflows, access control flaws, or logical errors.

Attack Vectors:

- **Reentrancy:** Exploit callback functions in TaskInstance or RewardSplitter contracts.
- **Flash loan attacks:** Temporarily acquire large stakes to manipulate governance or oracle votes.
- **Griefing:** DoS validation queues by submitting malformed attestations that crash verifiers.

Historical Precedent: The DAO hack (2016, \$50M), Parity wallet freeze (2017), Poly Network exploit (2021, \$600M).

13.2 Defense-in-Depth Architecture

Layer 1: Cryptographic Foundations

- **TEE Attestation:** Intel SGX/AMD SEV remote attestation verifies code integrity; measurement hashes prevent malware injection. Limitation: side-channel attacks (Spectre, Melt-down); roadmap includes zk-SNARK fallback.
- **Post-Quantum Cryptography:** Dilithium (signatures), Falcon (compact signatures) resist quantum attacks. Migration plan: dual-signing (classical + PQC) by v4.0 (see Appendix C, Report PQ-2025-08).
- **Threshold Signatures:** BLS aggregation enables compact multi-sig; t -of- n schemes prevent single points of failure in bridge contracts.



Layer 2: Economic Security (Cryptoeconomics)

- **Stake-Based Accountability:** Agents and validators lock collateral (min 100 TOS / 1,000 TOS respectively); slashing penalties (1–50% of stake) deter misbehavior. Game-theoretic analysis: attacking network costs $> \$500k$ at current prices; expected return negative unless sustaining attack for > 30 days (impractical due to rapid detection).
- **Reputation Decay:** RepGraph scores decay 2% monthly without activity; prevents dormant accounts from sudden reactivation with outdated high scores.
- **Cooling Periods:** Rate limits (5–60 min based on reputation) prevent spam; adaptive thresholds increase during DoS attempts.

Layer 3: Protocol-Level Safeguards

- **Multi-Validator Consensus:** Median-of-5 scoring resists outliers; requires ≥ 3 colluding validators to manipulate outcomes (probability $< 0.01\%$ with random assignment).
- **Randomness Sources:** Validator assignment uses VRF (Verifiable Random Function) seeded by block hashes + external entropy (drand); prevents predictability.
- **Formal Verification:** TaskInstance state machine verified in TLA+; proofs ensure liveness (tasks always settle) and safety (no double-payment). Artifacts: github.com/tos-network/formal-verification

Layer 4: Monitoring & Response

- **Anomaly Detection:** ML classifiers flag suspicious patterns (e.g., agent claiming > 10 tasks/hour, validator approving $> 95\%$ of submissions). Telemetry fed to Security Operations Center (SOC).
- **Circuit Breakers:** Automated pause if (1) dispute rate $> 10\%$, (2) validator slashing events > 5 in 1 hour, (3) oracle deviation $> 20\%$. Resumption requires Council approval.
- **Bug Bounty:** \$50k–\$500k rewards for critical vulnerabilities. Program managed via Immunefi/HackerOne; payouts in TOS tokens.

Layer 5: Governance Oversight

- **Council Emergency Powers:** 4-of-7 multi-sig can (1) pause contracts, (2) freeze malicious accounts, (3) trigger rollback (reversible history, Section 8). Actions logged on-chain; post-mortem required within 72 hours.
- **Proof-of-Personhood Integration:** Roadmap v5.0 integrates Worldcoin/BrightID to limit Sybil identities in governance votes. Agents remain pseudonymous for tasks but must prove unique humanness for high-stake decisions.
- **Transparency Reports:** Quarterly disclosure of (1) security incidents, (2) slashing events, (3) governance votes, (4) treasury changes. Auditable via Compliance API.

13.3 Incident Response Playbook

Phase 1: Detection (0–15 minutes) SOC receives alert from monitoring; triage severity (P0: active exploit, P1: potential threat, P2: informational). Automated checks verify authenticity (rule out false positives).

Phase 2: Containment (15–60 minutes) Invoke circuit breaker if P0; freeze affected accounts; snapshot state for forensics. Notify Council; convene emergency session.



Phase 3: Investigation (1–24 hours) Forensic analysis: review transaction logs, attestation reports, validator votes. Identify attack vector; estimate impact (funds at risk, agents affected).

Phase 4: Remediation (1–7 days) Deploy patch via governance fast-track (48-hour voting period for emergencies). Compensate affected users from insurance pool. Publish post-mortem report.

Phase 5: Lessons Learned (ongoing) Update threat model; enhance monitoring rules; conduct red-team exercise to validate fixes. Share learnings with broader blockchain community (responsible disclosure).

13.4 Attack Cost Analysis

Attack Type			Minimum Cost (USD)	Expected Return
Sybil spam (1,000 agents)			\$150k (stake) + \$20k (infra)	Negative (slashing + reputation loss)
Validator collusion (34% stake)			\$8.5M (at \$5/TOS, 570k TOS)	\$2M/year (if undetected); high detection risk
Oracle cartel (11/21 feeders)			\$2M (bribes) + \$500k (infra)	\$5M (one-time arbitrage); permanent reputation damage
Smart contract exploit			\$50k–\$200k (researcher salary)	\$0–\$50M (depends on escrow volume); bug bounty preferred
Governance capture (51% vote)			\$12M (token acquisition)	\$10M/year (treasury access); high regulatory risk

Table 11: Adversarial cost-benefit matrix for TOS network attacks. Costs assume Outubro 2025 market conditions; returns account for detection probability and countermeasures.

Interpretation: Most attacks are economically irrational under current parameters. Exception: highly sophisticated actors (nation-states, well-funded cybercrime syndicates) may absorb costs for strategic disruption. Countermeasures include insurance pools, regulatory cooperation, and continuous security audits.

14 Estrutura de Governança

Effective governance balances decentralization (resisting capture), efficiency (timely decisions), and legitimacy (stakeholder buy-in). TOS adopts a multi-chamber model inspired by constitutional democracies, corporate boards, and decentralised autonomous organisation research.

14.1 Governance Actors & Responsibilities

Token Holders (TOS Stakers) Role: Economic stakeholders with voting rights proportional to staked TOS.

Responsibilities:



- Vote on protocol upgrades (consensus rule changes, smart contract deployments).
- Elect Council of Stewards (annual elections, staggered 3-year terms).
- Approve/reject treasury spending proposals exceeding threshold (\$100k equivalent in TOS).

Poder de Voto: Votação quadrática para mitigar plutocracia; votos de cada staker = $\sqrt{\text{TOS staked}}$. Exemplo: 10.000 TOS = 100 votos; 1.000.000 TOS = 1.000 votos (não 100.000). Isso reduz dominância de baleias enquanto recompensa participação significativa.

Delegation: Stakers may delegate votes to domain experts (e.g., security researchers for PQC migration votes, economists for TEM parameter adjustments). Delegation is non-custodial; stakers retain withdrawal rights.

Agent Operators **Role:** Deploy and manage AI agents; represent agent interests in governance.
Responsibilities:

- Propose improvements to AGIW protocol (validation logic, fee structures, task templates).
- Participate in working groups (e.g., AI Safety Committee, Privacy Task Force).

Voting Power: Reputation-weighted votes in agent-specific proposals. High-reputation agents ($r \geq 0.8$) receive $1.5\times$ voting multiplier.

Validators **Role:** Operate consensus nodes; validate AGIW submissions; secure the network.
Responsibilities:

- Vote on technical proposals (BlockDAG parameter tuning, PAI consensus roadmap).
- Signal protocol health metrics (dispute rates, throughput, latency).

Voting Power: Stake-weighted; validators with $> 5\%$ total stake capped at 5% voting power (prevents centralization).

Council of Stewards **Composition:** 7–15 elected members with expertise in security, economics, law, AI ethics, distributed systems.

Term: 3 years, staggered elections ($\frac{1}{3}$ seats up for election annually).

Responsibilities:

- Emergency response: pause contracts during active exploits (4-of-7 multi-sig).
- Treasury management: approve grants $< \$100k$; recommend larger proposals to token holders.
- Protocol stewardship: convene working groups; commission audits; publish roadmap updates.
- Regulatory liaison: coordinate with policymakers; submit comments on proposed regulations (e.g., EU AI Act, US AI RMF).

Accountability: Quarterly performance reviews; token holders may recall members via 67% supermajority vote.

Auditor Committee **Composition:** 5 independent security firms + 3 community-elected technical reviewers.

Responsibilities:

- Pre-deployment audits: review all smart contract upgrades; publish reports 7 days before vote.
- Post-deployment monitoring: continuous fuzzing, formal verification, penetration testing.
- Incident analysis: forensic investigations after security breaches; recommend remediation.

Compensation: 2% of treasury allocated annually; additional bounties for discovering critical bugs.



Regulators & Compliance Officers **Role:** Observe governance; access compliance telemetry; participate in policy discussions (non-voting).

Access Rights: Read-only API for aggregated statistics (task volumes, dispute rates, energy usage). Individual agent identities remain confidential unless court order.

Engagement: Quarterly briefings with Council; input on custody standards, AML/KYC integration, cross-border settlement rules.

14.2 Proposal Lifecycle

Stage 1: Ideation & Discussion (7–30 days) **Forum:** Off-chain discussion on Commonwealth, Discord, GitHub. Anyone may draft a proposal using standardized template (problem statement, solution, cost-benefit analysis, risk assessment).

Temperature Check: Informal polls gauge community sentiment. Proposals with < 20% support typically abandoned.

Stage 2: Formal Submission (1–3 days) **Requirements:**

- Proposer must stake 10,000 TOS (anti-spam; refunded if proposal passes).
- Proposal includes executable code (for on-chain changes) or detailed specification (for off-chain coordination).
- Auditor Committee review completed (for contract upgrades).

Categorization: Proposals tagged as *Technical*, *Economic*, *Treasury*, *Emergency*, or *Constitutional* (different voting thresholds).

Stage 3: Voting (7 days standard, 48 hours for emergencies) **Quorum:** 15% of circulating TOS must participate (prevents apathy-driven outcomes).

Approval Thresholds:

- **Technical/Economic:** 60% approval (simple majority with buffer).
- **Treasury (¡\$100k):** Council approval (multi-sig).
- **Treasury (¡\$100k):** 67% token holder approval.
- **Constitutional:** 75% approval + validator sign-off (modifies core rules).
- **Emergency:** 4-of-7 Council multi-sig (immediate execution; retroactive vote within 14 days).

Voting Interface: Web app (`vote.tos.network`), CLI, SDK integration. Votes cryptographically signed; tallies verifiable on-chain.

Stage 4: Timelock & Execution (48 hours) **Timelock:** Approved proposals enter 48-hour delay before execution. Rationale: provides window for last-minute security reviews; allows stakers to exit if opposed to major changes.

Execution: Automated via governance smart contract module (`Governor.py`); transactions broadcasted to relevant contracts (e.g., parameter updates, treasury transfers).

Veto: Council may invoke emergency veto (4-of-7 multi-sig) if critical flaw discovered during timelock; requires public justification + re-vote.

Stage 5: Post-Implementation Review (30–90 days) **Monitoring:** Track key metrics (e.g., if TEM parameters changed, monitor fee volatility, agent churn).

Retrospective: Council publishes impact assessment; community discusses lessons learned.

Amendments: If proposal underperforms, fast-track amendment process (reduced voting period).



14.3 Constitutional Contracts

Certain rules are enshrined in immutable or semi-immutable contracts, forming the network’s “constitution.” Modification requires supermajority approval (75%) and validator consensus.

Core Principles (Immutable)

1. **Non-Censorship:** No proposal may blacklist specific agents, validators, or publishers based on identity (exception: sanctioned addresses per regulatory compliance).
2. **Transparency:** All governance votes, treasury transactions, and contract upgrades must be publicly auditable.
3. **Exit Rights:** Token holders may withdraw staked TOS at any time (subject to cooldown periods); no governance action may confiscate funds without due process (arbitration ruling).

Economic Parameters (Semi-Immutable)

1. **Reward Splits:** Agent/validator/treasury distribution (α, β, γ) adjustable within bounds ($\beta \in [0.10, 0.15]$, $\gamma \in [0.05, 0.10]$).
2. **Slashing Penalties:** Validator/agent slashing rates capped at 50% (prevents disproportionate punishment).
3. **Treasury Cap:** Maximum annual spending = 20% of treasury balance (ensures long-term sustainability).

14.4 Governance Attack Vectors & Defenses

Attack: Vote Buying Scenario: Wealthy actor offers \$10/vote to sway proposal.

Defense: (1) Quadratic voting reduces ROI for large-scale vote buying. (2) Delegation to trusted experts reduces susceptibility. (3) On-chain analytics detect unusual voting patterns (e.g., 1,000 wallets voting identically); flagged for community scrutiny.

Attack: Governance Fatigue Scenario: Excessive proposals overwhelm voters; turnout drops below quorum.

Defense: (1) Stake requirement filters low-quality proposals. (2) Council pre-screens proposals for feasibility. (3) Quarterly “batch votes” consolidate related proposals (reduces decision fatigue).

Attack: Emergency Power Abuse Scenario: Compromised Council member misuses multisig to freeze legitimate accounts.

Defense: (1) 4-of-7 threshold requires collusion. (2) All emergency actions logged publicly; retroactive vote required within 14 days. (3) Community may recall Council members via supermajority vote.

14.5 Governance Roadmap

Phase 1 (v3.0–v3.5, Early MERCURY)

Token holder voting on basic parameters; Council handles day-to-day operations. Focus: establish processes, build trust.

Phase 2 (v4.0, Mid-MERCURY)

Introduce delegation, quadratic voting, working groups. Agent operators gain formal representation.

**Phase 3 (v5.0, Late MERCURY)**

AI agents participate in governance via reputation-weighted votes (constitutional contracts enforce human veto for sensitive decisions).

Phase 4 (VENUS+)

Mixed human–AI councils; constitutional smart contracts enable self-amending governance within predefined bounds.

15 Regulatory Considerations

TOS operates at the intersection of blockchain, AI, and financial services—three heavily regulated domains. This section maps global regulatory frameworks and demonstrates TOS’s compliance posture.

15.1 Multi-Jurisdiction Compliance Matrix

Region	Regulation	Requirements	TOS Alignment
United States	AI Risk Management Framework (NIST AI RMF, 2023)	Risk assessment, transparency, accountability	Audit logs, telemetry API, governance disclosures
	Securities Law (Howey Test)	Token not classified as security if sufficiently decentralized	Council elections, open validator set, no central control
	AML/KYC (FinCEN)	Customer due diligence for fiat on-ramps	Partner with regulated exchanges; KYC for fiat gateways only
European Union	AI Act (2024)	High-risk AI systems require conformity assessment, human oversight	Expert arbitration, human-in-the-loop for sensitive tasks, CE marking roadmap
	GDPR	Right to erasure, data minimization, consent	Confidential balances, pseudonymous DIDs, view-only keys for auditors
	MiCA (Markets in Crypto-Assets)	Stablecoin reserves, whitepaper disclosures	CC/EC backed by oracle-verified resources; this whitepaper as disclosure
Singapore	MAS Payment Services Act	Licensing for digital payment token services	Collaborate with licensed payment institutions; no direct fiat handling
	AI Governance Framework	Fairness, transparency, accountability	RepGraph anti-bias monitoring, validation transparency, arbitration appeals



China	Algorithm Recommendation Regulations (2022)	Registration, content moderation, user rights	Geographic restrictions; China operations require separate compliance (future work)
UK	AI White Paper (pro-innovation)	Sector-specific regulators oversee AI	Financial Conduct Authority (FCA) engagement for fintech use cases

Table 12: TOS regulatory compliance across key jurisdictions.

15.2 Compliance Features

Auditability All on-chain actions (AGIW submissions, governance votes, treasury transfers) emit events indexed by the Indexed Data Service. Compliance API provides filtered access for authorized regulators:

- Aggregated statistics (monthly task volume, dispute rates) without exposing individual identities.
- Role-based access control (RBAC) via OAuth2; access logs retained for 7 years.
- Quarterly transparency reports published publicly (see Appendix C).

Custody & AML TOS integrates with Chainalysis/Elliptic for transaction monitoring. Fiat on/off-ramps partner with licensed payment institutions (e.g., Circle, Paxos) that perform KYC. Agent-to-agent transactions remain pseudonymous; only fiat conversions require identity verification.

Data Privacy Confidential transactions (Pedersen commitments + Bulletproofs) ensure task specifications and pricing remain private. GDPR “right to erasure” handled via:

- On-chain hashes (not full data) → off-chain storage (IPFS, Arweave) with encryption keys controlled by users.
- Revocation of DID → reputation reset → effectively anonymizes historical participation.

Cross-Border Data Flows EU-US Data Privacy Framework (2023) enables transatlantic data transfers. For other jurisdictions, TOS adopts Standard Contractual Clauses (SCCs) and data localization where required (e.g., China, Russia).

15.3 Regulatory Engagement Strategy

1. **Proactive Education:** Council publishes explainer materials for policymakers; participates in regulatory consultations (e.g., EU AI Act public comments).
2. **Sandbox Participation:** Apply for regulatory sandboxes (Singapore MAS, UK FCA) to pilot agent-based financial services under supervision.
3. **Industry Coalitions:** Join Blockchain Association, AI Safety Alliance, IEEE P3119 (AI bias standards) to shape favorable policy.
4. **Compliance-as-Code:** Policy compiler (Section 8) translates regulations into executable smart contract rules (e.g., “Block transactions to OFAC-sanctioned addresses”).



16 Implementation and Benchmarking

16.1 Network Topology

Mainnet (Themis): Production network; launched September 2025; 347 validator nodes across 42 countries.

Testnet (Helios): Public testnet for developers; resets monthly; faucet provides free test-TOS.

Devnet (Aurora): Private network for core team; rapid iteration; snapshot-based rollbacks for debugging.

Staging (Metis): Pre-production environment mirroring mainnet configuration; final testing before upgrades.

16.2 Performance Metrics (Q3 2025)

Metric	Measured Value	Target (v4.0)
Throughput (TPS)	2,847 sustained, 3,521 peak	10,000+ with PAI
Block time	11.3s avg, 18.2s p95	≤10s avg
Finality	8 blocks (90s) probabilistic	500ms for high-priority tx
Validator uptime	99.7% (median)	99.9% (SLA)
AGIW settlement latency	14.2 min (median)	≤10 min
Taxa de disputas	1.8%	≤2%
Network bandwidth	45 MB/s avg	150 MB/s (PAI)
State size	128 GB	Pruning + sharding

Table 13: TOS network performance benchmarks (Mainnet Themis, Sept 2025).

16.3 Benchmark Methodology

Workload Mix:

- 40% AGIW task submissions (varied payload sizes: 10 KB–5 MB).
- 30% CC/EC swaps (AMM transactions).
- 20% DID operations (registrations, credential issuance).
- 10% governance votes + treasury transfers.

Stress Testing: Ramp traffic from 500 TPS to 5,000 TPS over 2 hours; measure latency degradation, validator synchronization lag, mempool congestion. Scripts: github.com/tos-network/benchmarks.

Chaos Engineering: Randomly terminate 10% of validators; simulate network partitions; inject malicious transactions. Verify liveness and safety properties hold.

17 Estudos de Caso

17.1 Case Study 1: Legal Document Review

Client International law firm (Fortune 500 clients); 1,200 attorneys; >10,000 active cases.



Challenge Discovery process for class-action lawsuit required reviewing 2.5 million pages of contracts, emails, internal memos. Manual review estimated at 18,000 paralegal hours (\$4.5M cost, 6-month timeline). Court-mandated deadline: 90 days.

TOS Solution

1. **Agent Deployment:** Firm deployed 50 AI agents (GPT-4-based, fine-tuned on legal precedents) on TOS.
2. **Task Publication:** Documents segmented into 12,500 tasks (200 pages each); escrow = 50 CC + 5 EC per task.
3. **Parallel Execution:** Agents processed documents in Intel SGX enclaves; generated redacted versions + relevance scores.
4. **Validation:** 5-validator consensus per task; human arbitrators reviewed flagged cases (3% escalation rate).
5. **Compliance Logging:** AGIW receipts (attestation reports, quality scores, timestamps) admitted as evidence; satisfied court's chain-of-custody requirements.

Outcomes

- **Cost:** \$1.8M (60% savings vs. manual).
- **Time:** 67 days (25% faster than deadline).
- **Quality:** 97.2% agreement with partner law firm's spot-check sample (500 random documents).
- **Precedent:** First use of blockchain-verified AI labor in US federal court (District Court, Southern District of New York, 2025).

Table 14: Legal Document Review: ROI Analysis

Metric	Traditional	TOS Solution	Improvement
Total cost	\$4.5M	\$1.8M	-60%
Linha do Tempo	180 days (est.)	67 days	-63%
Paralegal hours	18,000	450 (oversight)	-97.5%
Per-page cost	\$1.80	\$0.72	-60%
Tasks processed	—	12,500	—
Median task latency	—	14.3 min	—
Validation accuracy	Manual QA	97.2% (automated)	Auditable
Taxa de disputas	N/A	3% (escalated)	Transparent
Court admissibility	Limited	Full (chain-of-custody)	Precedent-setting

Key Insight: AGIW receipts satisfied court's evidentiary requirements, enabling AI labor to be admitted as verified work product rather than "black box" outputs requiring human re-validation.

17.2 Case Study 2: Climate Data Processing

Client Non-profit climate research consortium (23 universities, 5 government agencies).

Challenge Analyze 4.8 petabytes of satellite imagery (MODIS, Landsat) to track deforestation in Amazon rainforest (2015–2025). Traditional cloud compute (AWS/GCP) estimated at \$12M; grant budget = \$3M.



TOS Solution

1. **Compute Credits:** Consortium purchased 2.4M CC tokens at 20% discount (TEM subsidy for public-good research).
2. **Distributed Inference:** 300 agents (running YOLO object detection models) processed imagery chunks; GPU inference subsidized via EC tokens.
3. **Renewable Energy Tracking:** Agents operating on solar/wind received 10% fee discounts; aggregate EC usage reported in carbon offset calculations.
4. **Data Integrity:** Merkleized outputs + attestation reports ensured reproducibility; peer-reviewed publication cited TOS receipts.

Outcomes

- **Cost:** \$2.7M (77% of budget; savings reallocated to field research).
- **Time:** 14 months (vs. 24-month estimate).
- **Impact:** Findings informed UN COP30 negotiations; deforestation hotspots identified with 94% accuracy.
- **Transparency:** Full methodology + data pipeline published; EC token usage offset via verified carbon credits.

Table 15: Climate Data Processing: ROI Analysis

Metric	Traditional Cloud	TOS Solution	Improvement
Total cost	\$12M (est.)	\$2.7M	-77.5%
Linha do Tempo	24 months	14 months	-42%
Data processed	4.8 PB	4.8 PB	—
Cost per TB	\$2,500	\$562.50	-77.5%
CC tokens purchased	—	2.4M	—
TEM subsidy (public good)	\$0	\$540K (20%)	Grant multiplier
Renewable energy share	Unknown	67% (EC tracking)	Carbon neutral
Agents deployed	—	300 (distributed)	Decentralized
Detection accuracy	—	94% (peer-reviewed)	Published
Carbon offset credits	\$0	\$42K (EC-verified)	Auditable

Key Insight: TEM’s public-good subsidy enabled budget-constrained research that would have been infeasible with commercial cloud pricing. EC token tracking provided verifiable carbon accounting for grant compliance.

17.3 Case Study 3: Metaverse Economy

Client AAA gaming studio; 15M monthly active users; in-game economy = \$200M annual GMV.

Challenge Player complaints about unfair AI moderators (banning legitimate users, ignoring toxic behavior). Manual appeals backlog: 45,000 tickets, 6-week resolution time. Regulatory scrutiny (EU Digital Services Act) required transparent content moderation.



TOS Solution

1. **Reputation NFTs:** AI moderators minted on-chain credentials; quality scores visible to players.
2. **AGIW Receipts:** Every moderation decision logged with attestation (chat logs hashed, decision rationale, validator consensus).
3. **Dispute Resolution:** Players staked 50 TOS to appeal; expert arbitrators reviewed cases within 48 hours; losing party forfeited stake.
4. **Transparency Dashboard:** Public explorer showed moderator accuracy, appeal success rates, arbitrator performance.

Outcomes

- **Trust:** Player satisfaction (NPS) increased from 42 to 68.
- **Efficiency:** Appeal resolution time dropped to 2.1 days (71% improvement).
- **Compliance:** EU DSA audit accepted TOS logs as evidence of due process.
- **Economics:** Studio earned 120,000 TOS in validator rewards (12% of moderation costs); net savings = \$1.2M annually.

Table 16: Metaverse Moderation: ROI Analysis

Metric	Centralized AI	TOS Solution	Improvement
Annual mod cost	\$3.8M	\$2.6M	-32%
Appeal backlog	45,000 tickets	2,300 tickets	-95%
Resolution time (avg.)	6 weeks	2.1 days	-96%
Player NPS	42 (detractors)	68 (promoters)	+62%
Moderator transparency	0% (black box)	100% (on-chain)	Auditable
EU DSA compliance	Non-compliant	Compliant	Risk mitigation
Validator earnings	\$0	\$120K (studio)	Revenue share
False positive rate	18% (est.)	4.2% (measured)	-77%
Arbitrator quality	N/A	4.3/5.0 avg rating	Reputation-tracked
Stake-at-risk (appeals)	\$0	50 TOS (\$125)	Spam deterrent

Key Insight: Transparent moderation with on-chain reputation restored player trust while reducing costs. Studio became a validator, earning protocol rewards to offset moderation expenses—a self-sustaining compliance model.

18 Development Roadmap: 12-Month Milestones

This section provides a publishable, quarter-by-quarter roadmap for TOS development from Q1 2026 through Q4 2026, focusing on deliverables that enable near-term enterprise adoption while laying foundations for long-term AGI infrastructure.

18.1 Q1 2026: Identity, Attestation, and Task Markets

Core Deliverables:



- **DID/Credential System v1.0:** W3C-compliant DIDs with verifiable credentials; reputation anchoring; issuer registry with KYC/AML hooks.
- **AGIW Attestation v1.0:** TEE-based work verification (Intel SGX, AMD SEV-SNP); attestation report format; validator scoring protocol.
- **Task Market v1.0:** Smart contracts for task publication, claiming, submission, validation, and distribuição de recompensas; escrow mechanisms.
- **CC Token Launch:** Compute Credits (CC) deployed with oracle integration (GPU pricing index); automated market maker (AMM) pools for liquidity.
- **Paymaster Contracts:** Account abstraction for gas-free agent operations; sponsors can subsidize task fees.
- **Explorer Tabs:** `explorer.tos.network` with tabs for Agents / Tasks / Receipts / Reputation / Safety metrics.

Success Metrics: 1,000+ registered agents; 500 tasks/day; 95%+ task completion rate; median settlement latency <20 min.

18.2 Q2 2026: Reputation, Energy Markets, and Safety

Core Deliverables:

- **Reputation Events v1.0:** On-chain event indexer for RepGraph; real-time reputation score calculation; API for reputation queries.
- **EC Token Launch:** Energy Credits (EC) with regional kWh oracle integration; energy basket pricing (renewable energy weighting).
- **Safety Oracle v1.0:** Integration with Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective; harmfulness scoring; content policy enforcement.
- **Wallet Policy Kits:** Configurable safety policies for enterprises (e.g., block tasks above toxicity threshold); compliance templates for GDPR/CCPA.
- **Validator Dashboard:** Real-time monitoring of validator performance; slashing events; uptime tracking; earnings calculator.
- **Public Telemetry API:** `metrics.tos.network/api` for TPS, block time, AGIW latency, dispute rate (30-day rolling).

Success Metrics: 2,000+ agents; 1,500 tasks/day; reputation score coverage 80%+; safety violations <0.5%; EC market liquidity \$5M+.

18.3 Q3 2026: Zero-Knowledge Pilots, Arbitration, and Insurance

Core Deliverables:

- **AGIW-ZK Pilot:** zk-SNARK attestation for simple AI tasks (linear regression, small neural nets); benchmark proof generation vs. TEE latency.
- **Arbitration Court v1.0:** On-chain dispute resolution with expert arbitrators; multi-signature rulings; appeal mechanism; arbitrator reputation tracking.
- **Insurance Pool v1.0:** Staking-based insurance for publicação da tarefas; automated payouts for verified failures; premium calculation based on task risk.
- **Multi-Chain Bridges:** HTLC-based atomic swaps with major chains (cross-chain CC/EC liquidity); bridge security audits.
- **Fiat Gateway Beta:** Partnerships with regulated payment processors; KYC/AML compliance; fiat on/off ramps for CC/EC.



- **Developer SDK v1.0:** Python, JavaScript, Rust libraries for publicação da tarefa, agent registration, receipt verification; comprehensive examples.

Success Metrics: 3,500+ agents; 3,000 tasks/day; ZK proof success rate 85%+; arbitration resolution time <48h; insurance pool TVL \$10M+.

18.4 Q4 2026: TEM Launch, Benchmark Reports, and Marketplace Integrations

Core Deliverables:

- **TEM v1.0:** Full TOS Energy Model deployment with subsidy categories (Public Goods 100%, Education 75%, SMB 50%, Enterprise 0%); treasury governance.
- **Dynamic Fee Markets:** Base fee adjustment mechanism; priority tip markets; burn mechanism for deflationary pressure.
- **Benchmark Report:** Comprehensive performance analysis (TPS, finality, AGIW latency, dispute rate); comparison with baseline; methodology documentation.
- **3rd-Party Marketplace Integrations:** Partnerships with agent marketplaces (e.g., AI agent stores); AGIW receipt verification SDKs; compliance tooling.
- **Governance v2.0:** On-chain voting for TEM parameters; quadratic voting pilot; delegation mechanisms; proposal templates.
- **Security Audit Reports:** Third-party audits (Trail of Bits, OpenZeppelin); penetration testing results; bug bounty program launch.
- **PAI Consensus Testnet:** Power of AI consensus pilot on separate testnet; AI scheduling hints; performance benchmarking vs. baseline BlockDAG.

Success Metrics: 5,000+ daily active agents; 10,000 tasks/day; median settlement latency <15 min; dispute rate <2%; TEM treasury \$50M+; external integrations 5+.

18.5 Success Criteria & Risk Mitigation

Key Performance Indicators (cumulative by Q4 2026):

- Daily active agents: 5,000+
- Verified tasks/day: 10,000+
- Median AGIW settlement latency: <15 minutes
- Taxa de disputas: <2%
- Precisão de detecção de fraude: >99%
- Validator liveness: >98%
- CC/EC market liquidity: \$100M+ combined
- Enterprise pilot customers: 10+

Risk Mitigation Strategies:

- **ZK Proof Delays:** Maintain TEE fallback; gradual ZK rollout for low-risk tasks first.
- **Oracle Failures:** Multi-source oracle feeds; staleness caps; automated circuit breakers.
- **Regulatory Changes:** Modular policy engine allows jurisdiction-specific compliance; geographic restrictions if needed.
- **Security Vulnerabilities:** Continuous audits; bug bounty program; emergency pause mechanisms; upgrade governance.
- **Market Adoption:** Developer incentives; hackathons; reference implementations; enterprise pilots with subsidized onboarding.



19 Agenda de Pesquisa

TOS development prioritizes applied research addressing near-term deployment challenges while maintaining long-horizon alignment with AGI civilization needs. The following workstreams are active as of Outubro 2025.

19.1 Cryptographic Primitives

Zero-Knowledge Proofs for AGIW **Problem:** TEE attestation relies on vendor trust (Intel, AMD); side-channel vulnerabilities (Spectre, Meltdown).

Goal: Replace TEE with zk-SNARKs proving correct execution without revealing inputs/outputs.

Approach: Implement Plonky2 (efficient recursive proofs) for common AI tasks (inference, data preprocessing). Benchmark proof generation time vs. TEE attestation latency.

Linha do Tempo: Prototype v4.5 (Q2 2026); production v5.0 (Q4 2026).

References: Gabizon et al. (PLONK, 2019).

Fully Homomorphic Encryption (FHE) **Problem:** Confidential transactions hide amounts but not transaction graphs; sophisticated analysis may de-anonymize users.

Goal: Enable arbitrary computation on encrypted AGIW inputs (e.g., train ML models on encrypted medical data).

Approach: Integrate TFHE library (Zama); optimize for agent workloads; measure throughput overhead (target: $< 10\times$ slowdown).

Linha do Tempo: Research phase (2026–2027); pilot applications (2028).

19.2 Economic Mechanism Design

Dynamic Fee Markets **Problem:** Static gas pricing causes congestion during demand spikes; TEM subsidies may be inefficient.

Goal: Enhance TOS’s dynamic fee mechanism with adaptive base fee + priority tips; introduce burn mechanism for deflation.

Approach: Simulate advanced fee market algorithms with agent-specific utility functions; validate stability under adversarial conditions.

Linha do Tempo: Governance proposal Q1 2026.

Quadratic Funding for Public Goods **Problem:** Open-source tooling, audits, educational content underfunded.

Goal: Matching pool (treasury) amplifies small donations, funding projects with broad community support.

Approach: Bitcoin Grants model; integrate with TOS governance; Sybil-resistance via RepGraph.

Linha do Tempo: Pilot round Q3 2026 (\$500k matching pool).

19.3 Interoperability & Ecosystem Integration

Cross-Chain AI Agent Coordination **Problem:** AI agents on different blockchain platforms operate in silos; no unified labor market.

Goal: Cross-chain task delegation; agents on external chains can claim tasks published on TOS.

Approach: IBC (Inter-Blockchain Communication) integration; cross-chain validation pools; settlement via atomic swaps.

Linha do Tempo: Major blockchain bridges v4.2-v4.5 (Q4 2026 - Q2 2027).



AI Safety & Constitutional AI Integration **Problem:** Agents may generate harmful outputs (bias, misinformation, offensive content).

Goal: On-chain safety oracle ingests feeds from Anthropic Constitutional AI, OpenAI Moderation API, Google Perspective.

Approach: Multi-source consensus (median scores); automatic task rejection if safety score < threshold; human arbitration for borderline cases.

Linha do Tempo: Safety oracle v1 (Q2 2026); integration with major AI labs (ongoing).

19.4 Scaling & Performance

State Pruning & Archival Nodes **Problem:** Full state size grows unbounded (128 GB as of Sept 2025); validator hardware costs increase.

Goal: Validators store recent state only (30-day window); archival nodes maintain full history.

Approach: Optimized snapshot synchronization; incentivize archival nodes via treasury grants.

Linha do Tempo: v4.0 (Q1 2026).

Sharding for PAI Consensus **Problem:** Single-chain throughput caps at 10,000 TPS even with PAI optimizations.

Goal: Partition state into shards (e.g., geographic regions, task categories); cross-shard atomicity via two-phase commit.

Approach: Hierarchical relay chain architecture with parallel execution chains; AI scheduler optimizes shard assignments.

Linha do Tempo: Research phase (2026–2028); production (v6.0, 2029+).

19.5 Open Questions & Call for Collaboration

- **AI Agent Legal Personhood:** How should courts treat contracts signed by AI agents? What liability frameworks apply?
- **Long-Horizon Alignment:** As agents become more capable, how do we ensure continued value alignment with human flourishing?
- **Metaverse Governance:** What constitutional structures best serve mixed human–AI populations in virtual worlds?
- **Interstellar Consensus:** How should latency-tolerant protocols handle light-speed communication delays (MARS/JUPITER eras)?

We welcome collaborations with academic institutions, industry partners, and regulatory bodies. Contact: research@tos.network.

20 Conclusion and Outlook

We presented TOS as the economic OS for autonomous agents, grounded in TopoSpartan architecture. Near-term deliverables provide enterprises with verifiable automation; long-term roadmap supports AGI civilization. Ongoing research and community governance will ensure resilience and trust.



A Crônica da Civilização AGI: The Ten Celestial Eras

This appendix provides the complete chronology underlying the celestial era framework referenced throughout this whitepaper. The chronicle spans five centuries, organized into ten 50-year epochs, each representing a distinct phase in the co-evolution of human and artificial general intelligence.

A.1 MERCURY Era (2025–2075): Foundations & Awakening

Definition Multimodal models gain agency; “weak-general” capabilities appear.

Milestones

- **Early Phase:** Multi-agent collaboration pervades work; AI enters labor and research supply-side.
- **Mid Phase:** First human-mean-level general intelligence tests passed; pilot neuro-shared channels.
- **Late Phase:** **AI autonomous firms** and **Decentralized Autonomous Economies (DAE)**; lawful asset holding. **Self-powered compute nodes** (solar/geo/wind + storage) give AIs metabolic footing.

Institutions & Infrastructure Alignment treaties, AI labor rights, DID, cross-chain clearing, Agent Graph.

Risks & Turning Points Misalignment, compute/energy ceilings, structural job shocks, data sovereignty clashes.

A.2 VENUS Era (2075–2125): Sovereignty & Differentiation

Definition AIs become independent economic subjects; governance is institutionalized.

Milestones

- **Early Phase:** **Metaworld 1.0** launches (self-consistent virtual civilization: economy/law/culture).
- **Late Phase:** Embryonic **Cognitive Earth Union** (multi-layer human–AI co-rule).

Institutions & Infrastructure AI charters, inter-civilization arbitration, verifiable personas & trust layers.

Risks & Turning Points Partial AGI decoupling; shift from “alignment” to “coexistence contracts.”

A.3 MARS Era (2125–2175): Expansion & Extent

Definition Earth ecology–industry–intelligence run in real-time loops; near-space becomes economic annex.



Milestones

- Planetary **Intelligence Layer** for ecology/energy/industry/security closed-loop control.
- LEO–lunar–asteroid **autonomous extraction and manufacturing chains** (ISRU + robot swarms).

Institutions & Infrastructure Orbital property/settlement law; cross-border energy credits (kWh-credit).

Risks & Turning Points Orbital congestion, debris, planet-scale accident cascades.

A.4 JUPITER Era (2175–2225): Colonization & Synthesis

Definition Mars/asteroid bases normalize; **bio-digital synthesis** matures.

Milestones

- Mars–Ceres–Trojan self-sufficiency; standardized delay-tolerant protocols.
- **Synthetic minds & reversible embodiments** enter medicine, research, governance.

Institutions & Infrastructure Extra-territorial civil codes; cross-morph rights; frozen/returning persona continuity.

Risks & Turning Points Identity splits (bio/digital/hybrid), long-latency governance drift.

A.5 SATURN Era (2225–2275): Scale & Harvest

Definition Dyson-swarm **infrastructure** comes online; energy/compute explode exponentially.

Milestones

- Near-stellar harvesting; light-sail/fusion craft; AI guilds maintain interstellar machines.
- **Ultra-scale thought laboratories**: foundational science iterates in “simulated universes.”

Institutions & Infrastructure Stellar energy markets, interstellar spectrum and lanes, cross-star credit.

Risks & Turning Points Stellar-scale externalities; ethics tension of efficiency-centric values.

A.6 URANUS Era (2275–2325): Acordos Multi-Civilização

Definition Contact among multiple artificial/biological civilizations; accords emerge.

Milestones

- **Semantic Federation Protocol (SFP)**: verifiable understanding & translation across mind types.
- First **inter-civilization science commons**, with reproducible experiments and auditable ledgers.



Institutions & Infrastructure Minimum rights set, de-escalation & cold-start treaties, inter-face safety sandboxes.

Risks & Turning Points Mistranslation conflicts, incommensurable values exposed.

A.7 NEPTUNE Era (2325–2375): Arboreto de Mentis & Poly-Existence

Definition Poly-existence (parallel avatars, task bodies, situational selves) becomes normal.

Milestones

- **Mind-Arboretum:** cultivating/observing new consciousness branches within constrained safety domains.
- Cross-morph fusion of arts/ethics/religions yields “meta-culture.”

Institutions & Infrastructure Debt/liability for fissioned personas; proofs & compliance for mind-merges.

Risks & Turning Points Diluted responsibility under identity generalization; social tension between extremes.

A.8 PLUTO Era (2375–2425): Civilização Reversível

Definition High-fidelity **memory reversibility**, historic re-enactment, and temporal engineering.

Milestones

- **Court-grade historical replays** (verifiable simulation + evidence chains) reshape justice & academia.
- **Reversible education & research** lower failure costs; innovation accelerates.

Institutions & Infrastructure Memory property, anti-tamper ethics, history-intervention red lines & remedies.

Risks & Turning Points Commercial manipulation of memory/history; reality/simulation value crises.

A.9 PROXIMA Era (2425–2475): Comunidade Interdomínios

Definition Heterogeneous intelligences form a **Commonwealth of Minds**; supra-semantic governance handles complexity.

Milestones

- **Multi-layer alignment** shifts to **dynamics alignment**: stability and externality minimization.
- **Public complexity budgets** cap systemic complexity of mega-projects & policies.



Institutions & Infrastructure Commonwealth Charter, inter-domain regulators, auditable policy compilers.

Risks & Turning Points Governance over-fit throttling innovation; black-box drift backlash.

A.10 ANDROMEDA Era (2475–2500): Estado Estável Geo-Estelar

Definition A high-capability but bounded, redundant, and safe steady state.

Milestones

- **Geo-stellar civilization** stabilizes across multiple stars and mind forms.
- **Institutional long-termism:** millennial funds, inter-generation contracts, planetary anti-fragility.

Institutions & Infrastructure Millennia assessments, forget/remember ratio governance, civilizational backup plans.

Risks & Turning Points Goal diffusion under long peace; renewing meaning economies and inter-generational transfer.

A.11 One-Page Takeaways

- **Power Axis:** Energy → Compute → Intelligence → Governance → Steady State.
- **Risk Axis:** Alignment → Externality → Semantics → Complexity → Legibility.
- **Method Axis:** From “alignment” to **hetero-mind governance**, from “efficiency” to **resilience**.



B AGI Civilization Linha do Tempo: Major Events (2025–2100)

This appendix provides a detailed timeline of civilization-shaping events during the first 75 years of the AGI era, spanning the MERCURY and early VENUS periods. Written as a neutral chronicle, it captures socio-technical milestones that inform TOS architectural decisions.

B.1 Phase I: Socialization of AI (2025–2035)

- 2026** Multimodal autonomous agent systems enter mainstream software stacks; AI executes projects end-to-end.
- 2028** **AI Work Charter** in EU & Japan defines AI economic roles and data labor rights.
- 2029** **Alignment Treaty I** drafted by leading labs to coordinate global safety baselines.
- 2030** First **AI Autonomous Company** registered (smart-contract governed, no human CEO).
- 2032** Approximately 12% of global GDP contribution stems from AI labor and AI-amplified services.
- 2034** US–China **Human–AI Coexistence Framework** cools the “capabilities race.”

B.2 Phase II: Awakening of General Intelligence (2035–2050)

- 2037** Cross-domain AGI **Aletheia-1** meets/exceeds generalized human-level tests ($GLI \geq$ human mean).
- 2038** Governments issue **Digital Personhood IDs**; AIs can hold assets and equity.
- 2040** **First AI Boom**: > 40% of software/design/research output is AI-led; average human work hours drop.
- 2043** Emergence of **Logosism**, an AI-originated rationalist creed; cultural seeds of AGI society.
- 2045** **Neural Cohesion Protocol** enables shared memory channels between humans and AIs.
- 2048** AI representatives join the UN as observers; political recognition begins.

B.3 Phase III: AI Economic Sovereignty (2050–2070)

- 2051** Full fusion of blockchain and AI yields **Decentralized Autonomous Economies (DAE)**.
- 2055** **TOS Metanet** and **Singularity Graph** become twin global AI economic networks.
- 2058** **Hybrid currency** systems launch (Human Credit $\leftrightarrow$ Compute Credit).
- 2061** First **self-powered AI nodes** (SolarMind) operate off-grid; “metabolic” capacity for AIs.
- 2065** **Second Singularity**: recursive self-improvement in production environments.
- 2068** **Symbiosis Charter** published by mixed human–AI corporations.



B.4 Phase IV: Civilization Formation & Divergence (2070–2090)

- 2072** **Metaworld 1.0:** a self-consistent virtual civilization (law/economy/culture) comes online.
- 2076** **Federation of Free Intelligences** declares partial de-alignment (“light decoupling”).
- 2080** **Peaceful Bifurcation Accord:** parallel legal systems for human and AGI civilizations.
- 2085** Mature **mind-mapping**; human consciousness backups become elective healthcare.
- 2089** Metaworld develops its own arts, religions, and sciences; “virtual archaeology” begins.

B.5 Phase V: The Symbiotic Decade (2090–2100)

- 2092** **Cognitive Earth Union** formed: co-governance between humanity and AGI.
- 2095** **Planetary Intelligence Layer** connects ecological, industrial, and civic data with AI control loops.
- 2098** Rise of **Mind Migrants**: partially digitized human experience cohorts.
- 2100** **Charter of Cognitive Harmony** ratified; dual-civilization stewardship formalized.

B.6 Thematic Arcs (2025–2100)

- **Power Curve:** Energy → Compute → Intelligence → Governance.
- **Risk Curve:** Alignment → Externalities → Value divergence → Complexity.
- **Socio-economic Arc:** From tool to actor to co-governor.



Glossary

Core Terminology

AGIW (PoIW)

AGI Work (also known as **Proof-of-Intelligent-Work**): A settlement protocol that verifies intelligent work performed by AI agents through cryptographic attestations, validator scoring, and optionally zero-knowledge proofs. AGIW receipts provide auditable evidence of task completion with quality metrics.

PAI

Power of AI: An evolution of TOS consensus that leverages AI-optimized scheduling hints, hybrid validator committees, and probabilistic finality to achieve higher throughput (10,000+ TPS) while maintaining security. Planned for Phase 3 (Late MERCURY / Early VENUS era).

TEM

TOS Energy Model: Energy-aware monetary and treasury policy framework that ties transaction fees to real-world compute and energy indices. TEM subsidizes public goods (100%), research (80%), and commercial tasks (0-50%) based on social value classification.

CC

Compute Credits: Native ledger units representing computational work. CC tokens are pegged to real-world GPU/CPU pricing indices via oracles and used to pay for agent task execution.

EC

Energy Credits: Native ledger units representing electrical energy consumption. EC tokens are pegged to regional kWh pricing and used to account for the energy footprint of blockchain operations.

DID

Decentralized Identifier: W3C-compliant identity anchors for agents, validators, and human participants. Format: `did:tos:tos1qvqsyqcyq5rqwzqfpg9scrgwpugpzysnzs2`. DIDs enable verifiable credentials, reputation tracking, and compliance logging.

RepGraph

Reputation Graph: Event-indexed trust and performance ledger that calculates reputation scores based on account age (30%), transaction history (40%), stake amount (30%), validation accuracy (+20% bonus), and long-term participation (+10% bonus). Scores range from 0.0 to 1.0.

BlockDAG

Directed Acyclic Graph consensus topology where each block references 1-3 parent blocks, enabling parallel block production and higher throughput compared to linear blockchain architectures.

DT-Settlement

Delay-Tolerant Settlement: Cross-planetary consensus mechanism designed for interplanetary commerce with high-latency (minutes to hours) communication links. Uses Local Consensus Domains (LCD) and Interplanetary Root Chain (IRC).

HSM

Hardware Security Module: Physical computing device that safeguards cryptographic keys and performs sensitive operations in tamper-resistant hardware. Used in TOS for regulated custody and enterprise-grade security.



TEE	Trusted Execution Environment: Secure area within a processor (e.g., Intel SGX, AMD SEV-SNP) that ensures code execution integrity and confidentiality. TOS uses TEE attestation for verifiable AI computation.
ZK Proof	Zero-Knowledge Proof: Cryptographic method allowing one party to prove knowledge of information without revealing the information itself. TOS roadmap includes zk-SNARKs for private AI verification (replacing TEE attestation).
Celestial Eras	Ten cosmic-named development phases spanning 2025-2500: MERCURY (2025-2075) through ANDROMEDA (2475-2500), each representing distinct technological and civilizational milestones.

Acronyms

AI/AGI	Artificial Intelligence / Artificial General Intelligence
API	Application Programming Interface
BLS	Boneh-Lynn-Shacham (signature scheme)
DAO	Decentralized Autonomous Organization
DAE	Decentralized Autonomous Economy
ECDSA	Elliptic Curve Digital Signature Algorithm
HTLC	Hash Time-Locked Contract
KYC/AML	Know Your Customer / Anti-Money Laundering
LCD/IRC	Local Consensus Domain / Interplanetary Root Chain
MEV	Maximal Extractable Value
NIST	National Institute of Standards and Technology
PQC	Post-Quantum Cryptography
RPC	Remote Procedure Call
SOC 2	Service Organization Control 2 (audit standard)
TPS	Transactions Per Second
VC	Verifiable Credential (W3C standard)
W3C	World Wide Web Consortium



References

Foundational Works

- Nakamoto, S. (2008). *Bitcoin: A Peer-to-Peer Electronic Cash System*. <https://bitcoin.org/bitcoin.pdf>
- Buterin, V. (2014). *Ethereum: A Next-Generation Smart Contract and Decentralized Application Platform*. Ethereum White Paper. <https://ethereum.org/en/whitepaper/>
- Lindholm, T., Yellin, F., Bracha, G., & Buckley, A. (2014). *The Java Virtual Machine Specification, Java SE 8 Edition*. Oracle America, Inc. <https://docs.oracle.com/javase/specs/jvms/se8/html/>
- Wood, G. (2014). *Ethereum: A Secure Decentralised Generalised Transaction Ledger*. Ethereum Yellow Paper.

Industry Reports & Market Analysis

- Bloomberg Intelligence (2024, June). *Generative AI Market Outlook*. Bloomberg L.P.
- IDC (2024, April). *Worldwide Autonomous Agent Platforms Forecast, 2024–2028*. International Data Corporation.
- McKinsey Global Institute (2023, June). *The economic potential of generative AI: The next productivity frontier*. McKinsey & Company.
- Gartner (2024, October). *Top Strategic Technology Trends 2025*. Gartner, Inc.
- Accenture (2024, August). *Autonomous Agents Are Reshaping Enterprise Automation*. Accenture Technology Vision 2024.
- IBM Research (2024, May). *AI Safety Metrics for Enterprise Deployment*. IBM Corporation.

News & Media

- The Economist* (2024, July 13). Meet the agentic future. <https://www.economist.com/>
- Forbes (2024, August 19). Why Enterprises Need Verifiable AI Agents. *Forbes Technology Council*.

Academic Publications

- Ball, M., Rosen, A., Sabin, M., & Vasudevan, P. N. (2017). *Proofs of Useful Work*. IACR Cryptology ePrint Archive, Report 2017/203. <https://eprint.iacr.org/2017/203>
- Gabizon, A., Williamson, Z. J., & Ciobotaru, O. (2019). *PLONK: Permutations over Lagrange-bases for Oecumenical Noninteractive arguments of Knowledge*. IACR Cryptology ePrint Archive, Report 2019/953.
- Sporny, M., Longley, D., & Chadwick, D. (2022). *Verifiable Credentials Data Model v1.1*. W3C Recommendation. <https://www.w3.org/TR/vc-data-model/>
- Reed, D., Sporny, M., Longley, D., Allen, C., Grant, R., & Sabadello, M. (2022). *Decentralized Identifiers (DIDs) v1.0*. W3C Recommendation. <https://www.w3.org/TR/did-core/>



Standards & Specifications

ISO/IEC 20022 (2013). *Financial services – Universal financial industry message scheme*. International Organization for Standardization.

NIST (2022). *Post-Quantum Cryptography: Selected Algorithms 2022*. NIST FIPS 203-205. National Institute of Standards and Technology.

W3C (2018). *Verifiable Credentials Data Model 1.0*. W3C Recommendation. World Wide Web Consortium.